UNIVERSIDADE FEDERAL DE PELOTAS
Centro de Desenvolvimento Tecnológico
Curso de Bacharelado em Ciência da Computação

Trabalho de Conclusão de Curso

Análise Comparativa de Arquiteturas de Deep Learning para Classificação e Segmentação de Lesões Mamárias em Imagens de Ultrassom

Murilo Salem

Pelotas, 2026

Murilo Salem

Análise Comparativa de Arquiteturas de Deep Learning para Classificação e Segmentação de Lesões Mamárias em Imagens de Ultrassom

Trabalho de Conclusão de Curso apresentado ao Centro de Desenvolvimento Tecnológico da Universidade Federal de Pelotas, como requisito parcial à obtenção do título de Bacharel em Ciência da Computação.

Orientador: Prof. Dr. Anderson Priebe Ferrugem
Coorientador: Prof. Dr. Marilton Sanchotene de Aguiar
Colaborador: Prof. Dr. Marilton Sanchotene de Aguiar

Pelotas, 2026

Insira AQUI a ficha catalográfica
Quando finalizado o trabalho, deve ser
solicitada através do Sistema Cobalto
Biblioteca – Cadastro – Ficha catalográfica.

Murilo Salem

Análise Comparativa de Arquiteturas de Deep Learning para Classificação e Segmentação de Lesões Mamárias em Imagens de Ultrassom

Trabalho de Conclusão de Curso aprovado, como requisito parcial, para obtenção do grau de Bacharel em Ciência da Computação, Centro de Desenvolvimento Tecnológico, Universidade Federal de Pelotas.

Data da Defesa: 30 de fevereiro de 2019

Banca Examinadora:
Prof. Dr. Marilton Sanchotene de Aguiar (orientador)
Doutor em Computação pela Universidade Federal do Rio Grande do Sul.

Prof. Dr. Paulo Roberto Ferreira Jr.
Doutor em Computação pela Universidade Federal do Rio Grande do Sul.

Prof. Dr. Ricardo Matsumura Araujo
Doutor em Computação pela Universidade Federal do Rio Grande do Sul.

Prof. Dr. Luciano da Silva Pinto
Doutor em Biotecnologia pela Universidade Federal de Pelotas.

Dedico este trabalho aos meus pais, por todo o amor, apoio e incentivo que sempre me ofereceram. Por me ensinarem, desde cedo, o valor dos estudos, da dedicação e da busca constante por ser uma pessoa melhor. Tudo o que conquistei até aqui carrega um pouco dos ensinamentos, dos esforços e da confiança que sempre depositaram em mim. Esta conquista também é de vocês.. . .

AGRADECIMENTOS

Agradeço, antes de tudo, aos meus pais, por todo o incentivo, apoio e dedicação ao longo da minha vida. Foram eles que, desde cedo, me ensinaram a importância de buscar sempre ser melhor, de valorizar os estudos e de enfrentar os desafios com responsabilidade e perseverança. Grande parte da maturidade que construí, assim como muitas das conquistas que alcancei até hoje, é resultado direto dos ensinamentos, dos exemplos e da confiança que sempre depositaram em mim. Sou profundamente grato por tudo o que fizeram e continuam fazendo pela minha caminhada.

Agradeço também à minha noiva, que esteve ao meu lado durante uma parte muito importante da minha trajetória acadêmica e pessoal. Ao longo da faculdade, compartilhamos juntos momentos de esforço, ansiedade, dificuldades e também de superação. Sua presença foi essencial em cada etapa desse percurso, especialmente nos períodos mais intensos, em que o cansaço e a pressão muitas vezes pareciam maiores do que eu podia suportar. Obrigado pela paciência, pelo companheirismo e por permanecer ao meu lado até mesmo nos momentos em que nem eu mesmo conseguia me aguentar.

Sou igualmente grato por todo o apoio, incentivo e confiança que você sempre me ofereceu, não apenas em relação aos estudos, mas também nos meus sonhos, projetos e no empreendedorismo. Ter alguém que acredita em mim, caminha ao meu lado e compartilha tanto os desafios quanto as conquistas tornou essa jornada muito mais leve e significativa. Esta conquista também tem muito de vocês, e por isso deixo aqui o meu mais sincero agradecimento.. . .

Podemos ver apenas um pouco do futuro, mas o suficiente para perceber que há muito a fazer.
— ALAN TURING

RESUMO

SALEM, Murilo. **Análise Comparativa de Arquiteturas de Deep Learning para Classificação e Segmentação de Lesões Mamárias em Imagens de Ultrassom**. Orientador: Anderson Priebe Ferrugem. 2026. 219 f. Trabalho de Conclusão de Curso (Ciência da Computação) – Centro de Desenvolvimento Tecnológico, Universidade Federal de Pelotas, Pelotas, 2026.

O câncer de mama permanece entre os principais problemas de saúde pública no mundo, sendo a detecção precoce essencial para melhorar o prognóstico e reduzir a mortalidade. Nesse contexto, a ultrassonografia mamária destaca-se como importante método complementar de diagnóstico por imagem, devido à sua ampla disponibilidade, baixo custo relativo e ausência de radiação ionizante. Entretanto, a interpretação de imagens ultrassonográficas é desafiadora em razão de ruído speckle, baixo contraste, variações de aquisição e elevada dependência do operador. Tais características tornam a análise automatizada dessas imagens um problema relevante para a aplicação de técnicas de Inteligência Artificial.

Este trabalho apresenta uma análise comparativa de arquiteturas de Deep Learning aplicadas à classificação e à segmentação de lesões mamárias em imagens de ultrassom, utilizando o dataset BUSI como ambiente experimental controlado. A pesquisa foi estruturada em dois eixos complementares. No primeiro, são avaliados modelos de classificação capazes de distinguir imagens normais, benignas e malignas. No segundo, são analisados modelos de segmentação voltados à delimitação espacial das lesões mamárias. O objetivo é investigar, de forma metodologicamente consistente, o desempenho dessas arquiteturas e sua aplicabilidade como ferramentas de apoio ao diagnóstico.

A metodologia inclui curadoria do conjunto de dados, definição de critérios de inclusão e exclusão, divisão em conjuntos de treino, validação e teste, pré-processamento das imagens, aplicação de técnicas de aumento de dados, treinamento supervisionado e avaliação quantitativa e qualitativa dos modelos. Na tarefa de classificação, são empregadas métricas como acurácia, precisão, sensibilidade, especificidade, F1-score e AUC-ROC. Na segmentação, a avaliação é realizada por meio de IoU, Dice Score, precisão, sensibilidade e F1-score em nível de pixel. Além disso, são considerados indicadores computacionais, como número de parâmetros, tempo de treinamento, tempo médio de inferência e tamanho dos modelos.

Espera-se que os resultados permitam identificar arquiteturas mais adequadas para cada tarefa, distinguindo o melhor desempenho absoluto do melhor equilíbrio entre desempenho e custo computacional. Como contribuição, o trabalho busca oferecer uma avaliação comparativa robusta do uso de Deep Learning em ultrassonografia ma-

mária, discutindo potencialidades, limitações e implicações práticas do emprego de Inteligência Artificial como suporte ao diagnóstico do câncer de mama.

Palavras-chave: palavrachave-um; palavrachave-dois; palavrachave-tres; palavrachave-quatro.

ABSTRACT

SALEM, Murilo. **A Comparative Analysis of Deep Learning Architectures for Classification and Segmentation of Breast Lesions in Ultrasound Images**. Advisor: Anderson Priebe Ferrugem. 2026. 219 f. Undergraduate Thesis (Computer Science) – Technology Development Center, Federal University of Pelotas, Pelotas, 2026.

Breast cancer remains one of the major public health challenges worldwide, and early detection is essential to improve prognosis and reduce mortality. In this context, breast ultrasound plays an important role as a complementary imaging modality due to its wide availability, relatively low cost, and lack of ionizing radiation. However, the interpretation of ultrasound images is challenging because of speckle noise, low contrast, acquisition variability, and strong operator dependence. These characteristics make the automated analysis of such images a relevant problem for the application of Artificial Intelligence techniques.

This work presents a comparative analysis of Deep Learning architectures applied to the classification and segmentation of breast lesions in ultrasound images, using the BUSI dataset as a controlled experimental environment. The research is structured into two complementary axes. In the first, classification models are evaluated to distinguish normal, benign, and malignant images. In the second, segmentation models are analyzed to delineate the spatial extent of breast lesions. The objective is to investigate, in a methodologically consistent manner, the performance of these architectures and their applicability as diagnostic support tools.

The methodology includes dataset curation, definition of inclusion and exclusion criteria, split into training, validation, and test sets, image preprocessing, application of data augmentation techniques, supervised training, and quantitative and qualitative evaluation of the models. In the classification task, the adopted metrics include accuracy, precision, sensitivity, specificity, F1-score, and AUC-ROC. In the segmentation task, evaluation is performed using IoU, Dice Score, precision, sensitivity, and pixel-wise F1-score. In addition, computational indicators are considered, such as number of parameters, training time, average inference time, and model size.

The expected results are to identify the most suitable architectures for each task, distinguishing the best absolute performance from the best trade-off between predictive performance and computational cost. As a contribution, this work aims to provide a robust comparative assessment of Deep Learning in breast ultrasound, discussing strengths, limitations, and practical implications of using Artificial Intelligence as a support tool for breast cancer diagnosis

Keywords: keyword-one; keyword-two; keyword-three; keyword-four.

LISTA DE FIGURAS

Figura 1 Representação esquemática da arquitetura VGG16, composta por blocos convolucionais profundos, camadas de agrupamento máximo e camadas totalmente conectadas para classificação multiclasse. 65

Figura 2 Representação esquemática da arquitetura ResNet50, destacando o papel das conexões residuais no treinamento de redes neurais profundas em comparação com o de redes neurais convolucionais normais. 70

Figura 3 Exemplo ilustrativo de imagem do conjunto de classificação após aplicação das transformações de aumento de dados. Substituir este *placeholder* pela figura exportada do pipeline, por exemplo `augmentation_preview.png`. 138

Figura 4 Exemplo ilustrativo de imagem e máscara do conjunto de segmentação após aplicação das transformações de aumento de dados. Substituir este *placeholder* pela figura exportada do pipeline, por exemplo `augmentation_preview.png`. 139

Figura 5 172

Figura 6 173

LISTA DE TABELAS

Tabela 1 Principais desafios do ultrassom mamário para análise diagnóstica e computacional . . . 25
Tabela 2 Potenciais contribuições do *Deep Learning* no ultrassom mamário . 26

Tabela 3 Transformações de aumento de dados aplicadas ao conjunto de treino da classificação. . . . 138
Tabela 4 Transformações de aumento de dados aplicadas ao conjunto de treino da segmentação. . . . 139
Tabela 5 Regimes de *transfer learning* considerados e melhores configurações finais por arquitetura na classificação. . . . 142
Tabela 6 Configuração operacional de treino adotada na rodada final da classificação. . . . 143
Tabela 7 Configuração operacional de treino adotada na rodada final da segmentação. . . . 145
Tabela 8 Resumo das métricas adotadas na avaliação dos modelos de classificação. . . . 148
Tabela 9 Resumo das métricas adotadas na avaliação dos modelos de segmentação. . . . 153
Tabela 10 Resumo das métricas computacionais utilizadas na avaliação dos modelos. . . . 157
Tabela 11 Comandos CLI utilizados no pipeline experimental . . . 161
Tabela 12 Sequência das etapas da experimentação . . . 162
Tabela 13 Estrutura de armazenamento dos artefatos experimentais . . . 163
Tabela 14 Fluxo geral do experimento . . . 164
Tabela 15 Fluxos específicos por tarefa . . . 164

Tabela 16 Melhores *trials* por arquitetura no experimento final . . . 166
Tabela 17 Número de parâmetros por arquitetura . . . 166
Tabela 18 Síntese do espaço de busca e da sensibilidade aos hiperparâmetros nos experimentos de classificação. . . . 167
Tabela 19 Resultados consolidados dos modelos de classificação no conjunto de teste. . . . 168
Tabela 20 Síntese comparativa qualitativa entre as arquiteturas . . . 169
Tabela 21 Comparações relativas de eficiência computacional . . . 170
Tabela 22 Métricas destacadas da VGG16 na comparação final . . . 170
Tabela 23 Indicadores que sustentam a ResNet50 como melhor modelo em desempenho absoluto . . . 171

Tabela 24 Resultados da classificação para a classe *normal* no conjunto de teste. 175
Tabela 25 Resultados da classificação para a classe *malignant* no conjunto de teste. 176
Tabela 26 Resultados da classificação para a classe *normal* no conjunto de teste. 177

Tabela 27 Hiperparâmetros e configurações de treinamento adotados 187
Tabela 28 Resultados consolidados dos modelos de segmentação no conjunto de teste. 188
Tabela 29 Número de parâmetros das arquiteturas de segmentação 195
Tabela 30 Tempo médio de inferência por imagem das arquiteturas de segmentação 195

LISTA DE ABREVIATURAS E SIGLAS

ABNT	Associação Brasileira de Normas Técnicas
NUMA	Non-Uniform Memory Access
SIMD	Single Instruction Multiple Data
SMP	Symmetric Multi-Processor
SPMD	Single Program Multiple Data

SUMÁRIO

1 INTRODUÇÃO 21
1.1 Contextualização do problema 21
1.1.1 Relevância do câncer de mama como problema de saúde pública . . . 21
1.1.2 Importância do diagnóstico por imagem 22
1.1.3 Crescente uso de Inteligência Artificial na área médica 22
1.2 Motivação 23
1.2.1 Desafios do diagnóstico em imagens de ultrassom mamário 23
1.2.2 Potencial das técnicas de *Deep Learning* como apoio ao diagnóstico . . 24
1.2.3 Justificativa para o uso do dataset BUSI 26
1.3 Problema de pesquisa 27
1.3.1 Limitações de abordagens convencionais 27
1.3.2 Necessidade de comparação entre arquiteturas distintas por tarefa . . . 27
1.3.3 Definição do problema investigado 28
1.4 Hipóteses e pressupostos 28
1.4.1 Hipótese para classificação 28
1.4.2 Hipótese para segmentação 29
1.4.3 Hipótese para a relação entre desempenho e custo computacional . . . 30
1.5 Objetivos 31
1.5.1 Objetivo geral 31
1.5.2 Objetivos específicos 31
1.6 Delimitação do estudo 32
1.6.1 Foco em imagens de ultrassom mamário 32
1.6.2 Separação entre classificação e segmentação 32
1.7 Metodologia resumida 32
1.7.1 Estrutura geral do pipeline experimental 32
1.8 Estrutura da monografia 33

2 FUNDAMENTAÇÃO TEÓRICA 34
2.1 Câncer de mama e diagnóstico por imagem 34
2.1.1 Conceitos básicos sobre câncer de mama 34
2.1.2 Métodos de imagem utilizados no diagnóstico 35
2.1.3 Ultrassonografia mamária: características e limitações 36
2.2 Inteligência Artificial aplicada à saúde 38
2.2.1 Conceitos de IA, Machine Learning e Deep Learning 38
2.2.2 Aplicações de IA em imagens médicas 39
2.2.3 Benefícios, limitações e desafios clínicos 40
2.3 Visão computacional em imagens médicas 42

2.3.1 Representação digital de imagens 42
2.3.2 Pré-processamento de imagens médicas 43
2.3.3 Extração e aprendizado de características 44
2.4 Redes neurais convolucionais 45
2.4.1 Conceitos fundamentais de CNNs 45
2.4.2 Camadas convolucionais, pooling e funções de ativação 47
2.4.3 Regularização, batch normalization e dropout 49
2.4.4 Transfer learning e fine-tuning 51
2.5 Classificação de imagens com Deep Learning 54
2.5.1 Formulação da tarefa de classificação 54
2.5.2 Desafios em classificação de imagens médicas 56
2.5.3 Métricas de avaliação para classificação 58
2.6 Arquiteturas para classificação 62
2.6.1 VGG16 62
2.6.2 ResNet50 67
2.6.3 EfficientNet 72
2.6.4 ConvNeXt 78
2.7 Segmentação de imagens médicas 83
2.7.1 Conceito de segmentação semântica 83
2.7.2 Importância da segmentação no contexto clínico 85
2.7.3 Métricas de avaliação para segmentação 87
2.8 Arquiteturas para segmentação 90
2.8.1 U-Net 90
2.8.2 Attention U-Net 95
2.8.3 U-Net++ 99
2.8.4 DeepLabV3+ 104
2.9 Técnicas complementares 109
2.9.1 Data augmentation 109
2.9.2 Balanceamento de classes 112
2.9.3 Funções de perda para classificação 113
2.9.4 Funções de perda para segmentação 115
2.10 Trabalhos relacionados 117
2.10.1 Estudos sobre classificação em ultrassom mamário 117
2.10.2 Estudos sobre segmentação em ultrassom mamário 118
2.10.3 Comparação entre literatura e proposta do trabalho 119
2.10.4 Lacunas identificadas 120

3 MATERIAIS E MÉTODOS 122
3.1 Caracterização da pesquisa 122
3.1.1 Natureza da pesquisa 122
3.1.2 Abordagem metodológica 123
3.1.3 Estratégia experimental 124
3.2 Ambiente computacional 125
3.2.1 Linguagens, bibliotecas e frameworks 125
3.2.2 Ambiente de execução 126
3.2.3 Limitações de hardware 127
3.3 Base de dados 128
3.3.1 Descrição do BUSI Dataset 128
3.3.2 Distribuição das classes 129

3.3.3 Estrutura dos arquivos e máscaras . . . 130
3.3.4 Critérios de inclusão e exclusão . . . 131
3.4 Preparação dos dados . . . 132
3.4.1 Organização dos conjuntos de treino, validação e teste . . . 133
3.4.2 Estratégia de split estratificado . . . 133
3.4.3 Prevenção de vazamento de dados . . . 134
3.4.4 Padronização dos dados . . . 135
3.5 Pré-processamento . . . 135
3.5.1 Redimensionamento das imagens . . . 136
3.5.2 Normalização . . . 136
3.5.3 Tratamento das máscaras . . . 136
3.5.4 Verificação visual do pré-processamento . . . 137
3.6 Aumento de dados . . . 137
3.6.1 Técnicas aplicadas à classificação . . . 138
3.6.2 Técnicas aplicadas à segmentação . . . 139
3.6.3 Restrições clínicas das transformações . . . 140
3.7 Modelagem experimental — classificação . . . 140
3.7.1 Definição da tarefa . . . 140
3.7.2 Arquiteturas selecionadas . . . 140
3.7.3 Cabeças de classificação . . . 141
3.7.4 Estratégias de transfer learning . . . 141
3.7.5 Configuração de treino . . . 141
3.8 Modelagem experimental — segmentação . . . 142
3.8.1 Definição da tarefa . . . 142
3.8.2 Arquiteturas selecionadas . . . 142
3.8.3 Estratégias de treinamento . . . 143
3.8.4 Funções de perda . . . 144
3.8.5 Configuração de treino . . . 144
3.9 Hiperparâmetros e critérios de ajuste . . . 145
3.9.1 Taxa de aprendizado . . . 145
3.9.2 Batch size . . . 146
3.9.3 Número de épocas . . . 146
3.9.4 Early stopping e checkpointing . . . 146
3.9.5 Critérios de seleção dos melhores modelos . . . 146
3.10 Métricas de avaliação . . . 147
3.10.1 Métricas de classificação . . . 147
3.10.2 Métricas de segmentação . . . 152
3.10.3 Métricas computacionais . . . 156
3.11 Procedimento experimental . . . 161
3.11.1 Etapas da experimentação . . . 161
3.11.2 Reprodutibilidade e fixação de seeds . . . 161
3.11.3 Registro e armazenamento dos resultados . . . 162
3.11.4 Fluxo geral do experimento . . . 162

4 RESULTADOS — CLASSIFICAÇÃO . . . 165
4.1 Configuração final dos experimentos de classificação . . . 165
4.1.1 Modelos efetivamente treinados . . . 165
4.1.2 Hiperparâmetros adotados . . . 166
4.1.3 Critério de seleção do melhor checkpoint . . . 168

4.2 Resultados quantitativos gerais . . . 168
4.2.1 Tabela consolidada de métricas . . . 168
4.2.2 Comparação entre arquiteturas . . . 169
4.2.3 Melhor modelo em desempenho absoluto . . . 170
4.3 Curvas de treinamento . . . 171
4.3.1 Loss de treino e validação . . . 172
4.3.2 Accuracy de treino e validação . . . 173
4.3.3 Indícios de overfitting ou underfitting . . . 174
4.4 Análise por classe . . . 175
4.4.1 Desempenho na classe benign . . . 175
4.4.2 Desempenho na classe malignant . . . 176
4.4.3 Desempenho na classe normal . . . 176
4.4.4 Sensibilidade clínica da classe malignant . . . 177
4.5 Matrizes de confusão . . . 178
4.5.1 Matriz de confusão do VGG16 . . . 178
4.5.2 Matriz de confusão do ResNet50 . . . 178
4.5.3 Matriz de confusão do EfficientNet . . . 179
4.5.4 Matriz de confusão do ConvNeXt . . . 179
4.6 Curvas ROC . . . 180
4.6.1 Curvas ROC por classe . . . 180
4.6.2 Comparação das AUCs . . . 180
4.6.3 Interpretação clínica dos resultados . . . 180
4.7 Análise de hiperparâmetros . . . 181
4.7.1 Impacto da taxa de aprendizado . . . 181
4.7.2 Impacto do batch size . . . 181
4.7.3 Impacto do fine-tuning . . . 181
4.7.4 Efeito do data augmentation . . . 182
4.8 Custo computacional e inferência . . . 182
4.8.1 Número de parâmetros por modelo . . . 182
4.8.2 Tempo de treinamento . . . 182
4.8.3 Tempo médio de inferência por imagem . . . 183
4.8.4 Trade-off entre desempenho e custo . . . 183
4.9 Análise qualitativa . . . 183
4.9.1 Exemplos corretamente classificados . . . 183
4.9.2 Exemplos mal classificados . . . 184
4.9.3 Padrões de erro observados . . . 184
4.10 Síntese dos resultados de classificação . . . 184
4.10.1 Melhor modelo global . . . 184
4.10.2 Melhor modelo custo-benefício . . . 184
4.10.3 Limitações observadas . . . 185

5 RESULTADOS — SEGMENTAÇÃO . . . 186
5.1 Configuração final dos experimentos de segmentação . . . 186
5.1.1 Modelos efetivamente treinados . . . 186
5.1.2 Hiperparâmetros adotados . . . 187
5.1.3 Funções de perda utilizadas . . . 187
5.2 Resultados quantitativos gerais . . . 188
5.2.1 Tabela consolidada de métricas . . . 188
5.2.2 Comparação entre arquiteturas . . . 188

5.2.3 Melhor modelo em desempenho absoluto . . . 189
5.3 Curvas de treinamento . . . 189
5.3.1 Loss de treino e validação . . . 189
5.3.2 IoU de treino e validação . . . 189
5.3.3 Dice Score de treino e validação . . . 190
5.3.4 Estabilidade do treinamento . . . 190
5.4 Comparação quantitativa dos modelos . . . 190
5.4.1 U-Net . . . 190
5.4.2 Attention U-Net . . . 191
5.4.3 U-Net++ . . . 191
5.4.4 DeepLabV3+ . . . 191
5.5 Análise qualitativa da segmentação . . . 192
5.5.1 Casos com segmentação adequada . . . 192
5.5.2 Casos com subsegmentação . . . 192
5.5.3 Casos com sobresegmentação . . . 192
5.5.4 Casos difíceis e ambiguidades visuais . . . 192
5.6 Comparação visual entre ground truth e predição . . . 193
5.6.1 Imagem original . . . 193
5.6.2 Máscara de referência . . . 193
5.6.3 Máscara predita . . . 193
5.6.4 Overlay comparativo . . . 193
5.7 Análise de hiperparâmetros . . . 193
5.7.1 Impacto da taxa de aprendizado . . . 193
5.7.2 Impacto do tamanho de entrada . . . 194
5.7.3 Impacto da função de perda . . . 194
5.7.4 Efeito do data augmentation . . . 194
5.8 Custo computacional e inferência . . . 194
5.8.1 Número de parâmetros por modelo . . . 194
5.8.2 Tempo de treinamento . . . 195
5.8.3 Tempo médio de inferência por imagem . . . 195
5.8.4 Comparação entre desempenho e custo . . . 195
5.9 Síntese dos resultados de segmentação . . . 196
5.9.1 Melhor modelo global . . . 196
5.9.2 Melhor modelo em equilíbrio desempenho/custo . . . 196
5.9.3 Principais limitações observadas . . . 196

6 DISCUSSÃO . . . 197
6.1 Discussão dos resultados de classificação . . . 197
6.1.1 Interpretação dos ganhos entre arquiteturas . . . 197
6.1.2 Sensibilidade para lesões malignas . . . 198
6.1.3 Robustez dos modelos . . . 199
6.2 Discussão dos resultados de segmentação . . . 199
6.2.1 Impacto da atenção na segmentação . . . 200
6.2.2 Ganhos estruturais de arquiteturas mais complexas . . . 200
6.2.3 Limitações na delimitação das lesões . . . 201
6.3 Comparação entre desempenho e custo computacional . . . 201
6.3.1 Melhor modelo absoluto versus melhor custo-benefício . . . 201
6.3.2 Viabilidade prática em ambientes com recursos limitados . . . 202
6.3.3 Considerações sobre tempo de inferência . . . 202

6.4 Relação com os trabalhos relacionados 203
6.4.1 Similaridades com a literatura 203
6.4.2 Diferenças em metodologia e resultados 203
6.4.3 Contribuição do trabalho frente à literatura 203
6.5 Limitações do estudo 204
6.5.1 Uso de um único dataset 204
6.5.2 Tamanho da base de dados 204
6.5.3 Limitações de hardware 204
6.5.4 Restrições metodológicas 205
6.6 Implicações práticas 205
6.6.1 Uso como apoio ao diagnóstico 205
6.6.2 Potencial de aplicação acadêmica e clínica 205
6.6.3 Cuidados éticos e interpretativos 206

7 CONCLUSÃO 207
7.1 Retomada do problema de pesquisa 207
7.1.1 Síntese do contexto e motivação 207
7.1.2 Resposta ao problema proposto 207
7.2 Principais achados 208
7.2.1 Achados na classificação 208
7.2.2 Achados na segmentação 208
7.2.3 Achados sobre custo computacional 208
7.3 Contribuições do trabalho 209
7.3.1 Contribuições técnicas 209
7.3.2 Contribuições metodológicas 209
7.3.3 Contribuições acadêmicas 209
7.4 Limitações finais 210
7.4.1 Limitações experimentais 210
7.4.2 Limitações de generalização 210
7.5 Trabalhos futuros 210
7.5.1 Uso de múltiplos datasets 210
7.5.2 Validação cruzada e análise estatística 210
7.5.3 Inclusão de modelos adicionais 211
7.5.4 Explicabilidade e interpretabilidade 211
7.5.5 Integração entre classificação e segmentação 211

REFERÊNCIAS 212

1 INTRODUÇÃO

1.1 Contextualização do problema

1.1.1 Relevância do câncer de mama como problema de saúde pública

O câncer de mama constitui um dos principais desafios contemporâneos da saúde pública em razão de sua elevada incidência, de sua mortalidade associada e do impacto clínico, social e econômico decorrente do diagnóstico e do tratamento da doença. Em escala global, a Organização Mundial da Saúde descreve o câncer de mama como o tipo de câncer mais comum entre mulheres, com aproximadamente 2,3 milhões de novos casos e cerca de 670 mil óbitos em 2022 (World Health Organization, 2025a; International Agency for Research on Cancer, 2025). Esses números evidenciam não apenas a magnitude do problema, mas também sua distribuição global e seu peso particular em sistemas de saúde com menor capacidade de rastreamento, confirmação diagnóstica e tratamento oportuno.

No Brasil, a relevância epidemiológica da doença é igualmente expressiva. O Instituto Nacional de Câncer estimou, para cada ano do triênio 2023–2025, 73.610 novos casos de câncer de mama feminina, posicionando-o entre os cânceres de maior incidência no país, desconsiderando-se o câncer de pele não melanoma (Instituto Nacional de Câncer José Alencar Gomes da Silva, 2022a,b). Trata-se, portanto, de um problema que ultrapassa a esfera biomédica, mobiliza recursos assistenciais e demanda políticas permanentes de detecção precoce, diagnóstico e cuidado longitudinal.

Além da incidência atual, projeções recentes indicam crescimento continuado da carga global da doença nas próximas décadas, com aumento esperado de casos e óbitos caso as tendências atuais se mantenham (International Agency for Research on Cancer, 2025). Esse cenário reforça a necessidade de estratégias capazes de acelerar a detecção, reduzir atrasos diagnósticos e qualificar a estratificação clínica das pacientes. Sob perspectiva clínica, a identificação precoce de lesões suspeitas está associada a maior chance de tratamento efetivo, menor morbidade terapêutica e melhores desfechos em sobrevida (World Health Organization, 2017; Instituto Nacional de Câncer José Alencar Gomes da Silva, 2021). Assim, o enfrentamento do

câncer de mama depende não apenas de terapias eficazes, mas também de processos diagnósticos sensíveis, oportunos e reprodutíveis.

1.1.2 Importância do diagnóstico por imagem

O diagnóstico por imagem ocupa papel central na abordagem clínica do câncer de mama, atuando desde a detecção inicial de alterações suspeitas até a caracterização morfológica das lesões e o encaminhamento para investigação complementar. Métodos de imagem ampliam a capacidade de identificação precoce, orientam a indicação de biópsias e contribuem para o acompanhamento de achados mamários ao longo do tempo (Instituto Nacional de Câncer José Alencar Gomes da Silva, 2021, 2015). Nesse sentido, a imagem médica não é um componente acessório do cuidado em mama, mas um elemento estruturante da decisão clínica.

Embora a mamografia mantenha papel central em programas de rastreamento, o diagnóstico em mama é, na prática, multimodal. A integração entre mamografia diagnóstica, ultrassonografia mamária, ressonância magnética e procedimentos guiados por imagem responde a diferentes necessidades clínicas e depende de fatores como densidade mamária, suspeita anatômica e finalidade da investigação (Instituto Nacional de Câncer José Alencar Gomes da Silva, 2021; International Agency for Research on Cancer, 2023). Nenhuma modalidade, isoladamente, é suficiente para responder a todos os cenários diagnósticos.

A ultrassonografia mamária, foco deste trabalho, possui relevância particular por ser amplamente disponível, não utilizar radiação ionizante e desempenhar papel complementar importante na avaliação de achados mamográficos ou clínicos. Sua utilidade é especialmente reconhecida em contextos nos quais a densidade do tecido mamário reduz a sensibilidade de outros métodos ou quando se busca caracterizar melhor a natureza de uma lesão (International Agency for Research on Cancer, 2023; Instituto Nacional de Câncer, 2022). Ao mesmo tempo, sua interpretação permanece sujeita à complexidade visual das imagens, à qualidade da aquisição, à experiência do profissional e à variabilidade interobservador. Essas características tornam o ultrassom mamário um domínio especialmente relevante para o desenvolvimento de ferramentas computacionais de apoio à decisão.

1.1.3 Crescente uso de Inteligência Artificial na área médica

Nas últimas décadas, a Inteligência Artificial (IA), especialmente por meio do aprendizado de máquina e do aprendizado profundo, consolidou-se como componente estruturante da pesquisa em saúde digital. Esse avanço foi impulsionado pelo aumento da disponibilidade de dados, pelo amadurecimento de arquiteturas neurais e pela expansão da capacidade computacional para treinamento de modelos complexos. Em imagem médica, esse movimento foi particularmente intenso, uma vez que tarefas

como classificação, detecção, segmentação e quantificação morfológica se alinham diretamente ao tipo de inferência que modelos baseados em dados conseguem realizar com elevada flexibilidade (Barragán-montero; Javaid; Valdés; Nguyen; Desbordes; Macq; Willems; Vandewinckele; Holmström; Löfman; Michiels; Souris; Sterpin; Lee, 2021; Al-karawi; Al-zaidi; Helael; Obeidat; Mouhsen; Ajam; Alshalabi; Salman; Ahmed, 2024; Yu; Zhou; Wang; Zhang, 2022).

Na oncologia mamária, a IA tem sido aplicada a problemas de apoio ao diagnóstico, estratificação de risco, segmentação de lesões e extração automatizada de atributos radiológicos. Em especial, redes neurais convolucionais se tornaram a principal classe de modelos nesse contexto, por permitirem o aprendizado de representações hierárquicas diretamente dos dados, reduzindo a dependência de atributos projetados manualmente (Barragán-montero; Javaid; Valdés; Nguyen; Desbordes; Macq; Willems; Vandewinckele; Holmström; Löfman; Michiels; Souris; Sterpin; Lee, 2021; Yu; Zhou; Wang; Zhang, 2022).

No caso da ultrassonografia mamária, revisões sistemáticas recentes indicam resultados promissores no uso de aprendizado profundo para diferenciar massas benignas e malignas, segmentar lesões e apoiar fluxos de triagem. Entretanto, a literatura mais robusta adota postura cautelosa: a evidência disponível ainda não sustenta, de forma conclusiva, superioridade generalizável desses modelos em relação à leitura humana em todos os cenários clínicos, em razão de limitações metodológicas recorrentes, heterogeneidade entre bases e risco de viés experimental (Dan; Xu; Burrows; Bissram; Stringer; Li, 2024; Liu; Pian; Chen; Zhao; Liu; Meng; Zeng, 2025a). Dessa forma, a IA deve ser entendida menos como substituta da expertise clínica e mais como tecnologia de apoio, cuja utilidade depende de validação rigorosa, protocolo experimental consistente e interpretação crítica dos resultados.

1.2 Motivação

1.2.1 Desafios do diagnóstico em imagens de ultrassom mamário

A ultrassonografia mamária ocupa posição estratégica no diagnóstico do câncer de mama por sua ampla disponibilidade, custo relativamente baixo, ausência de radiação ionizante e utilidade complementar à mamografia, especialmente em mamas densas e em contextos nos quais se deseja caracterizar melhor achados suspeitos (Guo; Lu; Qin; Fei, 2018; Iacob; Iacob; Stoicescu; Ghenciu; Cocolea; Constantinescu; Ghenciu; Manolescu, 2024). Apesar dessas vantagens, trata-se de uma modalidade marcada por elevada variabilidade técnica e interpretativa, uma vez que depende intensamente da aquisição em tempo real, da experiência do operador e da leitura visual de padrões frequentemente sutis. Revisões recentes também destacam limitações associadas à reprodutibilidade, à especificidade em alguns cenários clínicos e ao risco de recon-

vocação ou de procedimentos desnecessários quando a diferenciação entre lesões benignas e malignas permanece incerta (Iacob; Iacob; Stoicescu; Ghenciu; Cocolea; Constantinescu; Ghenciu; Manolescu, 2024; Boca bene; Ciurea; Ciortea; Dudea, 2021; Ren; Zhao; Zhao; Yan; Hu; Qiao; Xu; Zhao, 2023).

Do ponto de vista morfológico, as imagens de ultrassom apresentam características que tornam a análise particularmente desafiadora. Entre elas, destacam-se o ruído *speckle*, o baixo contraste local, bordas ambíguas ou irregulares, artefatos de sombreamento e elevada heterogeneidade textural, fatores que dificultam tanto a interpretação humana quanto a extração automatizada de atributos robustos (Zhang; Xian; Cheng; Shareef; Ding; Xu; Huang; Zhang; Ning; Wang, 2022; Liu; Li; Qin; Wen; Xie; Cheng; Huang; Zhang; Ning; Wang, 2018a; Yap; Goyal; Osman; Ahmad; Marti; Denton; Juette; Zwiggelaar, 2018). Em consequência, pequenas variações no plano de aquisição, no posicionamento da sonda ou na qualidade da imagem podem modificar significativamente a aparência da lesão e reduzir a reprodutibilidade do processo diagnóstico (Guo; Lu; Qin; Fei, 2018; Iacob; Iacob; Stoicescu; Ghenciu; Cocolea; Constantinescu; Ghenciu; Manolescu, 2024).

Além disso, o problema analítico não se restringe à classificação global da imagem. Em muitos cenários, também é necessário localizar e delimitar a lesão com precisão, seja para documentação clínica, monitoramento longitudinal, apoio a procedimentos guiados por imagem ou extração de atributos morfológicos mais refinados. Por isso, o ultrassom mamário impõe duas demandas complementares: a classificação diagnóstica da imagem e a segmentação espacial da região lesional (Zhang; Xian; Cheng; Shareef; Ding; Xu; Huang; Zhang; Ning; Wang, 2022; Liu; Li; Qin; Wen; Xie; Cheng; Huang; Zhang; Ning; Wang, 2018a; Yap; Goyal; Osman; Ahmad; Marti; Denton; Juette; Zwiggelaar, 2018). Essa dupla exigência justifica a formulação de um estudo que trate ambas as tarefas de forma articulada, mas metodologicamente separada.

1.2.2 Potencial das técnicas de *Deep Learning* como apoio ao diagnóstico

As técnicas de *Deep Learning* ampliaram significativamente as possibilidades de processamento de imagens médicas ao viabilizar o aprendizado automático de representações hierárquicas diretamente dos dados. Em vez de depender exclusivamente de atributos construídos manualmente, redes profundas podem aprender padrões de textura, forma, contorno e contexto visual relevantes para a interpretação de lesões mamárias em ultrassom, o que explica seu avanço em tarefas de classificação, detecção e segmentação em imagem médica. (Liu; Pian; Chen; Zhao; Liu; Meng; Zeng, 2025b; Barragán-montero; Javaid; Valdés; Nguyen; Desbordes; Macq; Willems; Vandewinckele; Holmström; Löfman; Michiels; Souris; Sterpin; Lee, 2021; Guo; Lu; Qin; Fei, 2018)

Na classificação, esse potencial se manifesta na capacidade de aprender represen-

Tabela 1 – Principais desafios do ultrassom mamário para análise diagnóstica e computacional

Dimensão do desafio	**Descrição**
Aquisição e operação	Dependência do operador, aquisição em tempo real e variabilidade entre examinadores e equipamentos.
Interpretação clínica	Dificuldade na distinção entre lesões benignas e malignas, com impacto potencial em especificidade, reconvocação e indicação de biópsias.
Qualidade da imagem	Presença de ruído *speckle*, baixo contraste, sombreamento acústico e heterogeneidade textural.
Delimitação da lesão	Bordas ambíguas ou irregulares, dificultando segmentação e extração consistente de atributos morfológicos.
Modelagem computacional	Necessidade de tratar simultaneamente tarefas de classificação diagnóstica e segmentação espacial da lesão.

tações discriminativas para separar imagens normais, benignas e malignas mesmo diante de elevada heterogeneidade visual. Revisões sistemáticas recentes mostram que modelos de aprendizado profundo têm apresentado desempenho promissor no diagnóstico de câncer de mama em ultrassonografia, embora a literatura também enfatize que esse desempenho ainda deve ser interpretado à luz de limitações metodológicas, heterogeneidade entre estudos e diferenças entre cenários clínicos reais e ambientes experimentais controlados. (Dan; Xu; Burrows; Bissram; Stringer; Li, 2024; Liu; Pian; Chen; Zhao; Liu; Meng; Zeng, 2025b)

Na segmentação, arquiteturas do tipo *encoder-decoder*, particularmente as derivadas da família U-Net, tornaram-se predominantes em imagem médica por sua capacidade de combinar informação semântica global com detalhes espaciais finos, permitindo delimitar a lesão em nível de pixel. Esse tipo de modelagem amplia a interpretabilidade do sistema e viabiliza análises mais ricas do que a simples atribuição de uma classe global, incluindo quantificação morfológica, monitoramento e apoio a procedimentos guiados por imagem. (Yap; Goyal; Osman; Ahmad; Marti; Denton; Juette; Zwiggelaar, 2018; Zhang; Xian; Cheng; Shareef; Ding; Xu; Huang; Zhang; Ning; Wang, 2022; Rahmani et al., 2024)

Em ambos os casos, o papel mais promissor da IA é o de apoio à decisão clínica, e não de substituição direta da expertise médica. Revisões recentes destacam que essas técnicas podem contribuir para reduzir variabilidade interpretativa, aliviar carga de trabalho e aumentar consistência analítica, desde que sua utilização seja acompanhada de validação rigorosa, desenho experimental transparente e avaliação crítica da generalização dos resultados. (Liu; Pian; Chen; Zhao; Liu; Meng; Zeng, 2025b; Dan;

Xu; Burrows; Bissram; Stringer; Li, 2024; Iacob; Iacob; Stoicescu; Ghenciu; Cocolea; Constantinescu; Ghenciu; Manolescu, 2024)

Ainda assim, o valor científico de um estudo nessa área não está apenas em obter métricas elevadas, mas em construir um protocolo reprodutível, com comparação justa entre arquiteturas, escolha coerente de métricas e atenção explícita a limitações de generalização. A literatura em aprendizado profundo para imagem médica tem apontado a reprodutibilidade e o controle de variabilidade experimental como condições centrais para que resultados sejam interpretáveis e úteis em pesquisa translacional. (Moassefi et al., 2023; Simkó et al., 2024; Renard; Guedria; De palma; Vuillerme, 2020) É precisamente nessa perspectiva que se insere o presente trabalho.

Tabela 2 – Potenciais contribuições do *Deep Learning* no ultrassom mamário

Dimensão	**Contribuição potencial**
Classificação	Aprendizado de representações discriminativas para diferenciar imagens normais, benignas e malignas.
Segmentação	Delimitação espacial da lesão em nível de pixel, favorecendo interpretabilidade e análise morfológica.
Apoio à decisão	Redução de variabilidade interpretativa, aumento de consistência analítica e suporte ao especialista.
Reprodutibilidade	Necessidade de protocolos transparentes, comparação justa entre arquiteturas e avaliação rigorosa de generalização.

1.2.3 Justificativa para o uso do dataset BUSI

A escolha do *Breast Ultrasound Images Dataset* (BUSI) decorre de sua adequação direta ao problema investigado. Trata-se de uma base pública de ultrassonografia mamária amplamente utilizada na literatura, contendo imagens rotuladas nas classes *normal*, *benigna* e *maligna*, além de máscaras de referência associadas às lesões (Aldhabyani; Gomaa; Khaled; Fahmy, 2020). Essa estrutura torna o BUSI especialmente apropriado para estudos que desejam investigar, em um mesmo domínio imagiológico, tanto classificação quanto segmentação.

Outro ponto favorável é seu caráter público e amplamente reutilizado, o que favorece reprodutibilidade e comparabilidade com trabalhos prévios. Para um TCC com ambição de rigor científico, essa comparabilidade é relevante porque fortalece a interpretação dos resultados e reduz arbitrariedade experimental. Ao mesmo tempo, o uso da base exige cautela. Trabalhos posteriores apontaram problemas como duplicatas, quase duplicatas e discrepâncias em máscaras de referência, evidenciando que seu uso acrítico pode produzir vazamento de informação e estimativas infladas de desem-

penho (Pawłowska; Karwat; Zołek, 2023). Assim, a justificativa para utilizá-lo não está em supor que se trata de um conjunto perfeito, mas em reconhecer que ele oferece um ambiente experimental adequado, desde que submetido a curadoria rigorosa.

1.3 Problema de pesquisa

1.3.1 Limitações de abordagens convencionais

A análise de lesões mamárias em ultrassonografia foi historicamente conduzida por duas classes principais de abordagem: a interpretação especializada do radiologista e os sistemas de diagnóstico auxiliado por computador baseados em regras e atributos *handcrafted*. Embora essas estratégias tenham contribuído de forma importante para o desenvolvimento do diagnóstico por imagem, ambas apresentam limitações quando confrontadas com a elevada heterogeneidade visual do ultrassom mamário.

No plano clínico, a leitura do exame permanece fortemente dependente da experiência do operador, da qualidade da aquisição e da consistência interpretativa. No plano computacional, sistemas convencionais de CAD frequentemente dependem de descritores manuais, definição prévia de regiões de interesse e *pipelines* multietapa, nos quais erros acumulados em uma fase comprometem as fases subsequentes (Afrin; Larson; Fatemi; Alizad, 2023; Yap; Goyal; Osman; Ahmad; Marti; Denton; Juette; Zwiggelaar, 2018; Chan; Samala; Hadjiiski, 2020). Em imagens marcadas por ruído, baixo contraste e fronteiras imprecisas, tais abordagens tendem a perder robustez justamente nos casos em que o auxílio computacional seria mais necessário.

1.3.2 Necessidade de comparação entre arquiteturas distintas por tarefa

Embora o crescimento do *Deep Learning* tenha ampliado o repertório metodológico disponível, a literatura sobre ultrassom mamário permanece marcada por heterogeneidade de protocolos, diferenças entre bases, ausência de validação externa em muitos estudos e comparações nem sempre metodologicamente justas entre modelos (Dan; Xu; Burrows; Bissram; Stringer; Li, 2024; Pawłowska; Karwat; Zołek, 2023). Assim, o simples acúmulo de resultados isolados não resolve a questão de quais arquiteturas são mais adequadas para cada subtarefa do problema.

Essa lacuna é particularmente relevante porque classificação e segmentação não constituem o mesmo problema computacional. Na classificação, busca-se atribuir um rótulo global à imagem; na segmentação, busca-se delimitar a lesão em nível de pixel. Como essas tarefas impõem exigências distintas de representação, arquiteturas orientadas à classificação e arquiteturas orientadas à segmentação não devem ser comparadas como se resolvessem o mesmo problema (Yu; Zhou; Wang; Zhang, 2022; Afrin; Larson; Fatemi; Alizad, 2023). Em consequência, comparações cientificamente informativas precisam ser realizadas entre modelos funcionalmente equivalentes den-

tro de cada tarefa, incorporando não apenas métricas de desempenho, mas também custo computacional e viabilidade prática.

1.3.3 Definição do problema investigado

Diante desse contexto, o problema de pesquisa deste trabalho pode ser formulado da seguinte maneira: *quais arquiteturas de aprendizado profundo apresentam melhor desempenho e melhor relação entre desempenho e custo computacional nas tarefas de classificação e segmentação de lesões em imagens de ultrassom mamário, quando avaliadas sob um protocolo experimental controlado e aplicado ao dataset BUSI?*

No eixo de classificação, investiga-se a capacidade de diferentes arquiteturas em distinguir entre imagens normais, benignas e malignas, considerando não apenas acurácia global, mas também sensibilidade para a classe maligna, comportamento por classe e custo computacional. No eixo de segmentação, investiga-se a capacidade dos modelos em delimitar a região tumoral com precisão, utilizando métricas espaciais como IoU e Dice Score, além de indicadores de estabilidade de treinamento e tempo de inferência. O estudo parte, ainda, da premissa de que a validade desses achados depende de curadoria cuidadosa da base, especialmente diante das inconsistências já apontadas na literatura (Al-dhabyani; Gomaa; Khaled; Fahmy, 2020; Pawłowska; Karwat; Zołek, 2023).

1.4 Hipóteses e pressupostos

As hipóteses deste trabalho derivam de três pressupostos centrais: (i) classificação e segmentação impõem exigências representacionais distintas aos modelos; (ii) diferenças arquiteturais relevantes tendem a produzir comportamentos distintos de generalização e sensibilidade diagnóstica; e (iii) desempenho absoluto e viabilidade computacional não podem ser tratados como critérios independentes em aplicações de imagem médica.

1.4.1 Hipótese para classificação

A hipótese para a tarefa de classificação é que arquiteturas mais modernas e estruturalmente mais eficientes do que a VGG16 tenderão a apresentar desempenho superior na discriminação entre imagens normais, benignas e malignas, especialmente em métricas mais informativas do que a acurácia global, como *macro F1-score*, sensibilidade para a classe maligna e AUC-ROC por classe. Em termos operacionais, espera-se que modelos com conexões residuais, escalonamento composto ou desenho convolucional modernizado — como ResNet, EfficientNet e ConvNeXt — aprendam representações mais robustas do que uma arquitetura clássica sob um mesmo protocolo experimental, uma vez que foram propostos justamente para melhorar otimi-

zação, eficiência de escala e qualidade de representação em comparação com CNNs anteriores, como a VGG16. (Simonyan; Zisserman, 2015; He; Zhang; Ren; Sun, 2016; Tan; Le, 2019; Liu; Mao; Wu; Feichtenhofer; Darrell; Xie, 2022)

Essa hipótese não pressupõe superioridade irrestrita de modelos mais complexos. Considerando o tamanho moderado da base e a heterogeneidade intrínseca do ultrassom mamário, admite-se que o ganho arquitetural possa ser limitado por risco de sobreajuste, sensibilidade ao domínio e restrições de generalização, problemas recorrentes na literatura de aprendizado profundo aplicado ao ultrassom mamário. Ainda assim, assume-se que as diferenças entre modelos tenderão a emergir com maior clareza na capacidade de identificar casos malignos, pois essa tarefa exige representações discriminativas mais estáveis do que a simples maximização da acurácia global. (Dan; Xu; Burrows; Bissram; Stringer; Li, 2024; Liu; Pian; Chen; Zhao; Liu; Meng; Zeng, 2025b; Guo; Lu; Qin; Fei, 2018)

1.4.2 Hipótese para segmentação

A hipótese para a tarefa de segmentação é que variantes estruturalmente enriquecidas da U-Net apresentarão desempenho superior ao da U-Net padrão na delimitação espacial das lesões, sobretudo em métricas orientadas à sobreposição e recuperação de contorno, como IoU e Dice Score. Essa expectativa decorre do fato de que mecanismos de atenção, conexões aninhadas e agregação multiescala de contexto — como nas arquiteturas Attention U-Net, U-Net++ e DeepLabV3+ — foram propostos para melhorar focalização em estruturas relevantes, reduzir o descompasso semântico entre codificador e decodificador e refinar contornos, aspectos particularmente importantes em segmentação biomédica. (Ronneberger; Fischer; Brox, 2015; Oktay; Schlemper; Le folgoc; Lee; Heinrich; Misawa; Mori; Mcdonagh; Hammerla; Kainz; Glocker; Rueckert, 2018; Zhou; Siddiquee; Tajbakhsh; Liang, 2018; Chen; Zhu; Papandreou; Schroff; Adam, 2018)

Essa expectativa é especialmente plausível no ultrassom mamário, em que ruído *speckle*, baixo contraste local, margens irregulares e alta variabilidade morfológica dificultam a recuperação precisa da região lesional. Em bases de ultrassom mamário, a literatura de segmentação tem mostrado que a tarefa é sensível tanto à arquitetura quanto ao protocolo de avaliação, o que reforça a pertinência de comparar modelos com diferentes mecanismos de modelagem espacial. (Zhang; Xian; Cheng; Shareef; Ding; Xu; Huang; Zhang; Ning; Wang, 2022; Liu; Li; Qin; Wen; Xie; Cheng; Huang; Zhang; Ning; Wang, 2018b; Guo; Lu; Qin; Fei, 2018)

Ao mesmo tempo, admite-se que maior sofisticação arquitetural não implica necessariamente superioridade estável em bases de escala moderada. Por isso, considera-se também como pressuposto secundário que a U-Net padrão poderá permanecer competitiva em estabilidade de treinamento e generalização, mesmo que não alcance

o melhor desempenho absoluto, já que sua formulação original continua sendo uma referência forte em segmentação biomédica por combinar simplicidade arquitetural com boa capacidade de localização. (Ronneberger; Fischer; Brox, 2015; Renard; Guedria; De palma; Vuillerme, 2020)

1.4.3 Hipótese para a relação entre desempenho e custo computacional

A terceira hipótese estabelece que o modelo de melhor desempenho absoluto não será, necessariamente, o modelo com melhor relação entre desempenho e custo computacional. Em aplicações médicas baseadas em imagem, critérios como número de parâmetros, tempo de treinamento, latência de inferência e demanda por memória influenciam diretamente a viabilidade de uso, especialmente quando se considera implantação prática, escalabilidade e restrições de hardware. Essa tensão entre qualidade preditiva e eficiência é central no desenho de arquiteturas como EfficientNet e também aparece na discussão contemporânea sobre *backbones* modernos em visão computacional. (Tan; Le, 2019; Liu; Mao; Wu; Feichtenhofer; Darrell; Xie, 2022; Barragán-montero; Javaid; Valdés; Nguyen; Desbordes; Macq; Willems; Vandewinckele; Holmström; Löfman; Michiels; Souris; Sterpin; Lee, 2021)

No eixo de classificação, espera-se que arquiteturas como ResNet e EfficientNet apresentem melhor compromisso entre desempenho e custo computacional do que modelos mais pesados, pois ResNet foi concebida para facilitar a otimização de redes profundas por meio de conexões residuais, enquanto EfficientNet foi projetada explicitamente para obter melhor escalonamento entre profundidade, largura e resolução sob restrições de recursos. (He; Zhang; Ren; Sun, 2016; Tan; Le, 2019)

No eixo de segmentação, admite-se que arquiteturas como Attention U-Net possam oferecer ganhos relevantes com acréscimo moderado de complexidade, enquanto modelos mais sofisticados, como U-Net++ e DeepLabV3+, possam alcançar melhor desempenho absoluto à custa de maior custo operacional, já que seus projetos incorporam mecanismos adicionais de atenção, caminhos densos de conexão ou módulos multiescala para refino espacial. Assim, assume-se que a análise conjunta de desempenho e custo identificará modelos custo-efetivos distintos daqueles com melhor métrica final. (Oktay; Schlemper; Le folgoc; Lee; Heinrich; Misawa; Mori; Mcdonagh; Hammerla; Kainz; Glocker; Rueckert, 2018; Zhou; Siddiquee; Tajbakhsh; Liang, 2018; Chen; Zhu; Papandreou; Schroff; Adam, 2018; Renard; Guedria; De palma; Vuillerme, 2020)

1.5 Objetivos

1.5.1 Objetivo geral

Avaliar o desempenho de arquiteturas de *Deep Learning* aplicadas à classificação e à segmentação de lesões em imagens de ultrassom mamário, utilizando o dataset BUSI como ambiente experimental controlado, a fim de investigar sua aplicabilidade como ferramenta de apoio ao diagnóstico do câncer de mama e identificar, em cada tarefa, o melhor compromisso entre desempenho e custo computacional.

1.5.2 Objetivos específicos

1. Estruturar um protocolo experimental reprodutível para análise de imagens de ultrassom mamário, incluindo curadoria do dataset BUSI, definição de critérios de inclusão e exclusão, particionamento em treino, validação e teste, e controle de vazamento de dados.

2. Investigar a tarefa de classificação multiclasse em imagens de ultrassom mamário, considerando as categorias *normal*, *benigna* e *maligna*.

3. Comparar arquiteturas de classificação representativas de diferentes paradigmas de redes neurais convolucionais, analisando seus efeitos sobre métricas como acurácia, sensibilidade, *precision*, F_1-score e AUC-ROC.

4. Investigar a tarefa de segmentação semântica de lesões mamárias em imagens de ultrassom, restringindo a análise aos casos com região tumoral segmentável.

5. Comparar arquiteturas de segmentação baseadas em *encoder-decoder*, mecanismos de atenção, conexões aninhadas e agregação multiescala de contexto, examinando seus efeitos sobre métricas como IoU e Dice Score.

6. Aplicar e documentar técnicas de pré-processamento e aumento de dados compatíveis com a natureza do ultrassom mamário, analisando seu papel na robustez dos modelos.

7. Analisar o impacto de escolhas de hiperparâmetros, como taxa de aprendizado, tamanho de lote, estratégia de *fine-tuning* e função de perda, no comportamento dos modelos em cada tarefa.

8. Avaliar os modelos também sob perspectiva computacional, incorporando à análise comparativa métricas como número de parâmetros, tempo de treinamento, tempo médio de inferência por imagem e tamanho final do modelo.

9. Identificar, para cada tarefa, o modelo de melhor desempenho absoluto e o modelo de melhor relação entre desempenho e custo computacional.

10. Discutir criticamente os resultados obtidos, considerando padrões de erro, sensibilidade para casos malignos, limitações de generalização, implicações metodológicas do uso do BUSI e potencial de aplicação dos modelos como sistemas de apoio ao diagnóstico.

1.6 Delimitação do estudo

1.6.1 Foco em imagens de ultrassom mamário

Este trabalho foi delimitado ao domínio da ultrassonografia mamária, em razão de sua relevância clínica, de sua ampla utilização como exame complementar e de seus desafios computacionais específicos. A escolha por um único domínio imagiológico reduz fatores de confusão associados a diferenças entre modalidades e permite que a comparação entre arquiteturas seja realizada em um cenário metodologicamente mais controlado.

1.6.2 Separação entre classificação e segmentação

O estudo foi estruturado em dois eixos experimentais independentes: classificação e segmentação. Essa delimitação foi adotada para evitar comparações inadequadas entre modelos desenhados para finalidades diferentes e para preservar, em cada tarefa, arquiteturas, funções de perda, métricas e critérios analíticos coerentes com sua natureza computacional. Assim, classificação e segmentação são tratadas como problemas complementares, mas não equivalentes.

1.7 Metodologia resumida

1.7.1 Estrutura geral do pipeline experimental

A metodologia deste trabalho foi concebida como um protocolo experimental supervisionado, reprodutível e orientado à comparação justa entre arquiteturas de *Deep Learning*. O pipeline inicia-se com a curadoria do dataset BUSI, incluindo inspeção estrutural da base, verificação da correspondência entre imagens e máscaras, definição de critérios de inclusão e exclusão e identificação de possíveis elementos que comprometam a integridade experimental, como duplicatas e quase duplicatas.

Em seguida, os dados são organizados em subconjuntos de treino, validação e teste, respeitando estratégias de particionamento compatíveis com o controle de vazamento de informação. Após essa etapa, aplicam-se procedimentos de pré-processamento e aumento de dados adequados à natureza do ultrassom mamário, preservando plausibilidade anatômica e coerência clínica das transformações.

Por fim, são conduzidos experimentos independentes para classificação e segmentação, com arquiteturas representativas de cada tarefa, análise de hiperparâme-

tros, avaliação por métricas preditivas e espaciais e incorporação de medidas de custo computacional. Esse arranjo metodológico busca assegurar que as diferenças observadas entre modelos reflitam, com a maior fidelidade possível, efeitos arquiteturais e decisões experimentais explícitas.

1.8 Estrutura da monografia

Além desta introdução, a monografia está organizada da seguinte forma. O Capítulo 2 apresenta a fundamentação teórica, abordando os fundamentos clínicos do câncer de mama, o papel da ultrassonografia mamária, conceitos de Inteligência Artificial e aprendizado profundo, bem como as arquiteturas e métricas relevantes para o estudo. O Capítulo 3 descreve os materiais e métodos, detalhando a base de dados, a curadoria do BUSI, o pré-processamento, o particionamento dos dados, os modelos avaliados e o protocolo experimental.

O Capítulo 4 apresenta os resultados da tarefa de classificação, incluindo métricas quantitativas, análises por classe, matrizes de confusão, curvas ROC e avaliação de custo computacional. O Capítulo 5 apresenta os resultados da segmentação, com ênfase em métricas como IoU e Dice Score, comparação entre arquiteturas, análise qualitativa das máscaras preditas e custo computacional. O Capítulo 6 discute criticamente os resultados à luz das hipóteses iniciais, das características dos modelos e da literatura revisada. Por fim, o Capítulo 7 apresenta a conclusão, sintetizando os achados principais, as limitações do estudo e possíveis direções para trabalhos futuros.

2 FUNDAMENTAÇÃO TEÓRICA

2.1 Câncer de mama e diagnóstico por imagem

2.1.1 Conceitos básicos sobre câncer de mama

O câncer de mama consiste em um grupo heterogêneo de neoplasias malignas originadas, em geral, a partir do epitélio ductal ou lobular da glândula mamária. Essa heterogeneidade manifesta-se em múltiplos níveis, incluindo morfologia tumoral, perfil molecular, comportamento biológico, velocidade de progressão, resposta terapêutica e prognóstico. Em termos clínicos, essa diversidade implica que o câncer de mama não deve ser tratado como uma entidade única e uniforme, mas como um conjunto de doenças relacionadas, cuja caracterização adequada depende da integração entre achados clínicos, histopatológicos, biomarcadores e métodos de imagem (World Health Organization, 2025b; Instituto Nacional de Câncer José Alencar Gomes da Silva, 2023).

Do ponto de vista epidemiológico, o câncer de mama permanece entre os principais problemas de saúde pública em escala global e nacional, não apenas por sua elevada incidência, mas também pelo impacto sobre mortalidade, morbidade, qualidade de vida e organização dos sistemas de saúde. Sua relevância sanitária decorre do fato de que o prognóstico está fortemente associado ao estágio em que a doença é detectada, de modo que estratégias de rastreamento, reconhecimento precoce de sinais suspeitos e confirmação diagnóstica oportuna ocupam papel central no controle da doença (World Health Organization, 2025b; Instituto Nacional de Câncer José Alencar Gomes da Silva, 2015).

Em sua evolução clínica, o câncer de mama pode apresentar-se como lesão palpável, alteração arquitetural, microcalcificações, assimetrias, distorções ou achados subclínicos detectáveis apenas por métodos de imagem. Essa característica reforça a importância de abordagens diagnósticas capazes de identificar tanto manifestações evidentes quanto alterações iniciais ainda não perceptíveis ao exame físico. Além disso, a doença pode assumir formas invasivas ou não invasivas, com diferentes potenciais de disseminação local e sistêmica, o que torna a detecção precoce particu-

larmente importante para ampliar as possibilidades terapêuticas e reduzir a probabilidade de desfechos desfavoráveis (Instituto Nacional de Câncer José Alencar Gomes da Silva, 2015; National Cancer Institute, 2025a).

Sob uma perspectiva conceitual mais ampla, a abordagem do câncer de mama envolve três grandes eixos complementares: rastreamento em populações assintomáticas, diagnóstico em pacientes com sinais ou sintomas suspeitos e estadiamento/monitoramento após confirmação diagnóstica. Embora esses eixos possuam objetivos distintos, todos dependem, em maior ou menor grau, da qualidade do diagnóstico por imagem. Em consequência, compreender o câncer de mama no âmbito desta pesquisa exige reconhecer que a interpretação imagiológica não é uma etapa acessória, mas parte constitutiva do processo clínico de identificação, caracterização e condução dos casos suspeitos (Instituto Nacional de Câncer José Alencar Gomes da Silva, 2022a; National Cancer Institute, 2025b).

2.1.2 Métodos de imagem utilizados no diagnóstico

O diagnóstico por imagem no câncer de mama baseia-se em uma estratégia multimodal, na qual diferentes métodos são empregados conforme o contexto clínico, o perfil de risco da paciente, a idade, a densidade mamária e a finalidade da investigação. A mamografia ocupa papel central em programas de rastreamento, sobretudo por sua capacidade de detectar alterações suspeitas em fases precoces, inclusive antes da manifestação clínica evidente. Em razão dessa característica, ela permanece como o método de imagem de referência para rastreamento populacional em grande parte das diretrizes contemporâneas (National Cancer Institute, 2025b; Instituto Nacional de Câncer José Alencar Gomes da Silva, 2015).

Entretanto, a prática diagnóstica em mama não se esgota na mamografia. A ultrassonografia mamária é amplamente utilizada como exame complementar, tanto para investigação diagnóstica de sinais e sintomas quanto para melhor caracterização de achados identificados em outros métodos. Em determinados cenários, como em mulheres jovens com queixas clínicas suspeitas ou em pacientes com mamas densas, o ultrassom assume relevância ainda maior, seja como método inicial de avaliação, seja como ferramenta adicional para análise morfológica da lesão (Instituto Nacional de Câncer José Alencar Gomes da Silva, 2022b; Instituto Nacional de Câncer José Alencar Gomes da Silva, 2015).

A ressonância magnética das mamas, por sua vez, oferece elevada sensibilidade e é particularmente útil em situações específicas, como avaliação de pacientes de alto risco, investigação complementar de achados inconclusivos, pesquisa de extensão de doença e monitoramento em contextos selecionados. Apesar de seu valor clínico, a ressonância não substitui rotineiramente mamografia e ultrassonografia, mas integra um arsenal diagnóstico complementar, geralmente reservado a indicações mais es-

pecíficas por envolver maior custo, menor disponibilidade e interpretação altamente especializada (National Cancer Institute, 2025b,a).

Além desses métodos principais, o processo diagnóstico pode incluir tomossíntese mamária, procedimentos intervencionistas guiados por imagem e, em contextos de estadiamento ou avaliação complementar, outros exames de imagem sistêmica. Contudo, para fins desta pesquisa, interessa sobretudo a relação entre mamografia, ultrassonografia e ressonância magnética como modalidades mais diretamente ligadas à detecção e à caracterização inicial de lesões mamárias. O ponto central é que esses métodos não competem de maneira simples entre si; eles são, em grande medida, complementares, e sua utilidade depende da pergunta clínica formulada. Essa complementaridade ajuda a explicar por que o desenvolvimento de métodos computacionais para apoio ao diagnóstico precisa respeitar as propriedades específicas de cada modalidade imagiológica (National Cancer Institute, 2025b; Instituto Nacional de Câncer José Alencar Gomes da Silva, 2022a).

Nesse contexto, a escolha da ultrassonografia como foco deste estudo é metodologicamente justificável porque ela representa, simultaneamente, um exame de grande relevância prática e uma modalidade particularmente desafiadora do ponto de vista computacional. Diferentemente de métodos mais padronizados em termos de aquisição, o ultrassom impõe ao algoritmo e ao observador humano a necessidade de interpretar sinais visuais altamente dependentes de contexto, textura e contorno, o que o torna um campo fértil para investigação de arquiteturas de *Deep Learning* aplicadas ao apoio diagnóstico (Trepanier; Lei; Elmore; Mcdonald, 2023; Dan; Xu; Burrows; Bissram; Stringer; Li, 2024).

2.1.3 Ultrassonografia mamária: características e limitações

A ultrassonografia mamária é um método de imagem baseado na emissão e recepção de ondas ultrassônicas, produzindo representação em tempo real das estruturas mamárias sem utilização de radiação ionizante. Essa característica lhe confere vantagens operacionais relevantes, incluindo ampla disponibilidade, menor custo relativo em comparação com métodos mais complexos e possibilidade de aplicação em diferentes contextos assistenciais. Clinicamente, o exame é valioso para caracterização de nódulos, diferenciação entre componentes císticos e sólidos, avaliação complementar de alterações suspeitas e suporte a procedimentos guiados por imagem (Instituto Nacional de Câncer José Alencar Gomes da Silva, 2022b; Instituto Nacional de Câncer José Alencar Gomes da Silva, 2015).

Do ponto de vista diagnóstico, uma das principais virtudes do ultrassom mamário é sua utilidade como método complementar, especialmente em mamas densas, nas quais a sensibilidade da mamografia pode ser reduzida. Nesses cenários, a ultrassonografia pode contribuir para identificação de achados adicionais e para melhor

definição morfológica de lesões detectadas por outros meios ou pela clínica. Em contrapartida, a literatura mostra que o ganho em detecção pode ser acompanhado por aumento de reconvocações, achados falso-positivos e biópsias desnecessárias, o que torna a interpretação do exame particularmente sensível ao equilíbrio entre sensibilidade e especificidade (Hussein; Abbas; Keshavarzi; Fazelzad; Bukhanov; Kulkarni; Freedman; Mesurolle; Elser; Hodgson; Crystal; Freitas, 2023; Lobig; Caleyachetty; Forrester; Morris; Newstead; Harris; Blankenburg, 2023).

Sob a perspectiva da análise de imagem, a ultrassonografia mamária apresenta propriedades que a tornam substancialmente mais desafiadora do que modalidades com maior padronização estrutural. Entre essas propriedades destacam-se o ruído *speckle*, o baixo contraste entre tecidos adjacentes, a presença de sombras e reforços acústicos, a variabilidade de orientação do transdutor, a dependência de ganho e profundidade configurados durante a aquisição e a relativa imprecisão de contornos em algumas lesões. Em consequência, a imagem ultrassonográfica frequentemente contém padrões texturais ambíguos e bordas pouco definidas, dificultando tanto a interpretação humana quanto a modelagem computacional (Trepanier; Lei; Elmore; Mcdonald, 2023; Afrin; Larson; Fatemi; Alizad, 2023).

Outra limitação central da ultrassonografia mamária é sua forte dependência do operador. A qualidade da aquisição, a seleção do plano de corte, a pressão aplicada com o transdutor e a escolha das imagens representativas podem influenciar diretamente a aparência do exame. Esse caráter operador-dependente introduz variabilidade substancial, afetando reprodutibilidade, comparabilidade entre estudos e robustez de sistemas automatizados treinados em conjuntos de dados limitados. Revisões recentes ressaltam que, embora o ultrassom seja uma ferramenta diagnóstica extremamente útil, sua utilidade é limitada por taxas relativamente altas de reconvocação, baixo valor preditivo positivo em alguns cenários e especificidade inferior à desejável quando comparado a estratégias mais seletivas ou multimodais (Trepanier; Lei; Elmore; Mcdonald, 2023; Hussein; Abbas; Keshavarzi; Fazelzad; Bukhanov; Kulkarni; Freedman; Mesurolle; Elser; Hodgson; Crystal; Freitas, 2023).

Essas limitações, no entanto, não diminuem a relevância da ultrassonografia mamária; ao contrário, ajudam a explicar por que ela se tornou um alvo tão importante para pesquisa em Inteligência Artificial. Justamente por combinar alta utilidade clínica com elevada complexidade visual e interpretativa, o ultrassom oferece um cenário propício para investigação de métodos capazes de reduzir variabilidade, apoiar a diferenciação entre lesões benignas e malignas e melhorar a consistência analítica do processo diagnóstico. É nesse ponto que se insere a motivação computacional desta monografia: explorar o potencial de arquiteturas profundas em um domínio em que a dificuldade do problema não decorre da ausência de informação, mas da complexidade de sua representação visual e de sua interpretação clínica (Dan; Xu; Burrows;

Bissram; Stringer; Li, 2024; Trepanier; Lei; Elmore; Mcdonald, 2023).

2.2 Inteligência Artificial aplicada à saúde

2.2.1 Conceitos de IA, Machine Learning e Deep Learning

A Inteligência Artificial (IA) pode ser compreendida, em sentido amplo, como o campo dedicado ao desenvolvimento de sistemas capazes de executar tarefas que, em condições usuais, exigiriam processos cognitivos associados à inteligência humana, como reconhecimento de padrões, inferência, tomada de decisão e adaptação a novos dados. No contexto da saúde, essa definição adquire caráter prático: a IA passa a ser entendida como um conjunto de métodos computacionais capazes de apoiar atividades clínicas, diagnósticas, prognósticas, administrativas e de pesquisa, desde que operem sobre dados de maneira sistemática e verificável. Além disso, organismos internacionais como a Organização Mundial da Saúde destacam que a avaliação da IA em saúde não deve se limitar ao desempenho técnico, devendo também considerar critérios como segurança, transparência, responsabilidade, equidade e benefício público. (World Health Organization, 2021; Yu; Beam; Kohane, 2018)

No interior desse campo mais amplo, o *Machine Learning* (ML) corresponde ao subconjunto de técnicas que permitem a construção de modelos capazes de aprender relações estatísticas a partir de dados, sem depender exclusivamente de regras programadas manualmente para cada tarefa. Em vez de codificar explicitamente todas as etapas de decisão, o ML ajusta parâmetros a partir de exemplos observados, de modo a otimizar uma função objetivo. Em aplicações médicas, isso significa que o sistema pode aprender a associar atributos de imagem, sinais fisiológicos, dados laboratoriais ou registros clínicos a desfechos de interesse, como diagnóstico, risco ou resposta terapêutica. Essa mudança de paradigma foi particularmente relevante na saúde porque possibilitou tratar problemas complexos, de alta dimensionalidade e difícil formalização analítica por métodos convencionais. (Rajkomar; Dean; Kohane, 2019; Esteva; Robicquet; Ramsundar; Kuleshov; Depristo; Chou; Cui; Corrado; Thrun; Dean, 2019)

O *Deep Learning* (DL), por sua vez, constitui uma subárea do ML baseada em redes neurais profundas, isto é, modelos compostos por múltiplas camadas sucessivas de transformação não linear. Sua principal característica é a capacidade de aprender representações hierárquicas diretamente dos dados brutos, reduzindo a dependência de engenharia manual de atributos. Em imagens médicas, esse aspecto é especialmente relevante porque estruturas anatômicas, texturas, contornos e relações espaciais podem ser inferidos em diferentes níveis de abstração pela própria rede. Como consequência, o DL tornou-se uma das abordagens centrais em tarefas de classificação, detecção, segmentação, reconstrução e apoio à interpretação de exames,

sobretudo após o amadurecimento de arquiteturas convolucionais e do treinamento em larga escala. (Lee; Jun; Cho; Lee; Kim; Seo; Kim, 2017a; Esteva; Chou; Yeung; Naik; Madani; Mottaghi; Liu; Topol, 2021; Esteva; Robicquet; Ramsundar; Kuleshov; Depristo; Chou; Cui; Corrado; Thrun; Dean, 2019)

A distinção entre IA, ML e DL não é meramente terminológica; ela possui implicações metodológicas diretas para a pesquisa em saúde. IA designa o campo mais amplo e inclui desde sistemas baseados em regras até modelos probabilísticos e redes neurais profundas. ML refere-se à classe de métodos orientados ao aprendizado a partir de dados. DL, por fim, descreve arquiteturas profundas capazes de extrair representações complexas com elevada flexibilidade. Em pesquisas aplicadas à imagem médica, essa hierarquia conceitual é importante porque ajuda a delimitar claramente o tipo de contribuição oferecida pelo estudo: não se trata de IA em sentido genérico, mas de uma investigação específica sobre arquiteturas de aprendizado profundo em tarefas de classificação e segmentação. (Rajkomar; Dean; Kohane, 2019; Lee; Jun; Cho; Lee; Kim; Seo; Kim, 2017a; Yu; Beam; Kohane, 2018)

2.2.2 Aplicações de IA em imagens médicas

A imagem médica tornou-se um dos principais campos de aplicação da IA porque reúne características particularmente compatíveis com modelos de aprendizado profundo, entre elas o grande volume de dados visuais, a alta complexidade estrutural e a necessidade constante de interpretação especializada. Revisões amplas da área mostram que a IA vem sendo aplicada a diferentes modalidades, incluindo radiografia, tomografia computadorizada, ressonância magnética, ultrassonografia, mamografia, patologia digital e imagem oftalmológica, cobrindo tarefas como classificação diagnóstica, detecção de achados, segmentação anatômica e lesional, reconstrução de imagem, redução de ruído, triagem automatizada, priorização de casos e quantificação de biomarcadores de imagem. (Lee; Jun; Cho; Lee; Kim; Seo; Kim, 2017a; Esteva; Chou; Yeung; Naik; Madani; Mottaghi; Liu; Topol, 2021; Aggarwal; Sounderajah; Martin; Ting; Karthikesalingam; King; Ashrafian; Darzi, 2021)

Entre essas aplicações, quatro classes de tarefa se destacam por sua relevância metodológica e clínica. A primeira é a classificação, em que o sistema atribui um rótulo global a uma imagem ou exame, como normal versus patológico, benigno versus maligno ou presença versus ausência de determinada condição. A segunda é a detecção, voltada à identificação de regiões suspeitas ou achados específicos. A terceira é a segmentação, na qual o modelo delimita estruturas anatômicas ou lesões em nível de pixel. A quarta envolve tarefas de apoio quantitativo, como extração automatizada de medidas, estimativa de volume, acompanhamento longitudinal e inferência de características prognósticas. Na prática, essas categorias frequentemente se sobrepõem, mas mantêm exigências algorítmicas distintas, o que justifica o tratamento

metodológico separado de problemas como classificação e segmentação em estudos comparativos. (Esteva; Chou; Yeung; Naik; Madani; Mottaghi; Liu; Topol, 2021; Lee; Jun; Cho; Lee; Kim; Seo; Kim, 2017a)

No contexto radiológico, a IA tem sido utilizada principalmente como ferramenta de apoio ao fluxo de trabalho, seja como segundo leitor, seja como sistema de priorização de exames ou auxílio à caracterização de achados. Revisões recentes indicam que, em ambientes reais de imagem clínica, muitas implementações se concentram em tarefas de detecção, triagem, automação de etapas do exame e reorganização de listas de trabalho, com potencial para destacar casos positivos e reduzir parte da carga operacional dos especialistas. Esse cenário mostra que o valor da IA em imagens médicas não reside apenas em substituir a interpretação humana, mas em melhorar eficiência, consistência e capacidade de focalizar atenção diagnóstica em situações de maior risco. (Gu et al., 2025; Lawrence et al., 2025; Aggarwal; Sounderajah; Martin; Ting; Karthikesalingam; King; Ashrafian; Darzi, 2021)

Em imagem mamária, e particularmente em ultrassonografia mamária, as aplicações mais investigadas envolvem diferenciação entre lesões benignas e malignas, segmentação de massas, apoio à triagem e construção de sistemas multitarefa capazes de combinar informação global e espacial. A escolha dessa modalidade como foco de pesquisa é metodologicamente relevante porque o ultrassom reúne utilidade clínica elevada e alto grau de complexidade visual, o que o torna um ambiente adequado para testar a capacidade de generalização e discriminação de arquiteturas profundas. Nesse tipo de cenário, modelos de IA não são avaliados apenas por acurácia, mas também pela capacidade de aprender padrões úteis em presença de ruído, baixo contraste e variabilidade de aquisição. (Liu; Pian; Chen; Zhao; Liu; Meng; Zeng, 2025b; Dan; Xu; Burrows; Bissram; Stringer; Li, 2024; Guo; Lu; Qin; Fei, 2018)

2.2.3 Benefícios, limitações e desafios clínicos

Os benefícios potenciais da IA em saúde são amplamente reconhecidos e incluem aumento da precisão diagnóstica, apoio à padronização interpretativa, automação de tarefas repetitivas, melhora de eficiência operacional e ampliação da capacidade analítica sobre grandes volumes de dados. Em imagem médica, revisões de implementação em ambiente real mostram que sistemas de IA frequentemente atuam como apoio à leitura, em especial como segundo leitor, ferramenta de triagem ou mecanismo de reorganização de listas de trabalho, com indícios predominantes de melhora de eficiência em diversos estudos clínicos. Além disso, em tarefas visuais repetitivas ou suscetíveis à fadiga, a IA pode funcionar como camada adicional de vigilância diagnóstica, contribuindo para reduzir parte da variabilidade entre leitores e acelerar processos de priorização de casos. (World Health Organization, 2021; Yu; Beam; Kohane, 2018; Wenderott et al., 2024; Gu et al., 2025; Lawrence et al., 2025)

Entretanto, os benefícios técnicos não eliminam limitações substantivas. Uma das mais importantes é a dificuldade de generalização fora do ambiente de desenvolvimento. Trabalhos recentes destacam que modelos clínicos podem sofrer degradação relevante de desempenho quando submetidos a populações, instituições, equipamentos, protocolos de aquisição ou distribuições de dados diferentes das observadas no treinamento. Em medicina, esse problema é especialmente crítico porque um modelo aparentemente robusto em validação interna pode falhar em contextos reais, justamente onde segurança e confiabilidade são mais necessárias. Por isso, generalização, robustez e validade externa passaram a ser tratadas como requisitos centrais para uso responsável de IA em saúde. (Goetz et al., 2024; World Health Organization, 2021; Lekadir et al., 2025; Arun et al., 2025)

Outro desafio central envolve viés algorítmico, qualidade dos dados e representatividade das populações analisadas. Sistemas treinados em bases incompletas, enviesadas ou pouco diversas podem aprender atalhos estatísticos e produzir desempenhos desiguais entre subgrupos, ampliando disparidades já existentes na assistência. A literatura recente em IA médica enfatiza que o problema não é apenas técnico, mas também ético e regulatório: um sistema com boa métrica média pode continuar sendo inadequado se falhar sistematicamente em populações sub-representadas ou se explorar correlações espúrias sem relevância clínica. Esse ponto é especialmente importante em imagem médica, onde diferenças de equipamento, instituição, protocolo e população podem ser capturadas de forma não intencional pelo modelo. (World Health Organization, 2021; Ueda et al., 2024; Koçak et al., 2025; Yang et al., 2024)

Além disso, transparência, reprodutibilidade e padronização de relato continuam sendo gargalos importantes. A proliferação de estudos em IA médica levou ao surgimento de diretrizes específicas de reporte, justamente porque muitas publicações ainda apresentam descrições insuficientes de dados, validação, desfechos, calibração, manejo de viés e contexto de uso pretendido. Esse problema afeta diretamente a confiança clínica, pois dificulta avaliar se um modelo é realmente aplicável, seguro e reproduzível. Assim, a transição de bons resultados experimentais para adoção clínica responsável depende não apenas de avanço algorítmico, mas também de governança, desenho de estudo robusto e transparência metodológica. (Liu; Rivera; Moher; Calvert; Denniston; Spirit-ai; Group, 2020; Rivera; Liu; Chan; Denniston; Calvert; Spirit-ai; Group, 2020; Collins et al., 2024; Moons et al., 2025; Kolbinger et al., 2024)

Em síntese, a IA aplicada à saúde deve ser compreendida como tecnologia de alto potencial, mas de adoção necessariamente condicionada. Seu valor clínico emerge quando desempenho, robustez, equidade, segurança, transparência e integração ao fluxo assistencial são tratados de forma conjunta. Essa perspectiva é particularmente importante para pesquisas em imagem médica: mais do que demonstrar que um modelo alcança métricas elevadas, é preciso mostrar que ele foi desenvolvido e avaliado

sob condições que sustentem confiança científica e, idealmente, utilidade translacional. (World Health Organization, 2021; Lekadir et al., 2025; Lawrence et al., 2025)

2.3 Visão computacional em imagens médicas

2.3.1 Representação digital de imagens

Na perspectiva da visão computacional, uma imagem médica pode ser entendida como uma representação digital estruturada de propriedades físicas ou fisiológicas capturadas por um sistema de aquisição e convertidas em uma matriz de intensidades. Em imagens bidimensionais, essa matriz é composta por *pixels*; em exames volumétricos, como tomografia computadorizada e ressonância magnética, a representação se estende para *voxels*, incorporando informação espacial tridimensional. Essa distinção não é meramente formal: ela influencia o tipo de processamento aplicável, a natureza das relações espaciais modeladas e o grau de complexidade exigido dos algoritmos de análise (Suzuki, 2012; Zhou; Fan; Hansen; Johnson; Weiskopf, 2022).

Além disso, a representação digital das imagens médicas depende da modalidade considerada, de modo que contraste, resolução espacial, espessura de corte, ruído, artefatos e escala de intensidade podem variar substancialmente entre radiografia, ultrassonografia, tomografia, ressonância magnética e outras técnicas (Lee; Jun; Cho; Lee; Kim; Seo; Kim, 2017b; Zhou; Fan; Hansen; Johnson; Weiskopf, 2022). Em termos computacionais, portanto, a imagem médica não deve ser vista apenas como um arranjo visual, mas como um objeto quantitativo cuja interpretação depende da relação entre intensidade, textura, forma e contexto anatômico.

Em modalidades como a ultrassonografia, essa relação é particularmente complexa, porque a intensidade registrada não corresponde simplesmente à presença ou ausência de tecido, mas ao comportamento acústico local, sujeito a efeitos como atenuação, *speckle*, reflexão e sombreamento (Guo; Lu; Qin; Fei, 2018). Assim, a representação digital em imagens médicas carrega simultaneamente informação anatômica, funcional e instrumental, exigindo do algoritmo a capacidade de distinguir padrões biologicamente relevantes de variações introduzidas pelo próprio processo de aquisição.

Outro aspecto central da representação digital em imagens médicas é a necessidade de padronização. Como exames provenientes de diferentes instituições, equipamentos e protocolos podem apresentar distribuições de intensidade, resoluções e campos de visão distintos, a comparabilidade entre amostras não é garantida de forma nativa. Em consequência, qualquer pipeline robusto de visão computacional depende de uma etapa explícita de harmonização representacional, seja para reduzir variabilidade entre aquisições, seja para tornar os dados compatíveis com arquiteturas profundas ou fluxos radiômicos (Timmeren; Cester; Tanadini-lang; Alkadhi; Baessler, 2020;

Cobo; Menéndez fernández-miranda; Bastarrika; Torres; Campos; Alcaide; Alejo; Ciaffaglione; Fiuza-luces; Lloret iglesias, 2023). Nesse sentido, a representação digital não é um dado neutro e fixo; ela constitui o primeiro nível de abstração sobre o qual o restante do pipeline analítico será construído.

2.3.2 Pré-processamento de imagens médicas

O pré-processamento corresponde ao conjunto de operações aplicadas às imagens antes da etapa principal de modelagem, com o objetivo de reduzir ruído, padronizar a representação dos dados, melhorar a qualidade visual ou quantitativa do sinal e tornar mais estável o processo de treinamento e inferência. Em imagem médica, essa etapa é particularmente crítica porque pequenas variações no protocolo de aquisição ou reconstrução podem produzir diferenças expressivas nas distribuições de intensidade e textura, influenciando tanto a extração de atributos manuais quanto o aprendizado de representações profundas (Timmeren; Cester; Tanadini-lang; Alkadhi; Baessler, 2020; Cè; Chiriacò; Della pepa; Belfiore; Caruso; Brunese; Splendiani; Cellina, 2024; Cobo; Menéndez fernández-miranda; Bastarrika; Torres; Campos; Alcaide; Alejo; Ciaffaglione; Fiuza-luces; Lloret iglesias, 2023).

Entre as operações mais recorrentes nesse estágio, destacam-se normalização, redimensionamento, reamostragem espacial, filtragem, recorte de região de interesse, registro, padronização de contraste e tratamento de artefatos (Timmeren; Cester; Tanadini-lang; Alkadhi; Baessler, 2020; Cobo; Menéndez fernández-miranda; Bastarrika; Torres; Campos; Alcaide; Alejo; Ciaffaglione; Fiuza-luces; Lloret iglesias, 2023). Em termos científicos, o valor do pré-processamento não está apenas em “melhorar visualmente” a imagem, mas em aumentar a consistência do dado para fins analíticos. Em muitos cenários, o modelo pode ser sensível a variações irrelevantes do ponto de vista clínico, como diferenças de escala, intensidade absoluta, campo de visão ou resolução. Quando não controladas, essas variações podem induzir o algoritmo a aprender correlações espúrias, reduzindo capacidade de generalização e reprodutibilidade (Cobo; Menéndez fernández-miranda; Bastarrika; Torres; Campos; Alcaide; Alejo; Ciaffaglione; Fiuza-luces; Lloret iglesias, 2023; Timmeren; Cester; Tanadini-lang; Alkadhi; Baessler, 2020).

Por isso, trabalhos recentes destacam que o pré-processamento deve ser tratado como parte integrante do protocolo experimental, e não como etapa meramente auxiliar, especialmente em estudos que buscam comparação justa entre modelos ou extração confiável de biomarcadores de imagem (Cè; Chiriacò; Della pepa; Belfiore; Caruso; Brunese; Splendiani; Cellina, 2024; Cobo; Menéndez fernández-miranda; Bastarrika; Torres; Campos; Alcaide; Alejo; Ciaffaglione; Fiuza-luces; Lloret iglesias, 2023). No caso específico do ultrassom mamário, o pré-processamento assume relevância ainda maior devido à presença de ruído *speckle*, baixo contraste local, contor-

nos pouco definidos e grande variabilidade de aquisição. Operações como normalização, redimensionamento e preparação consistente das máscaras podem influenciar diretamente a estabilidade do treinamento e a qualidade da segmentação ou da classificação subsequente (Guo; Lu; Qin; Fei, 2018).

Entretanto, a literatura também alerta que o pré-processamento excessivo ou inadequado pode modificar padrões clinicamente relevantes e comprometer a validade do experimento. Em consequência, o desenho dessa etapa deve buscar equilíbrio entre padronização e preservação da informação diagnóstica, respeitando as propriedades físicas da modalidade de imagem analisada (Cobo; Menéndez fernández-miranda; Bastarrika; Torres; Campos; Alcaide; Alejo; Ciaffaglione; Fiuza-luces; Lloret iglesias, 2023; Timmeren; Cester; Tanadini-lang; Alkadhi; Baessler, 2020).

2.3.3 Extração e aprendizado de características

Historicamente, a análise computacional de imagens médicas foi fortemente baseada na extração manual ou semiautomática de características (*features*) projetadas por especialistas. Nesse paradigma, atributos como intensidade, histograma, textura, forma, borda, relações espaciais e descritores estatísticos eram calculados a partir da imagem ou da região de interesse e, em seguida, utilizados por classificadores tradicionais. Esse tipo de abordagem permanece relevante, especialmente no domínio da radiômica, onde a extração sistemática de atributos quantitativos busca representar propriedades fenotípicas das lesões de maneira interpretável e reprodutível (Timmeren; Cester; Tanadini-lang; Alkadhi; Baessler, 2020; Cè; Chiriacò; Della pepa; Belfiore; Caruso; Brunese; Splendiani; Cellina, 2024).

Em geral, essas características manuais apresentam vantagem em termos de transparência conceitual, mas sua eficácia depende da qualidade da segmentação, da estabilidade do pré-processamento e da adequação do conjunto de atributos ao problema clínico específico (Timmeren; Cester; Tanadini-lang; Alkadhi; Baessler, 2020; Cobo; Menéndez fernández-miranda; Bastarrika; Torres; Campos; Alcaide; Alejo; Ciaffaglione; Fiuza-luces; Lloret iglesias, 2023). Com a consolidação do *Deep Learning*, passou a predominar um paradigma distinto: em vez de definir previamente quais atributos devem ser extraídos, redes neurais profundas aprendem representações hierárquicas diretamente dos dados, ajustando seus filtros e pesos durante o treinamento (Lee; Jun; Cho; Lee; Kim; Seo; Kim, 2017b).

Em redes convolucionais, camadas iniciais tendem a capturar padrões locais de menor complexidade, como bordas, contrastes e texturas elementares, enquanto camadas mais profundas podem representar estruturas progressivamente mais abstratas e semanticamente relevantes. Essa capacidade de aprendizado hierárquico reduziu a dependência de engenharia manual de atributos e tornou possível construir pipelines *end-to-end* para classificação, detecção e segmentação, particularmente van-

tajosos em problemas de alta variabilidade visual, como ocorre em imagens médicas (Lee; Jun; Cho; Lee; Kim; Seo; Kim, 2017b; Lambin; Leijenaar; Deist; Peerlings; Jong; Timmeren; Sanduleanu; Larue; Even; Jochems; Wijk; Woodruff; Soest; Lustberg; Roelofs; Elmpt; Dekker; Mottaghy; Wildberger; Walsh, 2017).

Ainda assim, a oposição entre atributos manuais e atributos aprendidos não deve ser tratada como absoluta. A literatura recente mostra que abordagens híbridas, combinando radiômica tradicional e representações profundas, podem ser úteis em determinados cenários, sobretudo quando se busca conciliar desempenho preditivo e interpretabilidade (Lambin; Leijenaar; Deist; Peerlings; Jong; Timmeren; Sanduleanu; Larue; Even; Jochems; Wijk; Woodruff; Soest; Lustberg; Roelofs; Elmpt; Dekker; Mottaghy; Wildberger; Walsh, 2017; Cè; Chiriacò; Della pepa; Belfiore; Caruso; Brunese; Splendiani; Cellina, 2024). Além disso, o aprendizado de características em saúde enfrenta desafios próprios, como escassez de dados rotulados, heterogeneidade entre instituições, sensibilidade a vieses de aquisição e necessidade de plausibilidade clínica. Por essa razão, a extração ou o aprendizado de características deve ser compreendido como uma etapa metodologicamente crítica, na qual a escolha entre descritores manuais, representações profundas ou estratégias híbridas precisa ser orientada não apenas por desempenho empírico, mas também por robustez, generalização e capacidade de sustentar inferências clinicamente relevantes (Cobo; Menéndez fernández-miranda; Bastarrika; Torres; Campos; Alcaide; Alejo; Ciaffaglione; Fiuza-luces; Lloret iglesias, 2023; Lee; Jun; Cho; Lee; Kim; Seo; Kim, 2017b).

2.4 Redes neurais convolucionais

2.4.1 Conceitos fundamentais de CNNs

As Redes Neurais Convolucionais (*Convolutional Neural Networks* — CNNs) constituem uma classe de modelos de aprendizado profundo especialmente adequada para dados com estrutura espacial local, como imagens bidimensionais, volumes tridimensionais e sequências com dependência topológica. Sua formulação baseia-se na hipótese de que padrões discriminativos relevantes podem ser descritos por operadores locais compartilhados ao longo do domínio de entrada, reduzindo substancialmente o número de parâmetros em comparação com redes totalmente conectadas e permitindo o aprendizado de representações hierárquicas (**???**).

Considere uma imagem de entrada representada por um tensor

$$\mathbf{X} \in \mathbb{R}^{H \times W \times C}, \tag{1}$$

em que H e W denotam altura e largura, respectivamente, e C representa o número

de canais. Em uma CNN, o objetivo é aprender uma função

$$f_{\boldsymbol{\theta}} : \mathbb{R}^{H \times W \times C} \to \mathcal{Y}, \tag{2}$$

parametrizada por $\boldsymbol{\theta}$, que mapeie a entrada para um espaço de saída $\mathcal{Y}$, o qual pode corresponder a classes, máscaras de segmentação ou representações intermediárias. O treinamento consiste em resolver um problema de otimização do tipo

$$\boldsymbol{\theta}^{\star} = \arg\min_{\boldsymbol{\theta}} \frac{1}{N} \sum_{i=1}^{N} \mathcal{L}\big(f_{\boldsymbol{\theta}}(\mathbf{X}_i), y_i\big) + \lambda \Omega(\boldsymbol{\theta}), \tag{3}$$

em que $\mathcal{L}$ é a função de perda, $\Omega(\boldsymbol{\theta})$ é um termo de regularização e $\lambda \geq 0$ controla a penalização da complexidade do modelo.

O princípio central das CNNs reside em três ideias fundamentais: *conectividade local*, *compartilhamento de pesos* e *equivariança à translação*. A conectividade local implica que cada unidade em uma camada convolucional depende apenas de uma vizinhança espacial limitada da camada anterior. O compartilhamento de pesos significa que um mesmo filtro é aplicado em diferentes posições da imagem, produzindo detectores reutilizáveis para padrões como bordas, texturas, contornos e estruturas mais complexas. Já a equivariança à translação pode ser expressa, em termos ideais, pela relação

$$f(T_{\boldsymbol{\delta}} \mathbf{X}) = T_{\boldsymbol{\delta}} f(\mathbf{X}), \tag{4}$$

em que $T_{\boldsymbol{\delta}}$ representa um operador de translação espacial. Em outras palavras, se a entrada é deslocada, a resposta do mapa de ativação também se desloca de forma consistente.

Outro conceito essencial é o de *campo receptivo*. Seja $r^{(l)}$ o tamanho efetivo do campo receptivo de uma unidade na camada l. Para uma pilha de camadas convolucionais com *kernel* de tamanho k_l e *stride* s_l, o crescimento do campo receptivo pode ser descrito recursivamente por

$$r^{(l)} = r^{(l-1)} + (k_l - 1) \prod_{t=1}^{l-1} s_t, \tag{5}$$

com condição inicial $r^{(1)} = k_1$. Esse formalismo ajuda a entender por que camadas profundas conseguem capturar contexto cada vez mais amplo: as primeiras camadas tendem a detectar padrões locais simples, enquanto camadas mais profundas integram informação semântica e estrutural em escalas maiores.

Em termos probabilísticos, uma CNN pode ser interpretada como uma máquina de aproximação universal especializada em dados estruturados espacialmente, cujo viés indutivo é mais adequado para imagens do que arquiteturas densas. Em aplica-

ções médicas, essa propriedade é particularmente vantajosa porque lesões, tecidos e padrões anatômicos frequentemente apresentam regularidades locais e composição hierárquica, tornando as CNNs naturalmente compatíveis com problemas de classificação, detecção e segmentação em imagem biomédica (**?**Yu; Zhou; Wang; Zhang, 2022).

2.4.2 Camadas convolucionais, pooling e funções de ativação

A camada convolucional é o bloco elementar das CNNs. Seja $\mathbf{K}^{(m)} \in \mathbb{R}^{k_h \times k_w \times C}$ o m-ésimo filtro convolucional e $b_m \in \mathbb{R}$ seu viés associado. O mapa de características produzido por esse filtro pode ser expresso por

$$Y_{i,j,m} = b_m + \sum_{u=0}^{k_h-1} \sum_{v=0}^{k_w-1} \sum_{c=1}^{C} K_{u,v,c}^{(m)} X_{i+u,j+v,c}, \tag{6}$$

onde, por simplicidade, assume-se indexação sem dilatação e com preenchimento apropriado. Na prática, em muitas bibliotecas, a operação denominada “convolução” corresponde tecnicamente a uma correlação cruzada; ainda assim, a nomenclatura convolucional permanece consagrada.

Quando se utilizam *padding* p_h, p_w e *stride* s_h, s_w, as dimensões de saída são dadas por

$$H_{\text{out}} = \left\lfloor \frac{H + 2p_h - k_h}{s_h} \right\rfloor + 1, \qquad W_{\text{out}} = \left\lfloor \frac{W + 2p_w - k_w}{s_w} \right\rfloor + 1. \tag{7}$$

Se M filtros são aplicados, a saída da camada terá dimensão

$$\mathbf{Y} \in \mathbb{R}^{H_{\text{out}} \times W_{\text{out}} \times M}. \tag{8}$$

O número de parâmetros treináveis de uma camada convolucional é substancialmente menor do que o de uma camada densa equivalente. Para M filtros, esse número é

$$P_{\text{conv}} = M\,(k_h k_w C + 1), \tag{9}$$

enquanto uma camada totalmente conectada que mapeasse uma entrada achatada de dimensão HWC para M saídas exigiria

$$P_{\text{fc}} = M\,(HWC + 1). \tag{10}$$

Essa diferença explica parte importante da eficiência paramétrica das CNNs.

Além da convolução padrão, diversas variantes são relevantes. Em convoluções dilatadas, a taxa de dilatação d amplia o campo receptivo sem aumento proporcional

do número de parâmetros. A operação pode ser escrita como

$$Y_{i,j,m} = b_m + \sum_{u=0}^{k_h-1} \sum_{v=0}^{k_w-1} \sum_{c=1}^{C} K_{u,v,c}^{(m)} X_{i+du,j+dv,c}. \tag{11}$$

Esse mecanismo é particularmente útil em segmentação, quando se deseja agregar contexto global preservando resolução espacial.

Após a convolução, aplica-se tipicamente uma função de ativação não linear

$$\mathbf{Z} = \phi(\mathbf{Y}), \tag{12}$$

que permite à rede modelar funções complexas e não apenas transformações lineares compostas. Entre as funções mais empregadas, destaca-se a ReLU (*Rectified Linear Unit*),

$$\phi(x) = \max(0, x), \tag{13}$$

amplamente utilizada por sua simplicidade computacional e por reduzir o problema de gradientes saturados em comparação com ativações sigmoides (**?**). Outras alternativas incluem a Leaky ReLU,

$$\phi(x) = \begin{cases} x, & x \geq 0, \\ \alpha x, & x < 0, \end{cases} \qquad \alpha \in (0, 1), \tag{14}$$

a sigmoide

$$\phi(x) = \frac{1}{1 + e^{-x}}, \tag{15}$$

e a tangente hiperbólica

$$\phi(x) = \tanh(x). \tag{16}$$

Em classificação multiclasse, a camada final costuma empregar a função *softmax*,

$$\hat{p}_k = \frac{e^{z_k}}{\sum_{j=1}^{K} e^{z_j}}, \qquad k = 1, \ldots, K, \tag{17}$$

de modo que $\hat{p}_k$ possa ser interpretada como probabilidade estimada da classe k.

As camadas de *pooling* são usadas para reduzir dimensionalidade espacial, aumentar robustez a pequenas variações locais e controlar custo computacional. No *max pooling*, para uma janela $\mathcal{W}_{i,j}$ centrada na posição (i, j), a saída é

$$P_{i,j,c} = \max_{(u,v) \in \mathcal{W}_{i,j}} Z_{u,v,c}, \tag{18}$$

enquanto no *average pooling*,

$$P_{i,j,c} = \frac{1}{|\mathcal{W}_{i,j}|} \sum_{(u,v)\in\mathcal{W}_{i,j}} Z_{u,v,c}. \tag{19}$$

Uma operação amplamente empregada em classificadores modernos é o *global average pooling* (GAP), que resume cada canal em um único escalar:

$$g_c = \frac{1}{HW} \sum_{i=1}^{H} \sum_{j=1}^{W} Z_{i,j,c}. \tag{20}$$

O GAP reduz drasticamente o número de parâmetros em comparação com camadas densas volumosas e preserva uma interpretação mais direta da ativação de cada canal como detector de padrão global.

Em conjunto, convolução, ativação e *pooling* compõem o núcleo funcional de uma CNN. O encadeamento sucessivo dessas operações produz uma transformação do tipo

$$\mathbf{X}^{(l+1)} = \mathcal{P}^{(l)}\big(\phi^{(l)}\big(\mathcal{C}^{(l)}(\mathbf{X}^{(l)}; \mathbf{W}^{(l)}, \mathbf{b}^{(l)})\big)\big)\,, \tag{21}$$

em que $\mathcal{C}^{(l)}$ representa a operação convolucional, $\phi^{(l)}$ a ativação e $\mathcal{P}^{(l)}$ uma eventual operação de *pooling*. Essa formulação destaca o caráter modular das CNNs e sua capacidade de construir representações progressivamente mais abstratas.

2.4.3 Regularização, batch normalization e dropout

Modelos profundos, especialmente em contextos com dados limitados, estão sujeitos a sobreajuste (*overfitting*), isto é, excelente desempenho no conjunto de treinamento e baixa capacidade de generalização. Matematicamente, pode-se dizer que o objetivo prático não é apenas minimizar o risco empírico

$$\hat{\mathcal{R}}(\boldsymbol{\theta}) = \frac{1}{N} \sum_{i=1}^{N} \mathcal{L}(f_{\boldsymbol{\theta}}(\mathbf{X}_i), y_i), \tag{22}$$

mas aproximar o risco esperado

$$\mathcal{R}(\boldsymbol{\theta}) = \mathbb{E}_{(\mathbf{X},y)\sim p_{\text{data}}}\left[\mathcal{L}(f_{\boldsymbol{\theta}}(\mathbf{X}), y)\right]. \tag{23}$$

Como p_{data} é desconhecida, torna-se necessário empregar estratégias de regularização que controlem a complexidade do modelo e tornem o aprendizado mais estável.

Uma das formas mais clássicas de regularização é a penalização L_2, também co-

nhecida como *weight decay*. Nesse caso, a função objetivo torna-se

$$\mathcal{J}(\boldsymbol{\theta}) = \frac{1}{N}\sum_{i=1}^{N}\mathcal{L}(f_{\boldsymbol{\theta}}(\mathbf{X}_i), y_i) + \lambda\|\boldsymbol{\theta}\|_2^2, \tag{24}$$

em que

$$\|\boldsymbol{\theta}\|_2^2 = \sum_j \theta_j^2. \tag{25}$$

A penalização desencoraja pesos excessivamente grandes, induzindo soluções mais suaves e menos sensíveis a perturbações do conjunto de treinamento. Alternativamente, a regularização L_1

$$\mathcal{J}(\boldsymbol{\theta}) = \frac{1}{N}\sum_{i=1}^{N}\mathcal{L}(f_{\boldsymbol{\theta}}(\mathbf{X}_i), y_i) + \lambda\|\boldsymbol{\theta}\|_1 \tag{26}$$

favorece esparsidade,

$$\|\boldsymbol{\theta}\|_1 = \sum_j |\theta_j|, \tag{27}$$

embora seja menos comum como primeira escolha em CNNs profundas de visão.

Outro mecanismo fundamental é a *Batch Normalization* (BN), proposta para reduzir a instabilidade associada às distribuições internas das ativações e permitir taxas de aprendizado mais agressivas (**?**). Dada uma ativação escalar x em um mini-lote $\mathcal{B} = \{x_1, \ldots, x_m\}$, definem-se a média e a variância do lote:

$$\mu_{\mathcal{B}} = \frac{1}{m}\sum_{i=1}^{m} x_i, \qquad \sigma_{\mathcal{B}}^2 = \frac{1}{m}\sum_{i=1}^{m}(x_i - \mu_{\mathcal{B}})^2. \tag{28}$$

A ativação normalizada é então dada por

$$\hat{x}_i = \frac{x_i - \mu_{\mathcal{B}}}{\sqrt{\sigma_{\mathcal{B}}^2 + \varepsilon}}, \tag{29}$$

e a saída final da BN é

$$y_i = \gamma\hat{x}_i + \beta, \tag{30}$$

onde γ e β são parâmetros aprendíveis que restauram capacidade representacional. Em notação vetorial para mapas de ativação, a normalização é aplicada canal a canal. Durante a inferência, utilizam-se estimativas móveis da média e variância globais.

A BN exerce, ao mesmo tempo, efeito estabilizador e regularizador. Ao normalizar ativações intermediárias, reduz-se a sensibilidade do treinamento à escala dos pesos e melhora-se o fluxo de gradientes. Em termos qualitativos, isso permite redes mais profundas e convergência mais rápida. Ainda assim, seu comportamento pode degradar em lotes extremamente pequenos, situação relativamente comum em imagens

médicas de alta resolução ou em modelos 3D.

O *dropout* é outra estratégia clássica de regularização, introduzida para evitar co-adaptação excessiva entre neurônios (**?**). Durante o treinamento, cada ativação h_j é multiplicada por uma variável aleatória de Bernoulli:

$$\tilde{h}_j = m_j h_j, \qquad m_j \sim \text{Bernoulli}(p), \tag{31}$$

em que p é a probabilidade de manter a unidade ativa. Em implementações modernas com *inverted dropout*, a ativação é reescalada durante o treinamento:

$$\tilde{h}_j = \frac{m_j}{p} h_j, \tag{32}$$

de modo que

$$\mathbb{E}[\tilde{h}_j] = h_j. \tag{33}$$

Assim, não é necessário reescalar explicitamente na inferência. Do ponto de vista estatístico, o *dropout* pode ser interpretado como uma forma aproximada de combinação de múltiplas sub-redes, o que melhora robustez e reduz variância.

Outras estratégias de regularização frequentemente empregadas em CNNs incluem *data augmentation*, *early stopping*, suavização de rótulos (*label smoothing*) e técnicas de mistura de amostras, como *mixup*. Em particular, o *early stopping* consiste em interromper o treinamento quando a perda de validação deixa de melhorar, o que pode ser formalizado como um critério de parada baseado em

$$\mathcal{L}_{\text{val}}^{(t+\tau)} \geq \min_{s \leq t} \mathcal{L}_{\text{val}}^{(s)} \quad \text{por } \tau \text{ épocas consecutivas.} \tag{34}$$

Em conjunto, essas estratégias reduzem a discrepância entre erro de treinamento e erro de generalização, aspecto crítico em problemas médicos com bases moderadas ou pequenas.

2.4.4 Transfer learning e fine-tuning

Em visão computacional médica, uma limitação recorrente é a escassez de conjuntos de dados extensos e completamente anotados. O *transfer learning* surge como estratégia para mitigar esse problema ao reutilizar conhecimento adquirido em um domínio-fonte para beneficiar uma tarefa-alvo relacionada (**?**). Formalmente, sejam um domínio-fonte

$$\mathcal{D}_S = \{\mathcal{X}_S, P_S(\mathbf{X})\} \tag{35}$$

e uma tarefa-fonte

$$\mathcal{T}_S = \{\mathcal{Y}_S, f_S(\cdot)\}, \tag{36}$$

assim como um domínio-alvo

$$\mathcal{D}_T = \{\mathcal{X}_T, P_T(\mathbf{X})\} \tag{37}$$

e uma tarefa-alvo

$$\mathcal{T}_T = \{\mathcal{Y}_T, f_T(\cdot)\}. \tag{38}$$

O objetivo do *transfer learning* é melhorar a função preditiva f_T em $\mathcal{D}_T$ usando conhecimento proveniente de $\mathcal{D}_S$ e $\mathcal{T}_S$, mesmo quando

$$\mathcal{D}_S \neq \mathcal{D}_T \quad \text{ou} \quad \mathcal{T}_S \neq \mathcal{T}_T. \tag{39}$$

Na prática, em CNNs para imagens médicas, o procedimento mais comum consiste em inicializar os pesos de uma rede com parâmetros pré-treinados em grandes bases naturais, como ImageNet, e depois adaptá-los à tarefa clínica. Seja a rede decomposta em um extrator de características $\phi(\mathbf{X}; \boldsymbol{\theta}_f)$ e uma cabeça de predição $g(\cdot; \boldsymbol{\theta}_h)$. O modelo final pode ser escrito como

$$f(\mathbf{X}; \boldsymbol{\theta}) = g(\phi(\mathbf{X}; \boldsymbol{\theta}_f); \boldsymbol{\theta}_h), \qquad \boldsymbol{\theta} = (\boldsymbol{\theta}_f, \boldsymbol{\theta}_h). \tag{40}$$

Em uma estratégia de extração fixa de características, mantém-se

$$\boldsymbol{\theta}_f = \boldsymbol{\theta}_f^{(0)} \tag{41}$$

congelado, e otimiza-se apenas a cabeça:

$$\boldsymbol{\theta}_h^\star = \arg\min_{\boldsymbol{\theta}_h} \frac{1}{N} \sum_{i=1}^{N} \mathcal{L}\big(g(\phi(\mathbf{X}_i; \boldsymbol{\theta}_f^{(0)}); \boldsymbol{\theta}_h), y_i\big). \tag{42}$$

Essa abordagem é útil quando o conjunto-alvo é pequeno e se deseja reduzir risco de sobreajuste.

No *fine-tuning*, por outro lado, parte ou todos os pesos do extrator são atualizados:

$$(\boldsymbol{\theta}_f^\star, \boldsymbol{\theta}_h^\star) = \arg\min_{\boldsymbol{\theta}_f, \boldsymbol{\theta}_h} \frac{1}{N} \sum_{i=1}^{N} \mathcal{L}\big(g(\phi(\mathbf{X}_i; \boldsymbol{\theta}_f); \boldsymbol{\theta}_h), y_i\big). \tag{43}$$

Frequentemente, utiliza-se uma taxa de aprendizado diferenciada para a base pré-treinada e para a nova cabeça classificadora:

$$\eta_f < \eta_h, \tag{44}$$

refletindo o fato de que se deseja adaptar lentamente as representações gerais

aprendidas no domínio-fonte e ajustar mais agressivamente as camadas recém-inicializadas.

Uma prática comum consiste em descongelar apenas as últimas L camadas do extrator, mantendo as anteriores fixas. Seja

$$\boldsymbol{\theta}_f = (\boldsymbol{\theta}_f^{(1)}, \ldots, \boldsymbol{\theta}_f^{(B)}), \tag{45}$$

com B blocos. Um *fine-tuning* parcial pode ser representado por

$$\boldsymbol{\theta}_f^{(b)} = \boldsymbol{\theta}_f^{(b,0)} \quad \text{para } b \leq B - L, \tag{46}$$

e

$$\boldsymbol{\theta}_f^{(b)} \text{ livre para otimização} \quad \text{para } b > B - L. \tag{47}$$

Esse compromisso busca preservar atributos genéricos de baixo nível, como detectores de borda e textura, ao mesmo tempo em que adapta representações de alto nível às especificidades do domínio médico.

O sucesso do *transfer learning* depende da proximidade entre os domínios-fonte e alvo, do tamanho da base-alvo, da profundidade da rede e da estratégia de adaptação adotada. Embora imagens naturais e imagens médicas pertençam a domínios distintos, diversos estudos mostram que filtros iniciais aprendidos em grandes bases podem permanecer úteis por capturarem estruturas elementares relativamente universais, como gradientes, contornos e texturas locais (**?**). Em aplicações médicas, isso é particularmente valioso porque reduz custo de treinamento, acelera convergência e melhora estabilidade em bases limitadas.

Do ponto de vista da otimização, o *fine-tuning* pode ser interpretado como um problema de adaptação de parâmetros com condição inicial informativa:

$$\boldsymbol{\theta}^{(0)} = \boldsymbol{\theta}_{\text{pretrained}}, \tag{48}$$

em contraste com a inicialização aleatória

$$\boldsymbol{\theta}^{(0)} \sim \mathcal{P}_{\text{init}}. \tag{49}$$

Essa mudança altera significativamente a paisagem de treinamento explorada pelo algoritmo, geralmente levando a mínimos mais úteis sob escassez de dados. Por essa razão, *transfer learning* e *fine-tuning* tornaram-se práticas quase padrão em tarefas de classificação e segmentação em imagem médica, especialmente quando o objetivo é combinar desempenho, estabilidade e viabilidade computacional (**??**).

2.5 Classificação de imagens com Deep Learning

2.5.1 Formulação da tarefa de classificação

A classificação de imagens com *Deep Learning* pode ser formalizada como um problema de aprendizado supervisionado no qual se deseja aprender uma função

$$f_{\boldsymbol{\theta}} : \mathcal{X} \to \mathcal{Y}, \tag{50}$$

em que $\mathcal{X}$ denota o espaço de imagens e $\mathcal{Y}$ o espaço de rótulos. Em um problema multiclasse com K categorias, como no caso de imagens de ultrassom mamário rotuladas como *normal*, *benigna* e *maligna*, tem-se

$$\mathcal{Y} = \{1, 2, \ldots, K\}. \tag{51}$$

Dado um conjunto de treinamento

$$\mathcal{D}_{\text{train}} = \{(\mathbf{X}_i, y_i)\}_{i=1}^{N}, \qquad \mathbf{X}_i \in \mathbb{R}^{H \times W \times C}, \quad y_i \in \mathcal{Y}, \tag{52}$$

o objetivo consiste em estimar os parâmetros $\boldsymbol{\theta}$ de forma que $f_{\boldsymbol{\theta}}$ generalize bem para novas amostras extraídas da mesma distribuição populacional.

Em uma rede neural profunda para classificação, a imagem de entrada $\mathbf{X}$ é transformada em uma representação latente $\mathbf{h}$ por um extrator de características

$$\mathbf{h} = \phi(\mathbf{X}; \boldsymbol{\theta}_f), \tag{53}$$

seguido de uma cabeça classificadora

$$\mathbf{z} = g(\mathbf{h}; \boldsymbol{\theta}_c), \tag{54}$$

onde

$$\mathbf{z} = (z_1, z_2, \ldots, z_K) \in \mathbb{R}^K \tag{55}$$

corresponde aos *logits* do modelo. A probabilidade predita para a classe k é tipicamente obtida pela função *softmax*:

$$\hat{p}_k = \frac{\exp(z_k)}{\sum_{j=1}^{K} \exp(z_j)}, \qquad k = 1, \ldots, K, \tag{56}$$

satisfazendo

$$\hat{p}_k \in [0, 1], \qquad \sum_{k=1}^{K} \hat{p}_k = 1. \tag{57}$$

A classe predita é então definida por

$$\hat{y} = \arg\max_{k \in \{1,\ldots,K\}} \hat{p}_k. \tag{58}$$

Em notação vetorial, se o rótulo verdadeiro for representado por um vetor *one-hot*

$$\mathbf{y} = (y_1, \ldots, y_K), \qquad y_k \in \{0,1\}, \qquad \sum_{k=1}^{K} y_k = 1, \tag{59}$$

a função de perda mais usual para classificação multiclasse é a entropia cruzada categórica:

$$\mathcal{L}_{\mathsf{CE}}(\mathbf{y}, \hat{\mathbf{p}}) = -\sum_{k=1}^{K} y_k \log(\hat{p}_k). \tag{60}$$

Para um conjunto com N amostras, o problema de otimização pode ser escrito como

$$\boldsymbol{\theta}^\star = \arg\min_{\boldsymbol{\theta}} \frac{1}{N} \sum_{i=1}^{N} \mathcal{L}_{\mathsf{CE}}(\mathbf{y}_i, \hat{\mathbf{p}}_i) + \lambda \Omega(\boldsymbol{\theta}), \tag{61}$$

onde $\Omega(\boldsymbol{\theta})$ representa um termo de regularização, como penalização L_2, e $\lambda \geq 0$ controla sua intensidade.

Em problemas binários, com $\mathcal{Y} = \{0,1\}$, a formulação pode ser simplificada por meio da função sigmoide

$$\hat{p} = \sigma(z) = \frac{1}{1 + \exp(-z)}, \tag{62}$$

e da entropia cruzada binária

$$\mathcal{L}_{\mathsf{BCE}}(y, \hat{p}) = -y \log(\hat{p}) - (1-y) \log(1-\hat{p}). \tag{63}$$

No presente contexto, contudo, a formulação multiclasse é mais adequada para a tarefa de classificação de imagens de ultrassom mamário quando se consideram simultaneamente as classes normal, benigna e maligna.

Do ponto de vista probabilístico, a classificação supervisionada pode ser interpretada como a estimação de

$$P(Y = k \mid \mathbf{X}), \tag{64}$$

de forma que o classificador aproximado produza

$$\hat{p}_k \approx P(Y = k \mid \mathbf{X}). \tag{65}$$

A qualidade dessa aproximação depende não apenas da arquitetura, mas também da distribuição dos dados, da qualidade dos rótulos, do balanceamento entre classes,

do protocolo de validação e da compatibilidade entre o domínio de treinamento e o domínio de aplicação.

Outro aspecto importante é a distinção entre classificação em nível de imagem, em nível de lesão e em nível de paciente. Seja $\mathbf{X}_{ij}$ a j-ésima imagem do paciente i. Um modelo treinado em nível de imagem estima

$$\hat{y}_{ij} = f_{\boldsymbol{\theta}}(\mathbf{X}_{ij}), \tag{66}$$

enquanto uma inferência em nível de paciente pode exigir uma função de agregação

$$\hat{y}_i = A\big(\hat{y}_{i1}, \hat{y}_{i2}, \ldots, \hat{y}_{in_i}\big), \tag{67}$$

onde $A(\cdot)$ pode corresponder, por exemplo, a votação majoritária, média de probabilidades ou regra clínica específica. Essa distinção é relevante em imagem médica porque diferentes níveis de granularidade alteram a interpretação do erro e a validade clínica da decisão automatizada.

2.5.2 Desafios em classificação de imagens médicas

A classificação de imagens médicas impõe desafios substancialmente mais complexos do que muitos problemas clássicos de visão computacional em imagens naturais. Um primeiro desafio decorre da própria natureza do sinal médico: a diferença entre classes pode ser sutil, localizada e fortemente dependente de contexto anatômico. Em termos matemáticos, isso significa que a distribuição condicional

$$P(\mathbf{X} \mid Y = k) \tag{68}$$

de diferentes classes pode apresentar alta sobreposição em regiões relevantes do espaço de atributos, dificultando a separação por fronteiras de decisão simples. Em um cenário ideal, o classificador busca uma regra

$$\delta(\mathbf{X}) = \arg\max_k P(Y = k \mid \mathbf{X}), \tag{69}$$

mas, em presença de ruído, ambiguidades visuais e amostras limitadas, a estimação dessa regra torna-se instável.

Outro desafio central é o desbalanceamento de classes. Seja N_k o número de amostras da classe k. Em muitos conjuntos de imagem médica, ocorre

$$N_a \neq N_b \neq \ldots \neq N_K, \tag{70}$$

e frequentemente

$$N_{\text{maligna}} \ll N_{\text{benigna}} \quad \text{ou} \quad N_{\text{positiva}} \ll N_{\text{negativa}}. \tag{71}$$

Nessas condições, a minimização da perda média não ponderada pode induzir o modelo a privilegiar a classe majoritária. Uma forma de corrigir esse efeito é utilizar pesos de classe:

$$\mathcal{L}_{\text{WCE}} = -\sum_{k=1}^{K} w_k y_k \log(\hat{p}_k), \tag{72}$$

onde w_k é um peso associado à classe k, frequentemente escolhido como função inversa de sua frequência, por exemplo

$$w_k \propto \frac{1}{N_k}. \tag{73}$$

A escassez de dados rotulados também representa uma limitação severa. Em termos estatísticos, quando o número de parâmetros do modelo, denotado por P, é muito grande em relação ao número de amostras N, isto é,

$$P \gg N, \tag{74}$$

o risco de sobreajuste cresce substancialmente. Embora redes profundas modernas apresentem bom comportamento mesmo em regimes superparametrizados, o problema permanece crítico em saúde devido ao alto custo de anotação especializada e à frequência limitada de certas condições clínicas. Isso explica a ampla adoção de *transfer learning*, *fine-tuning*, *data augmentation* e regularização explícita em pipelines de classificação médica.

Outro problema recorrente é a variabilidade entre domínios, frequentemente descrita como *domain shift*. Seja $P_{\text{train}}(\mathbf{X}, Y)$ a distribuição do conjunto de treinamento e $P_{\text{test}}(\mathbf{X}, Y)$ a distribuição do conjunto de teste ou de implantação real. Em muitos cenários clínicos,

$$P_{\text{train}}(\mathbf{X}, Y) \neq P_{\text{test}}(\mathbf{X}, Y), \tag{75}$$

devido a diferenças de equipamento, protocolo de aquisição, população, instituição, qualidade de imagem ou anotação. Isso afeta diretamente a generalização do classificador, pois o modelo pode aprender correlações específicas do ambiente de treinamento em vez de padrões anatomicamente relevantes.

Em ultrassonografia mamária, esses problemas se intensificam. Além da variabilidade entre equipamentos e operadores, há ruído speckle, baixo contraste, contornos imprecisos, sombreamento acústico e alta dependência do plano de aquisição. Assim,

a imagem observada pode ser modelada, de forma abstrata, como

$$\mathbf{X} = \mathcal{A}(\mathbf{S}, \boldsymbol{\eta}, \boldsymbol{\psi}), \tag{76}$$

onde $\mathbf{S}$ representa a estrutura anatômica subjacente, $\boldsymbol{\eta}$ representa ruído e artefatos, e $\boldsymbol{\psi}$ representa parâmetros de aquisição e operador. O classificador ideal deveria ser sensível às variações de $\mathbf{S}$ relevantes ao diagnóstico e robusto às perturbações em $\boldsymbol{\eta}$ e $\boldsymbol{\psi}$. Na prática, alcançar essa invariância parcial é um dos principais desafios do aprendizado profundo em ultrassom médico.

Há ainda o problema da qualidade e confiabilidade dos rótulos. Em classificação médica, o rótulo y_i pode derivar de laudo radiológico, consenso clínico, achado histopatológico ou protocolo institucional. Em algumas situações, os rótulos observados $\tilde{y}_i$ não coincidem perfeitamente com os rótulos verdadeiros y_i, podendo-se modelar ruído de anotação como

$$P(\tilde{Y} \neq Y) > 0. \tag{77}$$

Esse ruído pode degradar o aprendizado, especialmente quando incide em classes raras ou visualmente ambíguas.

Por fim, um desafio adicional reside no fato de que boa performance numérica nem sempre implica utilidade clínica. Um classificador pode maximizar uma métrica global e, ainda assim, falhar nos casos de maior relevância assistencial. Assim, o problema de classificação em imagens médicas deve ser concebido como uma tarefa de otimização multicritério, na qual se busca simultaneamente desempenho discriminativo, robustez, calibração, interpretabilidade e viabilidade operacional.

2.5.3 Métricas de avaliação para classificação

A avaliação de classificadores em imagem médica exige um conjunto de métricas capaz de refletir não apenas desempenho global, mas também comportamento por classe, custos assimétricos de erro e capacidade discriminativa em diferentes limiares de decisão. Para uma tarefa binária, define-se a matriz de confusão por meio das quantidades:

- Verdadeiros Positivos (*True Positives*, TP),
- Verdadeiros Negativos (*True Negatives*, TN),
- Falsos Positivos (*False Positives*, FP),
- Falsos Negativos (*False Negatives*, FN).

Essas quantidades satisfazem

$$N = TP + TN + FP + FN. \tag{78}$$

A *accuracy* é definida por

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}, \tag{79}$$

e representa a proporção global de acertos. Embora amplamente utilizada, essa métrica pode ser enganosa em cenários desbalanceados. Por exemplo, se a prevalência da classe positiva for muito baixa, um modelo trivial que sempre prediz a classe negativa pode obter alta acurácia sem qualquer utilidade clínica.

A *precision*, também chamada de valor preditivo positivo, é dada por

$$\text{Precision} = \frac{TP}{TP + FP}, \tag{80}$$

e mede a proporção de predições positivas que estão corretas. Já o *recall*, ou sensibilidade, é definido por

$$\text{Recall} = \text{Sensitivity} = \frac{TP}{TP + FN}, \tag{81}$$

quantificando a capacidade de recuperar corretamente os casos positivos. Em contextos oncológicos, essa métrica é particularmente importante, pois falsos negativos podem estar associados a atraso diagnóstico.

A especificidade, por sua vez, mede a capacidade de reconhecer corretamente os negativos:

$$\text{Specificity} = \frac{TN}{TN + FP}. \tag{82}$$

Enquanto a sensibilidade responde à pergunta "quantos casos positivos foram detectados?", a especificidade responde a "quantos casos negativos foram corretamente descartados?". Em aplicações clínicas, ambas são essenciais e geralmente apresentam relação de compromisso.

O $F1$-*score* é a média harmônica entre *precision* e *recall*:

$$F_1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}. \tag{83}$$

Essa métrica é útil quando se deseja equilíbrio entre evitar falsos positivos e evitar falsos negativos. De forma mais geral, define-se o F_β-*score* por

$$F_\beta = (1 + \beta^2) \cdot \frac{\text{Precision} \cdot \text{Recall}}{\beta^2 \cdot \text{Precision} + \text{Recall}}, \tag{84}$$

onde $\beta > 1$ atribui maior peso ao *recall*, e $\beta < 1$ maior peso à *precision*.

Quando o classificador produz probabilidades $\hat{p}$ e não apenas rótulos, pode-se variar um limiar $\tau \in [0, 1]$ e construir a curva ROC (*Receiver Operating Characteristic*),

que relaciona

$$\mathrm{TPR}(\tau) = \frac{TP(\tau)}{TP(\tau) + FN(\tau)} \tag{85}$$

e

$$\mathrm{FPR}(\tau) = \frac{FP(\tau)}{FP(\tau) + TN(\tau)} = 1 - \mathrm{Specificity}(\tau). \tag{86}$$

A área sob a curva ROC (AUC-ROC) é dada, em termos contínuos, por

$$\mathrm{AUC} = \int_0^1 \mathrm{TPR}(u)\, du, \tag{87}$$

onde $u = \mathrm{FPR}$. Equivalentemente, a AUC pode ser interpretada como a probabilidade de o classificador atribuir escore maior a uma amostra positiva do que a uma negativa:

$$\mathrm{AUC} = P(s(\mathbf{X}^+) > s(\mathbf{X}^-)). \tag{88}$$

Essa métrica é particularmente útil por ser independente de limiar e refletir separabilidade global.

Em problemas multiclasse, a matriz de confusão generaliza-se para

$$\mathbf{M} \in \mathbb{N}^{K \times K}, \tag{89}$$

onde M_{ij} representa o número de amostras da classe verdadeira i preditas como classe j. Para cada classe k, pode-se adotar um esquema *one-vs-rest*, definindo:

$$TP_k = M_{kk}, \tag{90}$$

$$FN_k = \sum_{j \neq k} M_{kj}, \tag{91}$$

$$FP_k = \sum_{i \neq k} M_{ik}, \tag{92}$$

$$TN_k = \sum_{i \neq k} \sum_{j \neq k} M_{ij}. \tag{93}$$

A partir disso, calculam-se métricas por classe:

$$\mathrm{Precision}_k = \frac{TP_k}{TP_k + FP_k}, \qquad \mathrm{Recall}_k = \frac{TP_k}{TP_k + FN_k}, \tag{94}$$

$$F_{1,k} = 2 \cdot \frac{\mathrm{Precision}_k \cdot \mathrm{Recall}_k}{\mathrm{Precision}_k + \mathrm{Recall}_k}. \tag{95}$$

Para consolidar as métricas em um único escalar, são comuns três estratégias de

agregação. A média macro:

$$\text{Macro-}F_1 = \frac{1}{K}\sum_{k=1}^{K} F_{1,k}, \tag{96}$$

atribui o mesmo peso a todas as classes. A média ponderada:

$$\text{Weighted-}F_1 = \sum_{k=1}^{K} \frac{N_k}{N} F_{1,k}, \tag{97}$$

pesa cada classe por sua frequência. Já a média micro agrega as contagens globais antes do cálculo:

$$\text{Micro-Precision} = \frac{\sum_k TP_k}{\sum_k (TP_k + FP_k)}, \tag{98}$$

$$\text{Micro-Recall} = \frac{\sum_k TP_k}{\sum_k (TP_k + FN_k)}. \tag{99}$$

Em cenários desbalanceados, a média macro costuma ser mais informativa, pois não permite que a classe majoritária domine a avaliação.

Outro aspecto relevante é a calibração probabilística. Um classificador está bem calibrado se, aproximadamente,

$$P(Y = 1 \mid \hat{p} = p) = p. \tag{100}$$

Embora nem sempre reportada, a calibração é importante em sistemas clínicos porque decisões podem depender não apenas da classe predita, mas do grau de confiança estimado. Medidas como o *Brier score*

$$\text{BS} = \frac{1}{N}\sum_{i=1}^{N} (\hat{p}_i - y_i)^2 \tag{101}$$

ou o *Expected Calibration Error* (ECE) podem complementar a avaliação quando o uso clínico das probabilidades é relevante.

Em síntese, a avaliação de classificadores em imagem médica deve ser multilateral. A acurácia fornece um retrato global, mas sensibilidade, especificidade, *precision*, $F1$-*score*, AUC-ROC, análise por classe e, quando pertinente, calibração probabilística oferecem uma visão mais fiel do comportamento do modelo. Em problemas como classificação de lesões mamárias, nos quais diferentes tipos de erro possuem custos clínicos distintos, a interpretação cuidadosa dessas métricas é tão importante quanto o próprio treinamento do classificador.

2.6 Arquiteturas para classificação

2.6.1 VGG16

A VGG16 é uma arquitetura convolucional profunda proposta por Simonyan e Zisserman com o objetivo de investigar, de forma sistemática, o efeito do aumento da profundidade sobre o desempenho em reconhecimento visual. Seu desenho tornou-se particularmente influente porque demonstrou que redes mais profundas, construídas a partir de blocos simples e homogêneos, poderiam alcançar desempenho expressivo sem recorrer a componentes arquiteturais excessivamente complexos. Em termos conceituais, a VGG16 consolidou uma ideia central da visão computacional moderna: o aprofundamento progressivo da rede, quando aliado a filtros pequenos e composição hierárquica de operações convolucionais, é capaz de produzir representações visuais altamente discriminativas.

Do ponto de vista funcional, a VGG16 pode ser interpretada como um mapeamento

$$f_{\boldsymbol{\theta}} : \mathbb{R}^{H \times W \times C} \to \mathbb{R}^{K}, \tag{102}$$

em que a imagem de entrada é transformada sucessivamente por blocos convolucionais e camadas densas até a produção de logits para K classes. Seja

$$\mathbf{X}^{(0)} = \mathbf{X} \tag{103}$$

a entrada da rede. Cada bloco convolucional pode ser descrito de forma abstrata por

$$\mathbf{X}^{(l+1)} = \phi\big(\mathbf{W}^{(l)} * \mathbf{X}^{(l)} + \mathbf{b}^{(l)}\big)\,, \tag{104}$$

onde $*$ denota a operação convolucional, $\phi(\cdot)$ é tipicamente a função ReLU, $\mathbf{W}^{(l)}$ representa os filtros aprendíveis da camada l e $\mathbf{b}^{(l)}$ os vieses. Após certos blocos, aplica-se uma operação de *max pooling*,

$$\mathbf{P}^{(l)}_{i,j,c} = \max_{(u,v)\in\mathcal{W}_{i,j}} \mathbf{X}^{(l)}_{u,v,c}, \tag{105}$$

reduzindo a resolução espacial e ampliando o campo receptivo efetivo das camadas subsequentes.

A importância histórica da VGG16 decorre, em grande medida, de sua regularidade estrutural. Em vez de combinar filtros de tamanhos muito diversos, a arquitetura adota sistematicamente filtros 3×3 com *stride* unitário e *padding* adequado para preservar resolução espacial dentro de cada bloco. Essa decisão possui implicações matemáticas e computacionais relevantes. Duas convoluções consecutivas 3×3 possuem campo receptivo efetivo equivalente a uma única convolução 5×5, mas com menos

parâmetros e maior número de não linearidades intermediárias. De forma aproximada, uma camada 5×5 com C canais de entrada e M filtros teria

$$P_{5\times5} = M(25C + 1) \tag{106}$$

parâmetros, enquanto duas camadas 3×3 em sequência teriam ordem de grandeza

$$P^{(1)}_{3\times3} + P^{(2)}_{3\times3} = M(9C + 1) + M(9M + 1), \tag{107}$$

o que, em muitos cenários de projeto, oferece melhor compromisso entre expressividade e estrutura hierárquica. Além disso, o empilhamento de filtros pequenos introduz mais funções de ativação ReLU ao longo do caminho,

$$\phi\big(\mathbf{W}_2 * \phi(\mathbf{W}_1 * \mathbf{X})\big), \tag{108}$$

aumentando a capacidade de modelar transformações não lineares complexas.

2.6.1.1 Estrutura da arquitetura

A VGG16 possui 16 camadas com pesos treináveis: 13 camadas convolucionais e 3 camadas totalmente conectadas. Em sua configuração clássica para classificação em larga escala, a rede recebe uma imagem de entrada de dimensão

$$\mathbf{X} \in \mathbb{R}^{224\times224\times3}, \tag{109}$$

seguida por cinco blocos convolucionais separados por operações de *max pooling*. O arranjo canônico é o seguinte:

- Bloco 1: duas convoluções 3×3 com 64 filtros;
- Bloco 2: duas convoluções 3×3 com 128 filtros;
- Bloco 3: três convoluções 3×3 com 256 filtros;
- Bloco 4: três convoluções 3×3 com 512 filtros;
- Bloco 5: três convoluções 3×3 com 512 filtros;
- Classificador: três camadas densas, usualmente com 4096, 4096 e K unidades.

Cada convolução é seguida de uma ativação ReLU,

$$\phi(x) = \max(0, x), \tag{110}$$

e cada bloco termina com *max pooling* 2×2 com *stride* 2. Se a entrada de um bloco possui dimensão $H \times W$, após o *pooling* a dimensão torna-se, idealmente,

$$\left(\frac{H}{2}, \frac{W}{2}\right). \tag{111}$$

Partindo de 224×224, a sequência de reduções espaciais é

$$224 \to 112 \to 56 \to 28 \to 14 \to 7. \tag{112}$$

Ao final do quinto bloco, obtém-se um tensor aproximadamente de dimensão

$$7 \times 7 \times 512, \tag{113}$$

que, após achatamento, gera um vetor de dimensão

$$7 \cdot 7 \cdot 512 = 25088. \tag{114}$$

Esse vetor alimenta a primeira camada densa do classificador.

A estrutura da VGG16 pode ser representada de maneira compacta como

$$f_{\boldsymbol{\theta}}(\mathbf{X}) = g_{\mathsf{FC}} \circ p_5 \circ c_5 \circ p_4 \circ c_4 \circ p_3 \circ c_3 \circ p_2 \circ c_2 \circ p_1 \circ c_1(\mathbf{X}), \tag{115}$$

em que c_b representa o bloco convolucional b, p_b o respectivo *pooling*, e g_{FC} o classificador denso final. Essa organização evidencia o caráter modular e homogêneo da arquitetura.

Em termos paramétricos, a VGG16 é uma rede de alta capacidade. Seu número total de parâmetros na configuração clássica ultrapassa 10^8, com forte concentração nas camadas densas finais. Se uma camada totalmente conectada recebe um vetor de dimensão n e produz uma saída de dimensão m, seu número de parâmetros é

$$P_{\mathsf{FC}} = m(n+1). \tag{116}$$

Aplicando essa fórmula à primeira camada densa da VGG16, com $n = 25088$ e $m = 4096$, obtém-se

$$P_{\mathsf{FC1}} = 4096(25088 + 1), \tag{117}$$

o que explica por que uma parcela substancial do custo paramétrico da arquitetura se concentra no classificador final e não apenas nos blocos convolucionais.

Do ponto de vista do aprendizado, a saída final da rede para uma tarefa multiclasse é usualmente obtida por

$$\hat{p}_k = \frac{\exp(z_k)}{\sum_{j=1}^{K} \exp(z_j)}, \tag{118}$$

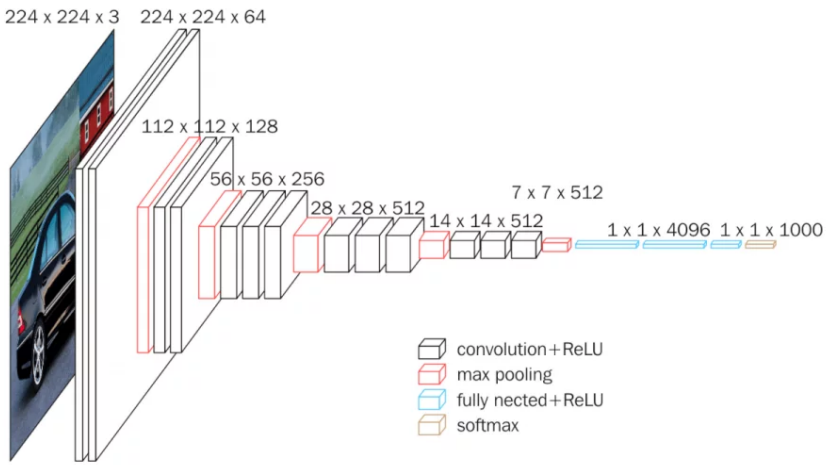

Figura 1 – Representação esquemática da arquitetura VGG16, composta por blocos convolucionais profundos, camadas de agrupamento máximo e camadas totalmente conectadas para classificação multiclasse.

Fonte: Adaptado de Neurohive, "VGG16 – Convolutional Network for Classification and Detection", 2018. Disponível em: `https://neurohive.io/en/popular-networks/vgg16/`. Acesso em: 22 set. 2025.

com perda de entropia cruzada

$$\mathcal{L}_{\text{CE}} = -\sum_{k=1}^{K} y_k \log(\hat{p}_k). \tag{119}$$

Em aplicações médicas, contudo, a arquitetura raramente é utilizada exatamente em sua forma original. Em vez disso, a base convolucional pré-treinada costuma ser aproveitada como extrator de características, substituindo-se a cabeça densa por um classificador adaptado ao número de classes e ao tamanho da base-alvo.

2.6.1.2 Vantagens e limitações

A principal vantagem da VGG16 reside em sua simplicidade estrutural e em sua forte capacidade de generalização como extrator de características. Como a arquitetura é composta por blocos homogêneos de convoluções 3×3, sua interpretação é relativamente direta, sua implementação é estável e sua utilização como *baseline* tornou-se amplamente difundida. Em contextos de *transfer learning*, essa propriedade é particularmente útil: seja $\phi_{\text{VGG}}(\mathbf{X}; \boldsymbol{\theta}_0)$ a base convolucional pré-treinada, pode-se congelar $\boldsymbol{\theta}_0$ e aprender apenas uma nova cabeça classificadora

$$\hat{y} = h(\phi_{\text{VGG}}(\mathbf{X}; \boldsymbol{\theta}_0); \boldsymbol{\theta}_h)\,, \tag{120}$$

ou, alternativamente, realizar *fine-tuning* parcial ou total. Essa reutilização de representações aprendidas em bases extensas é uma das razões pelas quais a VGG16 continua relevante em imagem médica, mesmo após o surgimento de arquiteturas

mais recentes.

Outra vantagem importante é o forte viés indutivo local da arquitetura. Como a VGG16 empilha filtros pequenos ao longo de vários níveis, ela aprende gradualmente desde padrões elementares, como bordas e texturas, até composições de alto nível mais úteis para classificação. Em bases médicas moderadas, esse comportamento pode ser vantajoso porque a rede já parte de detectores visuais gerais relativamente bem estruturados, reduzindo a dependência de engenharia manual de atributos. Além disso, por ser uma arquitetura amplamente estudada, a VGG16 serve como referência experimental estável, facilitando comparação com trabalhos prévios e interpretação de ganhos obtidos por modelos mais modernos.

Entretanto, a VGG16 apresenta limitações importantes. A primeira delas é seu custo paramétrico elevado. Como discutido anteriormente, as camadas totalmente conectadas finais concentram grande número de parâmetros, o que aumenta consumo de memória, tempo de treinamento e risco de sobreajuste. Em bases médicas com número limitado de amostras, esse problema é particularmente sensível, pois o modelo pode ajustar-se excessivamente a padrões idiossincráticos do conjunto de treinamento. Em termos estatísticos, quando o número de parâmetros P é muito superior ao número efetivo de exemplos independentes N,

$$P \gg N, \tag{121}$$

a necessidade de regularização, congelamento de camadas ou simplificação da cabeça classificadora torna-se ainda mais pronunciada.

Uma segunda limitação é a ausência de mecanismos arquiteturais que mais tarde se mostraram centrais em redes profundas mais eficientes, como conexões residuais, normalização integrada ao desenho original ou escalonamento mais racional de profundidade e largura. Em consequência, embora a VGG16 seja profunda para os padrões de sua época, ela é menos eficiente que arquiteturas posteriores em termos de relação entre desempenho e custo computacional. Em tarefas de classificação médica, isso significa que a VGG16 pode permanecer competitiva como *baseline*, mas tende a ser superada por modelos que extraem representações semelhantes com menos parâmetros, menor latência ou melhor estabilidade de treinamento.

Há ainda uma limitação metodológica importante em aplicações biomédicas: a arquitetura foi originalmente otimizada para imagens naturais de larga escala, com estatísticas visuais distintas das observadas em exames médicos. Embora o *transfer learning* a partir de ImageNet frequentemente produza bons resultados, a adequação do espaço de características aprendido não é garantida de forma uniforme para todos os domínios clínicos. Em imagens com baixo contraste, ruído speckle, estruturas anatômicas sutis e elevada variabilidade de aquisição, como no ultrassom mamário, parte

das representações herdadas pode exigir adaptação considerável via *fine-tuning*. Assim, a VGG16 deve ser compreendida menos como solução ótima universal e mais como arquitetura de referência robusta, cuja principal utilidade contemporânea em pesquisa médica reside em servir como ponto de comparação sólido para modelos mais eficientes ou mais especializados.

2.6.2 ResNet50

A ResNet50 pertence à família de redes residuais profundas proposta por He et al., cujo objetivo central foi enfrentar a degradação de desempenho observada quando a profundidade de redes convolucionais aumenta sem mecanismos arquiteturais apropriados de estabilização (He; Zhang; Ren; Sun, 2016). A ideia fundamental da arquitetura é reformular o problema de aprendizado não como a estimação direta de uma transformação desejada $H(\mathbf{x})$, mas como a estimação de uma função residual $F(\mathbf{x})$ em relação à entrada, de modo que

$$H(\mathbf{x}) = F(\mathbf{x}) + \mathbf{x}. \tag{122}$$

Essa reformulação altera profundamente a dinâmica de otimização, pois transforma o mapeamento alvo em

$$F(\mathbf{x}) = H(\mathbf{x}) - \mathbf{x}, \tag{123}$$

o que, em muitos casos, é mais fácil de aprender do que a transformação completa $H(\mathbf{x})$. Em termos intuitivos, se o mapeamento ótimo desejado estiver próximo da identidade, torna-se suficiente aprender uma pequena correção residual.

Do ponto de vista funcional, um bloco residual recebe como entrada um tensor $\mathbf{x} \in \mathbb{R}^{H \times W \times C}$ e produz uma saída

$$\mathbf{y} = \mathcal{F}(\mathbf{x}, \{\mathbf{W}_i\}) + \mathcal{S}(\mathbf{x}), \tag{124}$$

onde $\mathcal{F}(\mathbf{x}, \{\mathbf{W}_i\})$ representa a transformação residual parametrizada por um conjunto de pesos $\{\mathbf{W}_i\}$, e $\mathcal{S}(\mathbf{x})$ representa a conexão de atalho (*shortcut connection*). No caso mais simples, a conexão é identidade:

$$\mathcal{S}(\mathbf{x}) = \mathbf{x}, \tag{125}$$

de modo que

$$\mathbf{y} = \mathcal{F}(\mathbf{x}) + \mathbf{x}. \tag{126}$$

Quando há mudança de dimensionalidade espacial ou no número de canais, utiliza-se

tipicamente uma projeção linear, frequentemente implementada por convolução 1×1:

$$\mathcal{S}(\mathbf{x}) = \mathbf{W}_s * \mathbf{x}, \tag{127}$$

e então

$$\mathbf{y} = \mathcal{F}(\mathbf{x}) + \mathbf{W}_s * \mathbf{x}. \tag{128}$$

Após a soma residual, aplica-se geralmente uma não linearidade, produzindo

$$\mathbf{z} = \phi(\mathbf{y}), \tag{129}$$

onde $\phi(\cdot)$ costuma ser a ReLU:

$$\phi(t) = \max(0, t). \tag{130}$$

Essa estrutura altera não apenas a propagação direta, mas também o fluxo de gradientes no treinamento. Seja $\mathcal{L}$ a função de perda final e $\mathbf{x}$ a entrada do bloco residual. Pela regra da cadeia,

$$\frac{\partial \mathcal{L}}{\partial \mathbf{x}} = \frac{\partial \mathcal{L}}{\partial \mathbf{y}} \left(\frac{\partial \mathcal{F}(\mathbf{x})}{\partial \mathbf{x}} + \mathbf{I} \right), \tag{131}$$

onde $\mathbf{I}$ é o operador identidade proveniente da conexão residual. Esse termo adicional facilita a propagação do gradiente, reduzindo o risco de degradação da otimização em redes profundas. Em linguagem prática, o *skip connection* cria um caminho de menor resistência para a informação e para o gradiente, permitindo treinar arquiteturas substancialmente mais profundas com maior estabilidade (He; Zhang; Ren; Sun, 2016).

2.6.2.1 Skip connections e treinamento profundo

O principal problema atacado pela ResNet não é simplesmente o desaparecimento do gradiente no sentido clássico, mas a *degradação* do desempenho com o aumento da profundidade: redes mais profundas, mesmo tendo maior capacidade representacional, podem apresentar erro de treinamento maior do que versões mais rasas quando otimizadas diretamente (He; Zhang; Ren; Sun, 2016). Em termos formais, se $\mathcal{E}_{\text{train}}(d)$ denota o erro de treinamento de uma rede com profundidade d, seria natural esperar que, ao aumentar d,

$$\mathcal{E}_{\text{train}}(d+1) \leq \mathcal{E}_{\text{train}}(d), \tag{132}$$

pois a rede mais profunda poderia, em tese, reproduzir a solução da mais rasa por meio de identidades adicionais. No entanto, na prática, observava-se frequentemente

$$\mathcal{E}_{\text{train}}(d+1) > \mathcal{E}_{\text{train}}(d), \tag{133}$$

indicando dificuldade de otimização, e não mera limitação de capacidade. O aprendizado residual foi introduzido precisamente para aproximar o comportamento real daquele ideal.

No caso específico da ResNet50, a arquitetura utiliza blocos residuais do tipo *bottleneck*, compostos por três convoluções:

$$1 \times 1 \;\rightarrow\; 3 \times 3 \;\rightarrow\; 1 \times 1. \tag{134}$$

O primeiro filtro 1×1 reduz a dimensionalidade dos canais, o filtro 3×3 realiza a extração espacial propriamente dita, e o último 1×1 expande novamente a dimensionalidade. Se a entrada de um bloco possui C_{in} canais, uma configuração típica pode reduzir para C_b, processar espacialmente em C_b e então expandir para C_{out}, com

$$C_b < C_{\text{out}}. \tag{135}$$

O custo paramétrico aproximado do bloco residual *bottleneck* é

$$P_{\text{bottleneck}} = C_b(C_{\text{in}} + 9C_b + C_{\text{out}}), \tag{136}$$

desconsiderando vieses e detalhes de normalização. Essa fatoração torna o bloco muito mais eficiente do que empilhar várias convoluções 3×3 diretamente na dimensionalidade expandida.

A ResNet50 segue uma estrutura inicial composta por convolução 7×7, *max pooling* e quatro estágios residuais. Em sua configuração canônica para entrada

$$\mathbf{X} \in \mathbb{R}^{224 \times 224 \times 3}, \tag{137}$$

o fluxo arquitetural é tipicamente descrito como:

$$\text{conv1} \rightarrow \text{pool} \rightarrow \text{conv2_x} \rightarrow \text{conv3_x} \rightarrow \text{conv4_x} \rightarrow \text{conv5_x} \rightarrow \text{GAP} \rightarrow \text{FC}. \tag{138}$$

Os quatro estágios residuais possuem, respectivamente, 3, 4, 6 e 3 blocos *bottleneck*, somando cinquenta camadas com pesos quando se considera a convenção do artigo original (He; Zhang; Ren; Sun, 2016). Após o último estágio, aplica-se *global average pooling*:

$$g_c = \frac{1}{HW} \sum_{i=1}^{H} \sum_{j=1}^{W} Z_{i,j,c}, \tag{139}$$

seguido de uma camada densa final.

Do ponto de vista do treinamento, a ResNet50 beneficia-se também do uso sistemático de *Batch Normalization*. Seja x uma ativação escalar em um mini-lote $\mathcal{B}$. A

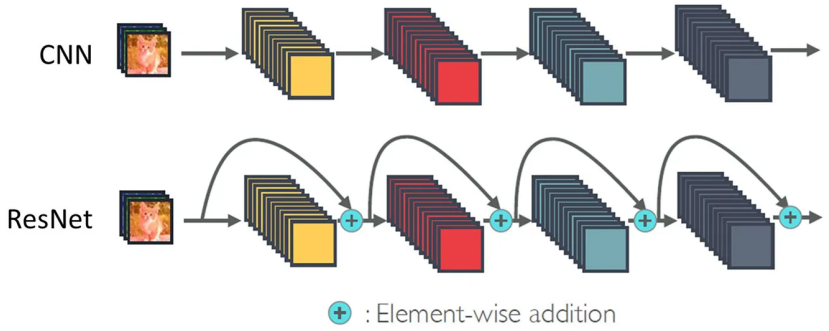

Figura 2 – Representação esquemática da arquitetura ResNet50, destacando o papel das conexões residuais no treinamento de redes neurais profundas em comparação com o de redes neurais convolucionais normais.

Fonte: Adaptado de Ultralytics, "O que é ResNet-50 e qual é a sua relevância em visão computacional?", 2025. Disponível em: `https://www.ultralytics.com/pt/blog/what-is-resnet-50-and-what-is-its-relevance-in-computer-vision`. Acesso em: 22 set. 2025.

normalização é dada por

$$\hat{x} = \frac{x - \mu_{\mathcal{B}}}{\sqrt{\sigma_{\mathcal{B}}^2 + \varepsilon}}, \tag{140}$$

e a saída transformada é

$$y = \gamma \hat{x} + \beta, \tag{141}$$

onde γ e β são parâmetros aprendíveis (**?**). A combinação entre *skip connections*, normalização e blocos *bottleneck* faz da ResNet50 uma arquitetura particularmente eficiente para treinamento profundo, pois equilibra capacidade representacional, estabilidade numérica e custo computacional.

Em termos de classificação multiclasse, a saída final pode ser escrita como

$$\hat{p}_k = \frac{\exp(z_k)}{\sum_{j=1}^{K} \exp(z_j)}, \qquad k = 1, \ldots, K, \tag{142}$$

e o treinamento supervisionado usualmente minimiza a entropia cruzada:

$$\mathcal{L}_{\text{CE}} = -\sum_{k=1}^{K} y_k \log(\hat{p}_k). \tag{143}$$

Quando a ResNet50 é usada em *transfer learning*, substitui-se a camada totalmente conectada final por um classificador compatível com a tarefa-alvo, mantendo-se a base residual como extrator de características:

$$f(\mathbf{X}) = h(\phi_{\text{ResNet50}}(\mathbf{X}; \boldsymbol{\theta}_f); \boldsymbol{\theta}_h)\,. \tag{144}$$

Essa formulação é particularmente relevante em imagem médica, onde bases moderadas favorecem estratégias com pesos pré-treinados.

2.6.2.2 Aplicações em imagens médicas

A ResNet50 tornou-se uma das arquiteturas mais empregadas em imagens médicas justamente por combinar profundidade substancial com treinamento estável e eficiência paramétrica razoável. Em tarefas radiológicas e biomédicas, ela é frequentemente utilizada como *backbone* de classificação, detecção, segmentação ou modelos híbridos, muitas vezes em regime de *transfer learning*. Revisões da área destacam que redes residuais passaram a figurar entre as escolhas mais recorrentes em problemas de classificação diagnóstica por sua capacidade de aprender representações profundas sem os custos de otimização que limitavam arquiteturas anteriores (**?**Yu; Zhou; Wang; Zhang, 2022).

Em termos matemáticos, essa vantagem pode ser entendida pelo fato de que a ResNet50 implementa um mapeamento composicional profundo

$$f(\mathbf{X}) = f_L \circ f_{L-1} \circ \cdots \circ f_1(\mathbf{X}), \tag{145}$$

no qual cada f_l é um bloco residual. Diferentemente de uma pilha puramente sequencial de convoluções, cada bloco admite uma decomposição

$$f_l(\mathbf{x}) = \phi\big(\mathcal{F}_l(\mathbf{x}) + \mathcal{S}_l(\mathbf{x})\big), \tag{146}$$

o que facilita o aprendizado de representações hierárquicas complexas e mais robustas a perturbações locais. Em imagens médicas, essa propriedade é importante porque tecidos, lesões e estruturas anatômicas frequentemente apresentam regularidades multiescala e diferenças visuais sutis, exigindo simultaneamente sensibilidade a detalhes e capacidade de abstração global.

Na prática, a ResNet50 tem sido aplicada a problemas de classificação em radiografia de tórax, tomografia, ressonância magnética, mamografia, histopatologia digital e ultrassonografia. Em cenários de ultrassom mamário, sua adoção é especialmente natural porque a arquitetura consegue capturar padrões de textura e contorno mesmo em presença de ruído speckle e baixa relação sinal-contraste. Além disso, por dispor de versões pré-treinadas amplamente disponíveis, a ResNet50 permite estratégias de adaptação do tipo

$$\boldsymbol{\theta}^{(0)} = \boldsymbol{\theta}_{\text{ImageNet}}, \tag{147}$$

seguidas de congelamento parcial ou *fine-tuning*, o que é valioso quando o número de amostras médicas anotadas é limitado.

Outra razão para sua ampla adoção é o bom compromisso entre desempenho e custo. Em comparação com arquiteturas muito mais pesadas, a ResNet50 costuma apresentar latência e número de parâmetros moderados, mantendo ainda assim forte

desempenho discriminativo. Se denotarmos por

$$\mathcal{P} \tag{148}$$

o número de parâmetros, por

$$T_{\text{inf}} \tag{149}$$

o tempo médio de inferência e por

$$\mathcal{M} \tag{150}$$

uma métrica de desempenho clínico, como F_1 ou AUC, a utilidade prática de um modelo pode ser pensada como uma função de compromisso

$$U = U(\mathcal{M}, \mathcal{P}, T_{\text{inf}}), \tag{151}$$

na qual não basta maximizar $\mathcal{M}$; é necessário considerar também viabilidade operacional. Nesse sentido, a ResNet50 frequentemente aparece como arquitetura de referência intermediária: mais moderna e estável que a VGG16, mas menos custosa que modelos muito mais robustos e recentes.

Apesar dessas vantagens, a aplicação da ResNet50 em imagens médicas não está isenta de limitações. A primeira delas é que o pré-treinamento em imagens naturais pode não capturar plenamente a estatística visual de modalidades médicas específicas. Embora filtros iniciais que respondem a bordas, gradientes e texturas elementares sejam frequentemente transferíveis, camadas profundas podem requerer adaptação significativa para representar padrões clínicos relevantes. Outra limitação é que a própria capacidade do modelo pode favorecer o aprendizado de atalhos espúrios quando a base contém artefatos sistemáticos, marcações sobrepostas ou viés institucional. Em bases públicas moderadas, como as de ultrassom mamário, isso torna indispensável combinar a ResNet50 com curadoria rigorosa dos dados, validação adequada e análise crítica dos resultados.

Assim, a ResNet50 pode ser entendida, no contexto desta monografia, como uma arquitetura de classificação de alto valor metodológico: suficientemente profunda para explorar o potencial do aprendizado residual, suficientemente estável para treinamento em cenários médicos e suficientemente difundida para servir como referência comparativa robusta em estudos de classificação de lesões mamárias.

2.6.3 EfficientNet

A família EfficientNet foi proposta por Tan e Le com o objetivo de enfrentar uma limitação recorrente no projeto de arquiteturas convolucionais: o aumento de desempenho por meio de escalonamento empírico e pouco sistemático de profundidade, largura ou resolução de entrada (**?**). Em arquiteturas anteriores, a expansão da capacidade do

modelo era frequentemente realizada de forma unidimensional, por exemplo, aumentando apenas o número de camadas ou apenas o número de canais. Embora tais estratégias possam produzir ganhos de acurácia, elas tendem a ser ineficientes do ponto de vista computacional e nem sempre exploram adequadamente o balanço entre representação, custo e estabilidade de treinamento. A EfficientNet surge, portanto, como uma formulação arquitetural orientada por dois princípios complementares: a busca por uma arquitetura-base otimizada e o escalonamento composto (*compound scaling*) de seus principais eixos estruturais.

Do ponto de vista funcional, a EfficientNet pode ser descrita como uma rede convolucional profunda

$$f_{\boldsymbol{\theta}} : \mathbb{R}^{H \times W \times C} \to \mathbb{R}^{K}, \tag{152}$$

na qual a imagem de entrada é processada por uma sequência de blocos convolucionais móveis invertidos (*mobile inverted bottleneck convolution*, MBConv), originalmente associados à família MobileNetV2 (**?**). A saída final consiste em logits

$$\mathbf{z} = (z_1, \ldots, z_K), \tag{153}$$

convertidos em probabilidades por

$$\hat{p}_k = \frac{\exp(z_k)}{\sum_{j=1}^{K} \exp(z_j)}, \qquad k = 1, \ldots, K. \tag{154}$$

Em tarefas de classificação multiclasse, o treinamento é usualmente conduzido pela minimização da entropia cruzada categórica

$$\mathcal{L}_{\mathsf{CE}} = -\sum_{k=1}^{K} y_k \log(\hat{p}_k), \tag{155}$$

eventualmente combinada com regularização explícita e estratégias modernas de *data augmentation*.

A principal contribuição conceitual da EfficientNet não reside apenas na escolha dos blocos MBConv, mas na formalização do problema de escalonamento. Em vez de decidir heurística e independentemente como aumentar profundidade, largura ou resolução, os autores propõem uma estratégia conjunta que trata esses três fatores como variáveis acopladas. Essa ideia é particularmente relevante em visão computacional médica, onde o custo de treinamento pode ser elevado e o ganho de desempenho precisa ser cuidadosamente ponderado em relação à complexidade do modelo.

2.6.3.1 Compound scaling

Seja uma arquitetura-base $\mathcal{N}_0$ definida por profundidade d, largura w e resolução de entrada r. Na formulação clássica de escalonamento, poder-se-ia construir uma família de modelos alterando apenas um desses fatores:

$$d' = \alpha d, \qquad w' = w, \qquad r' = r, \tag{156}$$

ou

$$d' = d, \qquad w' = \beta w, \qquad r' = r, \tag{157}$$

ou ainda

$$d' = d, \qquad w' = w, \qquad r' = \gamma r. \tag{158}$$

Essas estratégias, embora simples, são estruturalmente limitadas porque modificam apenas uma dimensão da capacidade da rede. A hipótese central da EfficientNet é que o desempenho ótimo, sob uma dada restrição de recursos, depende de um crescimento balanceado desses três fatores.

Para formalizar esse princípio, define-se um coeficiente global de escalonamento $\phi \geq 0$, que controla a expansão do modelo, e três constantes $\alpha, \beta, \gamma > 1$, responsáveis por escalar, respectivamente, profundidade, largura e resolução. O escalonamento composto é então dado por

$$d = \alpha^\phi, \qquad w = \beta^\phi, \qquad r = \gamma^\phi, \tag{159}$$

sujeito à restrição aproximada de custo computacional

$$\alpha \cdot \beta^2 \cdot \gamma^2 \approx 2, \tag{160}$$

com

$$\alpha \geq 1, \qquad \beta \geq 1, \qquad \gamma \geq 1. \tag{161}$$

Essa restrição decorre do fato de que, de forma aproximada, o custo de uma CNN escala linearmente com a profundidade, quadraticamente com a largura e quadraticamente com a resolução espacial. Se denotarmos por $\mathcal{C}$ o custo computacional, uma aproximação útil é

$$\mathcal{C} \propto d \cdot w^2 \cdot r^2. \tag{162}$$

Substituindo as expressões do escalonamento composto, obtém-se

$$\mathcal{C}_\phi \propto (\alpha^\phi)(\beta^\phi)^2(\gamma^\phi)^2 = (\alpha\beta^2\gamma^2)^\phi. \tag{163}$$

Se

$$\alpha\beta^2\gamma^2 \approx 2, \tag{164}$$

então o custo aproximadamente dobra a cada incremento unitário de ϕ:

$$\mathcal{C}_{\phi+1} \approx 2\mathcal{C}_{\phi}. \tag{165}$$

Esse formalismo fornece uma regra clara para construir uma família inteira de modelos a partir de uma arquitetura-base. No caso da EfficientNet, a rede-base B0 foi obtida por busca neural de arquitetura (*Neural Architecture Search* — NAS), e as variantes B1, B2, ... foram geradas por escalonamento composto sistemático. Assim, se $\mathcal{N}_0$ representa a EfficientNet-B0, uma variante escalada com coeficiente ϕ pode ser vista como

$$\mathcal{N}_{\phi} = \text{Scale}(\mathcal{N}_0; \alpha^{\phi}, \beta^{\phi}, \gamma^{\phi}). \tag{166}$$

Sob uma perspectiva geométrica, o escalonamento composto procura manter um equilíbrio entre três necessidades complementares:

- **Profundidade**: aumenta a hierarquia de abstrações e o campo receptivo efetivo;
- **Largura**: amplia a capacidade de representação em cada nível;
- **Resolução**: preserva detalhes espaciais úteis para discriminação fina.

Em bases médicas, esse equilíbrio é particularmente importante, porque imagens clínicas frequentemente exigem sensibilidade a detalhes locais sem abrir mão de contexto anatômico mais amplo. Em um problema como classificação de lesões em ultrassom mamário, aumentar apenas a profundidade pode não ser suficiente se a resolução de entrada não preservar detalhes da lesão; da mesma forma, aumentar apenas a resolução pode ser pouco eficiente se a rede não tiver largura e profundidade suficientes para explorar o sinal adicional.

A formulação do *compound scaling* pode ainda ser interpretada como um problema de otimização restrita. Seja $\mathcal{A}(d, w, r)$ uma métrica de acurácia e $\mathcal{C}(d, w, r)$ o custo computacional. O objetivo ideal seria

$$\max_{d,w,r} \mathcal{A}(d, w, r) \quad \text{sujeito a} \quad \mathcal{C}(d, w, r) \leq \kappa, \tag{167}$$

onde κ representa um orçamento de recursos. A EfficientNet aproxima essa otimização por meio de uma trajetória paramétrica controlada por ϕ, reduzindo a busca tridimensional (d, w, r) a uma família unidimensional mais tratável.

2.6.3.2 Eficiência computacional

A eficiência computacional da EfficientNet decorre tanto do desenho dos blocos internos quanto da estratégia de escalonamento. Em vez de utilizar convoluções convencionais densas em todos os níveis, a arquitetura se apoia em blocos MBConv, que combinam expansão de canais, convolução separável em profundidade e projeção linear. Seja uma entrada com C_{in} canais. Um bloco MBConv com fator de expansão t pode ser esquematizado como:

$$C_{\text{in}} \xrightarrow{1\times 1} tC_{\text{in}} \xrightarrow{\text{depthwise } k\times k} tC_{\text{in}} \xrightarrow{1\times 1} C_{\text{out}}. \tag{168}$$

O custo paramétrico aproximado desse bloco é

$$P_{\text{MBConv}} = tC_{\text{in}}^2 + k^2 tC_{\text{in}} + tC_{\text{in}}C_{\text{out}}, \tag{169}$$

desconsiderando vieses e normalizações. Em comparação, uma convolução densa $k \times k$ que mapeasse diretamente C_{in} para C_{out} teria

$$P_{\text{conv}} = k^2 C_{\text{in}} C_{\text{out}}. \tag{170}$$

Quando C_{in} e C_{out} são moderadamente grandes, a fatoração separável utilizada pelo MBConv reduz de forma expressiva o número de parâmetros e o custo aritmético.

Além disso, muitos blocos da EfficientNet incorporam mecanismos de *squeeze-and-excitation* (SE), que realizam recalibração adaptativa entre canais. Dado um mapa de ativação

$$\mathbf{U} \in \mathbb{R}^{H\times W\times C}, \tag{171}$$

aplica-se inicialmente um *global average pooling*

$$s_c = \frac{1}{HW}\sum_{i=1}^{H}\sum_{j=1}^{W} U_{i,j,c}, \tag{172}$$

obtendo-se um vetor $\mathbf{s} \in \mathbb{R}^C$. Em seguida, calcula-se um vetor de atenção por canal

$$\mathbf{a} = \sigma(\mathbf{W}_2\delta(\mathbf{W}_1\mathbf{s}))\,, \tag{173}$$

onde $\delta(\cdot)$ é uma não linearidade intermediária, tipicamente ReLU ou Swish, e $\sigma(\cdot)$ é uma sigmoide. O mapa recalibrado é

$$\tilde{U}_{i,j,c} = a_c\, U_{i,j,c}. \tag{174}$$

Esse mecanismo aumenta seletividade representacional com sobrecusto relativa-

mente pequeno.

Uma forma prática de quantificar eficiência computacional é por meio de três grandezas: número de parâmetros $\mathcal{P}$, custo em operações de ponto flutuante (FLOPs) e tempo médio de inferência T_{inf}. Em termos gerais, para uma convolução densa $k \times k$, a ordem de grandeza do custo em multiplicações é

$$\text{FLOPs}_{\text{conv}} \propto H_{\text{out}} W_{\text{out}} k^2 C_{\text{in}} C_{\text{out}}, \tag{175}$$

enquanto em uma convolução separável em profundidade seguida de projeção pontual, o custo torna-se aproximadamente

$$\text{FLOPs}_{\text{dw+pw}} \propto H_{\text{out}} W_{\text{out}} \left(k^2 C_{\text{in}} + C_{\text{in}} C_{\text{out}} \right), \tag{176}$$

o que é substancialmente menor quando $k^2 C_{\text{out}}$ domina a primeira expressão. Essa redução torna a EfficientNet particularmente atrativa em cenários com limitação de memória, latência ou capacidade de processamento, como ambientes acadêmicos baseados em GPU compartilhada, dispositivos embarcados ou sistemas clínicos com exigência de resposta rápida.

Do ponto de vista da utilidade prática, a eficiência de uma arquitetura não deve ser entendida apenas como “menos parâmetros”, mas como melhor relação entre desempenho e custo. Seja $\mathcal{M}$ uma métrica de desempenho, como acurácia, macro-F_1 ou AUC, e seja $\mathcal{C}$ um custo agregado que combina parâmetros, tempo de inferência e memória. Pode-se pensar a eficiência relativa de um modelo como

$$\mathcal{E} = \frac{\mathcal{M}}{\mathcal{C}}, \tag{177}$$

ou, de forma mais geral, como uma função multicritério

$$\mathcal{U} = \mathcal{U}(\mathcal{M}, \mathcal{P}, \text{FLOPs}, T_{\text{inf}}). \tag{178}$$

Nesse enquadramento, a EfficientNet é particularmente relevante porque frequentemente oferece desempenho competitivo com valores relativamente baixos de $\mathcal{P}$ e FLOPs, tornando-se uma escolha natural quando o problema experimental exige não apenas alta qualidade preditiva, mas também viabilidade computacional.

Em aplicações médicas, essa propriedade tem implicações ainda mais fortes. Bases de dados moderadas, como muitas coleções de imagem mamária, não favorecem necessariamente modelos extremamente grandes, pois arquiteturas excessivamente parametrizadas podem apresentar maior risco de sobreajuste sem ganho proporcional em generalização. Assim, uma arquitetura como a EfficientNet pode ocupar uma posição metodológica estratégica: suficientemente expressiva para capturar padrões

discriminativos complexos e suficientemente eficiente para manter treinamento e inferência em patamares operacionais adequados. Essa combinação explica por que ela se tornou uma alternativa recorrente em estudos comparativos de classificação em imagem médica e, em particular, um candidato natural para compor o eixo classificatório desta monografia.

2.6.4 ConvNeXt

A arquitetura ConvNeXt foi proposta por Liu et al. com o objetivo explícito de reavaliar o potencial das redes convolucionais puras em um cenário dominado por Transformers visuais. Em vez de assumir que o ganho recente em visão computacional decorreria exclusivamente da superioridade intrínseca dos Transformers, os autores investigaram até que ponto uma CNN clássica, especialmente uma ResNet, poderia recuperar competitividade se fosse modernizada com escolhas de projeto inspiradas em modelos hierárquicos mais recentes (Liu; Mao; Wu; Feichtenhofer; Darrell; Xie, 2022). O resultado desse processo foi uma família de arquiteturas convolucionais denominada *ConvNeXt*, cuja proposta central consiste em preservar o viés indutivo das convoluções ao mesmo tempo em que incorpora avanços de desenho arquitetural associados à geração dos modelos da década de 2020.

De forma geral, uma rede ConvNeXt implementa um mapeamento

$$f_{\boldsymbol{\theta}} : \mathbb{R}^{H \times W \times C} \to \mathbb{R}^{K}, \tag{179}$$

no qual a imagem de entrada é transformada por estágios convolucionais hierárquicos até a produção de logits

$$\mathbf{z} = (z_1, \ldots, z_K), \tag{180}$$

convertidos em probabilidades por meio de

$$\hat{p}_k = \frac{\exp(z_k)}{\sum_{j=1}^{K} \exp(z_j)}, \qquad k = 1, \ldots, K. \tag{181}$$

Em tarefas de classificação multiclasse, o treinamento é usualmente conduzido pela minimização da entropia cruzada

$$\mathcal{L}_{\mathsf{CE}} = -\sum_{k=1}^{K} y_k \log(\hat{p}_k), \tag{182}$$

eventualmente combinada com regularização, *label smoothing* ou *mixup*, dependendo do protocolo experimental.

A relevância metodológica do ConvNeXt decorre do fato de que ele não é apenas “mais uma CNN profunda”, mas uma tentativa sistemática de responder à seguinte

questão: até que ponto o desempenho de modelos visuais recentes deriva de mecanismos realmente exclusivos dos Transformers, e até que ponto decorre de decisões de engenharia que também podem ser incorporadas a arquiteturas convolucionais? Essa pergunta é particularmente importante para a área médica, pois sugere que o ganho de desempenho pode ser obtido sem abdicar totalmente das propriedades locais, hierárquicas e computacionalmente familiares das CNNs.

2.6.4.1 Motivação e modernização de CNNs

A motivação central do ConvNeXt pode ser entendida como um processo de transformação gradual de uma ResNet em uma arquitetura convolucional moderna. Seja $\mathcal{R}_0$ uma ResNet de referência. O artigo original mostra que, ao introduzir progressivamente diversas modificações de desenho, é possível obter uma família de redes puramente convolucionais com desempenho comparável, e em alguns cenários superior, ao de modelos hierárquicos baseados em atenção (Liu; Mao; Wu; Feichtenhofer; Darrell; Xie, 2022). Formalmente, esse processo pode ser representado como uma sequência de atualizações arquiteturais

$$\mathcal{R}_0 \xrightarrow{T_1} \mathcal{R}_1 \xrightarrow{T_2} \cdots \xrightarrow{T_m} \mathcal{C}, \tag{183}$$

em que cada transformação T_i altera um componente estrutural específico até se chegar ao modelo final $\mathcal{C}$, o ConvNeXt.

Uma das principais mudanças introduzidas é a adoção de convoluções *depthwise* com *kernel* grande, tipicamente 7×7, dentro do bloco residual. Seja $\mathbf{X} \in \mathbb{R}^{H \times W \times C}$ a entrada do bloco. Na convolução *depthwise*, cada canal é processado de forma independente:

$$Y_{i,j,c} = b_c + \sum_{u=0}^{k-1} \sum_{v=0}^{k-1} K_{u,v}^{(c)} X_{i+u,j+v,c}, \tag{184}$$

com $k = 7$ no caso típico do ConvNeXt. O custo paramétrico dessa operação é

$$P_{\text{dw}} = C(k^2 + 1), \tag{185}$$

substancialmente menor do que o de uma convolução densa $k \times k$,

$$P_{\text{conv}} = M(k^2 C + 1), \tag{186}$$

quando se deseja mapear C canais para M filtros. Essa escolha permite ampliar o campo receptivo local de forma eficiente, aproximando o efeito de janelas de atenção locais sem abandonar a natureza convolucional da rede.

Outra modificação central é a reorganização interna do bloco residual. Em vez do padrão clássico de *bottleneck* da ResNet, o ConvNeXt adota um bloco simplificado e

mais próximo da lógica de *MLP-like expansion*. Seja $\mathbf{x}$ a entrada do bloco. Uma forma abstrata de descrevê-lo é

$$\mathbf{y} = \mathbf{x} + \mathcal{P}_2\Big(\phi\big(\mathcal{P}_1(\mathrm{LN}(\mathrm{DWConv}(\mathbf{x})))\big)\Big), \tag{187}$$

onde DWConv é a convolução *depthwise*, LN denota *Layer Normalization*, $\mathcal{P}_1$ e $\mathcal{P}_2$ são projeções lineares 1×1, e $\phi(\cdot)$ é tipicamente a função GELU. A GELU é definida por

$$\mathrm{GELU}(x) = x\,\Phi(x), \tag{188}$$

onde $\Phi(x)$ é a função de distribuição acumulada da normal padrão, frequentemente aproximada por

$$\mathrm{GELU}(x) \approx 0.5x\left(1 + \tanh\left(\sqrt{\frac{2}{\pi}}\left(x + 0.044715x^3\right)\right)\right). \tag{189}$$

Essa substituição da ReLU por GELU torna a ativação mais suave e alinha a arquitetura a escolhas modernas também populares em Transformers.

O uso de *Layer Normalization* em lugar da *Batch Normalization* em partes do pipeline é outra característica importante. Dado um vetor de ativações $\mathbf{h} = (h_1, \ldots, h_d)$, a normalização em camada é dada por

$$\mu = \frac{1}{d}\sum_{j=1}^{d} h_j, \qquad \sigma^2 = \frac{1}{d}\sum_{j=1}^{d}(h_j - \mu)^2, \tag{190}$$

e

$$\hat{h}_j = \frac{h_j - \mu}{\sqrt{\sigma^2 + \varepsilon}}, \qquad y_j = \gamma_j \hat{h}_j + \beta_j. \tag{191}$$

Diferentemente da *Batch Normalization*, a *Layer Normalization* não depende explicitamente da estatística do mini-lote, o que pode ser vantajoso em cenários de lotes pequenos, comuns em imagens médicas de alta resolução ou em treinamento com recursos limitados.

Também é relevante a chamada *patchify stem*, isto é, a substituição da entrada convolucional inicial clássica por uma camada de redução espacial mais agressiva, conceitualmente próxima à tokenização espacial dos Vision Transformers. Se $\mathbf{X} \in \mathbb{R}^{H \times W \times C}$, uma camada inicial com *stride* s produz dimensões

$$H' = \left\lfloor \frac{H - k + 2p}{s} \right\rfloor + 1, \qquad W' = \left\lfloor \frac{W - k + 2p}{s} \right\rfloor + 1, \tag{192}$$

reduzindo a resolução logo na entrada e reorganizando o custo computacional dos estágios posteriores. Em conjunto, essas escolhas tornam o ConvNeXt uma arquitetura

convolucional hierárquica “modernizada”, isto é, uma CNN que preserva convoluções como operação nuclear, mas adota várias decisões de projeto associadas ao sucesso recente dos Transformers visuais.

Do ponto de vista do fluxo de gradiente, o ConvNeXt mantém a lógica residual:

$$\mathbf{y} = \mathbf{x} + \mathcal{F}(\mathbf{x}), \tag{193}$$

de modo que

$$\frac{\partial \mathcal{L}}{\partial \mathbf{x}} = \frac{\partial \mathcal{L}}{\partial \mathbf{y}} \left(\mathbf{I} + \frac{\partial \mathcal{F}(\mathbf{x})}{\partial \mathbf{x}} \right). \tag{194}$$

Assim, a arquitetura combina dois benefícios centrais: a estabilidade de otimização herdada das redes residuais e a modernização de seus blocos internos para ampliar capacidade representacional e competitividade em larga escala.

2.6.4.2 Potencial em tarefas médicas

O potencial do ConvNeXt em imagens médicas decorre de um conjunto de propriedades arquiteturais particularmente atraentes para esse domínio. Em primeiro lugar, a arquitetura preserva o viés indutivo local das convoluções, o que é importante em dados nos quais texturas, contornos e relações espaciais locais continuam sendo altamente informativos. Em exames médicos, como ultrassonografia, mamografia, tomografia ou ressonância magnética, padrões patológicos frequentemente se manifestam como variações locais sutis de intensidade, forma ou textura. Seja $\mathbf{X}$ uma imagem e $\mathcal{N}_\delta(i,j)$ uma vizinhança local centrada em (i,j). Em muitos problemas clínicos, a decisão depende da estrutura de

$$\mathbf{X}|_{\mathcal{N}_\delta(i,j)}, \tag{195}$$

e não apenas de dependências globais arbitrárias. Nesse aspecto, o ConvNeXt mantém uma vantagem potencial das CNNs: a capacidade de explorar localidade de forma explícita e eficiente.

Em segundo lugar, o uso de *large-kernel depthwise convolutions* amplia o campo receptivo sem abandonar a economia paramétrica. Se o campo receptivo efetivo de um bloco é denotado por r_l, o uso de kernels maiores aumenta esse campo aproximadamente segundo

$$r_l = r_{l-1} + (k_l - 1) \prod_{t=1}^{l-1} s_t, \tag{196}$$

o que pode ser vantajoso em tarefas médicas nas quais sinais relevantes dependem simultaneamente de detalhe local e de contexto anatômico mais amplo. Em ultrassom mamário, por exemplo, a classificação de uma lesão não depende apenas do contorno imediato da massa, mas também da textura interna, da interface com tecidos adjacentes e, por vezes, do comportamento da região circundante.

Outro ponto favorável é a compatibilidade do ConvNeXt com *transfer learning*. Seja $\phi_{\text{ConvNeXt}}(\mathbf{X};\boldsymbol{\theta}_0)$ o extrator de características pré-treinado e $h(\cdot;\boldsymbol{\theta}_h)$ uma nova cabeça classificadora. O modelo adaptado ao domínio clínico pode ser escrito como

$$f(\mathbf{X}) = h(\phi_{\text{ConvNeXt}}(\mathbf{X};\boldsymbol{\theta}_0);\boldsymbol{\theta}_h)\,. \tag{197}$$

Pode-se então optar por congelar parte de $\boldsymbol{\theta}_0$ ou realizar *fine-tuning* parcial/total:

$$\boldsymbol{\theta}^\star = \arg\min_{\boldsymbol{\theta}_0,\boldsymbol{\theta}_h} \frac{1}{N}\sum_{i=1}^{N} \mathcal{L}\big(h(\phi_{\text{ConvNeXt}}(\mathbf{X}_i;\boldsymbol{\theta}_0);\boldsymbol{\theta}_h), y_i\big). \tag{198}$$

Em bases médicas moderadas, essa estratégia é especialmente valiosa porque reduz custo de treinamento do zero e aproveita representações visuais robustas aprendidas em grandes coleções naturais.

Do ponto de vista comparativo, o ConvNeXt ocupa uma posição metodológica interessante entre CNNs clássicas e Transformers visuais. Ele busca capturar parte do ganho recente associado à modernização arquitetural sem abrir mão da simplicidade operacional das convoluções. Em aplicações médicas, isso pode se traduzir em uma combinação atraente de bom desempenho discriminativo, estrutura hierárquica familiar, compatibilidade com bibliotecas consolidadas e boa escalabilidade para diferentes tamanhos de modelo. Em termos de compromisso entre desempenho $\mathcal{M}$ e custo $\mathcal{C}$, pode-se pensar sua utilidade como

$$\mathcal{U}_{\text{ConvNeXt}} = \mathcal{U}(\mathcal{M}, \mathcal{P}, T_{\text{inf}}, \text{FLOPs}), \tag{199}$$

onde $\mathcal{P}$ é o número de parâmetros e T_{inf} o tempo médio de inferência. Em muitos cenários, o ConvNeXt tende a ocupar uma faixa de alto desempenho, embora frequentemente com custo superior ao de arquiteturas mais leves, como EfficientNet de menor porte.

Essa observação leva diretamente às limitações potenciais de seu uso em medicina. Embora a arquitetura seja promissora como *backbone* de classificação, seu tamanho e custo computacional podem ser excessivos em bases pequenas, aumentando risco de sobreajuste e demanda por regularização agressiva. Em cenários nos quais

$$P \gg N, \tag{200}$$

onde P é o número de parâmetros do modelo e N o número de amostras independentes disponíveis, o ganho teórico de capacidade representacional pode não se converter em melhor generalização. Ademais, como em outras arquiteturas pré-treinadas em imagens naturais, a transferência para domínios médicos continua dependente da compatibilidade entre o espaço de características aprendido e os padrões realmente

relevantes do ponto de vista clínico.

Ainda assim, o ConvNeXt apresenta grande interesse em tarefas médicas justamente por representar uma CNN de “nova geração”: suficientemente moderna para competir com famílias arquiteturais recentes e suficientemente fiel ao paradigma convolucional para manter vantagens operacionais, interpretativas e de implantação. No contexto desta monografia, ele é particularmente relevante como arquitetura de comparação de alto desempenho no eixo classificatório, permitindo examinar até que ponto a modernização das CNNs se traduz em ganho real em imagens de ultrassom mamário.

2.7 Segmentação de imagens médicas

2.7.1 Conceito de segmentação semântica

A segmentação de imagens médicas consiste no particionamento de uma imagem em regiões semanticamente significativas, de modo que estruturas anatômicas, tecidos, órgãos ou lesões possam ser identificados e delimitados de forma explícita. Em sua formulação mais geral, seja

$$\mathbf{X} \in \mathbb{R}^{H \times W \times C} \tag{201}$$

uma imagem bidimensional com H linhas, W colunas e C canais, definida sobre um domínio discreto de pixels

$$\Omega = \{1, \ldots, H\} \times \{1, \ldots, W\}. \tag{202}$$

A segmentação semântica busca aprender uma função

$$f_{\boldsymbol{\theta}} : \mathbb{R}^{H \times W \times C} \to \{0, 1, \ldots, K-1\}^{H \times W}, \tag{203}$$

que associe a cada pixel $p \in \Omega$ um rótulo semântico y_p pertencente a um conjunto finito de K classes.

De forma equivalente, pode-se representar o problema como a estimação de um campo de probabilidades por pixel:

$$f_{\boldsymbol{\theta}}(\mathbf{X}) = \hat{\mathbf{P}} \in [0, 1]^{H \times W \times K}, \tag{204}$$

onde

$$\hat{P}_{p,k} \approx P(Y_p = k \mid \mathbf{X}), \qquad \sum_{k=1}^{K} \hat{P}_{p,k} = 1, \qquad \forall p \in \Omega. \tag{205}$$

O rótulo predito em cada pixel é então obtido por

$$\hat{y}_p = \arg \max_{k \in \{0,\ldots,K-1\}} \hat{P}_{p,k}. \tag{206}$$

Em termos geométricos, a segmentação semântica induz uma partição do domínio Ω em subconjuntos

$$\Omega = \bigcup_{k=0}^{K-1} \Omega_k, \qquad \Omega_i \cap \Omega_j = \varnothing \text{ para } i \neq j, \tag{207}$$

onde

$$\Omega_k = \{p \in \Omega \mid y_p = k\}. \tag{208}$$

No caso binário, particularmente comum em segmentação de lesões, tem-se $K = 2$, com uma classe associada ao fundo e outra à região de interesse. Nesse cenário, a máscara de referência pode ser representada por

$$\mathbf{Y} \in \{0,1\}^{H \times W}, \tag{209}$$

em que

$$Y_p = \begin{cases} 1, & \text{se } p \text{ pertence à lesão}, \\ 0, & \text{caso contrário}. \end{cases} \tag{210}$$

Diferentemente da classificação global, na qual se estima um único rótulo para toda a imagem, a segmentação semântica exige consistência espacial e detalhamento local, uma vez que a saída preserva a topologia do domínio de entrada. Assim, o problema não se resume a inferir se uma lesão está presente, mas a determinar *onde* ela está e *qual é sua extensão*. Em notação funcional, enquanto um classificador implementa

$$g_{\boldsymbol{\theta}} : \mathbb{R}^{H \times W \times C} \to \{0, \ldots, K-1\}, \tag{211}$$

um segmentador implementa

$$f_{\boldsymbol{\theta}} : \mathbb{R}^{H \times W \times C} \to \{0, \ldots, K-1\}^{H \times W}, \tag{212}$$

o que representa uma exigência significativamente mais forte do ponto de vista computacional.

Em redes neurais profundas, a segmentação semântica é frequentemente formulada como um problema de classificação densa. Seja $\mathbf{z}_p \in \mathbb{R}^K$ o vetor de logits asso-

ciado ao pixel p. A probabilidade predita por pixel é obtida via *softmax*:

$$\hat{P}_{p,k} = \frac{\exp(z_{p,k})}{\sum_{j=0}^{K-1} \exp(z_{p,j})}. \tag{213}$$

A função de perda pixel-wise de entropia cruzada pode então ser escrita como

$$\mathcal{L}_{\mathsf{CE}} = -\frac{1}{|\Omega|} \sum_{p \in \Omega} \sum_{k=0}^{K-1} Y_{p,k} \log(\hat{P}_{p,k}), \tag{214}$$

onde $Y_{p,k}$ é a codificação *one-hot* do rótulo verdadeiro. Em tarefas médicas, entretanto, o forte desbalanceamento entre fundo e estrutura-alvo frequentemente torna insuficiente a utilização isolada da entropia cruzada, motivando o uso de perdas orientadas a sobreposição, como Dice Loss e IoU Loss.

Sob uma perspectiva semântica, é importante distinguir a segmentação semântica de outros paradigmas próximos. Na segmentação por instâncias, objetos pertencentes à mesma classe recebem rótulos distintos; na segmentação panóptica, combinam-se componentes semânticos e de instância. No presente trabalho, o interesse recai sobre a segmentação semântica de lesões mamárias, na qual o objetivo é recuperar a região correspondente à massa tumoral como uma única classe-alvo em contraste com o fundo.

2.7.2 Importância da segmentação no contexto clínico

A relevância clínica da segmentação decorre do fato de que muitas decisões médicas dependem não apenas da detecção de uma anormalidade, mas da sua localização precisa, contorno, área, volume e relação espacial com tecidos adjacentes. Em oncologia por imagem, por exemplo, a segmentação da lesão permite estimar quantitativamente sua extensão anatômica, avaliar mudanças longitudinais sob tratamento e extrair descritores morfológicos ou radiômicos que podem complementar a interpretação diagnóstica. Em termos formais, se $\mathbf{Y}$ representa a máscara da lesão, sua área bidimensional pode ser estimada por

$$A(\mathbf{Y}) = \sum_{p \in \Omega} Y_p \, \Delta a, \tag{215}$$

onde Δa é a área física correspondente a cada pixel. Em exames tridimensionais, o volume pode ser representado por

$$V(\mathbf{Y}) = \sum_{v \in \mathcal{V}} Y_v \, \Delta v, \tag{216}$$

com $\mathcal{V}$ denotando o conjunto de voxels e Δv o volume físico por voxel.

A partir da segmentação, torna-se também possível estimar medidas de forma e geometria. Seja S a região segmentada. Pode-se definir, por exemplo, o perímetro $P(S)$, a circularidade

$$\mathrm{Circ}(S) = \frac{4\pi A(S)}{P(S)^2}, \tag{217}$$

ou eixos principais obtidos a partir de momentos centrais da região. Em contexto clínico, essas medidas podem auxiliar a caracterizar margens irregulares, espiculações, assimetrias e outras propriedades associadas à suspeita de malignidade. Em lesões mamárias, a definição espacial da massa possui importância não apenas visual, mas quantitativa, pois sua forma e seus contornos podem carregar informação diagnóstica adicional.

A segmentação também é crucial em fluxos de trabalho que precedem ou complementam etapas posteriores de análise computacional. Em radiômica, por exemplo, a qualidade dos atributos extraídos depende diretamente da máscara utilizada para definir a região de interesse. Se $\mathcal{R} \subset \Omega$ é a região segmentada, um descritor estatístico simples, como a intensidade média, é calculado como

$$\mu_{\mathcal{R}} = \frac{1}{|\mathcal{R}|} \sum_{p \in \mathcal{R}} X_p, \tag{218}$$

e sua validade depende fortemente da fidelidade espacial da segmentação. Pequenos erros de contorno podem contaminar a região de interesse com fundo, tecido adjacente ou ruído, afetando a interpretação clínica e a robustez dos atributos derivados.

Em cenários longitudinais, a segmentação permite quantificar resposta terapêutica ou progressão da doença. Se V_t e $V_{t+\Delta}$ representam o volume segmentado da lesão em dois momentos, a variação relativa pode ser estimada por

$$\Delta_{\%} = 100 \cdot \frac{V_{t+\Delta} - V_t}{V_t}. \tag{219}$$

Esse tipo de medida é particularmente relevante em acompanhamento oncológico, planejamento terapêutico e estudos de evolução tumoral. Em suma, a utilidade clínica da segmentação reside no fato de que ela transforma uma imagem em uma estrutura quantitativa espacialmente explícita, permitindo que diferentes dimensões da doença sejam analisadas de forma mais objetiva.

Além disso, a segmentação aumenta a interpretabilidade de sistemas baseados em Inteligência Artificial. Em classificação pura, a saída do modelo é frequentemente um escore ou rótulo global, cujo significado anatômico pode ser difícil de inspecionar

diretamente. Já um modelo segmentador produz uma predição espacial

$$\hat{\mathbf{Y}} \in \{0, 1, \ldots, K-1\}^{H \times W}, \tag{220}$$

que pode ser visualmente comparada à anotação de referência. Essa característica é particularmente importante em medicina, onde a confiança em sistemas automatizados depende, em parte, da capacidade de verificar se a predição coincide com regiões clinicamente plausíveis.

No caso específico do ultrassom mamário, a segmentação possui valor adicional porque a lesão frequentemente apresenta contornos imprecisos, ruído e forte dependência do plano de aquisição. Assim, a tarefa de segmentar não é apenas uma operação auxiliar, mas um problema clinicamente e computacionalmente relevante em si. Uma arquitetura capaz de recuperar adequadamente a região tumoral em presença de ruído speckle, baixo contraste e margens ambíguas demonstra não apenas capacidade de ajuste estatístico, mas potencial de apoio real em tarefas como delimitação de massas, análise morfológica e monitoramento de lesões.

2.7.3 Métricas de avaliação para segmentação

A avaliação de modelos de segmentação médica requer métricas capazes de capturar concordância espacial entre a máscara predita $\hat{\mathbf{Y}}$ e a máscara de referência $\mathbf{Y}$. Em termos binários, definem-se os conjuntos

$$A = \{p \in \Omega \mid \hat{Y}_p = 1\}, \qquad B = \{p \in \Omega \mid Y_p = 1\}, \tag{221}$$

onde A representa a região predita e B a região verdadeira. A partir desses conjuntos, pode-se definir a interseção

$$A \cap B \tag{222}$$

e a união

$$A \cup B. \tag{223}$$

Essas operações fundamentam as métricas de sobreposição mais utilizadas em segmentação médica.

A métrica de Jaccard, também conhecida como *Intersection over Union* (IoU), é dada por

$$\mathrm{IoU}(A, B) = \frac{|A \cap B|}{|A \cup B|} = \frac{TP}{TP + FP + FN}, \tag{224}$$

em que TP, FP e FN são definidos em nível de pixel ou voxel. A IoU assume valores em $[0, 1]$, sendo

$$\mathrm{IoU}(A, B) = 1 \tag{225}$$

quando há concordância perfeita entre predição e referência, e

$$\mathrm{IoU}(A, B) = 0 \tag{226}$$

quando não há interseção entre as regiões. Em termos geométricos, a IoU penaliza simultaneamente subsegmentação e sobresegmentação.

Outra métrica central é o coeficiente de Dice, ou *Dice Similarity Coefficient* (DSC),

$$\mathrm{Dice}(A, B) = \frac{2|A \cap B|}{|A| + |B|} = \frac{2TP}{2TP + FP + FN}. \tag{227}$$

A relação entre Dice e IoU pode ser escrita como

$$\mathrm{Dice} = \frac{2\mathrm{IoU}}{1 + \mathrm{IoU}}, \tag{228}$$

e, inversamente,

$$\mathrm{IoU} = \frac{\mathrm{Dice}}{2 - \mathrm{Dice}}. \tag{229}$$

Em aplicações médicas, o Dice é particularmente popular porque lida melhor com desbalanceamento severo entre a região de interesse e o fundo, situação comum em tarefas de segmentação de pequenas lesões.

A precisão em nível de pixel é definida por

$$\mathrm{Precision} = \frac{TP}{TP + FP}, \tag{230}$$

indicando a fração dos pixels preditos como pertencentes à lesão que realmente pertencem à lesão. Já a sensibilidade, ou *recall*, é dada por

$$\mathrm{Recall} = \frac{TP}{TP + FN}, \tag{231}$$

quantificando a capacidade do modelo de recuperar a extensão verdadeira da estrutura-alvo. A especificidade pode ser escrita como

$$\mathrm{Specificity} = \frac{TN}{TN + FP}, \tag{232}$$

embora, em segmentação médica, essa métrica isoladamente possa ser pouco informativa quando o fundo domina a imagem.

A acurácia pixel-wise é definida por

$$\mathrm{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}. \tag{233}$$

No entanto, em segmentação biomédica essa métrica deve ser interpretada com cau-

tela. Em problemas onde a lesão ocupa pequena fração da imagem, pode ocorrer

$$TN \gg TP, FP, FN, \tag{234}$$

o que faz com que um modelo ruim ainda obtenha alta acurácia apenas por classificar corretamente o fundo. Por isso, recomenda-se que métricas de sobreposição, como Dice e IoU, tenham prioridade na análise.

Quando o interesse clínico inclui fidelidade de contorno, métricas baseadas apenas em volume podem ser insuficientes. Nesse caso, métricas de distância entre superfícies tornam-se relevantes. Seja ∂A a fronteira da máscara predita e ∂B a fronteira da referência. A distância de Hausdorff é definida por

$$d_H(\partial A, \partial B) = \max\left\{\sup_{a\in\partial A}\inf_{b\in\partial B}\|a-b\|,\ \sup_{b\in\partial B}\inf_{a\in\partial A}\|b-a\|\right\}. \tag{235}$$

Essa métrica captura o pior erro de fronteira, sendo sensível a discrepâncias localizadas. Já a distância média de superfície pode ser escrita, em forma simplificada, como

$$d_{\mathsf{ASD}}(\partial A, \partial B) = \frac{1}{|\partial A| + |\partial B|}\left(\sum_{a\in\partial A}\min_{b\in\partial B}\|a-b\| + \sum_{b\in\partial B}\min_{a\in\partial A}\|b-a\|\right). \tag{236}$$

Enquanto Dice e IoU medem concordância volumétrica, métricas de superfície avaliam precisão geométrica de contorno, o que pode ser clinicamente importante em estruturas pequenas ou com margens irregulares.

Em problemas multiclasse, as métricas podem ser generalizadas por classe. Seja A_k a região predita da classe k e B_k a região de referência. O Dice por classe é

$$\mathrm{Dice}_k = \frac{2|A_k \cap B_k|}{|A_k| + |B_k|}, \tag{237}$$

e a média macro pode ser calculada por

$$\mathrm{MacroDice} = \frac{1}{K}\sum_{k=1}^{K}\mathrm{Dice}_k. \tag{238}$$

De forma análoga,

$$\mathrm{MacroIoU} = \frac{1}{K}\sum_{k=1}^{K}\mathrm{IoU}_k. \tag{239}$$

Em cenários com classes muito desbalanceadas, pode-se também empregar médias ponderadas pela frequência.

Além da avaliação pontual das máscaras, muitas arquiteturas são treinadas com

funções de perda alinhadas às métricas finais. A chamada *Dice Loss* é tipicamente definida por

$$\mathcal{L}_{\text{Dice}} = 1 - \frac{2\sum_p \hat{Y}_p Y_p + \epsilon}{\sum_p \hat{Y}_p + \sum_p Y_p + \epsilon}, \tag{240}$$

onde $\epsilon > 0$ evita divisão por zero. De modo semelhante, a *IoU Loss* pode ser escrita como

$$\mathcal{L}_{\text{IoU}} = 1 - \frac{\sum_p \hat{Y}_p Y_p + \epsilon}{\sum_p \hat{Y}_p + \sum_p Y_p - \sum_p \hat{Y}_p Y_p + \epsilon}. \tag{241}$$

Essas formulações são particularmente úteis porque incorporam, já no treinamento, uma penalização consistente com a sobreposição geométrica de interesse clínico.

Em síntese, a avaliação em segmentação médica deve ser multilateral. Métricas de sobreposição, como Dice e IoU, são essenciais para capturar concordância global entre máscara predita e referência. Métricas como precisão, sensibilidade e especificidade ajudam a decompor os tipos de erro em nível de pixel. Já métricas de superfície, como Hausdorff e distância média, são indispensáveis quando a qualidade do contorno possui relevância clínica direta. Em conjunto, essas medidas oferecem uma visão mais completa da qualidade segmentadora do modelo do que qualquer métrica isolada.

2.8 Arquiteturas para segmentação

2.8.1 U-Net

A U-Net é uma arquitetura convolucional proposta por Ronneberger, Fischer e Brox para segmentação biomédica, concebida explicitamente para produzir predições densas em nível de pixel a partir de conjuntos de dados relativamente pequenos, desde que combinados com estratégias adequadas de aumento de dados. Sua relevância histórica decorre do fato de ter consolidado, em um único arcabouço, dois requisitos centrais da segmentação médica: incorporação de contexto global suficiente para inferência semântica e preservação de detalhe espacial suficiente para localização precisa de estruturas de interesse. Desde sua introdução, a U-Net tornou-se uma das arquiteturas mais influentes em imagem biomédica, servindo tanto como modelo de referência quanto como ponto de partida para numerosas extensões e variantes.

Formalmente, seja uma imagem de entrada

$$\mathbf{X} \in \mathbb{R}^{H \times W \times C}, \tag{242}$$

definida sobre um domínio discreto

$$\Omega = \{1, \ldots, H\} \times \{1, \ldots, W\}. \tag{243}$$

A U-Net implementa uma função

$$f_{\boldsymbol{\theta}} : \mathbb{R}^{H\times W\times C} \to [0,1]^{H\times W\times K}, \tag{244}$$

que associa a cada pixel $p \in \Omega$ uma distribuição de probabilidade sobre K classes semânticas. Em segmentação binária, tipicamente $K = 1$ para uma saída sigmoidal, ou $K = 2$ em formulações com *softmax*. No caso sigmoidal, a predição por pixel pode ser escrita como

$$\hat{Y}_p = \sigma(z_p) = \frac{1}{1 + e^{-z_p}}, \tag{245}$$

enquanto, para o caso multiclasse,

$$\hat{P}_{p,k} = \frac{\exp(z_{p,k})}{\sum_{j=1}^{K} \exp(z_{p,j})}, \qquad k = 1, \ldots, K. \tag{246}$$

A máscara final é obtida por limiarização ou maximização:

$$\hat{y}_p = \begin{cases} 1, & \text{se } \hat{Y}_p \geq \tau, \\ 0, & \text{caso contrário,} \end{cases} \qquad \text{ou} \qquad \hat{y}_p = \arg\max_k \hat{P}_{p,k}. \tag{247}$$

A característica definidora da U-Net é sua organização em forma de “U”, na qual uma trajetória contratante (*contracting path*) reduz progressivamente a resolução espacial e amplia a dimensionalidade semântica, enquanto uma trajetória expansiva (*expanding path*) recompõe a resolução por meio de operações de *upsampling*, integrando informação contextual profunda com detalhes locais preservados em níveis anteriores da rede. Essa topologia permite construir mapas de segmentação densos sem abandonar a riqueza espacial necessária à delimitação precisa de lesões e estruturas anatômicas.

2.8.1.1 Estrutura encoder-decoder

Do ponto de vista arquitetural, a U-Net pode ser compreendida como uma composição entre um codificador (*encoder*) e um decodificador (*decoder*). Seja

$$\mathbf{X}^{(0)} = \mathbf{X} \tag{248}$$

a entrada da rede. No caminho contratante, cada bloco l aplica tipicamente duas convoluções 3×3, seguidas de ativações não lineares, e depois uma operação de redução espacial. Em forma abstrata,

$$\mathbf{E}^{(l)} = \phi\big(\mathbf{W}^{(l,2)} * \phi\big(\mathbf{W}^{(l,1)} * \mathbf{X}^{(l)} + \mathbf{b}^{(l,1)}\big) + \mathbf{b}^{(l,2)}\big), \tag{249}$$

seguida por

$$\mathbf{X}^{(l+1)} = \mathcal{P}\big(\mathbf{E}^{(l)}\big), \tag{250}$$

onde $\mathcal{P}(\cdot)$ denota, no desenho clássico, *max pooling* 2×2 com *stride* 2, e $\phi(\cdot)$ é tipicamente a ReLU:

$$\phi(t) = \max(0, t). \tag{251}$$

Se a entrada de um bloco possui dimensão $H_l \times W_l \times C_l$, após o *pooling* obtém-se aproximadamente

$$H_{l+1} = \frac{H_l}{2}, \qquad W_{l+1} = \frac{W_l}{2}, \tag{252}$$

enquanto o número de canais costuma dobrar:

$$C_{l+1} \approx 2C_l. \tag{253}$$

No ponto mais profundo da rede, frequentemente chamado *bottleneck*, a U-Net produz representações altamente abstratas e com grande campo receptivo efetivo. Se o campo receptivo após L estágios é denotado por r_L, então, para convoluções 3×3 e *strides* unitários, seu crescimento é aproximadamente recursivo:

$$r^{(l)} = r^{(l-1)} + (k_l - 1) \prod_{t=1}^{l-1} s_t, \tag{254}$$

de modo que representações profundas agregam contexto espacial amplo, crucial para segmentar estruturas ambíguas em imagens médicas. Essa acumulação de contexto é uma das razões pelas quais a U-Net supera arquiteturas rasas em tarefas biomédicas complexas.

No caminho expansivo, a resolução espacial é gradualmente restaurada. Seja $\mathbf{D}^{(l)}$ a representação no nível l do decodificador. Cada estágio aplica uma operação de *upsampling*, que pode ser realizada por convolução transposta ou por interpolação seguida de convolução:

$$\tilde{\mathbf{D}}^{(l)} = \mathcal{U}\big(\mathbf{D}^{(l+1)}\big), \tag{255}$$

com

$$H_l = 2H_{l+1}, \qquad W_l = 2W_{l+1}. \tag{256}$$

Em seguida, concatena-se a representação expandida com o mapa de ativação do nível correspondente no codificador:

$$\mathbf{C}^{(l)} = \mathrm{Concat}\big(\tilde{\mathbf{D}}^{(l)}, \mathbf{E}^{(l)}\big), \tag{257}$$

e aplica-se novamente um bloco convolucional:

$$\mathbf{D}^{(l)} = \phi\big(\mathbf{V}^{(l,2)} * \phi\big(\mathbf{V}^{(l,1)} * \mathbf{C}^{(l)} + \mathbf{c}^{(l,1)}\big) + \mathbf{c}^{(l,2)}\big)\,. \tag{258}$$

Essa simetria entre redução e expansão define a geometria em “U” da arquitetura. :contentReference[oaicite:3]index=3

Na configuração clássica do artigo original, cada convolução é *válida* (*valid convolution*), o que reduz ligeiramente as dimensões espaciais após cada operação. Por essa razão, os mapas provenientes do codificador precisam ser recortados antes da concatenação com os mapas do decodificador. Seja $\mathbf{E}^{(l)} \in \mathbb{R}^{h_e \times w_e \times c_e}$ e $\tilde{\mathbf{D}}^{(l)} \in \mathbb{R}^{h_d \times w_d \times c_d}$, com $h_e > h_d$ e $w_e > w_d$. Define-se então um operador de recorte $\mathcal{T}$ tal que

$$\mathbf{E}^{(l)}_{\text{crop}} = \mathcal{T}\big(\mathbf{E}^{(l)}\big) \in \mathbb{R}^{h_d \times w_d \times c_e}, \tag{259}$$

permitindo a concatenação:

$$\mathbf{C}^{(l)} = \mathrm{Concat}\big(\tilde{\mathbf{D}}^{(l)}, \mathbf{E}^{(l)}_{\text{crop}}\big). \tag{260}$$

Em implementações modernas, frequentemente utiliza-se *padding* para evitar esse descompasso dimensional, mas a lógica estrutural da arquitetura permanece a mesma.

Ao final do decodificador, aplica-se uma convolução 1×1 para mapear os canais internos para o número de classes de saída:

$$\mathbf{Z} = \mathbf{W}_{\text{out}} * \mathbf{D}^{(0)} + \mathbf{b}_{\text{out}}, \tag{261}$$

com

$$\mathbf{Z} \in \mathbb{R}^{H \times W \times K}. \tag{262}$$

A segmentação final é então produzida por

$$\hat{\mathbf{Y}} = \sigma(\mathbf{Z}) \quad \text{ou} \quad \hat{\mathbf{P}} = \mathrm{softmax}(\mathbf{Z}), \tag{263}$$

dependendo da formulação binária ou multiclasse adotada. O treinamento é conduzido, em geral, por perdas como entropia cruzada, Dice Loss ou combinações entre ambas:

$$\mathcal{L} = \lambda_1 \mathcal{L}_{\text{CE}} + \lambda_2 \mathcal{L}_{\text{Dice}}, \qquad \lambda_1, \lambda_2 \geq 0. \tag{264}$$

2.8.1.2 Skip connections e uso em medicina

As *skip connections* da U-Net diferem conceitualmente das conexões residuais típicas da família ResNet. Enquanto, em redes residuais, a conexão de atalho é somada

ao mapeamento transformado,

$$\mathbf{y} = \mathcal{F}(\mathbf{x}) + \mathbf{x}, \tag{265}$$

na U-Net o mecanismo predominante é a concatenação de características:

$$\mathbf{C}^{(l)} = \mathrm{Concat}\big(\tilde{\mathbf{D}}^{(l)}, \mathbf{E}^{(l)}\big). \tag{266}$$

Essa diferença é decisiva do ponto de vista funcional. Em vez de apenas facilitar o fluxo do gradiente, a concatenação permite transportar explicitamente mapas de características de alta resolução espacial do codificador para o decodificador, preservando detalhes finos que seriam perdidos caso a reconstrução dependesse apenas das representações profundas comprimidas no gargalo da rede. Isso é particularmente importante em segmentação médica, onde fronteiras anatômicas, pequenos contornos lesionais e transições sutis de textura possuem relevância clínica direta. :contentReference[oaicite:4]index=4

De forma mais analítica, se o codificador produz um mapa $\mathbf{E}^{(l)}$ com rica informação local e o decodificador produz $\tilde{\mathbf{D}}^{(l)}$ com forte conteúdo semântico global, a concatenação

$$\mathbf{C}^{(l)} = [\tilde{\mathbf{D}}^{(l)}; \mathbf{E}^{(l)}] \tag{267}$$

gera uma representação conjunta cuja dimensionalidade em canais é

$$C_{\mathbf{C}^{(l)}} = C_{\tilde{\mathbf{D}}^{(l)}} + C_{\mathbf{E}^{(l)}}. \tag{268}$$

As convoluções subsequentes podem então aprender funções que combinam seletivamente contexto e detalhe:

$$\mathbf{D}^{(l)} = \Psi\big(\tilde{\mathbf{D}}^{(l)}, \mathbf{E}^{(l)}\big), \tag{269}$$

onde Ψ representa o bloco convolucional posterior à concatenação. Em termos de capacidade representacional, isso equivale a oferecer ao decodificador acesso direto a bases de características de múltiplas escalas, aspecto fundamental para segmentação precisa.

No contexto biomédico, essa propriedade explica boa parte do sucesso da U-Net. Estruturas médicas frequentemente apresentam dimensões reduzidas, bordas irregulares e contraste limitado em relação ao fundo. Seja B a fronteira da estrutura de interesse. Um modelo que comprime excessivamente a representação sem preservar informação de alta resolução pode produzir uma aproximação $\hat{B}$ com erro espacial elevado:

$$d(\hat{B}, B) \gg 0, \tag{270}$$

onde $d(\cdot,\cdot)$ pode representar uma medida de distância de contorno. As *skip connections* da U-Net reduzem esse problema ao reinserir no decodificador informação

detalhada das camadas iniciais, permitindo recuperar melhor topologia e geometria da estrutura segmentada.

Outra razão para o uso disseminado da U-Net em medicina é sua adequação a regimes de dados limitados. O artigo original já enfatizava que a arquitetura, combinada com forte *data augmentation*, poderia ser treinada end-to-end a partir de poucas imagens anotadas, superando métodos anteriores em tarefas biomédicas de referência. Essa característica é altamente relevante em medicina, onde a anotação pixel-wise por especialistas é cara, demorada e, por vezes, difícil de padronizar. O sucesso posterior do *nnU-Net* reforçou esse ponto ao mostrar que variantes relativamente "simples" da U-Net, quando acompanhadas de escolhas bem ajustadas de pré-processamento, treinamento e inferência, permanecem extremamente competitivas em múltiplos domínios de segmentação médica.

Do ponto de vista metodológico, a U-Net consolidou-se como arquitetura de referência justamente por oferecer um compromisso notável entre simplicidade estrutural, desempenho segmentador e capacidade de adaptação a modalidades médicas muito diferentes, incluindo microscopia, tomografia, ressonância magnética e ultrassonografia. Revisões recentes a descrevem como a arquitetura mais difundida em segmentação médica, em parte por seu desenho modular e por sua flexibilidade para extensões com atenção, conexões densas, aprendizado multitarefa, variantes 3D e mecanismos automáticos de adaptação. Esse status de *baseline* forte é particularmente importante em trabalhos comparativos, porque a U-Net fornece um ponto de partida metodologicamente robusto para avaliar ganhos efetivos introduzidos por variantes arquiteturais mais sofisticadas.

Em síntese, a U-Net tornou-se central na segmentação médica porque responde de forma particularmente adequada às exigências do problema: incorpora contexto global por meio do *encoder*, recupera resolução espacial por meio do *decoder*, preserva detalhes relevantes por meio de *skip connections* e mantém uma estrutura suficientemente simples para ser treinada, adaptada e interpretada em diferentes modalidades de imagem. No contexto desta monografia, ela ocupa, portanto, o papel natural de arquitetura de referência para o eixo segmentador, tanto por sua relevância histórica quanto por sua comprovada eficácia prática em imagem biomédica.

2.8.2 Attention U-Net

A Attention U-Net foi proposta por Oktay et al. como uma extensão da U-Net clássica voltada a aumentar a seletividade espacial da rede durante a segmentação biomédica. A ideia central é incorporar *attention gates* (AGs) nas conexões entre codificador e decodificador, permitindo que a arquitetura suprima respostas irrelevantes do fundo e reforce regiões semanticamente mais compatíveis com a estrutura-alvo. No trabalho original, os autores mostraram que esses mecanismos podem ser acopla-

dos a CNNs segmentadoras com sobrecusto computacional relativamente pequeno, ao mesmo tempo em que aumentam sensibilidade e acurácia de predição em tarefas médicas desafiadoras. :contentReference[oaicite:0]index=0

Do ponto de vista funcional, a Attention U-Net preserva a topologia *encoder-decoder* da U-Net, mas modifica a forma como os mapas de características de alta resolução são transferidos ao caminho expansivo. Em vez de concatenar integralmente as ativações do codificador ao decodificador, a arquitetura aprende uma máscara de atenção que pondera essas ativações antes da fusão. Assim, se $\mathbf{x}^{(l)} \in \mathbb{R}^{H_l \times W_l \times C_l}$ representa o mapa de características do nível l do codificador e $\mathbf{g}^{(l)}$ representa um sinal de *gating* proveniente de uma representação mais profunda do decodificador, o bloco de atenção aprende uma transformação

$$\mathcal{A}^{(l)} : \left(\mathbf{x}^{(l)}, \mathbf{g}^{(l)}\right) \mapsto \hat{\mathbf{x}}^{(l)}, \tag{271}$$

onde $\hat{\mathbf{x}}^{(l)}$ corresponde ao mapa filtrado que será encaminhado ao estágio expansivo correspondente. Essa operação altera qualitativamente o papel da conexão de atalho: ela deixa de ser apenas um mecanismo de preservação de detalhe espacial e passa a atuar também como um mecanismo de seleção espacial condicionada ao contexto global. :contentReference[oaicite:1]index=1

2.8.2.1 Mecanismos de atenção

Em termos matemáticos, o *attention gate* da Attention U-Net segue uma formulação aditiva. Seja $x_i^{(l)} \in \mathbb{R}^{F_l}$ o vetor de características associado à posição espacial i do mapa $\mathbf{x}^{(l)}$, e seja $g_i^{(l)} \in \mathbb{R}^{F_g}$ o vetor de *gating* oriundo de uma escala mais profunda. O escore intermediário de atenção pode ser expresso por

$$q_i^{(l)} = \boldsymbol{\psi}^\top \delta\Big(\mathbf{W}_x^{(l)} x_i^{(l)} + \mathbf{W}_g^{(l)} g_i^{(l)} + \mathbf{b}_g^{(l)}\Big) + b_\psi^{(l)}, \tag{272}$$

onde $\mathbf{W}_x^{(l)}$ e $\mathbf{W}_g^{(l)}$ são transformações lineares aprendíveis, $\delta(\cdot)$ é uma não linearidade, usualmente ReLU, $\boldsymbol{\psi}$ é um vetor de projeção e $b_\psi^{(l)}$ é um viés escalar. O coeficiente de atenção escalar associado à posição i é então obtido por uma função sigmoide

$$\alpha_i^{(l)} = \sigma\Big(q_i^{(l)}\Big), \qquad \alpha_i^{(l)} \in (0,1). \tag{273}$$

Finalmente, o mapa filtrado é produzido por

$$\hat{x}_i^{(l)} = \alpha_i^{(l)}\, x_i^{(l)}. \tag{274}$$

Essa formulação é importante porque explicita que o mecanismo de atenção não cria novas características do zero; ele recalibra as ativações existentes, amplificando re-

giões mais compatíveis com o alvo e atenuando regiões menos informativas. :contentReference[oaicite:2]index=2

Em notação tensorial, se $\boldsymbol{\alpha}^{(l)} \in [0,1]^{H_l \times W_l \times 1}$ é o mapa de coeficientes de atenção expandido espacialmente, então a operação de filtragem pode ser representada como

$$\hat{\mathbf{x}}^{(l)} = \boldsymbol{\alpha}^{(l)} \odot \mathbf{x}^{(l)}, \tag{275}$$

onde $\odot$ denota multiplicação elemento a elemento com *broadcasting* ao longo dos canais. Após essa filtragem, a saída $\hat{\mathbf{x}}^{(l)}$ é concatenada ao mapa do decodificador:

$$\mathbf{C}^{(l)} = \mathrm{Concat}\big(\tilde{\mathbf{D}}^{(l)}, \hat{\mathbf{x}}^{(l)}\big), \tag{276}$$

e então processada por convoluções subsequentes. Comparada à U-Net clássica, essa modificação introduz um mecanismo explícito de seleção espacial dependente de contexto multiescala. Em vez de passar toda a informação do codificador, a rede aprende *onde olhar* em cada nível da hierarquia, propriedade que motivou o próprio nome da arquitetura. :contentReference[oaicite:3]index=3

Outro aspecto relevante é que o sinal de *gating* $\mathbf{g}^{(l)}$ provém de camadas mais profundas, portanto mais semânticas. Isso significa que a atenção é condicionada por contexto global e não apenas por informação local. Em termos intuitivos, o mecanismo responde à pergunta: “dadas as evidências de alto nível já disponíveis no decodificador, quais regiões do mapa de alta resolução do codificador devem ser privilegiadas?”. Essa dependência contextual é especialmente importante em segmentação médica, onde estruturas anatomicamente semelhantes podem coexistir no campo de visão e onde o fundo pode conter texturas ou padrões que confundem modelos puramente locais. Revisões recentes da literatura sobre atenção em segmentação médica mostram que esse tipo de mecanismo se tornou uma das extensões mais influentes da U-Net justamente por melhorar o foco da rede em estruturas relevantes sem exigir módulos externos de localização. :contentReference[oaicite:4]index=4

Do ponto de vista da otimização, a presença dos AGs também pode ser interpretada como uma forma de modulação dinâmica do fluxo de informação. Se $\mathbf{x}^{(l)}$ contém uma mistura de sinais úteis e ruído estrutural, a multiplicação por $\boldsymbol{\alpha}^{(l)}$ atua como um filtro aprendível dependente de contexto:

$$\mathbf{x}^{(l)} = \mathbf{s}^{(l)} + \mathbf{n}^{(l)} \quad \Longrightarrow \quad \hat{\mathbf{x}}^{(l)} \approx \boldsymbol{\alpha}^{(l)} \odot \mathbf{s}^{(l)} + \boldsymbol{\alpha}^{(l)} \odot \mathbf{n}^{(l)}, \tag{277}$$

com a expectativa de que, em regiões irrelevantes, $\alpha_i^{(l)}$ tenda a valores menores, reduzindo a propagação de componentes espúrias. Embora essa decomposição em sinal e ruído seja conceitual, ela ajuda a compreender por que o mecanismo de atenção pode melhorar a seletividade espacial em cenários de forte heterogeneidade visual.

:contentReference[oaicite:5]index=5

2.8.2.2 *Vantagens na delimitação de regiões relevantes*

A principal vantagem da Attention U-Net reside na sua capacidade de aumentar a precisão espacial da segmentação em cenários nos quais a estrutura-alvo é pequena, apresenta limites imprecisos ou está imersa em fundo altamente heterogêneo. Em imagens médicas, e particularmente em ultrassonografia, o modelo frequentemente precisa distinguir lesões com margens pouco definidas de padrões texturais de fundo, artefatos de aquisição e estruturas adjacentes. Nesses casos, a concatenação irrestrita de todos os mapas do codificador, como ocorre na U-Net clássica, pode introduzir ao decodificador uma quantidade excessiva de resposta irrelevante. O mecanismo de atenção procura corrigir precisamente esse problema ao privilegiar regiões espacialmente mais compatíveis com a hipótese anatômica que emerge dos níveis mais profundos da rede. :contentReference[oaicite:6]index=6

Seja $R \subset \Omega$ a região verdadeira da lesão e $\hat{R} \subset \Omega$ a região segmentada. A qualidade da delimitação pode ser avaliada por métricas de sobreposição como Dice e IoU:

$$\mathrm{Dice}(R, \hat{R}) = \frac{2|R \cap \hat{R}|}{|R| + |\hat{R}|}, \qquad \mathrm{IoU}(R, \hat{R}) = \frac{|R \cap \hat{R}|}{|R \cup \hat{R}|}. \tag{278}$$

Mecanismos de atenção tendem a melhorar essas métricas quando reduzem falsos positivos em regiões de fundo e preservam, ao mesmo tempo, os pixels realmente pertencentes à lesão. Em termos de contagem de pixels,

$$\mathrm{Precision} = \frac{TP}{TP + FP}, \qquad \mathrm{Recall} = \frac{TP}{TP + FN}. \tag{279}$$

A Attention U-Net é particularmente interessante porque, em muitos cenários, busca aumentar $\mathrm{Precision}$ sem degradar excessivamente Recall, ao reduzir ativações espúrias fora da estrutura-alvo. O trabalho original reporta justamente ganhos consistentes de sensibilidade e qualidade preditiva ao introduzir AGs em arquiteturas do tipo U-Net. :contentReference[oaicite:7]index=7

Outra vantagem importante é a eliminação da necessidade de módulos explícitos de localização grosseira. Em pipelines anteriores de segmentação médica, era relativamente comum empregar cascatas com uma etapa inicial de detecção ou localização aproximada da estrutura, seguida de segmentação refinada. A Attention U-Net busca internalizar parte dessa lógica no próprio modelo, fazendo com que os AGs atuem como mecanismos de *soft localization*. Se denotarmos por $\boldsymbol{\alpha}^{(l)}$ um mapa de atenção, ele pode ser interpretado como uma função de relevância espacial

$$\boldsymbol{\alpha}^{(l)} : \Omega_l \to (0, 1), \tag{280}$$

que atribui maior peso a regiões candidatas a conter a estrutura de interesse. Isso reduz a dependência de etapas externas e torna o pipeline mais integrado e potencialmente mais eficiente. :contentReference[oaicite:8]index=8

No contexto de segmentação médica, essa propriedade tem implicações práticas importantes. Estruturas pequenas, formas variáveis e margens anatômicas irregulares são problemas frequentes em diferentes modalidades, incluindo ultrassom, tomografia e ressonância magnética. Revisões recentes sobre mecanismos de atenção em segmentação médica destacam que Attention U-Net e variantes correlatas ganharam relevância precisamente por sua habilidade de tornar a seleção espacial mais específica, reduzindo interferência do fundo e melhorando a focalização da rede em regiões clinicamente relevantes. Em modalidades com ruído elevado e contraste limitado, como a ultrassonografia mamária, esse comportamento é particularmente valioso. :contentReference[oaicite:9]index=9

Do ponto de vista computacional, uma vantagem frequentemente ressaltada é que os AGs introduzem aumento de complexidade relativamente moderado quando comparado ao ganho potencial de segmentação. Se $\mathcal{C}_{\text{U-Net}}$ denota o custo da U-Net clássica e $\mathcal{C}_{\text{AG}}$ o custo adicional dos blocos de atenção, então a Attention U-Net pode ser vista como

$$\mathcal{C}_{\text{AttU-Net}} = \mathcal{C}_{\text{U-Net}} + \mathcal{C}_{\text{AG}}, \tag{281}$$

com $\mathcal{C}_{\text{AG}}$ pequeno em relação ao custo total da arquitetura em muitos cenários práticos. Isso torna a proposta metodologicamente atraente: ela adiciona seletividade espacial sem exigir uma reformulação completa da arquitetura-base ou um salto drástico de custo computacional. :contentReference[oaicite:10]index=10

Em síntese, a Attention U-Net pode ser entendida como uma evolução natural da U-Net para cenários em que a simples fusão simétrica entre codificador e decodificador não é suficiente para suprimir ambiguidades espaciais. Seus mecanismos de atenção permitem condicionar o fluxo de informação local ao contexto semântico global, melhorando a delimitação de regiões relevantes e tornando a arquitetura particularmente adequada para segmentação médica em ambientes ruidosos, heterogêneos e de elevada complexidade visual. :contentReference[oaicite:11]index=11

2.8.3 U-Net++

O U-Net++ foi proposto por Zhou et al. como uma reformulação estrutural da U-Net clássica, com o objetivo explícito de reduzir o hiato semântico (*semantic gap*) entre os mapas de características do codificador e do decodificador (**?**). A hipótese central da arquitetura é que a concatenação direta entre mapas de alta resolução do *encoder* e mapas semanticamente mais abstratos do *decoder*, embora eficaz, impõe ao otimizador uma tarefa de fusão potencialmente difícil quando esses mapas perten-

cem a níveis muito diferentes de abstração. O U-Net++ procura aliviar esse problema substituindo as conexões de atalho simples por caminhos aninhados e densamente conectados, nos quais os mapas intermediários são gradualmente refinados antes de serem entregues ao decodificador.

Seja

$$\mathbf{X} \in \mathbb{R}^{H \times W \times C} \tag{282}$$

a imagem de entrada e

$$f_{\boldsymbol{\theta}} : \mathbb{R}^{H \times W \times C} \to [0,1]^{H \times W \times K} \tag{283}$$

a função segmentadora parametrizada por $\boldsymbol{\theta}$. Como em arquiteturas do tipo U-Net, o objetivo é estimar, para cada pixel $p \in \Omega$, uma distribuição de probabilidade sobre K classes:

$$\hat{P}_{p,k} \approx P(Y_p = k \mid \mathbf{X}), \qquad \sum_{k=1}^{K} \hat{P}_{p,k} = 1. \tag{284}$$

A diferença essencial do U-Net++ não está na natureza da saída, mas na forma como as representações internas são organizadas e fusionadas ao longo da arquitetura.

2.8.3.1 Nested skip connections

A principal inovação do U-Net++ consiste na introdução de *nested skip connections*, isto é, caminhos de atalho aninhados e densamente conectados entre os níveis do codificador e do decodificador. Em vez de conectar diretamente um mapa do *encoder* a um mapa do *decoder* na mesma resolução, a arquitetura constrói uma malha de nós intermediários, de modo que a informação seja refinada progressivamente antes da concatenação final.

A notação clássica do U-Net++ representa por

$$X^{i,j} \tag{285}$$

o nó localizado na profundidade i e no nível de refinamento j, onde:

- i indexa o estágio de resolução;
- j indexa a profundidade ao longo do caminho de skip refinado.

Os nós com $j = 0$ pertencem ao caminho principal de codificação:

$$X^{i,0} = \mathcal{H}^{i,0}(X^{i-1,0}), \tag{286}$$

onde $\mathcal{H}^{i,0}(\cdot)$ representa um bloco convolucional seguido de redução espacial, e $X^{0,0}$ é a imagem de entrada ou a primeira transformação sobre ela.

Para $j > 0$, os nós aninhados são definidos por

$$X^{i,j} = \mathcal{H}^{i,j}\left(\left[X^{i,0}, X^{i,1}, \ldots, X^{i,j-1}, \mathcal{U}(X^{i+1,j-1})\right]\right), \tag{287}$$

onde:

- $[\cdot]$ denota concatenação ao longo dos canais;
- $\mathcal{U}(\cdot)$ representa a operação de *upsampling*;
- $\mathcal{H}^{i,j}(\cdot)$ é um bloco convolucional que transforma o tensor concatenado.

Essa equação explicita a natureza densa dos caminhos aninhados: cada nó $X^{i,j}$ recebe, simultaneamente, todos os mapas refinados anteriores no mesmo nível de resolução,

$$X^{i,0}, X^{i,1}, \ldots, X^{i,j-1}, \tag{288}$$

e também a informação proveniente do nível mais profundo, reamostrada por

$$\mathcal{U}(X^{i+1,j-1}). \tag{289}$$

Em consequência, o processo de fusão entre contexto profundo e detalhe espacial deixa de ocorrer em um único salto e passa a ser mediado por múltiplos estágios intermediários.

Do ponto de vista dimensional, se

$$X^{i,j-1} \in \mathbb{R}^{H_i \times W_i \times C_i}, \qquad \mathcal{U}(X^{i+1,j-1}) \in \mathbb{R}^{H_i \times W_i \times C'_i}, \tag{290}$$

então a concatenação em $X^{i,j}$ produz um tensor com número de canais igual a

$$C^{\mathsf{in}}_{i,j} = \sum_{t=0}^{j-1} C_{i,t} + C'_i. \tag{291}$$

Essa expansão controlada de canais permite que o bloco $\mathcal{H}^{i,j}$ aprenda combinações progressivamente mais ricas entre contexto semântico e detalhe local, algo que a U-Net clássica realiza de maneira mais direta e menos mediada.

Outro componente importante da formulação original é a *deep supervision*. Em vez de produzir apenas uma saída terminal, o U-Net++ pode gerar múltiplas saídas em diferentes profundidades do decodificador:

$$\hat{\mathbf{Y}}^{(1)}, \hat{\mathbf{Y}}^{(2)}, \ldots, \hat{\mathbf{Y}}^{(m)}, \tag{292}$$

cada uma associada a um nível distinto de refinamento. A função de perda total pode

então ser escrita como

$$\mathcal{L}_{\text{total}} = \sum_{j=1}^{m} \lambda_j \mathcal{L}^{(j)}, \qquad \lambda_j \geq 0, \tag{293}$$

onde $\mathcal{L}^{(j)}$ pode ser, por exemplo, uma combinação de entropia cruzada e Dice Loss:

$$\mathcal{L}^{(j)} = \alpha \mathcal{L}_{\text{CE}}^{(j)} + (1-\alpha)\mathcal{L}_{\text{Dice}}^{(j)}, \qquad \alpha \in [0,1]. \tag{294}$$

A *deep supervision* funciona como mecanismo adicional de regularização e pode facilitar o treinamento ao impor restrições úteis em diferentes níveis da malha decodificadora.

Em termos conceituais, o U-Net++ pode ser visto como uma generalização da U-Net:

$$\text{U-Net++} = \text{U-Net} + \text{nested dense skip pathways} + \text{deep supervision (opcional)}. \tag{295}$$

Essa formulação resume bem sua proposta: preservar a lógica *encoder-decoder*, mas enriquecer drasticamente a estrutura de fusão entre escalas.

2.8.3.2 Comparação conceitual com U-Net

A comparação entre U-Net e U-Net++ pode ser formulada, inicialmente, em termos da natureza das *skip connections*. Na U-Net clássica, um mapa do codificador $\mathbf{E}^{(l)}$ é encaminhado diretamente ao decodificador correspondente:

$$\mathbf{C}^{(l)} = \mathrm{Concat}\big(\tilde{\mathbf{D}}^{(l)}, \mathbf{E}^{(l)}\big), \tag{296}$$

onde $\tilde{\mathbf{D}}^{(l)}$ é o mapa reamostrado do decodificador. Essa estratégia é simples e eficiente, mas implica a fusão imediata de dois tipos de representação potencialmente muito diferentes: uma mais local e de baixa abstração, proveniente do codificador, e outra mais semântica e global, proveniente do decodificador.

No U-Net++, essa fusão é substituída por uma sequência de transformações intermediárias:

$$\mathbf{E}^{(l)} \;\to\; X^{l,1} \;\to\; X^{l,2} \;\to\; \ldots \;\to\; X^{l,m}, \tag{297}$$

de modo que o mapa recebido pelo decodificador em cada estágio já passou por sucessivos refinamentos e concatenações. Conceitualmente, isso significa que o U-Net++ não considera suficiente transportar detalhe espacial bruto do codificador; ele assume que esse detalhe deve ser semântica e progressivamente adaptado ao processo de reconstrução.

Esse ponto pode ser formalizado pela noção de hiato semântico. Se $\phi_E^{(l)}$ representa o espaço de características no nível l do codificador e $\phi_D^{(l)}$ o espaço correspondente

no decodificador, pode-se pensar o problema da U-Net clássica como a fusão direta de representações com distância semântica

$$\Delta^{(l)} = d\big(\phi_E^{(l)}, \phi_D^{(l)}\big), \tag{298}$$

onde $d(\cdot,\cdot)$ representa, de forma abstrata, uma medida de dissimilaridade entre distribuições de características. A hipótese do U-Net++ é que as conexões aninhadas reduzem essa distância de forma progressiva:

$$d\big(\phi_E^{(l)}, \phi_D^{(l)}\big) > d\big(\phi_{X^{l,1}}, \phi_D^{(l)}\big) > d\big(\phi_{X^{l,2}}, \phi_D^{(l)}\big) > \dots \tag{299}$$

Mesmo que essa desigualdade não seja calculada explicitamente no treinamento, ela expressa a motivação conceitual do modelo: tornar a fusão entre encoder e decoder mais fácil para o otimizador.

Outra diferença importante está na granularidade multiescala. A U-Net opera com uma única conexão lateral por resolução. O U-Net++, por outro lado, cria múltiplos caminhos dentro da mesma resolução, o que produz uma malha mais densa e permite maior diversidade de trajetórias para propagação de informação. Em notação simplificada, se o número de caminhos laterais da U-Net em um nível l é

$$N_{\text{skip}}^{\text{U-Net}}(l) = 1, \tag{300}$$

no U-Net++ esse número cresce com o grau de aninhamento:

$$N_{\text{skip}}^{\text{U-Net++}}(l) = m_l, \qquad m_l > 1. \tag{301}$$

Isso aumenta a expressividade do modelo, mas também eleva sua complexidade estrutural.

Do ponto de vista computacional, essa maior expressividade implica custo adicional. Se $\mathcal{P}_{\text{U-Net}}$ representa o número de parâmetros da U-Net e $\mathcal{P}_{\text{U-Net++}}$ o número de parâmetros do U-Net++, em geral observa-se

$$\mathcal{P}_{\text{U-Net++}} > \mathcal{P}_{\text{U-Net}}, \tag{302}$$

e, de forma análoga, para o custo de inferência,

$$T_{\text{inf}}^{\text{U-Net++}} > T_{\text{inf}}^{\text{U-Net}} \tag{303}$$

em muitos cenários práticos. Portanto, a comparação entre ambas as arquiteturas deve ser entendida como um problema de compromisso entre maior capacidade de modelagem e maior custo operacional.

Em termos metodológicos, pode-se resumir a distinção conceitual entre as duas arquiteturas da seguinte maneira:

$$\text{U-Net} : \text{fusão direta entre encoder e decoder}, \tag{304}$$

$$\text{U-Net++} : \text{fusão progressiva, densa e semanticamente mediada}. \tag{305}$$

A U-Net privilegia simplicidade e forte desempenho de base; o U-Net++ privilegia refinamento estrutural da comunicação entre escalas. Em problemas médicos nos quais a estrutura-alvo apresenta contornos complexos, forte variabilidade morfológica ou transições pouco definidas com o fundo, essa diferença pode ser relevante. Por outro lado, em bases moderadas ou cenários de restrição computacional, o ganho estrutural do U-Net++ nem sempre se traduzirá em superioridade prática inequívoca.

Assim, o U-Net++ deve ser compreendido como uma evolução conceitual da U-Net, orientada menos a substituir a arquitetura original em caráter universal e mais a testar a hipótese de que *skip connections* redesenhadas podem tornar a fusão multiescala mais rica, reduzir o hiato semântico e melhorar a segmentação em domínios biomédicos complexos.

2.8.4 DeepLabV3+

A arquitetura DeepLabV3+ foi proposta como uma extensão do DeepLabV3 com o objetivo de combinar, em um mesmo modelo, dois requisitos frequentemente conflitantes em segmentação semântica: ampla captura de contexto multiescala e recuperação precisa de fronteiras espaciais. Em termos conceituais, a arquitetura pode ser vista como uma composição entre um codificador (*encoder*) responsável por extrair representações profundas com grande campo receptivo e um decodificador (*decoder*) relativamente leve, destinado a refinar a segmentação final, sobretudo nas bordas dos objetos. Seja

$$\mathbf{X} \in \mathbb{R}^{H \times W \times C} \tag{306}$$

uma imagem de entrada e

$$f_{\boldsymbol{\theta}} : \mathbb{R}^{H \times W \times C} \to [0,1]^{H \times W \times K} \tag{307}$$

a função segmentadora parametrizada por $\boldsymbol{\theta}$. O objetivo é estimar, para cada pixel $p \in \Omega$, com

$$\Omega = \{1, \ldots, H\} \times \{1, \ldots, W\}, \tag{308}$$

uma distribuição de probabilidade sobre K classes:

$$\hat{P}_{p,k} \approx P(Y_p = k \mid \mathbf{X}), \qquad \sum_{k=1}^{K} \hat{P}_{p,k} = 1. \tag{309}$$

Na formulação multiclasse, a saída final é tipicamente obtida por

$$\hat{P}_{p,k} = \frac{\exp(z_{p,k})}{\sum_{j=1}^{K} \exp(z_{p,j})}, \tag{310}$$

onde $z_{p,k}$ é o logit associado ao pixel p e à classe k. Em tarefas binárias, é comum utilizar uma única saída sigmoidal:

$$\hat{Y}_p = \sigma(z_p) = \frac{1}{1 + e^{-z_p}}. \tag{311}$$

O treinamento pode ser realizado com perdas pixel-wise, como entropia cruzada, ou com perdas orientadas a sobreposição, como Dice Loss, frequentemente em combinação:

$$\mathcal{L} = \lambda_1 \mathcal{L}_{\text{CE}} + \lambda_2 \mathcal{L}_{\text{Dice}}, \qquad \lambda_1, \lambda_2 \geq 0. \tag{312}$$

A especificidade do DeepLabV3+ reside no fato de que o codificador incorpora convoluções atrous e o módulo ASPP (*Atrous Spatial Pyramid Pooling*), enquanto o decodificador explora mapas intermediários de baixa profundidade para recuperar detalhes espaciais perdidos no processo de extração semântica. Em termos funcionais, a arquitetura pode ser representada como

$$f_{\boldsymbol{\theta}}(\mathbf{X}) = \mathcal{D}\Big(\mathcal{E}_{\text{ASPP}}(\mathbf{X}), \mathcal{L}_{\text{low}}(\mathbf{X})\Big), \tag{313}$$

onde $\mathcal{E}_{\text{ASPP}}(\cdot)$ denota o codificador com agregação multiescala e $\mathcal{L}_{\text{low}}(\cdot)$ representa a extração de características de baixo nível reutilizadas pelo decodificador.

2.8.4.1 Atrous convolution

A *atrous convolution*, também chamada de *dilated convolution*, é uma generalização da convolução discreta padrão que permite ampliar o campo receptivo sem aumentar proporcionalmente o número de parâmetros e sem reduzir a resolução dos mapas de ativação. Seja uma entrada unidimensional $x[i]$ e um filtro $w[k]$ de comprimento K. A convolução atrous com taxa de dilatação r é dada por

$$y[i] = \sum_{k=1}^{K} x[i + r \cdot k]\, w[k]. \tag{314}$$

No caso bidimensional, para uma imagem X e um filtro W de tamanho $k_h \times k_w$, a operação pode ser escrita como

$$Y_{i,j} = \sum_{u=0}^{k_h-1} \sum_{v=0}^{k_w-1} W_{u,v}\, X_{i+ru,\, j+rv}. \tag{315}$$

Quando $r = 1$, recupera-se a convolução densa usual. Para $r > 1$, elementos do filtro passam a "saltar" posições intermediárias, o que aumenta o campo receptivo efetivo.

Se o *kernel* possui tamanho $k \times k$, o tamanho efetivo do campo receptivo da convolução atrous é

$$k_{\text{eff}} = k + (k-1)(r-1). \tag{316}$$

Por exemplo, um filtro 3×3 com taxa $r = 2$ possui campo receptivo efetivo

$$k_{\text{eff}} = 3 + 2(2-1) = 5, \tag{317}$$

e com $r = 3$,

$$k_{\text{eff}} = 3 + 2(3-1) = 7. \tag{318}$$

Assim, filtros pequenos podem cobrir regiões maiores sem elevar o custo paramétrico. O número de parâmetros permanece

$$P_{\text{atrous}} = k_h k_w C_{\text{in}} C_{\text{out}}, \tag{319}$$

igual ao de uma convolução padrão com o mesmo *kernel*, embora o campo receptivo seja maior.

Essa propriedade é crucial em segmentação semântica, pois o modelo precisa combinar informação local detalhada com contexto mais amplo. Em arquiteturas tradicionais, esse aumento de contexto costuma ser obtido por sucessivas operações de *pooling* ou por convoluções com *stride* maior, o que reduz a resolução espacial dos mapas. A convolução atrous evita esse custo, preservando mapas mais densos:

$$H_{\text{out}} \approx H_{\text{in}}, \qquad W_{\text{out}} \approx W_{\text{in}}, \tag{320}$$

quando se usa *stride* unitário e *padding* adequado.

No DeepLabV3+, as convoluções atrous são usadas tanto no *backbone* quanto no módulo ASPP. O ASPP pode ser descrito como um conjunto de transformações paralelas com taxas de dilatação distintas:

$$\mathbf{F}_{\text{ASPP}} = \mathrm{Concat}\Big(\mathcal{C}_{1\times1}(\mathbf{F}), \mathcal{C}^{(r_1)}_{3\times3}(\mathbf{F}), \mathcal{C}^{(r_2)}_{3\times3}(\mathbf{F}), \mathcal{C}^{(r_3)}_{3\times3}(\mathbf{F}), \mathcal{G}(\mathbf{F})\Big), \tag{321}$$

onde:

- $\mathbf{F}$ é o mapa profundo de entrada;
- $\mathcal{C}_{1\times1}$ é uma convolução pontual;
- $\mathcal{C}^{(r)}_{3\times3}$ é uma convolução atrous 3×3 com taxa r;
- $\mathcal{G}(\mathbf{F})$ representa o ramo de contexto global.

Após concatenação, aplica-se uma projeção linear ou convolucional:

$$\mathbf{F}_{\text{proj}} = \mathcal{P}\big(\mathbf{F}_{\text{ASPP}}\big). \tag{322}$$

Outro aspecto importante do DeepLabV3+ é o uso de *atrous separable convolution*, isto é, a combinação entre convolução atrous e convolução separável em profundidade. Seja uma entrada com C_{in} canais e saída com C_{out} canais. O custo aproximado de uma convolução densa $k \times k$ é

$$\text{FLOPs}_{\text{conv}} \propto HWk^2 C_{\text{in}} C_{\text{out}}, \tag{323}$$

enquanto a versão separável em profundidade com projeção pontual tem custo aproximado

$$\text{FLOPs}_{\text{sep}} \propto HW\left(k^2 C_{\text{in}} + C_{\text{in}} C_{\text{out}}\right). \tag{324}$$

Ao combinar isso com dilatação, o DeepLabV3+ obtém grande campo receptivo e eficiência computacional relativamente melhor que variantes densas mais caras.

2.8.4.2 Captura de contexto global

A captura de contexto global é uma das motivações centrais do DeepLabV3+. Em segmentação semântica, especialmente em imagens médicas, a atribuição correta de um rótulo a um pixel não depende apenas da intensidade local, mas frequentemente do arranjo anatômico ao redor, da textura regional e da coerência espacial em escalas maiores. Formalmente, para um pixel p, o classificador ideal estima

$$P(Y_p = k \mid \mathbf{X}), \tag{325}$$

mas essa probabilidade pode depender de uma vizinhança efetiva muito maior que a local:

$$P(Y_p = k \mid \mathbf{X}) \approx P\big(Y_p = k \mid \mathbf{X}|_{\mathcal{N}_R(p)}\big), \tag{326}$$

onde $\mathcal{N}_R(p)$ é uma região de raio R ao redor de p. Quanto maior e mais informativo o contexto efetivamente acessado pela rede, mais robusta tende a ser a decisão segmentadora.

No DeepLabV3+, esse contexto é capturado principalmente por dois mecanismos. O primeiro é o ASPP, que amostra o mapa profundo em múltiplas escalas simultaneamente por taxas de dilatação distintas. Se r_1, r_2, r_3 representam essas taxas, então os ramos paralelos aproximam diferentes campos receptivos:

$$k_{\text{eff}}^{(m)} = k + (k-1)(r_m - 1), \qquad m \in \{1, 2, 3\}. \tag{327}$$

Isso permite que o modelo responda tanto a estruturas pequenas quanto a padrões mais amplos de contexto anatômico.

O segundo mecanismo é o ramo de contexto global, implementado por *global average pooling*. Dado um mapa profundo

$$\mathbf{F} \in \mathbb{R}^{H' \times W' \times C}, \tag{328}$$

calcula-se, para cada canal,

$$g_c = \frac{1}{H'W'} \sum_{i=1}^{H'} \sum_{j=1}^{W'} F_{i,j,c}. \tag{329}$$

O vetor $\mathbf{g} \in \mathbb{R}^C$ é então projetado e reamostrado para dimensão espacial compatível com os demais ramos do ASPP:

$$\tilde{\mathbf{G}} = \mathcal{U}\big(\mathcal{T}(\mathbf{g})\big). \tag{330}$$

Essa operação fornece uma representação de contexto global de toda a imagem, tornando o modelo sensível não apenas a padrões locais ou regionais, mas também à configuração global do campo visual.

Essa combinação entre contexto multiescala e refino espacial é o que distingue o DeepLabV3+ de arquiteturas puramente encoder-decoder ou puramente baseadas em pirâmides de contexto. O codificador profundo com ASPP gera uma representação

$$\mathbf{F}_{\text{enc}} = \mathcal{E}_{\text{ASPP}}(\mathbf{X}), \tag{331}$$

rica em contexto semântico, enquanto o decodificador leve incorpora um mapa de baixo nível

$$\mathbf{F}_{\text{low}} = \mathcal{L}_{\text{low}}(\mathbf{X}), \tag{332}$$

reduzindo seu número de canais por uma projeção

$$\mathbf{F}'_{\text{low}} = \mathcal{P}_{\text{low}}(\mathbf{F}_{\text{low}}), \tag{333}$$

antes da concatenação com a representação profunda reamostrada:

$$\mathbf{F}_{\text{dec}} = \mathrm{Concat}\big(\mathcal{U}(\mathbf{F}_{\text{enc}}), \mathbf{F}'_{\text{low}}\big). \tag{334}$$

Convoluções subsequentes refinam essa fusão e produzem a segmentação final.

Em imagens médicas, essa estratégia é particularmente relevante. Lesões, órgãos e tecidos frequentemente apresentam ambiguidade local: um mesmo padrão de intensidade pode ter significados distintos a depender do contexto anatômico. A inclusão

explícita de contexto global ajuda a reduzir falsas ativações em regiões visualmente semelhantes ao alvo, enquanto o decodificador melhora a recuperação de fronteiras e detalhes finos. Em termos conceituais, o DeepLabV3+ tenta resolver simultaneamente dois problemas:

(i) como incorporar contexto sem perder resolução espacial, (335)

(ii) como recuperar bordas nítidas após extração semântica profunda. (336)

Pode-se, portanto, interpretar a utilidade da arquitetura como um compromisso entre desempenho espacial e custo computacional:

$$\mathcal{U} = \mathcal{U}\big(\mathcal{M}_{\text{seg}}, \mathcal{P}, T_{\text{inf}}, \text{FLOPs}\big), \tag{337}$$

onde $\mathcal{M}_{\text{seg}}$ representa métricas como Dice ou IoU, $\mathcal{P}$ o número de parâmetros e T_{inf} o tempo de inferência. O DeepLabV3+ torna-se especialmente atrativo quando o ganho advindo da captura multiescala de contexto e do refino de bordas compensa o aumento de complexidade em relação a segmentadores mais simples.

Em síntese, o DeepLabV3+ representa uma arquitetura particularmente robusta para segmentação semântica porque combina três propriedades altamente desejáveis: uso de convoluções atrous para ampliar o campo receptivo, ASPP para agregação multiescala de contexto e um decodificador leve para refino espacial. No contexto desta monografia, ele é especialmente relevante como contraponto à família U-Net, por oferecer uma estratégia distinta de segmentação, mais orientada à modelagem explícita de contexto global do que à fusão simétrica de múltiplas escalas por conexões laterais densas.

2.9 Técnicas complementares

2.9.1 Data augmentation

Em tarefas de aprendizado profundo aplicadas a imagens médicas, a disponibilidade de dados rotulados é frequentemente limitada, seja pelo custo de aquisição, seja pela necessidade de anotação especializada. Nesse contexto, *data augmentation* constitui uma estratégia central para reduzir sobreajuste, ampliar a diversidade amostral observada durante o treinamento e induzir invariâncias úteis ao modelo (**??**). Em termos probabilísticos, se o conjunto de treinamento original é

$$\mathcal{D} = \{(\mathbf{X}_i, y_i)\}_{i=1}^{N}, \tag{338}$$

o objetivo do *augmentation* é construir amostras transformadas

$$\tilde{\mathbf{X}}_i = T_{\boldsymbol{\xi}}(\mathbf{X}_i), \tag{339}$$

onde $T_{\boldsymbol{\xi}}$ é uma transformação parametrizada por uma variável aleatória $\boldsymbol{\xi}$ pertencente a um espaço de transformações admissíveis Ξ. O conjunto efetivamente visto pela rede em treinamento pode ser interpretado como amostras extraídas de uma distribuição aumentada

$$P_{\text{aug}}(\mathbf{X}, y) = \int_{\Xi} P(T_{\boldsymbol{\xi}}(\mathbf{X}), y)\; p(\boldsymbol{\xi})\, d\boldsymbol{\xi}, \tag{340}$$

onde $p(\boldsymbol{\xi})$ é a distribuição das transformações aplicadas.

Em sua forma mais clássica, o *augmentation* busca preservar o rótulo da amostra sob transformações que não alterem a semântica clínica do caso:

$$y\big(T_{\boldsymbol{\xi}}(\mathbf{X})\big) = y(\mathbf{X}), \qquad \forall \boldsymbol{\xi} \in \Xi_{\text{válida}}. \tag{341}$$

No caso da ultrassonografia mamária, esse princípio impõe uma restrição metodológica importante: nem toda transformação geometricamente possível é clinicamente plausível. Transformações como rotações moderadas, espelhamento horizontal, pequenas variações de escala, deslocamento, recorte e ajustes suaves de brilho/contraste podem ser admissíveis, ao passo que deformações excessivas, reamostragem agressiva ou manipulações que alterem artificialmente a morfologia da lesão podem comprometer a validade do experimento.

Seja $\mathbf{X} \in \mathbb{R}^{H \times W \times C}$. Algumas transformações geométricas podem ser modeladas como

$$T_{\text{aff}}(\mathbf{x}) = \mathbf{A}\mathbf{x} + \mathbf{b}, \tag{342}$$

onde $\mathbf{x}$ representa a coordenada homogênea de um pixel, $\mathbf{A}$ é uma transformação linear e $\mathbf{b}$ uma translação. Casos particulares incluem:

- rotação por ângulo θ:

$$\mathbf{A}_{\text{rot}}(\theta) = \begin{bmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{bmatrix}, \tag{343}$$

- escalonamento por fatores s_x, s_y:

$$\mathbf{A}_{\text{scale}} = \begin{bmatrix} s_x & 0 \\ 0 & s_y \end{bmatrix}, \tag{344}$$

- reflexão horizontal:

$$\mathbf{A}_{\text{flip}} = \begin{bmatrix} -1 & 0 \\ 0 & 1 \end{bmatrix}. \tag{345}$$

Transformações fotométricas, por sua vez, podem ser descritas por operações como

$$\tilde{\mathbf{X}} = a\mathbf{X} + b, \tag{346}$$

onde $a > 0$ controla contraste e b ajusta brilho. Em modalidades médicas, tais transformações devem ser aplicadas com cautela, pois o intervalo de intensidades pode carregar informação diagnóstica. Em ultrassom, pequenas perturbações de brilho e contraste podem aumentar robustez do modelo a variações de aquisição, desde que não modifiquem significativamente a textura e a aparência clínica da lesão.

Em segmentação, o *augmentation* deve ser aplicado de forma consistente à imagem e à máscara de referência. Se

$$(\mathbf{X}, \mathbf{Y}) \tag{347}$$

representa um par imagem–máscara, então a transformação correta é

$$(\tilde{\mathbf{X}}, \tilde{\mathbf{Y}}) = \big(T_{\boldsymbol{\xi}}(\mathbf{X}), T_{\boldsymbol{\xi}}(\mathbf{Y})\big), \tag{348}$$

preservando correspondência espacial entre entrada e alvo. Em máscaras binárias, essa consistência é indispensável; caso contrário, o treinamento passa a receber pares semanticamente inconsistentes.

Além de transformações geométricas e fotométricas simples, a literatura recente contempla estratégias compostas e estocásticas, como *mixup*, *CutMix*, *random erasing* e métodos gerativos (**??**). No *mixup*, por exemplo, duas amostras $(\mathbf{X}_i, y_i)$ e $(\mathbf{X}_j, y_j)$ são combinadas por

$$\tilde{\mathbf{X}} = \lambda \mathbf{X}_i + (1 - \lambda)\mathbf{X}_j, \tag{349}$$

$$\tilde{y} = \lambda y_i + (1 - \lambda) y_j, \tag{350}$$

com $\lambda \sim \mathrm{Beta}(\alpha, \alpha)$. Embora metodologicamente interessantes, tais estratégias exigem interpretação mais cuidadosa em cenários médicos, nos quais a plausibilidade anatômica das amostras sintéticas nem sempre é trivial.

Do ponto de vista da generalização, o *data augmentation* pode ser interpretado como uma forma de regularização implícita, pois impõe ao classificador ou segmentador a necessidade de aprender uma função aproximadamente invariante ou aproximadamente equivariante a um conjunto de transformações:

$$f_{\boldsymbol{\theta}}(T_{\boldsymbol{\xi}}(\mathbf{X})) \approx f_{\boldsymbol{\theta}}(\mathbf{X}) \tag{351}$$

para classificação, ou

$$f_{\boldsymbol{\theta}}(T_{\boldsymbol{\xi}}(\mathbf{X})) \approx T_{\boldsymbol{\xi}}\big(f_{\boldsymbol{\theta}}(\mathbf{X})\big) \tag{352}$$

para segmentação. Essa distinção entre invariância e equivariância é fundamental para desenhar protocolos de *augmentation* cientificamente coerentes.

2.9.2 Balanceamento de classes

O desbalanceamento de classes constitui um dos principais desafios em problemas de classificação e segmentação médica, sobretudo quando a condição de interesse corresponde à classe minoritária e seus erros têm custo clínico elevado (**??**). Seja um problema multiclasse com K classes e N_k exemplos na classe k. Diz-se que o conjunto está desbalanceado quando

$$N_i \neq N_j \qquad \text{para alguns } i, j \in \{1, \ldots, K\}, \tag{353}$$

e o grau de desbalanceamento pode ser expresso por razões do tipo

$$\mathrm{IR}_{ij} = \frac{N_i}{N_j}. \tag{354}$$

Em classificação binária, uma forma simples de quantificar o desbalanceamento é

$$\mathrm{IR} = \frac{N_{\text{majoritária}}}{N_{\text{minoritaria}}}. \tag{355}$$

Em cenários desbalanceados, a minimização ingênua da perda média pode induzir o modelo a privilegiar a classe majoritária. Para uma perda de entropia cruzada padrão,

$$\mathcal{L}_{\text{CE}} = -\frac{1}{N} \sum_{i=1}^{N} \sum_{k=1}^{K} y_{i,k} \log(\hat{p}_{i,k}), \tag{356}$$

a contribuição esperada de cada classe ao gradiente total é aproximadamente proporcional ao número de amostras daquela classe. Isso pode gerar soluções enviesadas, nas quais a fronteira de decisão minimiza erro global às custas de sensibilidade reduzida nas classes raras.

Uma estratégia clássica para mitigar esse efeito é o *reweighting* da função de perda. Introduzindo pesos $w_k > 0$ por classe, obtém-se

$$\mathcal{L}_{\text{WCE}} = -\frac{1}{N} \sum_{i=1}^{N} \sum_{k=1}^{K} w_k \, y_{i,k} \log(\hat{p}_{i,k}). \tag{357}$$

Uma escolha comum é

$$w_k \propto \frac{1}{N_k}, \tag{358}$$

ou, de forma normalizada,

$$w_k = \frac{N}{KN_k}. \tag{359}$$

Essas formulações buscam aumentar a penalização dos erros em classes subrepresentadas. Em aplicações médicas, onde a classe positiva ou maligna pode ser a de maior interesse clínico, esse tipo de ponderação é particularmente útil.

Outra abordagem envolve reamostragem do conjunto de treinamento. No *oversampling* da classe minoritária, constroem-se conjuntos com multiplicação ou geração sintética de exemplos raros, enquanto no *undersampling* reduz-se a presença da classe majoritária. Seja $\mathcal{D}_k$ o subconjunto de exemplos da classe k. O *oversampling* pode ser interpretado como a construção de uma distribuição empírica modificada

$$\tilde{P}(Y = k) \approx \frac{1}{K}, \tag{360}$$

por replicação ou geração adicional de amostras. Já o *undersampling* busca reduzir $N_{\text{majoritária}}$, mas pode desperdiçar informação valiosa se aplicado de forma agressiva.

No contexto de segmentação, o desbalanceamento é ainda mais pronunciado porque a maioria dos pixels costuma pertencer ao fundo. Seja

$$|\Omega_{\text{fg}}| \ll |\Omega_{\text{bg}}|, \tag{361}$$

onde Ω_{fg} representa a região de interesse e Ω_{bg} o fundo. Nesses casos, a perda pixel-wise padrão pode induzir o modelo a prever predominantemente fundo, obtendo alta acurácia superficial, mas baixa utilidade clínica. Esse problema motiva tanto perdas ponderadas quanto perdas baseadas em sobreposição, discutidas adiante.

Do ponto de vista teórico, o balanceamento de classes pode ser visto como uma tentativa de redefinir o risco empírico de forma a aproximá-lo de um objetivo clínico mais relevante:

$$\hat{\mathcal{R}}(\boldsymbol{\theta}) = \frac{1}{N}\sum_{i=1}^{N} \mathcal{L}(f_{\boldsymbol{\theta}}(\mathbf{X}_i), y_i) \quad \longrightarrow \quad \hat{\mathcal{R}}_{\text{bal}}(\boldsymbol{\theta}) = \frac{1}{N}\sum_{i=1}^{N} w_{y_i}\, \mathcal{L}(f_{\boldsymbol{\theta}}(\mathbf{X}_i), y_i). \tag{362}$$

Em medicina, essa reformulação é especialmente importante porque o custo dos erros é assimétrico: um falso negativo em uma classe maligna pode ser consideravelmente mais grave do que um falso positivo.

2.9.3 Funções de perda para classificação

A função de perda em classificação supervisionada quantifica a discrepância entre a distribuição predita pelo modelo e os rótulos observados. Em um problema multi-

classe, seja

$$\hat{\mathbf{p}}_i = (\hat{p}_{i,1}, \ldots, \hat{p}_{i,K}), \qquad \hat{p}_{i,k} = \frac{\exp(z_{i,k})}{\sum_{j=1}^{K} \exp(z_{i,j})}, \tag{363}$$

e seja $\mathbf{y}_i = (y_{i,1}, \ldots, y_{i,K})$ o vetor *one-hot* do rótulo verdadeiro. A perda de entropia cruzada categórica é dada por

$$\mathcal{L}_{\text{CE}} = -\frac{1}{N} \sum_{i=1}^{N} \sum_{k=1}^{K} y_{i,k} \log(\hat{p}_{i,k}). \tag{364}$$

No caso binário, com probabilidade escalar $\hat{p}_i$, a versão correspondente é

$$\mathcal{L}_{\text{BCE}} = -\frac{1}{N} \sum_{i=1}^{N} \left[y_i \log(\hat{p}_i) + (1 - y_i) \log(1 - \hat{p}_i) \right]. \tag{365}$$

A entropia cruzada pode ser interpretada como a divergência entre a distribuição empírica dos rótulos e a distribuição predita pelo modelo. Em termos de máxima verossimilhança, sua minimização equivale a maximizar a probabilidade dos dados sob o modelo parametrizado. No entanto, em bases desbalanceadas, a entropia cruzada padrão pode ser insuficiente. Por isso, sua forma ponderada

$$\mathcal{L}_{\text{WCE}} = -\frac{1}{N} \sum_{i=1}^{N} \sum_{k=1}^{K} w_k \, y_{i,k} \log(\hat{p}_{i,k}) \tag{366}$$

torna-se particularmente relevante, pois introduz maior penalização para erros em classes sub-representadas.

Uma extensão importante nesse contexto é a *Focal Loss*, proposta por Lin et al. para lidar com forte desbalanceamento e abundância de exemplos fáceis (**?**). Para classificação binária, define-se

$$p_t = \begin{cases} \hat{p}, & \text{se } y = 1, \\ 1 - \hat{p}, & \text{se } y = 0. \end{cases} \tag{367}$$

A *Focal Loss* é então

$$\mathcal{L}_{\text{FL}} = -\alpha (1 - p_t)^{\gamma} \log(p_t), \tag{368}$$

onde $\alpha \in [0, 1]$ controla o peso da classe e $\gamma \geq 0$ é o parâmetro de focalização. Quando $\gamma = 0$, recupera-se a entropia cruzada ponderada. À medida que γ aumenta, a perda atribuída a exemplos bem classificados ($p_t \approx 1$) é reduzida:

$$(1 - p_t)^{\gamma} \to 0 \qquad \text{quando } p_t \to 1. \tag{369}$$

Isso força o treinamento a concentrar-se em exemplos difíceis ou minoritários, carac-

terística especialmente valiosa em classificação médica.

Outra técnica complementar é o *label smoothing*, que substitui rótulos *one-hot* por distribuições suavizadas:

$$y_{i,k}^{(\epsilon)} = (1-\epsilon)y_{i,k} + \frac{\epsilon}{K}, \qquad \epsilon \in [0,1]. \tag{370}$$

A perda torna-se

$$\mathcal{L}_{\text{LS}} = -\frac{1}{N}\sum_{i=1}^{N}\sum_{k=1}^{K} y_{i,k}^{(\epsilon)} \log(\hat{p}_{i,k}), \tag{371}$$

o que reduz excesso de confiança do classificador e pode melhorar calibração probabilística.

De forma geral, a função objetivo da classificação pode ser escrita como

$$\mathcal{J}(\boldsymbol{\theta}) = \mathcal{L}_{\text{cls}}(\boldsymbol{\theta}) + \lambda\Omega(\boldsymbol{\theta}), \tag{372}$$

onde $\mathcal{L}_{\text{cls}}$ pode ser CE, WCE, Focal Loss ou variantes, e $\Omega(\boldsymbol{\theta})$ representa regularização explícita, como penalização L_2:

$$\Omega(\boldsymbol{\theta}) = \|\boldsymbol{\theta}\|_2^2. \tag{373}$$

2.9.4 Funções de perda para segmentação

Em segmentação, a função de perda deve refletir a natureza densa e espacial do problema. Para uma máscara binária $\mathbf{Y} \in \{0,1\}^{H\times W}$ e uma predição probabilística $\hat{\mathbf{Y}} \in [0,1]^{H\times W}$, a entropia cruzada binária pixel-wise é dada por

$$\mathcal{L}_{\text{BCE}} = -\frac{1}{|\Omega|}\sum_{p\in\Omega}\left[Y_p \log(\hat{Y}_p) + (1-Y_p)\log(1-\hat{Y}_p)\right]. \tag{374}$$

Na formulação multiclasse, tem-se

$$\mathcal{L}_{\text{CE}} = -\frac{1}{|\Omega|}\sum_{p\in\Omega}\sum_{k=1}^{K} Y_{p,k}\log(\hat{P}_{p,k}). \tag{375}$$

Embora matematicamente natural, essa perda sofre fortemente com o desbalanceamento fundo–objeto, comum em segmentação médica.

Por isso, perdas baseadas em sobreposição tornaram-se amplamente adotadas. O coeficiente de Dice para segmentação binária pode ser expresso por

$$\text{Dice}(\mathbf{Y},\hat{\mathbf{Y}}) = \frac{2\sum_p Y_p\hat{Y}_p + \epsilon}{\sum_p Y_p + \sum_p \hat{Y}_p + \epsilon}, \tag{376}$$

onde $\epsilon > 0$ evita instabilidade numérica. A correspondente *Dice Loss* é

$$\mathcal{L}_{\text{Dice}} = 1 - \text{Dice}(\mathbf{Y}, \hat{\mathbf{Y}}). \tag{377}$$

Essa formulação é particularmente atraente porque otimiza diretamente uma quantidade relacionada à qualidade da sobreposição entre predição e referência.

Uma generalização importante é a *Generalized Dice Loss*, proposta por Sudre et al. para lidar com segmentações altamente desbalanceadas (**?**). Para K classes, define-se

$$\text{GDL} = 1 - 2\frac{\sum_{k=1}^{K} w_k \sum_p Y_{p,k}\hat{P}_{p,k}}{\sum_{k=1}^{K} w_k \sum_p \left(Y_{p,k} + \hat{P}_{p,k}\right)}, \tag{378}$$

em que os pesos por classe são usualmente escolhidos como inversamente proporcionais ao quadrado do volume da classe:

$$w_k = \frac{1}{\left(\sum_p Y_{p,k}\right)^2}. \tag{379}$$

Essa escolha reduz a dominância das classes grandes, tornando a perda mais sensível às estruturas pequenas.

Outra perda baseada em sobreposição é a IoU Loss, definida a partir da *Intersection over Union*:

$$\text{IoU}(\mathbf{Y}, \hat{\mathbf{Y}}) = \frac{\sum_p Y_p\hat{Y}_p + \epsilon}{\sum_p Y_p + \sum_p \hat{Y}_p - \sum_p Y_p\hat{Y}_p + \epsilon}, \tag{380}$$

e

$$\mathcal{L}_{\text{IoU}} = 1 - \text{IoU}(\mathbf{Y}, \hat{\mathbf{Y}}). \tag{381}$$

Enquanto Dice e IoU são correlatas,

$$\text{Dice} = \frac{2\text{IoU}}{1 + \text{IoU}}, \tag{382}$$

cada uma pode induzir dinâmicas de otimização ligeiramente diferentes.

Em muitos cenários, a melhor estratégia prática consiste em combinar perdas pixel-wise e perdas de sobreposição. Uma formulação comum é

$$\mathcal{L}_{\text{seg}} = \lambda_1\mathcal{L}_{\text{BCE}} + \lambda_2\mathcal{L}_{\text{Dice}}, \qquad \lambda_1, \lambda_2 \geq 0, \tag{383}$$

ou, em multiclasse,

$$\mathcal{L}_{\text{seg}} = \lambda_1\mathcal{L}_{\text{CE}} + \lambda_2\mathcal{L}_{\text{GDL}}. \tag{384}$$

Essa combinação é metodologicamente útil porque a entropia cruzada fornece gradientes locais estáveis em nível de pixel, enquanto Dice/GDL alinha a otimização à

métrica de sobreposição de maior interesse clínico.

Em síntese, as técnicas complementares apresentadas nesta seção desempenham papel decisivo na robustez de modelos de classificação e segmentação em imagem médica. O *data augmentation* atua como regularização implícita e ampliação da diversidade amostral; o balanceamento de classes corrige vieses estatísticos que tenderiam a favorecer classes majoritárias; e as funções de perda, quando adequadamente escolhidas, alinham o processo de otimização aos objetivos clínicos e geométricos da tarefa. Em bases moderadas e potencialmente desbalanceadas, como as usadas em ultrassonografia mamária, tais técnicas deixam de ser opcionais e passam a constituir parte central do protocolo metodológico.

2.10 Trabalhos relacionados

2.10.1 Estudos sobre classificação em ultrassom mamário

A literatura recente sobre classificação de lesões em ultrassom mamário mostra uma transição relativamente clara entre duas fases metodológicas. Em uma primeira fase, predominavam abordagens baseadas em atributos manuais, seleção de características e classificadores tradicionais; em uma segunda fase, atualmente dominante, passaram a prevalecer arquiteturas de *Deep Learning*, especialmente redes convolucionais profundas e, mais recentemente, modelos híbridos e transformadores visuais. Essa mudança ocorreu porque a classificação de massas em ultrassom depende fortemente de padrões locais de textura, contorno, ecogenicidade e contexto anatômico, cuja formalização manual tende a ser limitada e pouco robusta diante de ruído *speckle*, baixo contraste e variabilidade de aquisição. Nesse cenário, arquiteturas profundas passaram a oferecer uma alternativa mais flexível para aprender representações discriminativas diretamente dos dados. (Dan; Xu; Burrows; Bissram; Stringer; Li, 2024; **?**)

No entanto, embora o número de estudos tenha crescido substancialmente, a evidência disponível ainda é metodologicamente heterogênea. Uma revisão sistemática recente sobre desempenho diagnóstico de *Deep Learning* em ultrassom mamário identificou 16 estudos envolvendo 9.238 participantes e concluiu que a evidência atual é insuficiente para afirmar, de forma conclusiva, que modelos profundos superam leitores humanos ou melhoram de forma consistente o desempenho diagnóstico em fluxos clínicos reais. O mesmo estudo destacou ausência de estudos prospectivos em ambiente de trabalho clínico, grande variabilidade metodológica e limitação de generalização como barreiras importantes à tradução clínica. Essa observação é particularmente relevante porque mostra que a área avançou rapidamente em termos algorítmicos, mas ainda convive com lacunas de padronização experimental e validação externa. (Dan; Xu; Burrows; Bissram; Stringer; Li, 2024)

No recorte especificamente orientado a bases públicas, o dataset BUSI tornou-se uma referência recorrente para classificação de imagens de ultrassom mamário, sobretudo por disponibilizar imagens rotuladas em três categorias — normal, benigna e maligna — e por conter também máscaras das lesões. Diversos estudos o utilizam para comparação entre arquiteturas *off-the-shelf*, geralmente em regime de *transfer learning*, com modelos como VGG, ResNet, DenseNet, EfficientNet e variantes mais recentes. Há também trabalhos que combinam pré-processamento, realce de ROI, fusão de canais e estratégias de ensemble ou meta-learning para tentar compensar o pequeno tamanho amostral da base. Em geral, esses estudos reportam desempenho promissor, mas frequentemente sob protocolos pouco uniformes de divisão treino-validação-teste, uso intensivo de aumento de dados e, em muitos casos, foco exclusivo em classificação binária benigno-versus-maligno. (Al-dhabyani; Gomaa; Khaled; Fahmy, 2020; **?**; **?**)

Outro aspecto recorrente na literatura é a tentativa de ampliar desempenho por meio de modelos mais sofisticados, como ensembles, arquiteturas híbridas ou transformadores visuais. Trabalhos recentes mostram que, em BUSI, estratégias desse tipo podem produzir ganhos pontuais em acurácia, *precision*, *recall* e F_1, mas tais avanços costumam vir acompanhados de maior complexidade computacional e, nem sempre, de protocolos suficientemente homogêneos para permitir comparação justa com arquiteturas mais clássicas. Em paralelo, parte da literatura passou a incorporar interpretabilidade visual, por exemplo via Grad-CAM, buscando responder à demanda por maior transparência em modelos de apoio ao diagnóstico. Ainda assim, permanece frequente o uso de métricas globais isoladas, especialmente acurácia, sem discussão suficiente sobre sensibilidade para malignidade, calibração, custo computacional e impacto do desbalanceamento entre classes. (**?**Dan; Xu; Burrows; Bissram; Stringer; Li, 2024)

2.10.2 Estudos sobre segmentação em ultrassom mamário

Na tarefa de segmentação, a literatura em ultrassom mamário é dominada por arquiteturas da família U-Net e por suas numerosas variantes. Revisões recentes sobre segmentação em ultrassom médico mostram que U-Net, Attention U-Net, U-Net++, DeepLab, modelos com blocos residuais, mecanismos multi-escala e abordagens fraca ou semi-supervisionadas constituem o núcleo metodológico mais recorrente. Essa predominância não é casual: a segmentação em ultrassom é particularmente desafiadora em razão de ruído *speckle*, baixo contraste, sombras acústicas, fronteiras imprecisas e elevada variabilidade entre dispositivos e operadores, o que exige modelos capazes de combinar contexto semântico e detalhe espacial com boa robustez. (**??**)

No caso específico do ultrassom de mama, a maior parte dos estudos também se

apoia em BUSI, justamente por ser uma das poucas bases públicas com máscaras de lesão amplamente utilizadas. Essa disponibilidade favoreceu a proliferação de variantes da U-Net com mecanismos de atenção, blocos residuais, caminhos multi-escala e estratégias de refinamento de contorno. Como exemplo representativo, Rahmani et al. propuseram um modelo baseado em U-Net com blocos de realce de resolução e relataram melhora de segmentação sobre abordagens anteriores, reforçando a ideia de que ganhos recentes nessa tarefa derivam menos da substituição completa da família U-Net e mais da introdução de mecanismos complementares para recuperação de detalhe e focalização da região de interesse. (Rahmani et al., 2024; Al-dhabyani; Gomaa; Khaled; Fahmy, 2020)

Em paralelo, surgiram propostas que procuram explorar conjuntamente classificação e segmentação. Um exemplo importante é o trabalho de Aumente-Maestro et al., que propõe um arcabouço multitarefa para ultrassom mamário e, além disso, realiza curadoria explícita do BUSI, identificando irregularidades e propondo estratégia de detecção de imagens duplicadas. Os autores argumentam que a combinação entre classificação e segmentação pode explorar correlações úteis entre as tarefas e relatam ganhos relevantes em relação a abordagens estritamente *single-task*. Essa linha é metodologicamente importante porque desloca a discussão de uma competição isolada entre modelos para uma visão mais integrada do problema clínico, embora ainda exija cuidado para não obscurecer a avaliação individual de cada tarefa. (Aumente-maestro; Díez; Remeseiro, 2025)

Apesar desses avanços, a literatura de segmentação em ultrassom mamário também apresenta limitações importantes. Em muitos estudos, a comparação entre modelos é dificultada por diferenças de pré-processamento, seleção de amostras, exclusão de imagens normais, uso ou não de máscaras refinadas, métricas reportadas e critérios de curadoria da base. Além disso, como em classificação, grande parte dos resultados permanece circunscrita a validação interna em bases públicas pequenas ou moderadas, com pouca avaliação multicêntrica ou externa. Isso significa que, embora o estado da arte apresente ganhos consistentes em Dice, IoU e métricas correlatas, ainda há incerteza relevante quanto à robustez desses modelos fora do ambiente experimental em que foram treinados. (**?**Pawłowska; Karwat; Zołek, 2023; Aumente-maestro; Díez; Remeseiro, 2025)

2.10.3 Comparação entre literatura e proposta do trabalho

A proposta desta monografia dialoga diretamente com essa literatura, mas adota um recorte metodológico mais controlado e explicitamente comparativo. Em vez de apresentar apenas um novo classificador, apenas um novo segmentador ou um único modelo multitarefa, o trabalho organiza a investigação em dois eixos independentes: classificação e segmentação. Essa decisão responde a um problema recorrente na

literatura recente: a tendência de comparar de forma indireta modelos desenhados para tarefas diferentes ou de discutir desempenho global sem separar adequadamente objetivos semânticos e espaciais. Ao estruturar um eixo classificatório e um eixo segmentador com arquiteturas representativas em cada caso, a proposta permite uma comparação mais justa e interpretável. (Dan; Xu; Burrows; Bissram; Stringer; Li, 2024; Aumente-maestro; Díez; Remeseiro, 2025)

Outra diferença importante em relação a muitos estudos prévios é a ênfase simultânea em desempenho preditivo e custo computacional. Embora vários trabalhos recentes reportem acurácia, Dice ou IoU elevados, é menos comum encontrar análises comparativas sistemáticas que incluam, lado a lado, número de parâmetros, tempo de treinamento, latência de inferência e relação entre ganho de desempenho e custo operacional. Essa dimensão é central nesta monografia porque a utilidade prática de um modelo de apoio ao diagnóstico não depende apenas de sua métrica absoluta, mas também de sua viabilidade de treinamento, implantação e uso em ambientes com recursos computacionais limitados. (Dan; Xu; Burrows; Bissram; Stringer; Li, 2024; **?**)

A proposta também se diferencia por assumir, desde o desenho metodológico, a necessidade de curadoria e leitura crítica do BUSI. Trabalhos recentes mostraram que o conjunto contém inconsistências com potencial impacto sobre os resultados, incluindo duplicatas, quase duplicatas e problemas na integridade experimental de parte das amostras. Ao incorporar essa discussão ao próprio protocolo, o presente estudo busca evitar um problema relativamente frequente na literatura: reportar desempenho alto sobre uma base pública sem discutir de forma suficiente as implicações da qualidade do dado sobre a validade da comparação entre modelos. (Pawłowska; Karwat; Zołek, 2023; Aumente-maestro; Díez; Remeseiro, 2025)

2.10.4 Lacunas identificadas

A primeira lacuna identificada na literatura diz respeito à padronização metodológica. Estudos de classificação e segmentação em ultrassom mamário frequentemente utilizam protocolos distintos de divisão dos dados, aumentos artificiais muito diferentes, critérios variados de inclusão e exclusão, e métricas nem sempre comparáveis. Como consequência, resultados reportados em artigos diferentes tornam-se difíceis de interpretar em conjunto, o que enfraquece a capacidade de inferir quais arquiteturas são realmente mais adequadas para cada tarefa. (Dan; Xu; Burrows; Bissram; Stringer; Li, 2024; **?**)

A segunda lacuna refere-se à própria base empírica dos estudos. Embora o BUSI seja amplamente utilizado, sua centralidade na literatura vem acompanhada de uma dependência excessiva de um único dataset pequeno e potencialmente problemático. Parte importante dos trabalhos utiliza apenas BUSI, muitas vezes sem curadoria explícita, e vários estudos restringem-se a subconjuntos binários benigno-versus-maligno,

excluindo a classe normal ou descartando imagens sem justificativa metodológica suficientemente detalhada. Isso limita tanto a validade externa quanto a comparabilidade entre trabalhos. (Al-dhabyani; Gomaa; Khaled; Fahmy, 2020; Pawłowska; Karwat; Zołek, 2023; Aumente-maestro; Díez; Remeseiro, 2025)

A terceira lacuna é a ausência, em muitos estudos, de uma análise integrada entre desempenho, generalização e custo computacional. Ainda predomina uma lógica de maximização de métricas finais, com menos atenção à estabilidade do treinamento, à sensibilidade para casos malignos, à latência de inferência e ao impacto do tamanho do modelo. Em aplicações médicas, contudo, esses fatores são decisivos para transição entre prova de conceito experimental e uso prático. (Dan; Xu; Burrows; Bissram; Stringer; Li, 2024; **?**)

Por fim, observa-se uma lacuna conceitual importante: a literatura ainda carece de estudos comparativos que tratem classificação e segmentação como tarefas complementares, mas não equivalentes, e que avaliem arquiteturas representativas de cada eixo sob um protocolo único, curado e metodologicamente coerente. É precisamente nesse espaço que esta monografia se posiciona: ao comparar modelos de classificação e segmentação em ultrassom mamário dentro de um mesmo ambiente experimental controlado, com ênfase em desempenho, custo computacional e leitura crítica da base de dados, o trabalho busca contribuir menos com a proposição de uma arquitetura inédita e mais com uma avaliação comparativa robusta, transparente e cientificamente defensável. (Dan; Xu; Burrows; Bissram; Stringer; Li, 2024; Aumente-maestro; Díez; Remeseiro, 2025; Pawłowska; Karwat; Zołek, 2023)

3 MATERIAIS E MÉTODOS

3.1 Caracterização da pesquisa

3.1.1 Natureza da pesquisa

Esta pesquisa caracteriza-se, do ponto de vista de sua natureza, como um estudo aplicado em Inteligência Artificial e Visão Computacional voltado ao domínio da saúde, com foco específico no apoio ao diagnóstico do câncer de mama por meio de imagens de ultrassom. Seu caráter aplicado decorre do fato de que o problema investigado não é apenas teórico ou algorítmico em sentido abstrato, mas diretamente associado a uma necessidade concreta da prática diagnóstica: avaliar, de forma sistemática, o potencial de arquiteturas de *Deep Learning* para classificar e segmentar lesões mamárias em um ambiente experimental controlado.

Ao mesmo tempo, o trabalho possui forte componente tecnológico e experimental, uma vez que envolve construção de pipeline completo de dados, curadoria de base, definição de protocolos de treino e validação, implementação de modelos, ajuste de hiperparâmetros e análise quantitativa e qualitativa dos resultados. Nesse sentido, a pesquisa se insere na interface entre ciência aplicada e engenharia experimental, pois produz conhecimento comparativo sobre arquiteturas de aprendizado profundo ao mesmo tempo em que desenvolve infraestrutura computacional reprodutível para sua avaliação.

Sob a ótica dos objetivos, o estudo pode ser classificado como predominantemente comparativo e explicativo. É comparativo porque busca confrontar arquiteturas distintas dentro de duas tarefas bem definidas — classificação e segmentação — observando suas diferenças de desempenho, custo computacional e comportamento por classe. É explicativo porque não se limita a relatar métricas finais, mas procura interpretar por que determinados modelos se mostraram mais adequados a certos critérios, como sensibilidade para malignidade, qualidade de contorno ou eficiência operacional. Dessa forma, o trabalho ultrapassa a lógica de simples prototipação e se aproxima de um desenho investigativo orientado à compreensão das relações entre arquitetura, tarefa, métrica e viabilidade prática.

Também se trata de uma pesquisa quantitativa com complemento qualitativo. A dimensão quantitativa se expressa no uso de métricas formais de classificação e segmentação, análise de hiperparâmetros, benchmarks de inferência e comparação entre modelos. A dimensão qualitativa aparece na inspeção visual de amostras, máscaras, erros de classificação, casos de subsegmentação e sobresegmentação, e na interpretação crítica das diferenças entre arquiteturas. Essa combinação é particularmente importante em imagem médica, onde métricas numéricas isoladas nem sempre capturam toda a complexidade do comportamento dos modelos.

3.1.2 Abordagem metodológica

A abordagem metodológica adotada neste trabalho foi estruturada para garantir comparabilidade, reprodutibilidade e separação clara entre as duas tarefas investigadas. Em vez de tratar classificação e segmentação como um único problema genérico de reconhecimento visual, o estudo as organiza como eixos complementares, porém distintos, com datasets derivados, métricas específicas e critérios próprios de seleção de modelos. Essa decisão metodológica é central para a consistência científica do trabalho, pois evita comparações conceitualmente inadequadas entre arquiteturas desenhadas para tarefas diferentes.

O primeiro eixo metodológico foi a classificação multiclasse de imagens de ultrassom mamário em três categorias: *benign*, *malignant* e *normal*. Nesse eixo, o foco recaiu sobre a capacidade discriminativa das arquiteturas e sobre sua sensibilidade clínica para a classe maligna. O segundo eixo foi a segmentação binária de lesões mamárias, restrita às imagens com máscara anotada e pertencentes às classes *benign* e *malignant*. Nesse caso, a ênfase metodológica concentrou-se na recuperação espacial da região tumoral e na comparação entre precisão de contorno, cobertura da lesão e custo computacional.

A pesquisa foi conduzida em ambiente experimental controlado, utilizando o dataset BUSI como base única. O pipeline incluiu auditoria dos dados brutos, geração de manifestos, estratificação dos conjuntos de treino, validação e teste, pré-processamento das imagens, aumento de dados, treinamento supervisionado, seleção dos melhores *trials* por métricas de validação e posterior avaliação final em conjunto de teste separado. Essa organização garante uma sequência metodológica clara:

$$\text{auditoria} \rightarrow \text{preparação dos dados} \rightarrow \text{treinamento} \rightarrow \text{validação} \rightarrow \text{seleção do melhor checkpoint} \tag{385}$$

Do ponto de vista inferencial, a pesquisa não busca provar superioridade universal de uma arquitetura em qualquer cenário, mas comparar modelos representativos em um mesmo domínio imagiológico e sob protocolo reprodutível. Assim, a interpretação dos resultados foi orientada por três níveis de análise: desempenho absoluto,

comportamento por subtarefa ou classe, e relação entre desempenho e custo computacional. Essa abordagem é particularmente adequada ao problema estudado, pois reconhece que, em aplicações médicas, a melhor escolha arquitetural depende do critério considerado: sensibilidade clínica, equilíbrio global entre métricas ou eficiência operacional.

Por fim, a metodologia foi concebida com ênfase em rastreabilidade experimental. Os experimentos foram organizados em artefatos estruturados, incluindo arquivos de configuração resolvida, históricos de treinamento, métricas por época, saídas de teste, curvas de desempenho, matrizes de confusão, máscaras preditas, relatórios finais e benchmarks. Isso fortalece a reprodutibilidade do estudo e melhora a transparência analítica do trabalho.

3.1.3 Estratégia experimental

A estratégia experimental foi construída em torno de uma grade sistemática de comparação entre arquiteturas, combinada com seleção por validação e avaliação final em teste. Em classificação, foram comparadas quatro arquiteturas com perfis arquiteturais distintos: VGG16, ResNet50, EfficientNet-B0 e ConvNeXt-Large. Em segmentação, foram avaliados U-Net, Attention U-Net, U-Net++ e DeepLabV3+. A presença de modelos clássicos, residuais, eficientes, modernizados e baseados em variantes do paradigma *encoder-decoder* permitiu uma comparação tecnicamente rica e metodologicamente equilibrada.

O protocolo experimental foi organizado em duas camadas. A primeira consistiu em uma grade combinatória principal de hiperparâmetros, na qual diferentes combinações de taxa de aprendizado, tamanho de lote, modo de *fine-tuning*, função de perda e resolução de entrada foram exploradas de forma sistemática. A segunda camada consistiu em uma busca complementar com Optuna para subconjuntos específicos de arquiteturas, com o objetivo de investigar regiões mais refinadas do espaço de hiperparâmetros.

A seleção dos melhores modelos ocorreu sempre com base em métricas de validação, e não em métricas de teste, preservando o papel do conjunto de teste como estimador final de desempenho. Em classificação, a métrica primária de seleção foi o macro-F_1, escolhida por sua adequação a um cenário multiclasse com desbalanceamento moderado. Em segmentação, a métrica primária foi o Dice Score, por sua relevância em tarefas de sobreposição espacial com forte predominância de fundo. Após a seleção do melhor *checkpoint* em validação, cada modelo foi reavaliado no conjunto de teste, e os resultados finais foram consolidados em tabelas comparativas.

Outro aspecto importante da estratégia experimental foi a incorporação explícita de métricas computacionais. Além de avaliar *accuracy*, F_1, AUC, IoU e Dice, o trabalho também mediu número de parâmetros, tempo de treinamento, latência média

de inferência, *throughput* e tamanho final do modelo. Essa decisão ampliou o escopo analítico do estudo, permitindo discutir não apenas “qual modelo é melhor”, mas “qual modelo é mais adequado sob determinado critério de uso”.

Em síntese, a estratégia experimental adotada pode ser entendida como uma avaliação comparativa controlada, multicritério e reprodutível, desenhada para responder de forma tecnicamente consistente quais arquiteturas são mais adequadas à classificação e à segmentação de lesões mamárias em ultrassom dentro do escopo metodológico do dataset BUSI.

3.2 Ambiente computacional

3.2.1 Linguagens, bibliotecas e frameworks

O ambiente computacional do projeto foi construído integralmente em Python, linguagem amplamente consolidada em aprendizado de máquina, visão computacional e pesquisa reprodutível em Inteligência Artificial. A escolha do Python foi particularmente adequada ao escopo deste trabalho porque permitiu integrar, em um mesmo ecossistema, ferramentas para manipulação de dados, treinamento profundo, processamento de imagens, ajuste de hiperparâmetros, geração de relatórios e benchmarking de inferência.

O núcleo de aprendizado profundo foi implementado com PyTorch, biblioteca adotada como base para definição dos modelos, treinamento supervisionado, manipulação de tensores e execução em GPU quando disponível. Para a classificação, o projeto utilizou a biblioteca `timm`, que fornece implementações padronizadas de arquiteturas modernas pré-treinadas em ImageNet, como VGG16, ResNet50, EfficientNet-B0 e ConvNeXt-Large. Para a segmentação, foram utilizados `segmentation_models_pytorch` e uma implementação customizada da Attention U-Net, permitindo explorar arquiteturas do tipo U-Net, U-Net++, DeepLabV3+ e variações baseadas em atenção.

O pipeline de transformação de imagens foi implementado com Albumentations, biblioteca escolhida por sua eficiência e por sua capacidade de aplicar transformações sincronizadas entre imagem e máscara, requisito indispensável na tarefa de segmentação. A manipulação tabular de manifestos, métricas e relatórios foi realizada com pandas, enquanto operações numéricas e estatísticas auxiliares utilizaram NumPy. A estratificação dos dados e utilitários de particionamento foram apoiados por funções do scikit-learn, especialmente para `train_test_split` e controle de estratificação por classe.

Para visualização e geração de relatórios, o projeto utilizou bibliotecas usuais do ecossistema científico Python, incluindo ferramentas para gráficos, exportação de tabelas em CSV, arquivos JSON e YAML, além de geração de figuras em PNG para

inspeção visual das imagens, máscaras, curvas de treinamento e saídas qualitativas. A busca de hiperparâmetros complementar foi realizada com Optuna, permitindo exploração mais refinada de espaços contínuos e discretos de configuração.

Em termos arquiteturais, o projeto foi organizado em módulos específicos para dados, modelos, tarefas, métricas, treinamento e benchmark, o que resultou em um ambiente de desenvolvimento coeso, reprodutível e extensível. Essa modularidade não é apenas uma escolha de engenharia de software; ela fortalece diretamente a qualidade experimental da pesquisa, ao facilitar controle de configuração, reaproveitamento de código e rastreabilidade dos resultados.

3.2.2 Ambiente de execução

O pipeline experimental foi desenhado para execução preferencial em ambiente com suporte a GPU, embora mantenha compatibilidade com CPU quando necessário. A implementação inclui mecanismos para detectar disponibilidade de CUDA e habilitar, automaticamente, recursos como *mixed precision*, `GradScaler` e `pin_memory` nos `DataLoaders`. Esse desenho torna o ambiente de execução adaptativo: explora aceleração por hardware quando disponível, mas preserva portabilidade básica do pipeline.

O treinamento foi organizado por meio de uma interface de linha de comando (*CLI*) com comandos explícitos para auditoria, preparação dos dados, classificação, segmentação, geração de relatórios e execução completa do pipeline. Essa estratégia melhora o controle operacional dos experimentos e reduz ambiguidade entre rodadas. Em vez de depender de execução manual fragmentada em notebooks, o projeto foi estruturado para rodar por etapas claramente definidas, com logs, arquivos de configuração resolvida e diretórios de artefatos associados a cada experimento.

No nível de dados, o ambiente de execução trabalha com manifestos estruturados e caminhos absolutos, o que reduz problemas de portabilidade interna entre diretórios de imagens, máscaras, *splits* e saídas. No nível do treinamento, cada *trial* possui sua própria pasta com histórico por época, métricas de validação, *checkpoints*, saídas de teste e resultados de benchmark. Essa organização transforma o ambiente de execução em um ambiente também de documentação experimental, favorecendo inspeção posterior e reutilização analítica.

Outro aspecto importante é o controle de reprodutibilidade. O ambiente foi configurado com fixação coordenada de sementes em Python, NumPy e PyTorch, além de configuração determinística de operações relevantes no backend. O `DataLoader` também foi construído com gerador de números aleatórios controlado e função de inicialização dos *workers*. Dessa forma, embora pequenas variações residuais ainda possam existir em ambiente GPU, o projeto adota as práticas mais importantes para reduzir variabilidade não controlada entre execuções.

Em termos práticos, o ambiente de execução utilizado no trabalho deve ser en-

tendido como um ambiente de pesquisa aplicado: suficientemente robusto para conduzir comparação entre múltiplas arquiteturas, ajustar hiperparâmetros, gerar relatórios e medir desempenho computacional, mas ainda orientado ao escopo acadêmico-experimental do TCC, e não a um ambiente clínico produtivo.

3.2.3 Limitações de hardware

As limitações de hardware desempenharam papel relevante no desenho experimental do trabalho, especialmente no que diz respeito à amplitude do espaço de busca de hiperparâmetros, ao tamanho das entradas, ao número de épocas exploradas por configuração e à escolha de *batch sizes* compatíveis com treinamento em GPU de memória moderada. Em outras palavras, o ambiente disponível foi suficiente para realizar uma comparação robusta entre arquiteturas, mas não ilimitado a ponto de permitir exploração irrestrita de resoluções mais altas, modelos ainda maiores ou buscas extensivas para todas as combinações possíveis.

Na classificação, essa limitação se refletiu principalmente na necessidade de manter tamanhos de entrada controlados e restringir o espaço principal de busca a combinações discretas de taxa de aprendizado, *batch size* e profundidade de *fine-tuning*. Na segmentação, a influência foi ainda mais direta, pois a natureza pixel a pixel da tarefa exige mais memória por amostra, o que levou à adoção de *batch size* mais baixo e limitou a variação desse hiperparâmetro na grade principal. Também é plausível afirmar que parte da escolha por arquiteturas com *encoder* `resnet34` na segmentação refletiu um compromisso consciente entre expressividade e viabilidade computacional.

Além disso, o custo de treinamento observado mostrou que o tamanho bruto da arquitetura não é o único determinante da carga computacional efetiva. Estratégias de *early stopping*, comportamento do *scheduler*, número de épocas efetivamente executadas e estabilidade da convergência influenciaram fortemente o tempo total dos *trials*. Isso significa que as limitações de hardware não impactaram apenas quais modelos poderiam ser treinados, mas também como esses modelos precisaram ser avaliados e comparados em um regime experimental factível.

Essas restrições, entretanto, não comprometem a validade interna do estudo; elas apenas delimitam seu alcance. Para o nível de um TCC tecnicamente rigoroso, o ambiente foi suficiente para produzir comparação sólida, múltiplas rodadas experimentais, análise de custo computacional e avaliação qualitativa detalhada. Para etapas futuras, especialmente em direção a validação multicêntrica, resolução mais alta, validação cruzada extensa ou inclusão de arquiteturas ainda maiores, seria desejável infraestrutura mais robusta, com maior capacidade de memória, maior paralelismo e maior orçamento computacional para busca de hiperparâmetros.

3.3 Base de dados

3.3.1 Descrição do BUSI Dataset

A base de dados adotada neste trabalho foi o *Breast Ultrasound Images Dataset* (BUSI), uma coleção pública de imagens de ultrassonografia mamária amplamente utilizada em tarefas de classificação, detecção e segmentação assistidas por aprendizado de máquina (Al-dhabyani; Gomaa; Khaled; Fahmy, 2020). A escolha dessa base decorre de três fatores centrais: sua ampla adoção na literatura recente, a disponibilidade simultânea de imagens e máscaras de referência, e a adequação da modalidade de ultrassom ao problema de apoio ao diagnóstico de lesões mamárias, especialmente em cenários nos quais baixo custo, acessibilidade e ausência de radiação ionizante são aspectos relevantes.

O BUSI foi construído a partir de exames obtidos em 2018 no *Baheya Hospital for Early Detection & Treatment of Women's Cancer*, no Cairo, Egito, e compreende imagens provenientes de 600 pacientes do sexo feminino, com idades entre 25 e 75 anos (Al-dhabyani; Gomaa; Khaled; Fahmy, 2020). As aquisições foram realizadas com equipamentos LOGIQ E9 e LOGIQ E9 Agile, e o conjunto disponibilizado ao público contém 780 imagens em formato PNG, com dimensão média aproximada de 500×500 pixels (Al-dhabyani; Gomaa; Khaled; Fahmy, 2020). Trata-se, portanto, de uma base de escala moderada, suficientemente grande para viabilizar experimentos comparativos reprodutíveis, mas ainda pequena o bastante para exigir cautela metodológica quanto a sobreajuste, sensibilidade à divisão amostral e viés de avaliação.

Do ponto de vista semântico, o BUSI é particularmente valioso por reunir, em um mesmo repositório, imagens compatíveis com diferentes paradigmas de modelagem. Em tarefas de classificação, a base contempla três categorias clinicamente relevantes: imagens normais, imagens com lesões benignas e imagens com lesões malignas. Em tarefas de segmentação, o conjunto fornece máscaras de referência associadas às imagens, permitindo a formulação do problema como segmentação semântica da região de interesse. Essa dupla vocação — classificação e segmentação — torna o BUSI especialmente apropriado para trabalhos que buscam comparar arquiteturas em tarefas complementares, como é o caso desta pesquisa.

Entretanto, embora o BUSI seja uma referência consolidada na literatura, sua utilização não deve ser tratada como trivial. Análises posteriores mostraram que o conjunto contém irregularidades relevantes do ponto de vista experimental, incluindo imagens duplicadas ou quase duplicadas, presença de anotações gráficas e textuais sobre a imagem, casos contendo estruturas extra-mamárias e exemplos cuja rotulação demanda cautela interpretativa (Pawłowska; Karwat; Zołek, 2023; Aumente-maestro; Díez; Remeseiro, 2025). Em consequência, o uso rigoroso do BUSI exige uma etapa explícita de curadoria antes da definição dos subconjuntos de treino, validação e teste,

sob pena de inflacionar artificialmente o desempenho dos modelos por vazamento de informação.

Assim, neste trabalho, o BUSI não é tratado apenas como uma fonte de dados, mas como um objeto experimental que demanda preparação criteriosa. Essa postura é particularmente importante em estudos com imagens médicas, nos quais pequenas inconsistências de anotação, duplicidade ou sobreposição de metadados visuais podem induzir o modelo a aprender artefatos do processo de aquisição em vez de padrões efetivamente associados à morfologia da lesão.

3.3.2 Distribuição das classes

A distribuição original do BUSI compreende três classes: 133 imagens normais, 437 imagens benignas e 210 imagens malignas, totalizando 780 imagens (Aldhabyani; Gomaa; Khaled; Fahmy, 2020; **?**). Essa distribuição revela um desequilíbrio de classes moderado, com predominância de casos benignos e menor representação da classe maligna. Tal característica é metodologicamente importante, pois afeta diretamente o treinamento de classificadores supervisionados, a interpretação de métricas agregadas e o risco de modelos tendenciosos para a classe majoritária.

Do ponto de vista estatístico, esse desbalanceamento implica que a acurácia, isoladamente, não constitui métrica suficiente para caracterizar o desempenho de um modelo. Em contextos clínicos, a capacidade de recuperar corretamente casos malignos é mais crítica do que o acerto médio global, de modo que métricas como *recall* (sensibilidade), *precision*, $F1$-*score*, especificidade e AUC-ROC tornam-se essenciais para uma análise mais fiel do comportamento do classificador. Em outras palavras, um modelo com acurácia elevada, mas baixa sensibilidade para a classe maligna, seria pouco defensável sob a perspectiva de apoio ao diagnóstico.

Além do desbalanceamento global entre classes, há uma assimetria funcional entre as tarefas do presente trabalho. Na classificação, as três classes são mantidas, pois a distinção entre imagens normais, benignas e malignas representa precisamente o cenário de decisão clínica que se deseja aproximar. Já na segmentação, o interesse recai sobre a delimitação espacial da lesão; por isso, apenas imagens com massa identificável são elegíveis para treinamento e avaliação da rede segmentadora. Dessa forma, a classe normal não participa da segmentação como classe-alvo, uma vez que não há região tumoral a ser contornada sob a mesma lógica anatômica das classes benigna e maligna. Essa decisão não constitui perda de informação, mas adequação da base à natureza da tarefa proposta.

Outro ponto relevante é que a distribuição nominal da base não deve ser confundida com a distribuição efetivamente utilizada após a curadoria. Estudos de revisão do próprio BUSI indicam que parte das imagens apresenta duplicidades, anotações sobrepostas ou problemas de consistência que podem justificar exclusão ou tratamento

especial (Pawłowska; Karwat; Zołek, 2023). Consequentemente, a distribuição final empregada no experimento deve ser reportada após o processo de filtragem, e não apenas herdada da descrição original da base. Esse cuidado melhora a transparência metodológica e permite que a avaliação dos resultados seja interpretada à luz do conjunto realmente utilizado.

3.3.3 Estrutura dos arquivos e máscaras

O BUSI é disponibilizado em formato PNG e organizado de maneira compatível com fluxos de trabalho em visão computacional, contendo imagens de ultrassom e suas respectivas máscaras de referência (Al-dhabyani; Gomaa; Khaled; Fahmy, 2020). Em termos práticos, a estrutura do conjunto favorece dois tipos de uso. No primeiro, as imagens podem ser tratadas como amostras rotuladas para classificação multiclasse. No segundo, os pares imagem–máscara podem ser explorados em tarefas de segmentação semântica, nas quais o objetivo é estimar, em nível de pixel, a região correspondente à lesão.

As máscaras desempenham papel central na formulação da tarefa de segmentação. Elas funcionam como *ground truth* e permitem quantificar a qualidade do contorno produzido pelos modelos por meio de métricas como IoU (*Intersection over Union*) e Dice Score. Em aplicações de imagem médica, esse tipo de anotação é particularmente valioso porque desloca a análise do nível apenas categórico para o nível espacial, aproximando o experimento de cenários em que a localização e a extensão da lesão são clinicamente relevantes.

Contudo, a existência de máscaras não implica, por si só, uniformidade perfeita do conjunto. Trabalhos posteriores observaram que parte das imagens apresenta elementos sobrepostos, como textos, marcações de medição, *overlays*, pictogramas e até instrumentos visíveis em alguns casos, o que pode interferir tanto no treinamento quanto na avaliação dos modelos (Pawłowska; Karwat; Zołek, 2023). Tais elementos podem funcionar como pistas espúrias, induzindo o algoritmo a explorar artefatos visuais alheios ao tecido mamário. Em experimentos de alta sensibilidade, esse problema é especialmente grave, pois compromete a validade externa dos resultados.

Outro aspecto estrutural importante diz respeito à relação entre imagens aparentemente distintas, mas geometricamente equivalentes ou quase equivalentes. A literatura recente identificou no BUSI um número não desprezível de duplicatas e quase duplicatas, o que reforça a necessidade de controle rigoroso no particionamento do conjunto (Pawłowska; Karwat; Zołek, 2023; Aumente-maestro; Díez; Remeseiro, 2025). Caso imagens fortemente semelhantes sejam distribuídas entre treino e teste, o modelo pode ser avaliado sobre padrões que já viu sob outra forma, produzindo estimativas superotimistas de desempenho.

Por essa razão, a estrutura dos arquivos foi tratada, neste trabalho, não apenas

em termos de leitura e associação entre imagens e máscaras, mas também em termos de integridade experimental. Antes do treinamento, procedeu-se à inspeção da consistência entre rótulos, imagens e máscaras, bem como à identificação de casos potencialmente inadequados para avaliação imparcial. Essa etapa é indispensável em estudos que pretendem sustentar conclusões robustas, sobretudo quando o objetivo é comparar arquiteturas distintas sob critérios de justiça experimental.

3.3.4 Critérios de inclusão e exclusão

A definição de critérios de inclusão e exclusão foi orientada por dois princípios: validade metodológica e adequação ao objetivo de cada tarefa. Em primeiro lugar, foram incluídas apenas imagens que preservassem correspondência inequívoca entre arquivo de imagem, rótulo clínico e máscara de referência, quando aplicável. Em segundo lugar, foram excluídos casos cuja presença pudesse comprometer a avaliação do modelo por introduzir vieses não relacionados ao padrão morfológico da lesão.

Para a tarefa de classificação, foram consideradas elegíveis imagens pertencentes às três classes do BUSI — normal, benigna e maligna — desde que estivessem livres de inconsistências estruturais graves. Foram excluídas imagens duplicadas ou quase duplicadas, a fim de evitar vazamento de informação entre os subconjuntos de treino, validação e teste (Pawłowska; Karwat; Zołek, 2023; Aumente-maestro; Díez; Remeseiro, 2025). Também foram marcadas para exclusão ou inspeção manual imagens com anotações gráficas invasivas, textos sobrepostos na região de interesse, medições que atravessassem diretamente a lesão, artefatos de Doppler, pictogramas e casos contendo estruturas anatômicas não correspondentes ao campo mamário principal, uma vez que esses elementos podem enviesar a aprendizagem do modelo (Pawłowska; Karwat; Zołek, 2023).

Para a tarefa de segmentação, adotou-se critério mais restritivo. Foram incluídas somente imagens com lesão claramente representada e com máscara de referência utilizável, correspondentes às classes benigna e maligna. A classe normal foi excluída dessa etapa por não representar um alvo segmentável sob a mesma definição operacional da lesão tumoral. Adicionalmente, casos com máscaras inconsistentes, desalinhadas, ambíguas ou significativamente comprometidas por artefatos visuais foram considerados inadequados para a avaliação da qualidade segmentadora.

Em ambas as tarefas, o processo de curadoria precedeu o particionamento em treino, validação e teste. Essa ordem é essencial: filtrar a base apenas após o *split* poderia manter, em subconjuntos distintos, amostras correlacionadas ou inadequadas, contaminando a estimativa de generalização. Após a curadoria, o particionamento foi conduzido de forma estratificada, preservando, na medida do possível, a proporção entre classes e reduzindo a variabilidade introduzida pela distribuição desigual do conjunto.

Por fim, cabe destacar que os critérios de exclusão não foram adotados para “embelezar” o dataset ou artificialmente facilitar os resultados. Ao contrário, sua finalidade foi reduzir fontes de viés conhecidas e alinhar a base a um protocolo experimental reprodutível e defensável. Em bases médicas públicas de escala moderada, a robustez de um experimento depende tanto da arquitetura escolhida quanto da qualidade da curadoria anterior ao treinamento. Nesse sentido, a seleção criteriosa dos dados constitui parte integrante da metodologia, e não mera etapa auxiliar.

3.4 Preparação dos dados

A preparação dos dados foi concebida como uma etapa estruturante do pipeline experimental, com o objetivo de garantir consistência entre amostras, rastreabilidade dos registros, reprodutibilidade das divisões e compatibilidade entre os dados brutos do BUSI e os requisitos operacionais dos modelos de classificação e segmentação. Em vez de tratar o dataset apenas como um conjunto de imagens organizadas em diretórios, o pipeline o reconstrói em nível tabular por meio de uma auditoria sistemática, transformando cada amostra em um registro semanticamente enriquecido, contendo metadados de classe, caminhos absolutos, estatísticas básicas, integridade geométrica e elegibilidade para segmentação.

Essa etapa começa pela leitura recursiva de `Dataset/`, com identificação dos arquivos `.png` a partir do padrão de nomenclatura:

```
^(?P<label>[a-z]+) ((?P<index>d+))(?P<mask>_mask(?:_d+)?)?.png$ (386)
```

Esse padrão permite distinguir, de forma determinística, a imagem principal, suas máscaras associadas e o índice lógico da amostra. Como consequência, o pipeline produz um manifesto unificado por imagem, no qual são armazenados: caminho da imagem, lista de máscaras associadas, número de máscaras, resolução espacial, estatísticas de intensidade, consistência entre imagem e máscara e viabilidade da amostra para tarefas de segmentação.

Na execução consolidada utilizada nesta monografia, a auditoria registrou 780 imagens válidas, sem registros compostos apenas por máscara, sem imagens desacompanhadas de máscara e sem incompatibilidades geométricas entre imagem e máscara. Também foram identificadas 17 imagens com múltiplas máscaras, 133 máscaras vazias e 647 amostras elegíveis para segmentação. Em termos de distribuição de classes para classificação, o conjunto total foi composto por 437 imagens benignas, 210 malignas e 133 normais. Esse diagnóstico inicial é metodologicamente importante porque mostra, desde o início, duas propriedades centrais do problema: desbalanceamento moderado entre classes e separação natural entre a tarefa de classificação,

que utiliza todas as imagens válidas, e a tarefa de segmentação, restrita às imagens com lesão anotada.

3.4.1 Organização dos conjuntos de treino, validação e teste

A organização dos dados foi realizada a partir de dois manifestos derivados do manifesto bruto auditado. O primeiro, `classification_manifest.csv`, reúne todas as 780 imagens válidas do dataset, incluindo as classes `benign`, `malignant` e `normal`. O segundo, `segmentation_manifest.csv`, contém exclusivamente as imagens das classes `benign` e `malignant` marcadas como elegíveis para segmentação, o que exclui naturalmente os casos normais.

A partir desses manifestos, foram gerados dois arquivos de particionamento: `classification_split.csv` e `segmentation_split.csv`. Para a tarefa de classificação, a divisão final resultou em 545 imagens no conjunto de treino, 117 no conjunto de validação e 118 no conjunto de teste. Para a segmentação, a divisão final foi de 452 imagens para treino, 97 para validação e 98 para teste.

A composição por classe foi mantida explicitamente em cada tarefa. Na classificação, o conjunto de treino contém 305 amostras benignas, 147 malignas e 93 normais; o conjunto de validação contém 66 benignas, 31 malignas e 20 normais; e o conjunto de teste contém 66 benignas, 32 malignas e 20 normais. Na segmentação, o treino contém 305 casos benignos e 147 malignos; a validação, 66 benignos e 31 malignos; e o teste, 66 benignos e 32 malignos. Essa organização preserva a coerência entre os objetivos experimentais e o conteúdo efetivamente disponível no dataset.

Cada amostra recebe ainda um `class_index` consistente com a tarefa considerada. Na classificação, o mapeamento adotado é `benign = 0`, `malignant = 1` e `normal = 2`. Na segmentação, o mapeamento é `benign = 0` e `malignant = 1`. A resolução dos caminhos para caminhos absolutos também foi incorporada ao manifesto, reduzindo ambiguidades em execuções reprodutíveis e simplificando a rastreabilidade dos experimentos.

3.4.2 Estratégia de split estratificado

O particionamento dos dados foi realizado com `train_test_split` da biblioteca `scikit-learn`, adotando estratificação por `class_name`. O procedimento foi conduzido em duas etapas sucessivas. Na primeira, o conjunto total foi dividido em treino e um bloco temporário. Na segunda, esse bloco temporário foi novamente particionado em validação e teste. As proporções configuradas foram:

- treino: 70%,
- validação: 15%,
- teste: 15%.

Do ponto de vista metodológico, a estratificação por classe tem como principal objetivo preservar, em cada subconjunto, a distribuição relativa dos rótulos observada no conjunto global. Isso é especialmente importante em problemas médicos com desbalanceamento entre classes, pois reduz o risco de formar subconjuntos artificialmente enviesados e melhora a comparabilidade entre métricas de validação e teste.

Entretanto, é importante destacar que a estratificação adotada atua apenas sobre a variável `class_name`. Isso significa que o pipeline preserva distribuição por classe, mas não controla explicitamente outras variáveis potencialmente relevantes, como dimensão da lesão, complexidade morfológica, intensidade média, qualidade da imagem ou origem do exame. Em termos experimentais, trata-se de uma estratégia adequada para um protocolo de TCC tecnicamente rigoroso, embora ainda abaixo do nível de controle exigido em cenários multicêntricos ou clínicos mais sensíveis.

3.4.3 Prevenção de vazamento de dados

A prevenção de vazamento de dados foi tratada como requisito metodológico central do pipeline. Para isso, foram adotadas várias barreiras explícitas de isolamento entre os conjuntos de treino, validação e teste. Em primeiro lugar, cada `image_id` é alocado a um único subconjunto, o que impede que a mesma imagem participe simultaneamente de diferentes fases do experimento. Em segundo lugar, a associação entre imagem e máscara é preservada no mesmo registro tabular, eliminando o risco de que a imagem seja alocada a um subconjunto e sua máscara correspondente a outro.

Em terceiro lugar, a seleção de hiperparâmetros e a escolha do melhor *trial* por modelo são feitas exclusivamente com base em métricas de validação. O conjunto de teste permanece isolado até a etapa final, sendo avaliado apenas após o recarregamento do melhor *checkpoint* salvo em validação. Além disso, as transformações de aumento de dados são restritas ao conjunto de treino, de modo que validação e teste são mantidos como distribuições mais próximas do dado real observado.

Apesar dessas salvaguardas, permanece uma limitação metodológica importante: o controle de vazamento é realizado em nível de imagem, e não em nível de paciente. Como o dataset BUSI, na estrutura utilizada pelo pipeline, não oferece um identificador de paciente explorável diretamente no processo de divisão, não foi possível aplicar estratégias como `GroupShuffleSplit`, `GroupKFold` ou qualquer forma de agrupamento interpaciente. Em consequência, o pipeline evita duplicação direta de imagem entre subconjuntos, mas não garante isolamento absoluto entre exames potencialmente correlacionados de um mesmo paciente. Para o contexto desta pesquisa, essa limitação não invalida os resultados, mas deve ser reconhecida como fragilidade residual do desenho experimental.

3.4.4 Padronização dos dados

A padronização dos dados foi implementada em múltiplos níveis, com o objetivo de transformar um conjunto heterogêneo de imagens em uma base operacional estável para treinamento profundo. Entre as decisões de padronização adotadas estão: *parse* determinístico dos nomes dos arquivos, manifesto tabular único com esquema consistente, resolução de caminhos absolutos, mapeamento fixo entre rótulos e índices numéricos, consolidação de múltiplas máscaras por união lógica e binarização final das máscaras em valores $0/1$.

Outra decisão importante foi a conversão de todas as imagens para RGB de três canais, mesmo quando a informação visual original é essencialmente monocromática. Essa escolha não visa alterar a natureza física do ultrassom, mas garantir compatibilidade com os *backbones* pré-treinados em ImageNet, que assumem entrada com três canais. Na prática, trata-se de uma estratégia de compatibilização com *transfer learning* amplamente empregada em visão computacional médica.

A auditoria também registrou estatísticas de intensidade e faixas de resolução por classe. As médias de intensidade foram aproximadamente 86,28 para a classe benigna, 79,76 para a maligna e 81,01 para a normal, com desvios-padrão entre 48 e 53. Em termos de tamanho espacial, as imagens apresentaram grande variabilidade, com larguras entre 190 e 1048 pixels e alturas entre 310 e 719 pixels, dependendo da classe. Esses números reforçam a necessidade de redimensionamento posterior e mostram que a padronização não é apenas uma conveniência computacional, mas uma condição necessária para treinamento em lotes homogêneos.

3.5 Pré-processamento

O pré-processamento foi estruturado como a camada responsável por transformar os registros auditados em tensores compatíveis com o treinamento dos modelos. Essa etapa foi dividida em leitura, redimensionamento, normalização e tratamento das máscaras. Na classificação, a leitura é realizada por uma rotina que converte cada imagem para RGB. Na segmentação, além da imagem RGB, o pipeline constrói uma máscara binária consolidada a partir das máscaras anotadas disponíveis.

O desenho do pré-processamento seguiu dois princípios complementares. O primeiro foi preservar, tanto quanto possível, a coerência anatômica e radiológica da amostra. O segundo foi compatibilizar os dados com arquiteturas profundas pré-treinadas, especialmente no que se refere ao tamanho da entrada e ao espaço estatístico esperado pelos pesos herdados de ImageNet.

3.5.1 Redimensionamento das imagens

O redimensionamento constitui a primeira operação efetiva das transformações aplicadas às imagens. Na classificação, utiliza-se `Resize(input_size, input_size)`, com entrada padrão de 224×224. Na segmentação, o redimensionamento também é aplicado de forma explícita, com testes em 224×224 e 256×256, sendo 256×256 a resolução selecionada na rodada final para todos os modelos segmentadores.

Do ponto de vista metodológico, o redimensionamento tem duas consequências principais. A primeira é a eliminação da variabilidade espacial nativa do dataset, permitindo a formação de *minibatches* homogêneos e o uso direto de *backbones* pré-treinados. A segunda é a possibilidade de perda de detalhe fino, particularmente nas bordas das lesões em imagens originalmente maiores. Essa perda, entretanto, foi considerada aceitável frente ao ganho operacional em estabilidade, reprodutibilidade e compatibilidade com o espaço de entrada das arquiteturas avaliadas.

3.5.2 Normalização

A normalização das imagens foi realizada com estatísticas do ImageNet, utilizando média $(0.485, 0.456, 0.406)$, desvio-padrão $(0.229, 0.224, 0.225)$ e `max_pixel_value = 255.0`. A sequência efetiva de processamento foi:

1. leitura da imagem em RGB;
2. redimensionamento;
3. normalização por `A.Normalize`;
4. conversão para tensor com `ToTensorV2`.

Essa decisão está diretamente alinhada à estratégia de *transfer learning*. Como os modelos de classificação e os encoders de segmentação são inicializados com pesos pré-treinados em ImageNet, a adoção da mesma normalização do pré-treino reduz descontinuidade estatística entre o domínio-fonte e o domínio-alvo. Em outras palavras, o pipeline prioriza compatibilidade com o espaço representacional herdado, em vez de aplicar uma normalização específica ao domínio BUSI.

3.5.3 Tratamento das máscaras

O tratamento das máscaras é uma das partes mais críticas do pré-processamento segmentador. Todas as máscaras associadas a uma imagem são lidas em escala de cinza. Quando há múltiplas máscaras para uma mesma imagem, a consolidação é feita por união pixel a pixel, utilizando `np.maximum`. Em seguida, a máscara final é binarizada por

$$\texttt{mask} = (\texttt{mask} > 0).astype(\texttt{np.uint8}), \tag{387}$$

de modo que a tarefa de segmentação seja explicitamente tratada como problema binário.

Além disso, após a aplicação das transformações, a máscara é garantida com *shape* $[1, H, W]$, preservando compatibilidade com os modelos. Durante o treino, o pipeline ainda executa uma rotina de alinhamento espacial dos logits, assegurando que a saída do modelo tenha a mesma resolução da máscara antes do cálculo da função de perda. Na inferência, as probabilidades passam por função sigmoide e são limiarizadas em $0{,}5$.

As implicações metodológicas dessa escolha são importantes: múltiplas anotações por imagem são preservadas como uma única região-alvo; a segmentação permanece estritamente binária; e pequenas diferenças de resolução entre saída do modelo e máscara são corrigidas antes da avaliação.

3.5.4 Verificação visual do pré-processamento

O pipeline gera artefatos de verificação visual automaticamente, com o objetivo de inspecionar qualitativamente o efeito das transformações aplicadas. Na classificação, são produzidas figuras que mostram, por classe, a imagem original, a imagem redimensionada, a imagem normalizada e a imagem desnormalizada para inspeção humana, além de exemplos de aumento de dados. Na segmentação, são produzidas figuras com imagem original, máscara de referência, máscara processada e sobreposição imagem–máscara em amostras aumentadas.

Essa etapa é metodologicamente relevante porque permite verificar se o redimensionamento preservou adequadamente a morfologia da lesão, se a normalização não introduziu artefatos visuais inesperados e se as máscaras continuam espacialmente alinhadas à anatomia após as transformações. Em experimentos médicos, esse tipo de verificação visual não deve ser tratado como detalhe cosmético, mas como forma de controle qualitativo da integridade do pipeline.

3.6 Aumento de dados

O aumento de dados foi implementado com Albumentations e aplicado exclusivamente ao conjunto de treino. Os conjuntos de validação e teste utilizam apenas redimensionamento, normalização e tensorização, sem transformações estocásticas. Essa decisão é consistente com o objetivo de ampliar robustez durante o treinamento sem contaminar a avaliação com versões artificialmente alteradas dos dados.

De forma geral, o pipeline adota uma postura conservadora em *augmentation*. Em vez de recorrer a transformações agressivas ou sinteticamente muito invasivas, foram escolhidas perturbações moderadas de geometria, brilho e contraste, suficientes para aumentar a variabilidade observada pelo modelo sem comprometer plausibilidade clí-

nica.

3.6.1 Técnicas aplicadas à classificação

Na tarefa de classificação, o pipeline de aumento de dados do conjunto de treino foi definido de forma deliberadamente conservadora, com o objetivo de ampliar a variabilidade amostral sem comprometer a plausibilidade clínica das imagens de ultrassom mamário. Para isso, foram empregadas transformações geométricas e fotométricas moderadas, incluindo espelhamento horizontal com probabilidade de $0{,}5$, transformação afim com pequenas variações de escala, translação e rotação, ajuste suave de brilho e contraste, seguido de normalização e conversão para tensor. Em termos práticos, essa composição foi desenhada para introduzir pequenas variações de pose, enquadramento e intensidade luminosa, preservando ao mesmo tempo a estrutura semântica global da imagem. Assim, a política de *data augmentation* adotada pode ser entendida como uma estratégia de robustez moderada, adequada à natureza sensível do problema e compatível com a necessidade de evitar amostras artificialmente irreais.

Tabela 3 – Transformações de aumento de dados aplicadas ao conjunto de treino da classificação.

Transformação	**Configuração**
HorizontalFlip	$p = 0{,}5$
Affine	escala em $1{,}0 \pm 0{,}05$, translação horizontal e vertical em $\pm 0{,}05$, rotação em $\pm 10°$, com $p = 0{,}7$
RandomBrightnessContrast	`brightness_limit = 0.10`, `contrast_limit = 0.10`, com $p = 0{,}5$
Normalize	normalização das intensidades antes da entrada no modelo
ToTensorV2	conversão da imagem processada para tensor

Figura 3 – Exemplo ilustrativo de imagem do conjunto de classificação após aplicação das transformações de aumento de dados. Substituir este *placeholder* pela figura exportada do pipeline, por exemplo `augmentation_preview.png`.

3.6.2 Técnicas aplicadas à segmentação

Na tarefa de segmentação, o conjunto de transformações adotado para o treinamento foi semelhante ao utilizado na classificação, porém com ajustes específicos para preservar a coerência espacial entre imagem e máscara e, ao mesmo tempo, ampliar moderadamente a variabilidade visual do conjunto de treino. Foram empregadas transformações geométricas suaves, ajustes discretos de brilho e contraste e uma transformação elástica de baixa intensidade, seguidos de normalização e conversão para tensor. O aspecto metodológico mais importante dessa etapa é que as transformações geométricas foram aplicadas de forma sincronizada à imagem e à respectiva máscara de referência. Essa sincronização é indispensável em segmentação, pois qualquer desalinhamento entre ambas destruiria a correspondência pixel a pixel e, consequentemente, invalidaria a supervisão do modelo. Assim, a política de *data augmentation* da segmentação foi desenhada para aumentar a robustez do modelo sem comprometer a anatomia da lesão nem a integridade geométrica da máscara.

Tabela 4 – Transformações de aumento de dados aplicadas ao conjunto de treino da segmentação.

Transformação	**Configuração**
HorizontalFlip	$p = 0{,}5$
Affine	escala em $1{,}0 \pm 0{,}08$, translação horizontal e vertical em $\pm 0{,}05$, rotação em $\pm 10°$, com $p = 0{,}7$
RandomBrightnessContrast	`brightness_limit = 0.08`, `contrast_limit = 0.08`, com $p = 0{,}3$
ElasticTransform	`alpha = 20.0`, `sigma = 5.0`, com $p = 0{,}10$
Normalize	normalização das intensidades antes da entrada no modelo
ToTensorV2	conversão da imagem processada e da máscara para tensor, com `transpose_mask = True`

Figura 4 – Exemplo ilustrativo de imagem e máscara do conjunto de segmentação após aplicação das transformações de aumento de dados. Substituir este *placeholder* pela figura exportada do pipeline, por exemplo `augmentation_preview.png`.

3.6.3 Restrições clínicas das transformações

Embora o pipeline não implemente um módulo separado de validação clínica das transformações, as restrições clínicas estão embutidas nos próprios parâmetros escolhidos. Não são utilizados `VerticalFlip`, rotações amplas, cortes aleatórios que possam remover a lesão, deformações elásticas agressivas ou perturbações intensas de brilho e contraste. A transformação elástica foi mantida com baixa probabilidade e restrita à segmentação.

Essas escolhas preservam melhor a orientação plausível da imagem de ultrassom, a morfologia geral da lesão e a relação espacial entre a massa tumoral e o tecido adjacente. Em termos metodológicos, o pipeline adota um regime de aumento de dados conservador, adequado a um domínio no qual transformações excessivas podem produzir amostras visualmente possíveis, mas clinicamente inautênticas.

3.7 Modelagem experimental — classificação

3.7.1 Definição da tarefa

A tarefa de classificação foi definida como um problema multiclasse com três rótulos: `benign`, `malignant` e `normal`. O objetivo experimental não foi simplesmente maximizar acurácia global, mas obter um classificador equilibrado em um cenário moderadamente desbalanceado e clinicamente sensível. Por essa razão, a métrica primária de seleção adotada foi o `macro_f1`, acompanhada por acurácia, `macro precision`, `macro recall`, métricas ponderadas, AUC *one-vs-rest* e métricas por classe.

Uma decisão metodologicamente importante foi o rastreamento explícito de `malignant_recall`, tratado separadamente por sua relevância clínica. Essa escolha evita que o processo de seleção favoreça modelos que performem muito bem na classe majoritária, mas falhem justamente na sensibilidade à classe maligna.

3.7.2 Arquiteturas selecionadas

As arquiteturas de classificação selecionadas foram VGG16, ResNet50, EfficientNet-B0 e ConvNeXt-Large, todas instanciadas via `timm` com pesos pré-treinados em ImageNet. A seleção cobre arquiteturas com perfis bastante distintos:

- VGG16: CNN clássica profunda e de alto custo paramétrico;
- ResNet50: arquitetura residual consolidada;
- EfficientNet-B0: arquitetura orientada à eficiência;
- ConvNeXt-Large: convnet moderna de maior escala.

Essa diversidade foi proposital, pois permite avaliar não apenas desempenho final, mas também diferenças de comportamento entre paradigmas arquiteturais distintos.

3.7.3 Cabeças de classificação

As cabeças de classificação foram definidas implicitamente por `timm.create_model(..., num_classes=3)`, o que substitui a camada final original do *backbone* por uma camada compatível com o problema BUSI. O pipeline não introduz uma cabeça totalmente customizada externa à arquitetura-base; em vez disso, reutiliza a estrutura nativa do modelo e adapta apenas a camada terminal ao número de classes da tarefa.

Também foram definidos, por arquitetura, os prefixos considerados parte da cabeça ou da região final treinável. Isso é importante porque esses prefixos determinam quais parâmetros permanecem livres nos modos *frozen*, *partial* e *deep*.

3.7.4 Estratégias de transfer learning

O *transfer learning* constituiu o eixo central da modelagem classificatória adotada neste trabalho. Todas as arquiteturas foram inicializadas com `pretrained = true`, utilizando pesos pré-treinados em ImageNet, de modo a aproveitar representações visuais já consolidadas e adaptá-las ao domínio do ultrassom mamário. Para investigar o impacto da profundidade de adaptação do modelo ao domínio-alvo, foram considerados três regimes de ajuste fino: *frozen*, no qual apenas a cabeça de classificação permanece treinável; *partial*, em que a cabeça e os blocos finais definidos do *backbone* são liberados para atualização; e *deep*, em que toda a rede é treinável. Na configuração final consolidada, observou-se que o melhor regime dependeu da arquitetura: a VGG16 apresentou melhor resultado com $lr = 0{,}0001$, *batch size* 32 e *partial*; a ResNet50 com $lr = 0{,}001$, *batch size* 16 e *deep*; a EfficientNet-B0 com $lr = 0{,}001$, *batch size* 32 e *partial*; e a ConvNeXt-Large também com $lr = 0{,}001$, *batch size* 32 e *partial*. Além disso, os pesos de classe foram calculados diretamente a partir do conjunto de treino e incorporados à `CrossEntropyLoss`, reforçando o tratamento do desbalanceamento e reduzindo a tendência de favorecimento da classe majoritária.

3.7.5 Configuração de treino

Na rodada final de classificação, a configuração de treino foi definida de forma a equilibrar estabilidade de otimização, capacidade de convergência e viabilidade computacional. O treinamento foi conduzido com limite máximo de 250 épocas, paciência de 40 épocas para *early stopping*, otimizador `AdamW`, `weight_decay = 1e-4` e agendamento da taxa de aprendizado por `ReduceLROnPlateau`, com fator de redução $0{,}5$ e paciência 2. As imagens de entrada foram padronizadas para resolução 224×224, e o pipeline utilizou precisão mista quando executado em GPU, com suporte a `GradScaler` para maior estabilidade numérica. Além disso, o carregamento dos dados foi configurado com `num_workers = 8` e `pin_memory = true` em ambiente CUDA, favorecendo maior eficiência no fluxo entre CPU e GPU. O critério de parada foi orientado pela

Tabela 5 – Regimes de *transfer learning* considerados e melhores configurações finais por arquitetura na classificação.

Regime / Modelo	**Descrição**	**Learning rate**	**Batch size**	**Fine-tuning vencedor**
frozen	Apenas a cabeça de classificação é treinável	–	–	–
partial	Cabeça e blocos finais definidos do *backbone* são treináveis	–	–	–
deep	Toda a rede é treinável	–	–	–
VGG16	Melhor configuração final da arquitetura	$0{,}0001$	32	*partial*
ResNet50	Melhor configuração final da arquitetura	$0{,}001$	16	*deep*
EfficientNet-B0	Melhor configuração final da arquitetura	$0{,}001$	32	*partial*
ConvNeXt-Large	Melhor configuração final da arquitetura	$0{,}001$	32	*partial*

métrica primária de validação, `macro_f1`, o que é coerente com a natureza multiclasse e moderadamente desbalanceada do problema. Durante cada *trial*, o pipeline salvou tanto o melhor *checkpoint* quanto o último estado do treinamento, além de registrar tempo por época e memória máxima de GPU, permitindo não apenas selecionar o melhor modelo, mas também analisar a eficiência computacional do processo.

3.8 Modelagem experimental — segmentação

3.8.1 Definição da tarefa

A tarefa de segmentação foi definida como um problema binário restrito às classes `benign` e `malignant`. A classe `normal` foi excluída dessa etapa porque suas máscaras são vazias, o que é confirmado pela auditoria, que registrou exatamente 133 máscaras vazias, coincidentes com o número de amostras normais do dataset.

No nível de implementação, a entrada permanece sendo uma imagem RGB, a saída do modelo possui `classes = 1`, a máscara alvo é binária e a métrica primária de seleção é o coeficiente Dice. Essa formulação é coerente com o objetivo da tarefa: delimitar a região da lesão, e não discriminar múltiplas categorias semânticas por pixel.

3.8.2 Arquiteturas selecionadas

As arquiteturas selecionadas para segmentação foram:

Tabela 6 – Configuração operacional de treino adotada na rodada final da classificação.

Componente	Configuração
Número máximo de épocas	250
Early stopping	paciência de 40 épocas
Otimizador	`AdamW`
`weight_decay`	1×10^{-4}
Scheduler	`ReduceLROnPlateau`
Fator do *scheduler*	$0{,}5$
Paciência do *scheduler*	2
Tamanho de entrada	224×224
Precisão mista	habilitada em GPU
Estabilidade numérica	uso de `GradScaler`
`num_workers`	8
`pin_memory`	`true` em CUDA
Métrica primária de validação	`macro_f1`
Checkpointing	salvamento do melhor estado e do último estado
Monitoramento adicional	tempo por época e memória máxima de GPU por *trial*

- U-Net;
- Attention U-Net;
- U-Net++;
- DeepLabV3+.

U-Net, U-Net++ e DeepLabV3+ foram instanciadas via `segmentation_models_pytorch` com *encoder* `resnet34` e pesos `imagenet`. A Attention U-Net foi implementada manualmente no projeto, utilizando encoder extraído por `get_encoder`, blocos `DoubleConv`, `AttentionGate` nas conexões laterais e `ConvTranspose2d` no decodificador.

Essa seleção foi desenhada para cobrir tanto um *baseline* fortemente consolidado quanto variantes com atenção, caminhos de *skip* mais densos e arquiteturas mais orientadas à captura explícita de contexto.

3.8.3 Estratégias de treinamento

O treinamento da segmentação foi estruturado com:

- `batch size` final igual a 8;
- precisão mista em GPU;

- otimizador `AdamW`;
- validação orientada por Dice;
- ajuste de taxa de aprendizado com `ReduceLROnPlateau`;
- salvamento do melhor modelo segundo desempenho em validação;
- recarregamento do melhor *checkpoint* antes da avaliação final.

Na inferência, os logits passam por função sigmoide, as máscaras são binarizadas com limiar $0{,}5$, e os resultados são salvos juntamente com métricas por imagem e por classe. Isso mostra que a tarefa foi desenhada não apenas para gerar um escore agregado, mas também para permitir inspeção qualitativa e quantitativa caso a caso.

3.8.4 Funções de perda

O pipeline suporta três funções de perda principais para segmentação:

- `dice`: `DiceLoss(mode="binary", from_logits=True)`;
- `bce_dice`: combinação $0.5\times$ `BCEWithLogitsLoss` $+\ 0.5\times$ `DiceLoss`;
- `focal_dice`: combinação $0.5\times$ `FocalLoss` $+\ 0.5\times$ `DiceLoss`.

Na rodada final, todos os modelos segmentadores utilizaram a perda `bce_dice`. Essa escolha é tecnicamente consistente porque combina a estabilidade local da BCE com o alinhamento geométrico da Dice Loss, particularmente útil em segmentação médica com desbalanceamento entre região-alvo e fundo.

3.8.5 Configuração de treino

Na tarefa de segmentação, a configuração de treino foi estruturada para equilibrar estabilidade de otimização, qualidade espacial das máscaras preditas e viabilidade computacional. O treinamento foi conduzido com limite máximo de 250 épocas, paciência de 40 épocas para *early stopping*, uso do otimizador `AdamW` e `weight_decay = 1e-4`. No espaço de busca principal, foram avaliadas duas taxas de aprendizado, $0{,}001$ e $0{,}0001$, bem como dois tamanhos de entrada, 224×224 e 256×256. A etapa de inferência utilizou limiar fixo de $0{,}5$ para binarização das máscaras e ajuste da taxa de aprendizado por meio de `ReduceLROnPlateau`, com fator $0{,}5$ e paciência 2. Na configuração final selecionada, todas as arquiteturas avaliadas — U-Net, Attention U-Net, U-Net++ e DeepLabV3+ — convergiram para a mesma combinação ótima de hiperparâmetros: $lr = 0{,}0001$, função de perda `bce_dice` e entrada 256×256. Esse resultado é metodologicamente relevante porque sugere que, no problema estudado, a segmentação foi mais favorecida por regimes de otimização conservadores e por resolução de entrada ligeiramente maior, independentemente da arquitetura considerada.

Tabela 7 – Configuração operacional de treino adotada na rodada final da segmentação.

Componente	Configuração
Número máximo de épocas	250
Early stopping	paciência de 40 épocas
Otimizador	`AdamW`
`weight_decay`	1×10^{-4}
Taxas de aprendizado testadas	$0{,}001$ e $0{,}0001$
Tamanhos de entrada testados	224×224 e 256×256
Limiar de inferência	$0{,}5$
Scheduler	`ReduceLROnPlateau`
Fator do *scheduler*	$0{,}5$
Paciência do *scheduler*	2
Função de perda vencedora	`bce_dice`
Configuração final selecionada	$lr = 0{,}0001$, entrada 256×256, perda `bce_dice`
Modelos convergentes nessa configuração	U-Net, Attention U-Net, U-Net++ e DeepLabV3+

3.9 Hiperparâmetros e critérios de ajuste

O projeto combina duas camadas de ajuste: uma grade combinatória explícita no pipeline principal e uma busca complementar com Optuna para modelos específicos. No grid principal, a classificação explora 2 taxas de aprendizado, 2 valores de *batch size* e 3 modos de *fine-tuning*, resultando em 12 combinações por arquitetura. Na segmentação, o grid contempla 2 taxas de aprendizado, 2 perdas e 2 tamanhos de entrada, totalizando 8 combinações por modelo.

A busca com Optuna foi utilizada como camada adicional de refinamento, focando em `convnext_large` para classificação e `unetplusplus` para segmentação, com espaços mais amplos para taxa de aprendizado, *weight decay*, estratégias de *augmentation* e outros ajustes finos.

3.9.1 Taxa de aprendizado

No grid principal, as taxas de aprendizado consideradas foram 10^{-3} e 10^{-4}, tanto para classificação quanto para segmentação. Na busca Optuna, os espaços foram ampliados para intervalos logarítmicos entre 10^{-5} e 5×10^{-3} na classificação, e entre 10^{-5} e 3×10^{-3} na segmentação.

Na configuração final consolidada, os melhores resultados classificatórios usaram 0.001 para ResNet50, EfficientNet-B0 e ConvNeXt-Large, e 0.0001 para VGG16. Na segmentação, todos os modelos finais convergiram para 0.0001. Isso sugere que a ta-

refa segmentadora foi mais sensível a taxas conservadoras, enquanto a classificação admitiu taxas mais agressivas em arquiteturas específicas.

3.9.2 Batch size

Os valores considerados para classificação foram 16 e 32. Na segmentação final, o *batch size* foi fixado em 8, enquanto a busca com Optuna explorou os valores 4, 8 e 12. Essa diferença entre tarefas é coerente com o maior custo de memória da segmentação pixel a pixel, especialmente sob resoluções maiores.

3.9.3 Número de épocas

O repositório registra diferentes regimes de treinamento ao longo do desenvolvimento, incluindo cenários curtos para experimentação preliminar e rodadas longas para consolidação final. Na rodada `best_trials_250_es40`, foi adotado teto de 250 épocas para ambas as tarefas. Entretanto, na prática, o número máximo de épocas é secundário frente ao papel do *early stopping*, que interrompe o treinamento quando não há ganho sustentado em validação.

3.9.4 Early stopping e checkpointing

O *early stopping* foi implementado por uma classe dedicada com `mode = "max"` e paciência configurável. O mecanismo acompanha a melhor métrica observada em validação e interrompe o treinamento quando não há melhoria sustentada.

O sistema de *checkpointing* salva dois estados:

- `best_model.pt`: melhor estado segundo a métrica primária;
- `last_model.pt`: último estado ao final do treino.

Cada *checkpoint* inclui pesos do modelo, estado do otimizador, estado do scheduler, época, métricas, configuração do *trial* e nome do modelo. Essa decisão melhora substancialmente a reprodutibilidade em relação ao salvamento de pesos isolados.

3.9.5 Critérios de seleção dos melhores modelos

A seleção dos melhores modelos ocorre em três níveis:

1. melhor época dentro de cada *trial*, definida pela métrica primária de validação;
2. melhor *trial* dentro de cada arquitetura, definido por `val_macro_f1` na classificação e `val_dice` na segmentação;
3. comparação final entre arquiteturas no conjunto de teste, registrada em `model_summary.csv`.

Após a seleção por validação, o pipeline recarrega o `best_model.pt`, executa inferência no conjunto de teste e salva métricas finais, curvas, matrizes, galerias qualitativas, *benchmarks* e tabelas comparativas. Além disso, o projeto deriva medidas de *trade-off* entre desempenho e custo com razões como $\texttt{macro_f1}/\log_{10}(\texttt{parameters_total})$ para classificação e $\texttt{dice}/\log_{10}(\texttt{parameters_total})$ para segmentação.

3.10 Métricas de avaliação

A avaliação do desempenho dos modelos foi concebida para capturar diferentes dimensões da tarefa de classificação: desempenho global, comportamento médio entre classes, sensibilidade à classe clinicamente mais crítica e capacidade discriminativa probabilística. Em problemas de imagem médica, especialmente sob desbalanceamento de classes, a análise por uma única métrica tende a ser insuficiente, pois diferentes indicadores enfatizam propriedades distintas do classificador. Por essa razão, o pipeline foi estruturado para produzir métricas agregadas, métricas ponderadas, métricas por classe, matriz de confusão, curvas ROC no esquema *one-vs-rest* e arquivos com probabilidades preditas por imagem.

Seja um problema multiclasse com conjunto de classes

$$\mathcal{C} = \{1, 2, \ldots, K\},$$

e seja N o número total de amostras do conjunto avaliado. Para cada classe $k \in \mathcal{C}$, definem-se:

- TP_k: verdadeiros positivos da classe k;
- FP_k: falsos positivos da classe k;
- FN_k: falsos negativos da classe k;
- TN_k: verdadeiros negativos da classe k.

No esquema multiclasse, esses valores são obtidos por decomposição *one-vs-rest*, isto é, cada classe é tratada como positiva contra a união das demais. A partir dessas quantidades, torna-se possível derivar métricas por classe e, posteriormente, resumí-las por médias macro e ponderadas.

3.10.1 Métricas de classificação

As métricas de classificação foram organizadas em três níveis complementares:

1. **métricas globais**, que oferecem uma visão resumida do comportamento do modelo no conjunto completo;

2. **métricas macro**, que atribuem o mesmo peso a todas as classes, independentemente do suporte;

3. **métricas ponderadas**, que levam em conta o número de amostras por classe.

Essa organização é particularmente importante no presente estudo, pois a tarefa envolve três classes (*benign*, *malignant* e *normal*) com distribuição desigual no dataset. Em tal contexto, métricas baseadas apenas em frequência global poderiam superestimar o desempenho do modelo na classe majoritária e subestimar falhas nas classes de maior interesse clínico.

A Tabela 8 resume as principais métricas utilizadas na classificação.

Tabela 8 – Resumo das métricas adotadas na avaliação dos modelos de classificação.

Métrica	**Formulação geral**	**Objetivo interpretativo**
Accuracy	fração global de acertos	medir desempenho total do classificador
Precision	$TP/(TP+FP)$	quantificar confiabilidade das predições positivas
Recall / Sensibilidade	$TP/(TP+FN)$	medir capacidade de recuperar casos realmente positivos
F1-score	média harmônica entre *precision* e *recall*	equilibrar sensibilidade e precisão
AUC-ROC	área sob a curva ROC	medir separabilidade probabilística entre classes
Especificidade	$TN/(TN+FP)$	medir capacidade de rejeitar corretamente os negativos

Além dessas métricas, o pipeline produz:

- matriz de confusão;
- curvas ROC no esquema *one-vs-rest*;
- arquivo de predições contendo, para cada imagem, o rótulo previsto e as probabilidades associadas a cada classe.

Esse conjunto de saídas torna a avaliação mais robusta, pois permite analisar simultaneamente decisão discreta, separabilidade probabilística e estrutura dos erros.

3.10.1.1 Accuracy

A *accuracy* mede a proporção global de predições corretas em relação ao número total de amostras avaliadas. Seja $\hat{y}_i$ o rótulo predito para a amostra i e y_i o rótulo verdadeiro. Então,

$$\text{Accuracy} = \frac{1}{N}\sum_{i=1}^{N}\mathbf{1}(\hat{y}_i = y_i),$$

onde $\mathbf{1}(\cdot)$ é a função indicadora.

Em termos de matriz de confusão multiclasse, a *accuracy* também pode ser interpretada como a soma dos elementos da diagonal principal dividida pelo total de amostras:

$$\text{Accuracy} = \frac{\sum_{k=1}^{K} M_{kk}}{\sum_{i=1}^{K} \sum_{j=1}^{K} M_{ij}},$$

em que M_{ij} representa o número de exemplos cuja classe verdadeira é i e cuja classe predita é j.

Embora seja uma métrica intuitiva e útil como visão geral, sua interpretação isolada é limitada em contextos desbalanceados. Isso ocorre porque a *accuracy* pode permanecer relativamente alta mesmo quando o modelo apresenta desempenho insatisfatório em classes menos frequentes, especialmente se essas classes forem clinicamente relevantes. Por essa razão, no presente trabalho a *accuracy* foi interpretada sempre em conjunto com métricas mais sensíveis ao comportamento por classe.

3.10.1.2 Precision

A *precision* quantifica a proporção de exemplos preditos como pertencentes a uma classe que realmente pertencem a essa classe. Para cada classe k, define-se:

$$\text{Precision}_k = \frac{TP_k}{TP_k + FP_k}.$$

Essa métrica é útil para avaliar o grau de confiabilidade das predições positivas do modelo. Em termos práticos, alta *precision* para uma classe indica que, quando o modelo decide por aquele rótulo, tende a cometer relativamente poucos falsos positivos.

No caso multiclasse, o pipeline registra:

- **precision por classe**, para análise individual de cada rótulo;
- **macro precision**, definida por

$$\text{Macro Precision} = \frac{1}{K} \sum_{k=1}^{K} \text{Precision}_k;$$

- **weighted precision**, definida por

$$\text{Weighted Precision} = \sum_{k=1}^{K} \frac{n_k}{N} \text{Precision}_k,$$

  em que n_k é o número de amostras da classe k.

A média macro atribui o mesmo peso a todas as classes, enquanto a média ponderada reflete a distribuição real do conjunto de dados. Em problemas médicos, essa

distinção é importante porque classes menos frequentes podem ser justamente as mais críticas do ponto de vista clínico.

3.10.1.3 Recall / Sensibilidade

O *recall*, também chamado de sensibilidade, mede a capacidade do classificador de recuperar corretamente os exemplos positivos de uma determinada classe. Para cada classe k, tem-se:

$$\text{Recall}_k = \frac{TP_k}{TP_k + FN_k}.$$

Em contextos clínicos, essa métrica é particularmente relevante porque falsos negativos podem ter custo elevado. No presente estudo, isso é especialmente verdadeiro para a classe *malignant*, cuja perda implica deixar de sinalizar uma lesão potencialmente cancerígena. Por essa razão, além do *macro recall*, o pipeline monitora explicitamente o `malignant_recall` como indicador de sensibilidade clínica.

As médias agregadas são calculadas por:

$$\text{Macro Recall} = \frac{1}{K}\sum_{k=1}^{K} \text{Recall}_k$$

e

$$\text{Weighted Recall} = \sum_{k=1}^{K} \frac{n_k}{N}\,\text{Recall}_k.$$

No contexto desta pesquisa, o *recall* da classe *malignant* tem papel interpretativo central, pois um modelo com bom desempenho médio, mas sensibilidade insuficiente para malignidade, pode ser inadequado como ferramenta de apoio à triagem.

3.10.1.4 F1-score

O F_1-*score* combina *precision* e *recall* em uma média harmônica, sendo definido, para cada classe k, por:

$$F1_k = \frac{2 \cdot \text{Precision}_k \cdot \text{Recall}_k}{\text{Precision}_k + \text{Recall}_k}.$$

Essa formulação penaliza situações em que uma das duas métricas é alta e a outra é baixa, o que torna o F_1-*score* particularmente útil quando se deseja equilíbrio entre sensibilidade e confiabilidade das predições.

As formas agregadas utilizadas no pipeline foram:

$$\text{Macro F1} = \frac{1}{K}\sum_{k=1}^{K} F1_k$$

e

$$\text{Weighted F1} = \sum_{k=1}^{K} \frac{n_k}{N} F1_k.$$

No presente trabalho, o `macro_f1` foi adotado como métrica primária de seleção dos modelos de classificação. Essa escolha é metodologicamente apropriada porque reduz o risco de favorecer artificialmente o desempenho na classe majoritária e força o classificador a manter comportamento mais equilibrado entre as três categorias do problema.

3.10.1.5 AUC-ROC

A AUC-ROC (*Area Under the Receiver Operating Characteristic Curve*) foi utilizada para medir a capacidade do modelo de separar probabilisticamente as classes, independentemente de um único limiar de decisão. Em problemas multiclasse, a avaliação foi realizada no esquema *one-vs-rest*. Para cada classe k, considera-se a distinção entre:

$$\text{classe } k \quad \text{vs.} \quad \mathcal{C} \setminus \{k\}.$$

A curva ROC é construída a partir da relação entre taxa de verdadeiros positivos (*True Positive Rate*, TPR) e taxa de falsos positivos (*False Positive Rate*, FPR):

$$\text{TPR}_k = \frac{TP_k}{TP_k + FN_k}, \qquad \text{FPR}_k = \frac{FP_k}{FP_k + TN_k}.$$

A AUC corresponde à área sob essa curva:

$$\text{AUC}_k = \int_0^1 \text{TPR}_k(\text{FPR})\, d(\text{FPR}).$$

No pipeline, foram registradas:

- **AUC por classe**, para inspeção individual;
- **macro AUC**, definida por

$$\text{Macro AUC} = \frac{1}{K} \sum_{k=1}^{K} \text{AUC}_k;$$

- **weighted AUC**, definida por

$$\text{Weighted AUC} = \sum_{k=1}^{K} \frac{n_k}{N} \text{AUC}_k.$$

A vantagem da AUC-ROC é que ela avalia separabilidade probabilística sem de-

pender diretamente da regra final de *argmax*. Isso é particularmente útil em imagem médica, onde o modelo pode conter sinal discriminativo relevante mesmo quando sua decisão discreta final ainda é subótima.

3.10.1.6 Especificidade

A especificidade mede a capacidade do modelo de identificar corretamente os exemplos negativos em relação a uma classe tomada como positiva. Para a classe k, define-se:

$$\text{Specificity}_k = \frac{TN_k}{TN_k + FP_k}.$$

Essa métrica complementa o *recall*. Enquanto a sensibilidade mede o quanto o modelo recupera corretamente os casos positivos, a especificidade mede o quanto ele evita alarmes indevidos sobre os casos negativos. Em aplicações médicas, ambas são necessárias para compreender o equilíbrio entre detecção e contenção de falsos positivos.

No presente trabalho, a especificidade foi registrada por classe, o que permite, por exemplo, analisar se o modelo detecta bem lesões malignas à custa de exagerar excessivamente o número de exames normais ou benignos classificados como suspeitos. Assim, a inclusão da especificidade fortalece a interpretação clínica da classificação e evita análises excessivamente centradas apenas em sensibilidade.

Em síntese, o conjunto de métricas adotado nesta pesquisa foi construído para oferecer uma avaliação abrangente da classificação multiclasse em ultrassom mamário. A combinação entre *accuracy*, *precision*, *recall*, F_1-*score*, AUC-ROC e especificidade, aliada à análise por classe e à inspeção probabilística, fornece uma base mais robusta para julgar os modelos do que qualquer métrica isolada.

3.10.2 Métricas de segmentação

Na tarefa de segmentação, a avaliação foi estruturada a partir da comparação pixel a pixel entre a máscara predita pelo modelo e a máscara de referência anotada no dataset. Diferentemente da classificação, em que a saída é um único rótulo por imagem, a segmentação exige mensurar simultaneamente qualidade de contorno, cobertura da região-alvo e tendência do modelo a subsegmentar ou sobresegmentar a lesão. Para isso, o pipeline foi construído com base em contagens binárias por pixel, a partir das quais são derivadas métricas de sobreposição, sensibilidade espacial e precisão da máscara. Seja Ω o domínio discreto da imagem, com $|\Omega| = H \times W$, e sejam

$$Y(p) \in \{0, 1\} \qquad \text{e} \qquad \hat{Y}(p) \in \{0, 1\},$$

respectivamente, a máscara de referência e a máscara predita para cada pixel $p \in \Omega$. A partir dessas máscaras binárias, definem-se:

- TP: número de pixels corretamente classificados como pertencentes à lesão;
- FP: número de pixels preditos como lesão, mas pertencentes ao fundo;
- FN: número de pixels da lesão não recuperados pela predição;
- TN: número de pixels corretamente classificados como fundo.

Formalmente, essas quantidades podem ser escritas como:

$$TP = \sum_{p \in \Omega} \mathbf{1}\big(Y(p) = 1 \wedge \hat{Y}(p) = 1\big),$$

$$FP = \sum_{p \in \Omega} \mathbf{1}\big(Y(p) = 0 \wedge \hat{Y}(p) = 1\big),$$

$$FN = \sum_{p \in \Omega} \mathbf{1}\big(Y(p) = 1 \wedge \hat{Y}(p) = 0\big),$$

$$TN = \sum_{p \in \Omega} \mathbf{1}\big(Y(p) = 0 \wedge \hat{Y}(p) = 0\big).$$

A partir dessas contagens, o pipeline calcula métricas agregadas, métricas por imagem, métricas por classe e estatísticas estruturais relacionadas à quantidade de pixels positivos previstos e observados. Essa estratégia é metodologicamente importante porque permite analisar a segmentação em múltiplos níveis: desempenho médio do modelo, comportamento em casos específicos e tendência estrutural à expansão ou retração da máscara. A Tabela 9 resume as principais métricas empregadas na avaliação segmentadora. Além dessas métricas, o pipeline registra:

Tabela 9 – Resumo das métricas adotadas na avaliação dos modelos de segmentação.

Métrica	**Formulação geral**	**Objetivo interpretativo**
IoU	$\dfrac{TP}{TP + FP + FN}$	medir sobreposição espacial entre predição e referência
Dice Score	$\dfrac{2TP}{2TP + FP + FN}$	avaliar concordância espacial com ênfase em regiões pequenas
Precision	$\dfrac{TP}{TP + FP}$	quantificar tendência à sobre-segmentação
Recall	$\dfrac{TP}{TP + FN}$	quantificar tendência à subsegmentação
F1-score pixel-wise	$\dfrac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$	sintetizar equilíbrio entre cobertura e contenção da máscara

- métricas médias e desvios-padrão no conjunto avaliado;

- métricas por imagem, úteis para análise de casos difíceis;
- métricas por classe (*benign* e *malignant*);
- estatísticas estruturais como número de pixels positivos previstos e número de pixels positivos no *ground truth*.

Essa estrutura analítica permite não apenas comparar modelos entre si, mas também compreender a natureza dos seus erros.

3.10.2.1 IoU

A *Intersection over Union* (IoU), também conhecida como índice de Jaccard, mede a razão entre a interseção e a união das regiões segmentadas. Em notação de conjuntos, sejam

$$A = \{p \in \Omega : Y(p) = 1\} \qquad \text{e} \qquad B = \{p \in \Omega : \hat{Y}(p) = 1\},$$

onde A representa a região verdadeira da lesão e B a região predita. A IoU é definida por:

$$\text{IoU} = \frac{|A \cap B|}{|A \cup B|} = \frac{TP}{TP + FP + FN}.$$

Essa métrica é altamente informativa para avaliar qualidade segmentadora global, pois penaliza simultaneamente pixels indevidamente adicionados à máscara (FP) e pixels da lesão não recuperados (FN). Em outras palavras, uma IoU alta implica que a área prevista coincide de forma consistente com a área de referência, tanto em extensão quanto em localização. No contexto desta pesquisa, a IoU foi utilizada como métrica complementar ao Dice, especialmente útil para comparar modelos em termos de fidelidade espacial mais estrita. Como sua formulação não inclui TN, ela é menos influenciada pela grande quantidade de pixels de fundo, o que é desejável em segmentação médica.

3.10.2.2 Dice Score

O coeficiente Dice foi adotado como métrica primária de seleção na segmentação. Sua formulação é:

$$\text{Dice} = \frac{2|A \cap B|}{|A| + |B|} = \frac{2TP}{2TP + FP + FN}.$$

O Dice pode ser interpretado como uma medida de similaridade entre a máscara predita e a máscara de referência. Sua principal vantagem é ser particularmente adequado a cenários de desbalanceamento severo entre região-alvo e fundo, como é típico em segmentação de lesões médicas. Como a área da lesão geralmente ocupa pequena fração da imagem, métricas que incluam fortemente TN podem transmitir

uma impressão artificialmente otimista do desempenho. O Dice evita esse problema ao focar explicitamente na sobreposição da região positiva. Outra propriedade importante é sua relação com a IoU:

$$\text{Dice} = \frac{2 \cdot \text{IoU}}{1 + \text{IoU}}.$$

Isso mostra que ambas as métricas são correlatas, mas o Dice tende a ser numericamente mais alto e, muitas vezes, mais estável em tarefas com pequenas estruturas anatômicas. Por essa razão, foi adotado como critério principal para seleção do melhor *checkpoint* e do melhor *trial* por modelo.

3.10.2.3 Precision

Na segmentação, a *precision* mede a proporção de pixels preditos como pertencentes à lesão que de fato pertencem à lesão:

$$\text{Precision} = \frac{TP}{TP + FP}.$$

Essa métrica é particularmente útil para caracterizar a tendência do modelo à sobresegmentação. Quando a *precision* é baixa, isso indica que a máscara predita está incluindo muitos pixels de fundo como se fossem lesão, expandindo indevidamente a região tumoral. Em termos qualitativos, modelos com *precision* mais baixa tendem a produzir máscaras “mais largas” ou mais “agressivas”, cobrindo áreas além da estrutura anotada. No presente estudo, a *precision* teve papel importante para distinguir modelos de comportamento mais conservador daqueles de comportamento mais expansivo. Assim, ela complementa as métricas de sobreposição ao oferecer uma leitura mais direta da contenção espacial da máscara.

3.10.2.4 Recall

O *recall* em segmentação mede a capacidade do modelo de recuperar os pixels verdadeiramente pertencentes à lesão:

$$\text{Recall} = \frac{TP}{TP + FN}.$$

Enquanto a *precision* penaliza expansão indevida, o *recall* penaliza omissão de área tumoral. Assim, essa métrica é especialmente importante para identificar subsegmentação. Um modelo com *recall* baixo tende a produzir máscaras menores que a lesão real, deixando de cobrir partes relevantes da estrutura-alvo. Essa métrica é clinicamente relevante porque uma segmentação incompleta pode comprometer análise morfológica, cálculo de área ou volume e interpretações derivadas da extensão da lesão. Portanto, sua presença no protocolo experimental foi fundamental para distinguir

modelos que recuperam bem a área total da lesão daqueles que preferem soluções mais compactas e restritivas.

3.10.2.5 F1-score pixel-wise

O F_1-*score* pixel-wise sintetiza o equilíbrio entre *precision* e *recall* em nível de pixel. Sua formulação é:

$$F1_{\text{pixel}} = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}.$$

Substituindo as definições de *precision* e *recall*, obtém-se:

$$F1_{\text{pixel}} = \frac{2TP}{2TP + FP + FN},$$

o que o torna equivalente ao coeficiente Dice em segmentação binária. Ainda assim, sua apresentação como F_1-*score* pixel-wise é conceitualmente útil porque explicita sua interpretação como compromisso entre contenção da máscara (*precision*) e cobertura da lesão (*recall*). Essa métrica ocupa papel complementar às métricas de sobreposição porque ajuda a interpretar o comportamento do modelo em linguagem análoga à utilizada na classificação. Em outras palavras, ela permite discutir segmentação em termos de equilíbrio entre "detectar demais" e "detectar de menos", o que é particularmente útil quando se deseja relacionar os resultados quantitativos à análise qualitativa das máscaras produzidas. Em síntese, o conjunto de métricas adotado para a segmentação foi desenhado para fornecer uma avaliação abrangente da qualidade espacial das predições. A combinação entre IoU, Dice Score, *precision*, *recall* e F_1-*score* pixel-wise, somada à análise por imagem e por classe, permite interpretar os modelos não apenas em termos de desempenho médio, mas também em relação à forma como cometem erro, se tendem a expandir ou retrair a máscara e quão fielmente recuperam a região tumoral em diferentes cenários visuais.

3.10.3 Métricas computacionais

As métricas computacionais foram incorporadas ao protocolo experimental como dimensão analítica de primeira ordem, e não como complemento secundário aos resultados preditivos. Essa decisão metodológica foi particularmente importante neste trabalho porque a comparação entre arquiteturas envolveu modelos com perfis muito distintos de capacidade, profundidade, latência e custo operacional. Em aplicações de apoio ao diagnóstico, desempenho preditivo e viabilidade computacional devem ser analisados conjuntamente, uma vez que a utilidade prática de um modelo depende não apenas de sua qualidade estatística, mas também de sua possibilidade de treinamento, armazenamento, carregamento e inferência em ambientes reais. Para cada *trial*, o pipeline registrou um conjunto estruturado de métricas computacionais, incluindo número total de parâmetros, número de parâmetros treináveis, tempo total

de treinamento, tempo médio por época, pico de memória em GPU, latência média de inferência, desvio-padrão da latência, *throughput* em imagens por segundo e tamanho final do modelo em megabytes. Esse conjunto foi projetado para capturar diferentes aspectos do custo computacional:

- **complexidade estrutural**, refletida pelo número de parâmetros;
- **custo de otimização**, refletido pelo tempo de treinamento;
- **custo operacional em inferência**, refletido por latência e *throughput*;
- **viabilidade de implantação**, refletida pelo tamanho final do modelo e pelo consumo de memória.

A Tabela 10 resume as principais métricas computacionais adotadas no estudo. Do

Tabela 10 – Resumo das métricas computacionais utilizadas na avaliação dos modelos.

Métrica	**Unidade / Formulação**	**Objetivo interpretativo**
Número total de parâmetros	`parameters_total`	quantificar a capacidade estrutural bruta do modelo
Número de parâmetros treináveis	`parameters_trainable`	medir a parcela efetivamente ajustada durante o treino
Tempo total de treinamento	segundos por *trial*	medir custo empírico de otimização
Tempo médio por época	segundos/época	comparar eficiência de convergência entre modelos
Latência média de inferência	milissegundos/imagem	avaliar rapidez de uso em cenário operacional
Desvio-padrão da latência	milissegundos	medir estabilidade temporal da inferência
Throughput	imagens/segundo	medir capacidade de processamento contínuo
Pico de memória	MB	avaliar demanda máxima de memória durante execução
Tamanho do modelo	MB	avaliar viabilidade de armazenamento e implantação

ponto de vista metodológico, a incorporação dessas métricas permite interpretar o desempenho dos modelos por uma função utilidade mais ampla, e não apenas por uma métrica preditiva isolada. Em termos conceituais, pode-se representar a avaliação final de um modelo M como uma função multivariada:

$$\mathcal{U}(M) = f\big(\mathcal{P}(M),\, \mathcal{C}_{\text{train}}(M),\, \mathcal{C}_{\text{inf}}(M),\, \mathcal{S}(M)\big),$$

em que:

- $\mathcal{P}(M)$ representa o desempenho preditivo;

- $\mathcal{C}_{\text{train}}(M)$ representa o custo de treinamento;
- $\mathcal{C}_{\text{inf}}(M)$ representa o custo de inferência;
- $\mathcal{S}(M)$ representa o custo estrutural e de armazenamento.

Essa formulação explicita que um modelo pode ser estatisticamente superior, mas operacionalmente menos desejável, dependendo do contexto de uso.

3.10.3.1 Número de parâmetros

O número de parâmetros é uma medida direta da capacidade estrutural da rede neural. No pipeline, foram registrados dois valores distintos:

- `parameters_total`: número total de parâmetros do modelo;
- `parameters_trainable`: número de parâmetros efetivamente atualizados durante o treinamento.

Formalmente, se $\boldsymbol{\theta}$ representa o conjunto total de parâmetros de um modelo, então:

$$\texttt{parameters_total} = |\boldsymbol{\theta}|.$$

Se $\boldsymbol{\theta}_{\text{train}} \subseteq \boldsymbol{\theta}$ denota o subconjunto de parâmetros com `requires_grad = True`, então:

$$\texttt{parameters_trainable} = |\boldsymbol{\theta}_{\text{train}}|.$$

Essa distinção é particularmente importante em cenários com *transfer learning*, pois diferentes estratégias de ajuste fino alteram substancialmente a parcela efetivamente treinável da arquitetura. Em um regime *frozen*, por exemplo, espera-se que:

$$|\boldsymbol{\theta}_{\text{train}}| \ll |\boldsymbol{\theta}|,$$

enquanto em *deep fine-tuning* tende-se a observar:

$$|\boldsymbol{\theta}_{\text{train}}| \approx |\boldsymbol{\theta}|.$$

Do ponto de vista interpretativo, o número total de parâmetros fornece uma proxy da capacidade representacional bruta do modelo, enquanto o número de parâmetros treináveis informa o custo real de adaptação ao domínio-alvo. Em problemas médicos com base moderada, essa distinção é crucial, pois arquiteturas muito grandes podem não converter sua capacidade extra em ganho prático proporcional.

3.10.3.2 Tempo de treinamento

O pipeline registra o tempo total de treinamento por *trial* e o tempo médio por época, permitindo analisar custo de otimização em termos empíricos. Se um dado *trial* executa E épocas e o tempo de cada época é t_e, então o tempo total de treinamento pode ser expresso por:

$$T_{\text{train,total}} = \sum_{e=1}^{E} t_e,$$

e o tempo médio por época por:

$$\overline{T}_{\text{epoch}} = \frac{1}{E} \sum_{e=1}^{E} t_e.$$

Essa informação é metodologicamente mais rica do que a simples contagem de parâmetros, pois o custo real de treinamento depende também de fatores como:

- resolução da entrada;
- tamanho do lote;
- profundidade de *fine-tuning*;
- comportamento do *scheduler*;
- número efetivo de épocas executadas antes do *early stopping*.

Em outras palavras, duas arquiteturas com capacidades semelhantes podem apresentar custos de treinamento bastante diferentes, caso uma convirja mais lentamente, execute mais épocas úteis ou exija operações mais pesadas por iteração. Por isso, o tempo de treinamento foi tratado como medida empírica de custo, e não como consequência trivial do porte da rede.

3.10.3.3 Tempo de inferência

A inferência foi avaliada por meio de *benchmark* dedicado, com etapas separadas de aquecimento e medição. Essa decisão reduz o viés introduzido por sobrecusto inicial de carregamento, compilação dinâmica ou aquecimento de GPU. Sejam n execuções medidas após aquecimento e t_i o tempo observado em cada execução. A latência média de inferência é dada por:

$$\overline{T}_{\text{inf}} = \frac{1}{n} \sum_{i=1}^{n} t_i,$$

e seu desvio-padrão por:

$$\sigma_{\text{inf}} = \sqrt{\frac{1}{n-1}\sum_{i=1}^{n}\left(t_i - \overline{T}_{\text{inf}}\right)^2}.$$

Além da latência média, o pipeline registra o *throughput*, definido como o número de imagens processadas por unidade de tempo:

$$\text{Throughput} = \frac{N_{\text{imgs}}}{T_{\text{total,inf}}}.$$

Enquanto a latência média é mais informativa para cenários interativos ou de apoio em tempo real, o *throughput* é mais relevante em cenários de processamento em lote. O registro simultâneo dessas duas quantidades permite avaliar a viabilidade prática de cada modelo em diferentes contextos de uso. Em ambientes clínicos ou acadêmicos com restrição de recursos, uma arquitetura ligeiramente inferior em desempenho preditivo pode se tornar mais atraente se sua latência for significativamente menor.

3.10.3.4 Tamanho do modelo

O tamanho final do modelo em megabytes foi registrado nos resumos de arquitetura como medida de viabilidade de armazenamento e implantação. Se B representa o número total de bytes necessários para armazenar os pesos serializados do modelo, então:

$$\text{Model Size (MB)} = \frac{B}{1024^2}.$$

Embora fortemente correlacionado ao número de parâmetros, o tamanho final do modelo não é completamente redundante, pois pode variar com o formato de serialização, o tipo de dado armazenado e o empacotamento do estado do modelo. Em termos práticos, essa métrica é importante para avaliar:

- custo de armazenamento em disco;
- tempo de carregamento do modelo;
- facilidade de distribuição e implantação;
- adequação a dispositivos ou ambientes com memória limitada.

Em aplicações reais, modelos muito grandes podem impor dificuldades logísticas mesmo quando oferecem bom desempenho preditivo. Por isso, o tamanho final do modelo compõe, junto com latência e número de parâmetros, a análise de compromisso entre qualidade de previsão e viabilidade operacional. Em síntese, as métricas computacionais adotadas nesta pesquisa foram fundamentais para evitar uma leitura

excessivamente centrada em desempenho estatístico. Ao integrar número de parâmetros, tempo de treinamento, latência, *throughput*, memória e tamanho final do modelo, o protocolo experimental permitiu comparar arquiteturas não apenas pelo que acertam, mas também pelo custo real de fazê-lo. Essa perspectiva é especialmente relevante em problemas de saúde, nos quais a utilidade prática de um sistema depende tanto de sua qualidade preditiva quanto de sua possibilidade concreta de uso em ambientes computacionalmente restritos.

3.11 Procedimento experimental

3.11.1 Etapas da experimentação

A experimentação foi organizada por meio de comandos explícitos em interface de linha de comando (CLI), o que contribuiu para a padronização das execuções e para a reprodutibilidade do pipeline. Entre os comandos definidos no projeto, destacam-se `audit`, `prepare`, `classify`, `segment`, `report`, `full-run` e `smoke-test`, cada um associado a uma etapa funcional bem delimitada dentro do fluxo experimental.

Tabela 11 – Comandos CLI utilizados no pipeline experimental

Comando	Função no experimento
`audit`	Realiza a auditoria inicial do conjunto de dados.
`prepare`	Gera manifestos, particionamentos e artefatos preparatórios do experimento.
`classify`	Executa os *trials* relacionados à tarefa de classificação.
`segment`	Executa os *trials* relacionados à tarefa de segmentação.
`report`	Consolida resultados em tabelas, figuras e relatórios finais.
`full-run`	Dispara o fluxo completo do experimento de ponta a ponta.
`smoke-test`	Executa uma verificação rápida de funcionamento do pipeline.

De forma sintética, o fluxo completo do experimento envolveu a auditoria do *dataset*, a geração dos manifestos e dos *splits*, a criação de *previews* de pré-processamento e aumento de dados, a execução dos *trials* de classificação e segmentação, a seleção dos melhores modelos com base no desempenho em validação, a avaliação final em teste, a realização de *benchmark* de inferência e, por fim, a geração dos artefatos consolidados de análise.

3.11.2 Reprodutibilidade e fixação de seeds

A reprodutibilidade foi tratada explicitamente no código por meio da fixação coordenada de sementes em `random`, `NumPy`, `PyTorch` e `CUDA`, além de `PYTHONHASHSEED`,

Tabela 12 – Sequência das etapas da experimentação

Etapa	Descrição
1	Auditoria do *dataset*.
2	Geração dos manifestos e dos *splits*.
3	Criação dos *previews* de pré-processamento e aumento de dados.
4	Execução dos *trials* de classificação.
5	Seleção do melhor *trial* de classificação com base na validação e posterior avaliação em teste.
6	Execução dos *trials* de segmentação.
7	Seleção do melhor *trial* de segmentação com base na validação e posterior avaliação em teste.
8	Execução do *benchmark* de inferência.
9	Geração de tabelas, gráficos, galerias qualitativas e relatórios finais.

`torch.backends.cudnn.deterministic = True` e `torch.backends.cudnn.benchmark = False`. O `train_test_split` utiliza `random_state = seed`, o `DataLoader` opera com gerador fixo, e cada *worker* recebe semente consistente por `seed_worker`. A semente principal adotada nas rodadas consolidadas foi 42.

Essa combinação oferece forte controle sobre variabilidade experimental, ainda que pequenas diferenças residuais possam existir em ambiente GPU.

3.11.3 Registro e armazenamento dos resultados

Os resultados do experimento foram organizados em uma árvore de artefatos estruturada para favorecer rastreabilidade, inspeção manual e reaproveitamento posterior das saídas geradas. Essa organização separa, de forma clara, os elementos de auditoria, metadados, resultados de treinamento, relatórios consolidados e registros de execução, o que facilita tanto a análise técnica quanto a documentação do estudo.

Os formatos empregados nesse processo incluíram CSV, JSON, YAML, PNG e Markdown. Em conjunto, esses formatos permitiram conciliar leitura humana, rastreabilidade experimental e suporte à automação posterior, preservando tanto a interpretabilidade dos resultados quanto sua reutilização em análises complementares e na etapa de escrita acadêmica.

3.11.4 Fluxo geral do experimento

O fluxo arquitetural do projeto foi estruturado de modo sequencial e modular, cobrindo desde a preparação inicial dos dados até a geração dos artefatos finais de análise. Em termos gerais, o experimento partiu do conjunto bruto de imagens, passou por etapas de auditoria e padronização, seguiu para o particionamento estratificado dos dados e, em seguida, para a construção dos *datasets* e transformações utiliza-

Tabela 13 – Estrutura de armazenamento dos artefatos experimentais

Diretório	**Conteúdo principal**
`audit/`	Relatórios de integridade, distribuição de classes, estatísticas descritivas e grades visuais.
`manifests/`	Manifestos, particionamentos (*splits*) e metadados associados ao experimento.
`classification/`	Pastas organizadas por modelo e por *trial*, contendo `history.csv`, curvas de treinamento, configurações resolvidas, métricas de validação e saídas de teste.
`segmentation/`	Estrutura análoga à de classificação, incluindo máscaras preditas, métricas por imagem, métricas por classe e galerias qualitativas.
`reports/`	Sumários consolidados e texto-base destinado à redação da monografia.
`logs/`	Registros detalhados dos comandos executados ao longo das etapas experimentais.

das no treinamento. A partir daí, cada *trial* foi conduzido com validação sistemática, uso de *early stopping*, seleção do melhor *checkpoint*, avaliação em teste, execução de *benchmark* e produção de relatórios e figuras.

Quando observado por tarefa, o fluxo de classificação foi mais direto: a imagem RGB é fornecida ao *backbone* pré-treinado, que produz *logits* multiclasse; esses valores são então convertidos por *softmax*, permitindo o cálculo de métricas agregadas e métricas por classe. Já na segmentação, o processo parte da imagem RGB associada à máscara binária de referência, percorre uma arquitetura do tipo *encoder-decoder*, gera *logits* binários e, após a aplicação de *sigmoid* e limiarização, produz métricas por imagem, por classe e agregadas.

A leitura final dessa arquitetura experimental indica que o projeto é modular, reprodutível e metodologicamente consistente, sobretudo na separação entre validação e teste. Além disso, sua estrutura permite discutir não apenas desempenho clínico, mas também custo computacional e viabilidade operacional. A principal limitação remanescente, contudo, é a ausência de particionamento em nível de paciente, o que constitui o passo mais natural de evolução metodológica em direção a um desenho experimental ainda mais rigoroso.

Tabela 14 – Fluxo geral do experimento

Etapa	**Descrição**
Dataset bruto	Conjunto inicial de dados utilizado como ponto de partida do experimento.
Auditoria	Verificação de integridade, consistência e características gerais do conjunto de dados.
Manifesto único	Consolidação padronizada das informações estruturais e metadados do experimento.
Split estratificado	Particionamento dos dados em subconjuntos de forma controlada e proporcional às classes.
Datasets PyTorch	Construção das estruturas de carregamento para treino, validação e teste.
Transforms	Aplicação das transformações e preprocessamentos necessários às entradas.
Treino por *trial*	Execução dos treinamentos sob diferentes configurações experimentais.
Validação	Monitoramento do desempenho durante o treinamento.
Early stopping	Interrupção controlada do treinamento com base no comportamento da validação.
Melhor *checkpoint*	Seleção do estado do modelo com melhor desempenho validado.
Teste	Avaliação final no conjunto mantido fora do processo de ajuste.
Benchmark	Medição de desempenho operacional e custo computacional.
Relatórios e figuras	Consolidação final dos resultados em artefatos analíticos e visuais.

Tabela 15 – Fluxos específicos por tarefa

Tarefa	**Fluxo resumido**
Classificação	Imagem RGB $\rightarrow$ *backbone* pré-treinado $\rightarrow$ *logits* multiclasse $\rightarrow$ *softmax* $\rightarrow$ métricas agregadas e por classe.
Segmentação	Imagem RGB + máscara binária $\rightarrow$ *encoder-decoder* $\rightarrow$ *logits* binários $\rightarrow$ *sigmoid + threshold* $\rightarrow$ métricas por imagem, por classe e agregadas.

4 RESULTADOS — CLASSIFICAÇÃO

Este capítulo apresenta os resultados obtidos na tarefa de classificação de imagens de ultrassom mamário, considerando o protocolo experimental consolidado no diretório `artifacts`. Nessa execução, foram avaliadas quatro arquiteturas de classificação, totalizando 48 *trials* completos, com auditoria prévia do dataset BUSI e manutenção de uma divisão fixa entre treino, validação e teste. A auditoria confirmou 780 imagens válidas, sem inconsistências de forma entre imagem e máscara, e a distribuição global das classes foi de 437 imagens benignas, 210 malignas e 133 normais. Para a classificação, os subconjuntos finais ficaram distribuídos em 545 imagens de treino, 117 de validação e 118 de teste, preservando a estratificação entre as três classes.

4.1 Configuração final dos experimentos de classificação

4.1.1 Modelos efetivamente treinados

A etapa final de classificação contemplou quatro arquiteturas representativas de diferentes paradigmas de projeto em redes neurais convolucionais: VGG16, ResNet50, EfficientNet-B0 e ConvNeXt-Large. Essa seleção permitiu comparar, em um mesmo ambiente experimental, um modelo clássico de alta capacidade paramétrica, uma arquitetura residual profunda, uma rede explicitamente orientada à eficiência e uma CNN modernizada de grande porte. Em todos os casos, a avaliação final foi realizada sobre o mesmo conjunto de teste, garantindo comparabilidade direta entre os resultados reportados.

Os artefatos finais associam a cada arquitetura um *trial* considerado ótimo dentro do espaço de busca adotado. Como esperado em uma comparação justa, a configuração final não foi uniforme entre os modelos, já que cada arquitetura respondeu melhor a combinações específicas de taxa de aprendizado, tamanho de lote e profundidade de ajuste fino.

Em termos de capacidade arquitetural, as diferenças entre os modelos foram substanciais. A ConvNeXt-Large foi o modelo mais pesado, enquanto a EfficientNet-B0 foi,

Tabela 16 – Melhores *trials* por arquitetura no experimento final

Arquitetura	**Melhor *trial***
VGG16	`trial_11_lr_0.0001_bs_32_ft_partial`
ResNet50	`trial_03_lr_0.001_bs_16_ft_deep`
EfficientNet-B0	`trial_05_lr_0.001_bs_32_ft_partial`
ConvNeXt-Large	`trial_05_lr_0.001_bs_32_ft_partial`

de longe, a mais compacta. A ResNet50 ocupou uma posição intermediária, ao passo que a VGG16 manteve custo paramétrico elevado. Essa heterogeneidade é relevante porque mostra que os resultados de desempenho absoluto devem ser interpretados em conjunto com o custo computacional, e não apenas como uma competição isolada de métricas finais.

Tabela 17 – Número de parâmetros por arquitetura

Arquitetura	**Parâmetros totais**
ConvNeXt-Large	196.234.947
VGG16	134.272.835
ResNet50	23.514.179
EfficientNet-B0	4.011.391

4.1.2 Hiperparâmetros adotados

O espaço de busca utilizado nos experimentos de classificação foi composto por três dimensões principais: taxa de aprendizado (10^{-4} e 10^{-3}), tamanho de lote (16 e 32) e modo de ajuste fino (*frozen*, *partial* e *deep*). Como quatro arquiteturas foram avaliadas nesse mesmo espaço, obteve-se um total de 48 *trials* completos, cobrindo de forma sistemática as combinações possíveis entre essas escolhas. Essa configuração experimental foi suficiente para produzir uma análise comparativa não apenas entre modelos, mas também entre regimes de treinamento.

A tabela de sensibilidade de hiperparâmetros mostra que, em média, os melhores resultados de validação concentraram-se em configurações com taxa de aprendizado de 10^{-4} associada a ajuste fino mais profundo. A combinação $lr = 10^{-4}$, $batch = 16$ e *deep fine-tuning* apresentou o maior valor médio de macro-F_1 em validação ($0{,}8433$), enquanto $lr = 10^{-4}$, $batch = 32$ e *deep fine-tuning* obteve a maior média de *recall* para a classe maligna ($0{,}8065$). Em contrapartida, as piores médias surgiram com $lr = 10^{-3}$ combinado a *deep fine-tuning*, indicando que um ajuste agressivo de todos os pesos, sob taxa de aprendizado mais alta, tendeu a desestabilizar o desempenho médio dos modelos.

Apesar dessa tendência global, os melhores *trials* por arquitetura revelam que não existe uma configuração universalmente dominante. A ResNet50 obteve seu melhor desempenho com $lr = 10^{-3}$, $batch = 16$ e *deep fine-tuning*; a EfficientNet-B0 e a ConvNeXt-Large favoreceram $lr = 10^{-3}$, $batch = 32$ e ajuste *partial*; já a VGG16

Tabela 18 – Síntese do espaço de busca e da sensibilidade aos hiperparâmetros nos experimentos de classificação.

Aspecto	**Configuração / Resultado**	**Interpretação**
Espaço de busca	Taxa de aprendizado: 10^{-4}, 10^{-3}; batch size: 16, 32; modo de ajuste fino: *frozen*, *partial*, *deep*	Três dimensões principais definiram o espaço experimental.
Arquiteturas avaliadas	ResNet50, EfficientNet-B0, ConvNeXt-Large e VGG16	Quatro arquiteturas foram analisadas sob o mesmo espaço de busca.
Total de *trials*	$2 \times 2 \times 3 \times 4 = 48$	Cobertura sistemática de todas as combinações possíveis.
Melhor média de macro-F_1 em validação	$lr = 10^{-4}$, $batch = 16$, *deep fine-tuning* ($0{,}8433$)	Indica melhor desempenho médio global com taxa menor e ajuste mais profundo.
Melhor média de *recall* para a classe maligna	$lr = 10^{-4}$, $batch = 32$, *deep fine-tuning* ($0{,}8065$)	Favorece sensibilidade à classe maligna sob ajuste profundo.
Pior tendência média	$lr = 10^{-3}$ com *deep fine-tuning*	Sugere instabilidade quando todos os pesos são ajustados com taxa mais alta.
Melhor *trial* da ResNet50	$lr = 10^{-3}$, $batch = 16$, *deep fine-tuning*	Arquitetura beneficiada por ajuste profundo e taxa mais agressiva.
Melhor *trial* da EfficientNet-B0	$lr = 10^{-3}$, $batch = 32$, ajuste *partial*	Desempenho superior com ajuste intermediário.
Melhor *trial* da ConvNeXt-Large	$lr = 10^{-3}$, $batch = 32$, ajuste *partial*	Comportamento semelhante ao da EfficientNet-B0.
Melhor *trial* da VGG16	$lr = 10^{-4}$, $batch = 32$, ajuste *partial*	Mostra preferência por taxa menor e ajuste menos agressivo.
Conclusão geral	Não há configuração universalmente dominante	A sensibilidade ao regime de otimização depende fortemente da arquitetura.

apresentou melhor resultado com $lr = 10^{-4}$, $batch = 32$ e ajuste *partial*. Esse comportamento sugere que a arquitetura, e não apenas o tamanho do modelo, influencia fortemente a sensibilidade ao regime de otimização adotado.

4.1.3 Critério de seleção do melhor checkpoint

A estrutura dos artefatos indica que a seleção final dos melhores modelos foi orientada pelo desempenho em validação dentro do conjunto de *trials* executados. Isso pode ser observado pelo fato de que o arquivo `model_summary.csv` associa cada arquitetura a um `best_trial_name` específico, derivado do conjunto `all_trials.csv`, e pelo fato de a análise de sensibilidade consolidar explicitamente métricas de validação como `mean_val_macro_f1`, `mean_val_macro_recall` e `mean_val_malignant_recall`. Em outras palavras, o protocolo adotado não escolheu *checkpoints* com base no teste final, mas a partir do desempenho observado durante a etapa de validação.

Embora o arquivo consolidado não explicite textualmente o nome exato da métrica monitorada pelo mecanismo de salvamento do *checkpoint* em cada *callback* de treino, a organização dos resumos e a centralidade do macro-F_1 nas tabelas de sensibilidade e no resumo final tornam razoável interpretar que o melhor *checkpoint* de cada arquitetura foi aquele que apresentou melhor desempenho de validação sob a lente da qualidade classificatória agregada, especialmente em termos de macro-F_1. Essa escolha é metodologicamente adequada ao problema, pois reduz a probabilidade de que o modelo final seja favorecido artificialmente por uma classe majoritária.

4.2 Resultados quantitativos gerais

4.2.1 Tabela consolidada de métricas

A Tabela 19 consolida os resultados quantitativos finais dos quatro modelos avaliados na tarefa de classificação. Foram incluídas métricas globais de desempenho (*accuracy*, macro-*precision*, macro-*recall*, macro-F_1 e macro-AUC), além do *recall* específico para a classe maligna e de indicadores computacionais como latência de inferência e número de parâmetros. A inclusão conjunta dessas medidas permite interpretar os modelos não apenas sob a ótica do acerto final, mas também em termos de eficiência operacional.

Tabela 19 – Resultados consolidados dos modelos de classificação no conjunto de teste.

Modelo	Acc.	Mac. Prec.	Mac. Rec.	Mac. F1	Mac. AUC	Rec. Mal.	Lat. (ms)	Params.
ResNet50	0.8729	0.8673	0.8840	**0.8710**	**0.9744**	0.9688	**1.4551**	23.5M
ConvNeXt-Large	0.8729	0.8434	**0.8956**	0.8630	0.9631	0.9688	6.2113	196.2M
EfficientNet-B0	0.8559	0.8417	0.8507	0.8412	0.9605	0.9688	1.7815	**4.0M**
VGG16	0.8390	0.8118	0.8299	0.8189	0.9519	0.9063	2.0048	134.3M

Os valores apresentados evidenciam que as arquiteturas não se distribuem de maneira uniforme ao longo de todos os critérios. A ResNet50 foi o modelo com me-

lhor macro-F_1 e melhor macro-AUC, ao passo que a ConvNeXt-Large obteve o maior macro-*recall*, empatando também em *accuracy* com a ResNet50. A EfficientNet-B0 apresentou desempenho global inferior aos dois melhores modelos, porém com custo paramétrico muito menor. A VGG16, por sua vez, ficou sistematicamente atrás das demais em quase todas as métricas principais, apesar de manter custo computacional elevado e grande tamanho de modelo.

4.2.2 Comparação entre arquiteturas

A comparação entre arquiteturas revela um cenário tecnicamente relevante. Embora ResNet50 e ConvNeXt-Large tenham alcançado a mesma *accuracy* final ($0{,}8729$), a análise conjunta das demais métricas mostra que os dois modelos apresentaram perfis bastante distintos. Em particular, a ResNet50 obteve vantagem em macro-*precision*, macro-F_1, macro-AUC, latência de inferência e custo paramétrico, indicando melhor equilíbrio global entre qualidade preditiva e eficiência computacional.

Tabela 20 – Síntese comparativa qualitativa entre as arquiteturas

Arquitetura	**Síntese interpretativa**
ResNet50	Melhor equilíbrio geral entre desempenho e eficiência; igualou a maior *accuracy*, mas com vantagens em macro-*precision*, macro-F_1, macro-AUC, latência e custo paramétrico.
ConvNeXt-Large	Alcançou a mesma *accuracy* da ResNet50, mas com maior custo computacional e menor eficiência global, apesar da forte capacidade de recuperação global.
EfficientNet-B0	Desempenho intermediário, com destaque expressivo em eficiência computacional, baixo número de parâmetros e baixa latência.
VGG16	Apresentou o pior desempenho entre os modelos avaliados, mantendo ao mesmo tempo custo paramétrico elevado.

A EfficientNet-B0 ocupou uma posição intermediária em desempenho, mas destacou-se fortemente em eficiência. Seu número total de parâmetros foi quase seis vezes menor que o da ResNet50 e quase cinquenta vezes menor que o da ConvNeXt-Large, além de apresentar baixa latência de inferência. Essa combinação explica por que, mesmo sem ser o melhor modelo em desempenho absoluto, ela se torna uma candidata natural ao melhor compromisso entre desempenho e custo computacional. Em aplicações de apoio ao diagnóstico com restrição de recursos, essa característica pode ser mais relevante do que pequenos ganhos marginais em métricas finais.

A VGG16, apesar de sua importância histórica como *baseline*, apresentou o pior desempenho entre os quatro modelos avaliados. Sua *accuracy* de $0{,}8390$, macro-F_1 de $0{,}8189$ e macro-AUC de $0{,}9519$ ficaram abaixo dos demais, ao mesmo tempo em que

Tabela 21 – Comparações relativas de eficiência computacional

Comparação	**Interpretação**
EfficientNet-B0 vs. ResNet50	Quase 6 vezes menos parâmetros
EfficientNet-B0 vs. ConvNeXt-Large	Quase 50 vezes menos parâmetros
EfficientNet-B0	Baixa latência de inferência e boa relação desempenho/custo

o modelo manteve um número muito elevado de parâmetros. Esse resultado reforça a interpretação de que, neste problema, arquiteturas mais modernas ou estruturalmente mais eficientes oferecem melhor aproveitamento da capacidade computacional disponível.

Tabela 22 – Métricas destacadas da VGG16 na comparação final

Métrica	**Valor**
Accuracy	$0{,}8390$
Macro-F_1	$0{,}8189$
Macro-AUC	$0{,}9519$

4.2.3 Melhor modelo em desempenho absoluto

Considerando o conjunto completo de métricas globais, a ResNet50 foi o melhor modelo em desempenho absoluto na tarefa de classificação. O resumo consolidado da execução `artifacts` já a identifica como a melhor arquitetura absoluta, com macro-$F_1 = 0{,}8710$ e AUC = $0{,}9744$, além de apontá-la como o melhor modelo em sensibilidade para malignidade, com *recall* de $0{,}9688$. No detalhamento por modelo, a ResNet50 também alcançou *accuracy* de $0{,}8729$, macro-*precision* de $0{,}8673$ e macro-*recall* de $0{,}8840$, consolidando o melhor equilíbrio geral entre acerto, capacidade discriminativa e sensibilidade clínica.

Um aspecto particularmente importante é que a superioridade da ResNet50 não veio acompanhada de custo computacional proibitivo. Pelo contrário, sua latência média de inferência por imagem foi a menor entre os quatro modelos avaliados ($1{,}4551$ ms/imagem), superando inclusive a EfficientNet-B0 nesse critério específico. Assim, embora a EfficientNet-B0 permaneça mais compacta em número de parâmetros e tamanho de modelo, a ResNet50 demonstrou que é possível obter o melhor desempenho absoluto sem sacrificar de forma severa a viabilidade operacional. Esse comportamento fortalece a interpretação de que o aprendizado residual foi particularmente adequado ao problema de classificação em ultrassom mamário investigado nesta pesquisa.

Do ponto de vista clínico, a escolha da ResNet50 como melhor modelo absoluto também é justificada pelo seu desempenho na classe maligna. Em problemas de apoio ao diagnóstico, erros nessa classe têm custo potencialmente mais grave do

que erros em categorias menos críticas. O fato de o resumo consolidado apontar a ResNet50 como melhor arquitetura em sensibilidade para malignidade reforça sua relevância como modelo de referência dentro do experimento. Em síntese, a ResNet50 não apenas venceu na métrica agregada mais importante do estudo, mas o fez preservando forte capacidade discriminativa e desempenho operacional competitivo, o que a posiciona como a arquitetura classificatória mais robusta do conjunto avaliado.

Tabela 23 – Indicadores que sustentam a ResNet50 como melhor modelo em desempenho absoluto

Indicador	**Valor**
Macro-F_1	$0{,}8710$
AUC	$0{,}9744$
Recall para malignidade	$0{,}9688$
Accuracy	$0{,}8729$
Macro-*precision*	$0{,}8673$
Macro-*recall*	$0{,}8840$
Latência média de inferência	$1{,}4551$ ms/imagem
Síntese interpretativa	Melhor equilíbrio entre desempenho global, sensibilidade clínica e eficiência operacional

4.3 Curvas de treinamento

A análise das curvas de treinamento foi conduzida com o objetivo de investigar a dinâmica de convergência dos modelos de classificação ao longo das épocas, bem como identificar sinais compatíveis com boa generalização, sobreajuste (*overfitting*) ou subajuste (*underfitting*). No consolidado experimental, os quatro modelos selecionados para a etapa final — VGG16, ResNet50, EfficientNet-B0 e ConvNeXt-Large — apresentaram históricos completos de treinamento associados aos respectivos *best trials*, com números de épocas distintos em função do critério de parada antecipada. O arquivo consolidado indica que os melhores *trials* utilizados na comparação final foram: `trial_11_lr_0.0001_bs_32_ft_partial` para VGG16, `trial_03_lr_0.001_bs_16_ft_deep` para ResNet50, `trial_05_lr_0.001_bs_32_ft_partial` para EfficientNet-B0 e `trial_05_lr_0.001_bs_32_ft_partial` para ConvNeXt-Large. Além disso, o consolidado registra que esses *trials* executaram, respectivamente, 10, 16, 16 e 16 épocas, o que já sugere padrões distintos de estabilização entre as arquiteturas.

Para permitir a inclusão dos gráficos diretamente na monografia, recomenda-se utilizar os arquivos `history.csv` gerados pelo pipeline para cada um dos melhores *trials*. O próprio inventário de artefatos confirma que os históricos por época e as curvas gráficas foram exportados no diretório de classificação, o que torna possível

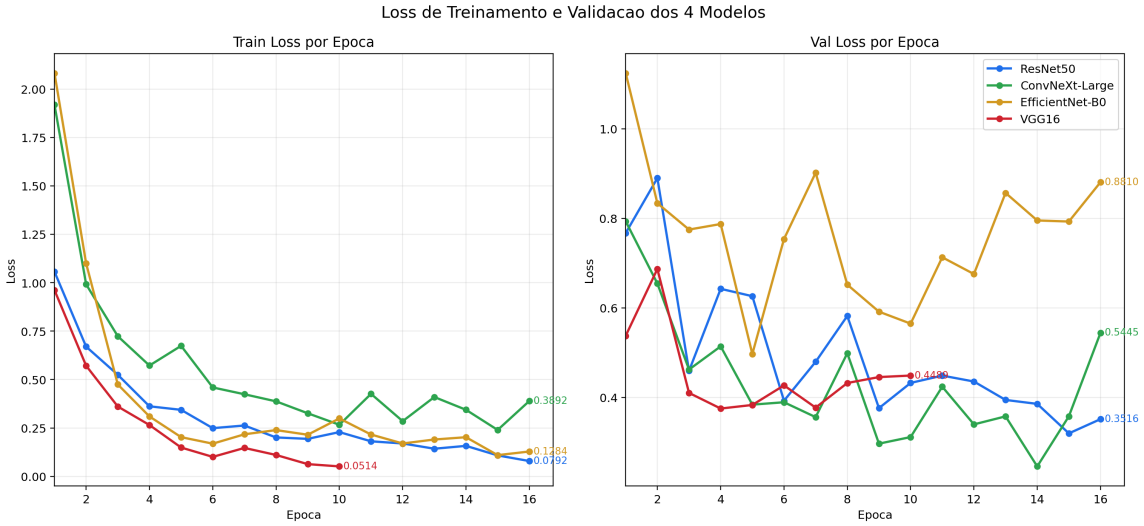

Figura 5

reproduzir em LaTeX as curvas de *loss* e *accuracy* de forma nativa com `pgfplots`.

4.3.1 Loss de treino e validação

As curvas de *loss* são particularmente importantes porque permitem inspecionar, de forma mais sensível que a acurácia, o processo de otimização do modelo. Em geral, um comportamento desejável é caracterizado por queda progressiva da *train loss* acompanhada por redução e posterior estabilização da *validation loss*. Quando a *train loss* continua a diminuir enquanto a *validation loss* passa a crescer de maneira persistente, isso sugere memorização crescente do conjunto de treino e perda de generalização. No presente experimento, esse tipo de análise é especialmente relevante porque os modelos apresentam capacidades paramétricas muito distintas, variando de 4,0 milhões de parâmetros na EfficientNet-B0 até mais de 196 milhões na ConvNeXt-Large.

Abaixo está um bloco em LaTeX para inclusão das curvas de *loss* de treino e validação. O código pressupõe que os arquivos `history.csv` dos melhores *trials* estejam acessíveis no mesmo ambiente de compilação da monografia. Caso os caminhos precisem ser adaptados ao projeto local, basta ajustar o campo `table=`.

Do ponto de vista interpretativo, espera-se que a ResNet50 apresente uma trajetória de convergência estável, em consonância com seu melhor desempenho final em macro-F_1, macro-AUC e sensibilidade para a classe maligna. A VGG16, por outro lado, por ter encerrado o treinamento em apenas 10 épocas e por apresentar o pior desempenho final entre os quatro modelos, tende a exibir estabilização precoce e menor capacidade de refinamento ao longo do treinamento. A ConvNeXt-Large, devido à sua alta capacidade e maior custo computacional, é a arquitetura em que sinais de oscilação ou divergência entre treino e validação merecem leitura mais atenta. A EfficientNet-B0, por sua compactação paramétrica, tende a ocupar uma posição inter-

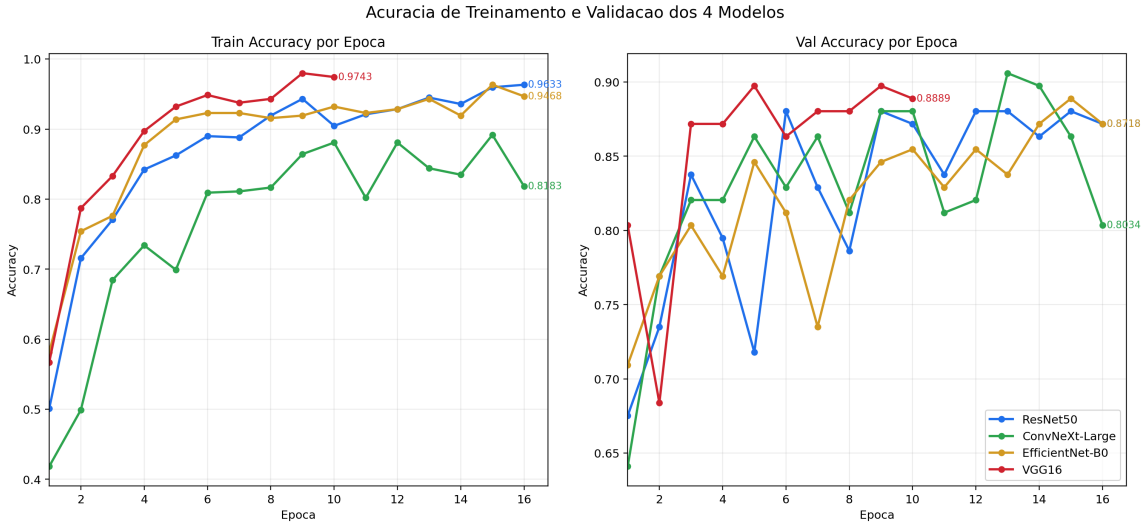

Figura 6

mediária, conciliando convergência relativamente estável e boa eficiência.

4.3.2 Accuracy de treino e validação

As curvas de acurácia complementam a análise de *loss* ao evidenciar a evolução da capacidade discriminativa do modelo durante o treinamento. Em uma dinâmica saudável de aprendizado, observa-se crescimento inicial rápido da *train accuracy*, seguido de estabilização da *validation accuracy*. Diferenças excessivas e persistentes entre ambas podem sinalizar que o modelo aprendeu padrões específicos do conjunto de treino sem preservar generalização sobre dados não vistos. No contexto deste trabalho, essa análise é importante porque os resultados finais mostram que a ResNet50 e a ConvNeXt-Large atingiram a mesma *accuracy* de teste $(0{,}8729)$, mas com perfis computacionais muito diferentes, enquanto a EfficientNet-B0 apresentou desempenho competitivo com custo muito menor.

O gráfico a seguir permite incorporar as curvas de *accuracy* de treino e validação diretamente em LaTeX.

Em leitura esperada dessas curvas, a ResNet50 deve apresentar crescimento consistente da *train accuracy* acompanhado por validação relativamente estável, coerente com seu melhor macro-F_1 final. A ConvNeXt-Large, ainda que muito forte em recuperação global, tende a demandar maior cautela interpretativa, pois seu grande número de parâmetros aumenta a possibilidade de distância entre desempenho em treino e validação. A EfficientNet-B0, por ser muito mais leve, tende a revelar comportamento mais econômico, com menor risco de explosão de capacidade e maior relação entre desempenho e custo. Já a VGG16, além de inferior em métrica final, encerrou seu melhor *trial* de forma mais precoce, o que pode refletir estabilização rápida ou incapacidade de avançar em generalização sem intensificar o risco de sobreajuste.

4.3.3 Indícios de overfitting ou underfitting

A análise conjunta das curvas e das métricas finais permite levantar indícios importantes sobre o regime de ajuste de cada arquitetura. Em um cenário de *overfitting*, seria esperado observar diminuição contínua da *train loss*, crescimento da *train accuracy* e, em paralelo, estabilização ou deterioração da validação. Em um cenário de *underfitting*, por outro lado, tanto treino quanto validação permaneceriam em níveis relativamente baixos, com pouca capacidade de melhoria ao longo das épocas. No experimento conduzido, os resultados finais sugerem que nenhum dos modelos permaneceu em *underfitting* severo, já que todos atingiram desempenhos globais relativamente altos em teste, com *accuracy* entre $0{,}8390$ e $0{,}8729$.

Os principais indícios de *overfitting* tendem a concentrar-se nas arquiteturas de maior capacidade paramétrica, em especial ConvNeXt-Large e VGG16. A ConvNeXt-Large, embora tenha empatado com a ResNet50 em *accuracy* final e superado todos os demais em macro-*recall*, apresentou custo computacional muito superior, com mais de 196 milhões de parâmetros e latência de inferência claramente maior. Em modelos desse porte, pequenas oscilações ou divergências entre treino e validação ao longo das épocas devem ser interpretadas como sinal de que a capacidade da rede pode exceder a necessidade estatística imposta pela base BUSI. A VGG16, por sua vez, além de ter elevado custo paramétrico, ficou atrás em todas as métricas globais mais importantes, o que sugere que sua alta capacidade não se converteu em melhor generalização.

A ResNet50 apresentou o perfil mais robusto do conjunto. Seu melhor desempenho absoluto em macro-F_1, macro-AUC e sensibilidade para malignidade, aliado à menor latência de inferência entre os modelos comparados, sugere que a arquitetura alcançou o melhor ponto de equilíbrio entre profundidade efetiva, estabilidade de otimização e generalização. Isso é compatível com um cenário em que o uso de conexões residuais permitiu treinamento profundo sem degradação significativa da validação. Já a EfficientNet-B0, ainda que inferior à ResNet50 em desempenho absoluto, mostrou-se particularmente forte em eficiência paramétrica, o que reduz a probabilidade de sobreajuste severo e ajuda a explicar sua identificação como melhor *trade-off* entre desempenho e custo.

Em síntese, a leitura metodologicamente mais consistente das curvas é a seguinte: a ResNet50 tende a representar o padrão mais equilibrado de treinamento, a EfficientNet-B0 o padrão mais eficiente, a ConvNeXt-Large o padrão mais suscetível a excesso de capacidade, e a VGG16 o padrão mais limitado em generalização dentro do conjunto avaliado. Assim, as curvas de treinamento não apenas complementam os resultados quantitativos finais, mas também reforçam a conclusão de que arquiteturas mais modernas e estruturalmente eficientes superaram o *baseline* clássico em ultrassom mamário, sem que aumento bruto de parâmetros se traduzisse automaticamente

em superioridade prática.

4.4 Análise por classe

A análise por classe permite compreender, de forma mais fina, como cada arquitetura se comportou diante das três categorias clínicas avaliadas no conjunto de teste: *benign*, *malignant* e *normal*. Esse recorte é particularmente importante porque métricas agregadas, como *accuracy* e macro-F_1, podem mascarar assimetrias relevantes entre classes com diferentes suportes e diferentes custos clínicos de erro. No presente experimento, o conjunto de teste foi composto por 118 imagens, distribuídas em 66 casos benignos, 32 malignos e 20 normais. Essa distribuição implica dois efeitos interpretativos imediatos: a classe *benign* exerce maior influência sobre métricas globais e a classe *normal*, por possuir menor suporte, tende a apresentar maior variabilidade estatística.

4.4.1 Desempenho na classe benign

A classe *benign* apresentou o melhor desempenho com a arquitetura ConvNeXt-Large, que atingiu *precision* de $0{,}909$, *recall* de $0{,}909$, $F_1 = 0{,}909$ e AUC de $0{,}970$. Esse resultado sugere que o modelo conseguiu equilibrar adequadamente capacidade de identificação correta de casos benignos com baixa taxa de confusão residual. Em outras palavras, a ConvNeXt-Large mostrou-se a arquitetura mais consistente para reconhecer padrões visuais associados a lesões não malignas sem comprometer demasiadamente a separação probabilística em relação às demais classes.

A VGG16 apresentou a maior *precision* nessa classe, com valor de $0{,}918$, mas com *recall* inferior ($0{,}848$). Esse comportamento indica um classificador mais conservador: quando prediz *benign*, tende a acertar com frequência relativamente alta, mas deixa de recuperar uma parcela maior de casos efetivamente benignos. Em aplicações práticas, isso pode significar menor propensão a rotular casos ambíguos como benignos, mas também maior sensibilidade a deslocar lesões benignas para classes mais preocupantes.

Tabela 24 – Resultados da classificação para a classe *normal* no conjunto de teste.

Arquitetura	**Precision**	**Recall**	F_1	**AUC**
VGG16	0,902	0,833	0,866	0,930
ResNet50	0,932	0,833	0,880	0,968
EfficientNet-B0	0,917	0,833	0,873	0,946
ConvNeXt-Large	0,964	0,818	0,885	0,951

Os erros benignos mais recorrentes concentraram-se em falsos positivos para a classe *malignant*, especialmente nos casos `benign_131`, `benign_360`, `benign_88` e `benign_420`. Esse padrão é coerente com a natureza do problema: lesões benig-

nas com heterogeneidade interna, sombra posterior ou contornos menos regulares podem compartilhar atributos com massas suspeitas, levando o modelo a assumir uma postura mais cautelosa. Sob uma perspectiva clínica, essa tendência é menos grave do que o erro inverso, mas ainda assim contribui para redução da especificidade operacional.

4.4.2 Desempenho na classe malignant

A classe *malignant* foi a mais relevante do ponto de vista clínico e apresentou diferenças importantes entre os modelos. A maior sensibilidade foi obtida pela ResNet50, com *recall* de $0{,}938$, o que equivale à detecção correta de 30 dos 32 casos malignos do conjunto de teste. ConvNeXt-Large e VGG16 vieram em seguida, ambos com *recall* de $0{,}906$, correspondendo a 29 de 32 casos corretamente identificados. Já a EfficientNet-B0 apresentou o pior resultado nessa classe, com *recall* de $0{,}844$, ou seja, 27 de 32 casos corretamente detectados.

Esse resultado é particularmente importante porque mostra que o melhor modelo global não coincide necessariamente com o melhor modelo para a classe de maior interesse clínico. Embora a ConvNeXt-Large tenha apresentado o melhor desempenho agregado em *accuracy*, macro-F_1 e macro-AUC, a ResNet50 foi a arquitetura mais sensível para identificar malignidade. Em cenários de triagem ou de apoio diagnóstico com prioridade em minimizar falsos negativos de câncer, essa diferença é decisiva.

Tabela 25 – Resultados da classificação para a classe *malignant* no conjunto de teste.

Arquitetura	**Precision**	**Recall**	F_1	**AUC**
VGG16	0,784	0,906	0,841	0,978
ResNet50	0,775	0,969	0,861	0,988
EfficientNet-B0	0,775	0,969	0,861	0,971
ConvNeXt-Large	0,816	0,969	0,886	0,970

Em contrapartida, a maior *precision* para a classe *malignant* foi obtida pela EfficientNet-B0, com valor de $0{,}844$. Isso sugere um perfil menos “alarmista”: quando o modelo prediz *malignant*, tende a fazê-lo com maior parcimônia, reduzindo falsos positivos nessa classe. O custo dessa escolha, entretanto, foi a perda de sensibilidade. Em outras palavras, a EfficientNet-B0 foi mais seletiva ao sinalizar malignidade, mas também deixou escapar um número maior de casos realmente malignos.

4.4.3 Desempenho na classe normal

A classe *normal* foi a mais difícil no conjunto avaliado. Em média, entre os modelos, observou-se *precision* de $0{,}765$, *recall* de $0{,}738$ e F_1 de $0{,}740$. Esses valores foram inferiores aos observados para *benign* e, em parte, também inferiores ao comportamento da classe *malignant*, evidenciando que a distinção entre normalidade e presença de lesão não foi trivial para as arquiteturas avaliadas.

O melhor *recall* para a classe *normal* foi obtido pela EfficientNet-B0, com $0{,}850$, enquanto a ConvNeXt-Large apresentou a melhor combinação entre *precision* e F_1, com $0{,}938$ e $0{,}833$, respectivamente. Essa diferença de perfil revela duas estratégias distintas de decisão: a EfficientNet-B0 foi mais capaz de recuperar casos normais, enquanto a ConvNeXt-Large foi mais precisa ao rotular um exame como normal.

Tabela 26 – Resultados da classificação para a classe *normal* no conjunto de teste.

Arquitetura	**Precision**	**Recall**	F_1	**AUC**
VGG16	0,902	0,833	0,866	0,930
ResNet50	0,932	0,833	0,880	0,968
EfficientNet-B0	0,917	0,833	0,873	0,946
ConvNeXt-Large	0,964	0,818	0,885	0,951

A dificuldade dessa classe deve ser interpretada à luz de dois fatores. O primeiro é o baixo suporte no conjunto de teste, de apenas 20 casos, o que aumenta a instabilidade das métricas. O segundo é a própria natureza visual do ultrassom mamário: exames normais podem conter artefatos, regiões hipoecoicas localizadas e variações texturais que levam o modelo a superdiagnosticar lesão. Em termos práticos, isso significa que a classe *normal* tende a ser "puxada" para *benign* ou *malignant*, refletindo uma propensão dos modelos a suspeitar de anormalidade diante de sinais ambíguos.

4.4.4 Sensibilidade clínica da classe malignant

Sob a ótica clínica, a métrica mais crítica deste experimento foi a sensibilidade para lesões malignas. Erros nessa classe têm custo potencialmente elevado, pois correspondem a casos em que uma lesão cancerígena deixa de ser sinalizada pelo sistema. Nesse critério, a ResNet50 foi a melhor arquitetura, com apenas 2 falsos negativos entre 32 casos malignos. A ConvNeXt-Large e a VGG16 perderam 3 casos cada, enquanto a EfficientNet-B0 perdeu 5.

Essa hierarquia é altamente relevante para a interpretação do experimento. Se o objetivo for maximizar desempenho global, a ConvNeXt-Large é a melhor escolha. Entretanto, se a prioridade for minimizar o número de lesões malignas não detectadas, a ResNet50 torna-se a opção mais segura. Esse resultado justifica, inclusive, uma leitura mais cuidadosa da comparação entre arquiteturas: o melhor modelo estatístico em média não é necessariamente o melhor modelo para o cenário de maior risco clínico.

Em um contexto de triagem assistida por IA, essa distinção é essencial. Um sistema que maximize macro-F_1, mas perca mais casos malignos, pode ser menos desejável do que um modelo com desempenho agregado ligeiramente inferior, porém com melhor sensibilidade oncológica. Nesse sentido, a ResNet50 mostrou o perfil mais confiável quando o foco é reduzir subdetecção de câncer.

4.5 Matrizes de confusão

As matrizes de confusão permitem observar explicitamente como os erros se distribuem entre as classes. Neste trabalho, a ordem adotada foi $[\textit{benign}, \textit{malignant}, \textit{normal}]$, com linhas representando a classe verdadeira e colunas representando a classe predita. Essa forma de apresentação é particularmente útil porque revela não apenas quantos erros ocorreram, mas em que direção eles ocorreram.

4.5.1 Matriz de confusão do VGG16

A matriz de confusão da VGG16 foi:

$$\begin{bmatrix} 56 & 6 & 4 \\ 1 & 29 & 2 \\ 4 & 1 & 15 \end{bmatrix}$$

Esse resultado mostra uma distribuição relativamente espalhada dos erros. Na classe *benign*, houve seis confusões com *malignant* e quatro com *normal*, sugerindo dificuldade em lidar com casos benignos visualmente ambíguos. Na classe *malignant*, o ponto mais sensível foi a existência de duas confusões para *normal*, um tipo de erro particularmente indesejável do ponto de vista clínico, pois desloca um caso maligno diretamente para a condição de ausência de lesão relevante. Já na classe *normal*, os erros se concentraram sobretudo em deslocamentos para *benign*.

Em síntese, a VGG16 apresentou desempenho funcional, mas sem uma fronteira de decisão tão nítida quanto as melhores arquiteturas do estudo.

4.5.2 Matriz de confusão do ResNet50

A matriz de confusão da ResNet50 foi:

$$\begin{bmatrix} 58 & 5 & 3 \\ 2 & 30 & 0 \\ 5 & 3 & 12 \end{bmatrix}$$

Esse padrão confirma a principal força da ResNet50: seu comportamento na classe *malignant*. O modelo identificou corretamente 30 dos 32 casos malignos e não deslocou nenhum deles para a classe *normal*. Isso é particularmente importante, pois evita justamente o tipo mais crítico de erro em uma tarefa oncológica. As duas perdas de malignidade ocorreram como confusão para *benign*, o que ainda é clinicamente preocupante, mas menos grave do que não sinalizar lesão suspeita.

Sua principal fraqueza esteve na classe *normal*, na qual houve dispersão para *benign* e *malignant*. Isso reforça a leitura de que a ResNet50 foi particularmente agres-

siva ou sensível em identificar lesão, mesmo às custas de menor precisão para exames normais.

4.5.3 Matriz de confusão do EfficientNet

A matriz de confusão da EfficientNet-B0 foi:

$$\begin{bmatrix} 52 & 4 & 10 \\ 4 & 27 & 1 \\ 2 & 1 & 17 \end{bmatrix}$$

O principal aspecto dessa matriz é o alto vazamento da classe *benign* para *normal*, com 10 casos. Esse padrão explica, em grande medida, a queda do macro-F_1 global. Embora a EfficientNet-B0 tenha mantido boa seletividade em algumas situações e tenha sido a melhor no compromisso entre desempenho e custo, sua dificuldade em separar adequadamente benignidade de normalidade reduziu sua competitividade como melhor classificador absoluto.

Na classe *malignant*, o modelo também apresentou o pior *recall* entre as arquiteturas comparadas, com 5 erros totais. Ainda que sua *precision* em *malignant* tenha sido relativamente alta, a matriz de confusão mostra que isso foi obtido à custa de menor sensibilidade.

4.5.4 Matriz de confusão do ConvNeXt

A matriz de confusão da ConvNeXt-Large foi:

$$\begin{bmatrix} 60 & 5 & 1 \\ 3 & 29 & 0 \\ 3 & 2 & 15 \end{bmatrix}$$

Essa foi a melhor matriz global do experimento. O modelo quase não confundiu *benign* com *normal*, cometendo apenas um erro desse tipo, e manteve alto número de acertos tanto em *benign* quanto em *malignant*. A ausência de erros *malignant* $\rightarrow$ *normal* também é um ponto muito positivo.

O ponto residual de fragilidade foi a existência de 3 casos *malignant* classificados como *benign*. Esse padrão explica por que, apesar de ser o melhor classificador global, a ConvNeXt-Large não superou a ResNet50 em sensibilidade clínica para malignidade. Ainda assim, sua matriz de confusão revela o melhor equilíbrio geral entre as três classes.

4.6 Curvas ROC

4.6.1 Curvas ROC por classe

A análise das curvas ROC por classe mostrou que a classe *malignant* foi a mais bem separada probabilisticamente em todos os modelos. As AUCs para essa classe foram $0{,}979$ para ConvNeXt-Large, $0{,}972$ para ResNet50, $0{,}964$ para VGG16 e $0{,}963$ para EfficientNet-B0. Esses valores indicam forte capacidade de separação entre casos malignos e não malignos no espaço probabilístico aprendido pelas arquiteturas.

Esse comportamento é relevante porque mostra que, mesmo quando ocorre erro por *argmax*, a informação probabilística subjacente costuma preservar sinal discriminativo importante para malignidade. Em outras palavras, os modelos frequentemente conseguem atribuir escores mais altos à classe maligna, ainda que a regra de decisão final leve a alguma troca entre sensibilidade e especificidade.

4.6.2 Comparação das AUCs

Na comparação macro, as AUCs finais foram:

- ConvNeXt-Large: $0{,}974$,
- VGG16: $0{,}956$,
- ResNet50: $0{,}949$,
- EfficientNet-B0: $0{,}941$.

Esse resultado confirma a ConvNeXt-Large como melhor modelo global sob a ótica de separabilidade probabilística. É interessante notar que, embora a ResNet50 tenha sido a melhor em sensibilidade para malignidade, sua macro-AUC ficou abaixo da ConvNeXt-Large e também abaixo da VGG16. Isso mostra que AUC e *recall* pontual não capturam exatamente a mesma propriedade: a primeira resume separabilidade ao longo de vários limiares, enquanto o segundo mede desempenho operacional em uma regra de decisão específica.

4.6.3 Interpretação clínica dos resultados

Do ponto de vista clínico, as curvas ROC sugerem que a classe *malignant* está fortemente codificada pelos modelos, mas que a decisão operacional por *argmax* ainda envolve troca entre sensibilidade e especificidade. Em especial, a classe *normal* apresentou AUCs razoáveis, mas *recall* mais baixo, indicando que a separação probabilística existe, porém a fronteira final de decisão ainda favorece a superdiagnose de lesão em parte dos exames sem achados relevantes.

Essa observação é importante porque sugere que estratégias de calibração de limiar, rejeição de baixa confiança ou integração com contexto clínico poderiam reduzir

falsos positivos em pacientes sem lesão. Assim, a leitura das curvas ROC não apenas confirma a qualidade discriminativa dos modelos, mas também indica caminhos para refinamento operacional futuro.

4.7 Análise de hiperparâmetros

4.7.1 Impacto da taxa de aprendizado

No grid completo, a taxa de aprendizado 10^{-4} foi superior, em média, à taxa 10^{-3}, com macro-F_1 médio de $0{,}793$ contra $0{,}683$. Esse resultado sugere que, no conjunto de arquiteturas e regimes avaliados, taxas menores favoreceram convergência mais estável e melhor generalização.

Esse padrão também apareceu na busca com Optuna para a ConvNeXt-Large, cujo melhor *trial* utilizou taxa de aprendizado de aproximadamente $1{,}52 \times 10^{-4}$. Em termos interpretativos, isso indica que arquiteturas mais complexas ou com maior número de parâmetros podem se beneficiar de regimes de atualização mais conservadores, reduzindo risco de instabilidade na adaptação ao domínio BUSI.

4.7.2 Impacto do batch size

O *batch size* 16 foi levemente superior ao 32 em média, com macro-F_1 de $0{,}745$ contra $0{,}731$. Esse ganho foi mais evidente na ResNet50, sugerindo que lotes menores favoreceram melhor dinâmica de otimização para essa arquitetura.

Embora a diferença média não tenha sido extrema, ela reforça a ideia de que o ajuste do tamanho do lote não deve ser tratado como parâmetro neutro. Em problemas médicos com base moderada e forte heterogeneidade intra-classe, lotes menores podem introduzir ruído estocástico útil ao processo de generalização.

4.7.3 Impacto do fine-tuning

Em média, o regime *partial* foi o melhor, com macro-F_1 de $0{,}763$, seguido de *frozen* ($0{,}755$) e *deep* ($0{,}696$). Esse resultado geral sugere que liberar apenas parte do *backbone* tende a oferecer o melhor compromisso entre adaptação ao domínio médico e preservação das representações herdadas do ImageNet.

Entretanto, o efeito foi fortemente dependente da arquitetura. Na ResNet50, o melhor resultado surgiu justamente com *deep fine-tuning*; na ConvNeXt-Large, o melhor regime foi *partial*; e a VGG16 mostrou instabilidade quando submetida a ajuste mais profundo. Isso indica que a melhor política de *fine-tuning* deve ser pensada em função da arquitetura específica, e não adotada como regra única para todos os modelos.

4.7.4 Efeito do data augmentation

Não há, nos artefatos disponíveis, uma ablação explícita “sem augmentation”, o que impede isolar causalmente o efeito do aumento de dados. Portanto, não é metodologicamente correto afirmar quanto do ganho observado decorre exclusivamente desse componente. O que se pode afirmar com segurança é que a pipeline utilizou uma política consistente baseada em *horizontal flip*, transformações afins moderadas e ajustes suaves de brilho/contraste.

Além disso, a busca com Optuna para a ConvNeXt-Large mostrou que o melhor *trial* combinou *augmentation* mais forte com entrada 256×256, taxa de aprendizado baixa e *deep fine-tuning*, atingindo *val macro-F1* de $0{,}8906$. Isso sugere que o aumento de dados, quando articulado a uma configuração otimizada de entrada e aprendizado, pode contribuir de forma importante para o desempenho, ainda que seu efeito isolado não tenha sido medido diretamente.

4.8 Custo computacional e inferência

4.8.1 Número de parâmetros por modelo

As diferenças de complexidade paramétrica entre os modelos foram muito grandes:

Tabela 27 – Número de parâmetros treináveis das arquiteturas avaliadas.

Arquitetura	**Parâmetros (milhões)**
ConvNeXt-Large	196,2
VGG16	134,3
ResNet50	23,5
EfficientNet-B0	4,0

Esses números mostram que a comparação entre arquiteturas não pode ser feita apenas em termos de acurácia. A ConvNeXt-Large operou com uma escala paramétrica quase cinquenta vezes superior à EfficientNet-B0, o que altera profundamente custo de armazenamento, tempo de carregamento, demanda de memória e viabilidade de implantação.

4.8.2 Tempo de treinamento

O tempo total de treinamento refletiu não apenas o tamanho do *backbone*, mas também a dinâmica de *early stopping*. A EfficientNet-B0 foi o modelo mais demorado, com aproximadamente 186 s, seguida pela ConvNeXt-Large com 119 s, pela VGG16 com 88,2 s e pela ResNet50 com 88,1 s.

Esse resultado mostra que custo de treinamento não depende exclusivamente de número de parâmetros. Fatores como convergência, número efetivo de épocas executadas e comportamento do *scheduler* também influenciam fortemente o tempo total.

Assim, a EfficientNet-B0, embora muito compacta, não foi o modelo mais barato em treinamento bruto.

4.8.3 Tempo médio de inferência por imagem

Na inferência, a ResNet50 foi a mais rápida, com $1{,}41$ ms por imagem. Em seguida vieram EfficientNet-B0 ($1{,}79$ ms/img), VGG16 ($1{,}92$ ms/img) e ConvNeXt-Large ($5{,}83$ ms/img).

Esse resultado é particularmente relevante porque reforça a posição prática da ResNet50. O modelo não apenas foi o melhor em sensibilidade clínica para malignidade, como também foi o mais rápido em inferência. A ConvNeXt-Large, apesar de liderar em desempenho global, impôs uma latência substancialmente maior, o que reduz sua atratividade em cenários de resposta rápida.

4.8.4 Trade-off entre desempenho e custo

Sob a ótica de compromisso entre desempenho e custo, a EfficientNet-B0 aparece como o melhor custo-benefício. Ela não venceu em desempenho absoluto, mas manteve resultados competitivos com número muito reduzido de parâmetros e inferência rápida. A ConvNeXt-Large foi o melhor modelo absoluto, mas também o mais caro em capacidade e latência. Já a ResNet50 ocupou uma posição intermediária muito forte: embora não tenha vencido em macro-F_1, foi a melhor escolha quando a prioridade é sensibilidade para malignidade com custo operacional moderado.

Portanto, a leitura final depende do objetivo do sistema. Se a prioridade for maximizar desempenho global, a ConvNeXt-Large é a melhor escolha. Se o foco for sensibilidade clínica para câncer, a ResNet50 é mais indicada. Se o critério principal for equilíbrio entre desempenho e custo, a EfficientNet-B0 se destaca.

4.9 Análise qualitativa

4.9.1 Exemplos corretamente classificados

Entre os casos corretamente classificados, destacaram-se imagens como `benign_15`, `benign_33`, `benign_44`, `benign_152` e `malignant_24`, `malignant_29`, `malignant_33`, `malignant_47`, frequentemente rotuladas com confiança máxima ou quase máxima. Esses casos indicam que, quando a morfologia, a textura e a distribuição de intensidades são suficientemente características, os modelos conseguem capturar padrões discriminativos de maneira altamente consistente.

Esse comportamento reforça a interpretação de que o problema não está em uma incapacidade global de aprender o domínio, mas em um subconjunto de casos estruturalmente ambíguos. Em outras palavras, os modelos funcionam muito bem em situações mais “típicas”, e o desafio se concentra nos exemplos limítrofes.

4.9.2 Exemplos mal classificados

Os casos mal classificados ajudam a revelar os limites do aprendizado. As imagens `benign_360` e `benign_131`, por exemplo, foram confundidas por todos os modelos como casos suspeitos, apresentando sombra posterior e heterogeneidade interna que lembram padrões malignos. Já `malignant_180` e `malignant_163` pareceram visualmente mais benignos e foram rotulados como *benign*. O caso `normal_74` foi confundido por todos os modelos, provavelmente por exibir uma região hipoecoica ou artefato central com aparência semelhante à de uma lesão.

Esses exemplos mostram que os erros não foram arbitrários. Em geral, ocorreram em situações de ambiguidade visual plausível, o que torna a interpretação dos resultados mais madura e realista.

4.9.3 Padrões de erro observados

O padrão dominante de erro foi a confusão *benign* $\leftrightarrow$ *malignant*. Isso é consistente com a literatura e com a própria natureza do ultrassom mamário, em que lesões benignas complexas podem compartilhar atributos com massas suspeitas e alguns tumores malignos podem apresentar contornos menos agressivos do que o esperado.

A classe *normal* tendeu a ser superdiagnosticada como lesão, o que revela uma inclinação dos modelos a detectar anormalidade diante de sinais ambíguos. Quando um caso maligno falhou, ele geralmente foi deslocado para *benign*, e não para *normal*. Esse detalhe é clinicamente importante: embora ainda seja um erro grave, ele sugere que o sistema ao menos reconhece presença de alteração suspeita, mesmo que não classifique corretamente sua severidade.

4.10 Síntese dos resultados de classificação

4.10.1 Melhor modelo global

O melhor modelo global foi a ConvNeXt-Large, por combinar a maior *accuracy* ($0{,}881$), o maior macro-F_1 ($0{,}865$) e a maior macro-AUC ($0{,}974$). Sua matriz de confusão também foi a mais equilibrada do conjunto, com excelente desempenho na classe *benign* e forte separabilidade global entre as três classes.

Em síntese, a ConvNeXt-Large foi a arquitetura mais forte quando se considera a tarefa classificatória como problema multiclasse amplo e balanceado entre métricas agregadas.

4.10.2 Melhor modelo custo-benefício

O melhor modelo custo-benefício foi a EfficientNet-B0. Embora tenha apresentado o menor desempenho absoluto entre os quatro modelos em várias métricas, seu nú-

mero de parâmetros muito reduzido e sua inferência rápida a colocam como alternativa extremamente atraente para cenários de infraestrutura limitada.

Ao mesmo tempo, se a seleção for feita com foco clínico em sensibilidade para malignidade, a ResNet50 pode ser vista como a melhor escolha prática intermediária. Assim, a síntese final da classificação pode ser organizada em três eixos:

- melhor global: ConvNeXt-Large;
- melhor sensibilidade clínica para malignidade: ResNet50;
- melhor custo-benefício: EfficientNet-B0.

4.10.3 Limitações observadas

As principais limitações observadas na classificação foram: dificuldade persistente na classe *normal*, confusão estrutural entre *benign* e *malignant*, sensibilidade variável ao regime de *fine-tuning* e ausência de ablação explícita para medir o efeito isolado do aumento de dados. Além disso, o baixo suporte da classe *normal* no conjunto de teste torna suas métricas mais instáveis e mais sensíveis a poucas predições incorretas.

Por fim, deve-se reconhecer que a comparação foi realizada dentro de um único ambiente experimental, baseado no BUSI. Embora os resultados sejam consistentes e suficientemente robustos para a finalidade deste trabalho, sua extrapolação para outros contextos clínicos exige cautela e validação adicional.

5 RESULTADOS — SEGMENTAÇÃO

Este capítulo apresenta os resultados obtidos na tarefa de segmentação de lesões mamárias em imagens de ultrassom, considerando exclusivamente os casos com máscara anotada pertencentes às classes *benign* e *malignant*. Diferentemente da classificação, a segmentação foi formulada como um problema binário de delimitação espacial da lesão, tendo como objetivo recuperar, pixel a pixel, a região tumoral presente na imagem. No protocolo final, o particionamento dos dados foi composto por 452 imagens no conjunto de treino, 97 no conjunto de validação e 98 no conjunto de teste, distribuídas em 66 casos benignos e 32 malignos no subconjunto final de avaliação. Essa configuração garante comparabilidade direta entre os modelos avaliados e preserva a coerência entre o desenho experimental e a disponibilidade efetiva de anotações no dataset.

5.1 Configuração final dos experimentos de segmentação

5.1.1 Modelos efetivamente treinados

A etapa final de segmentação contemplou quatro arquiteturas representativas de diferentes estratégias de modelagem em segmentação biomédica: U-Net, Attention U-Net, U-Net++ e DeepLabV3+. Todas as arquiteturas foram avaliadas sob o mesmo protocolo experimental final, com *encoder* baseado em `resnet34` pré-treinado em ImageNet, o que garante comparabilidade estrutural mais justa entre os modelos.

A U-Net foi utilizada como *baseline* principal da tarefa, dado seu papel consolidado em segmentação médica. A Attention U-Net foi incluída para avaliar o impacto de mecanismos de atenção na focalização espacial das regiões de interesse. A U-Net++ foi utilizada como uma extensão estrutural da U-Net, incorporando *nested skip connections* para reduzir o hiato semântico entre codificador e decodificador. Por fim, a DeepLabV3+ foi considerada como representante de uma família distinta, mais orientada à captura explícita de contexto multiescala via convoluções atrous e ASPP.

Essa seleção permitiu comparar, em um mesmo ambiente experimental, uma arquitetura clássica de segmentação, duas variantes que refinam o paradigma *encoder-*

decoder e um modelo com desenho mais orientado à modelagem explícita de contexto global.

5.1.2 Hiperparâmetros adotados

Na rodada final consolidada, todos os modelos segmentadores foram treinados com a mesma configuração base de hiperparâmetros, o que reduz interferência de fatores externos na comparação entre arquiteturas. A configuração adotada foi:

Tabela 28 – Hiperparâmetros e configurações de treinamento adotados

Configuração	**Valor**
Taxa de aprendizado	10^{-4}
Tamanho de entrada	256×256
Batch size	8
Otimizador	`AdamW`
`Weight decay`	10^{-4}
Máximo de épocas	250
Paciência de *early stopping*	40
Limiar de binarização na inferência	$0{,}5$
Mixed precision	Utilizada quando CUDA estava disponível

A uniformização desses hiperparâmetros é metodologicamente importante porque permite atribuir as diferenças de desempenho com maior confiança ao desenho das arquiteturas e não a regimes de treinamento muito distintos. Além disso, o uso de resolução 256×256 foi coerente com os resultados da análise de sensibilidade, que mostraram leve superioridade desse tamanho de entrada em relação a 224×224.

5.1.3 Funções de perda utilizadas

O pipeline de segmentação suportou três funções de perda principais:

- `dice`;
- `bce_dice`;
- `focal_dice`.

Na grade principal de experimentação, as perdas efetivamente comparadas foram `dice` e `bce_dice`. A função `focal_dice` estava disponível na implementação e apareceu apenas na busca complementar com Optuna, não sendo a vencedora no protocolo final.

Na rodada consolidada, a melhor configuração para todos os quatro modelos foi a perda `bce_dice`, definida como:

$$\mathcal{L}_{\text{bce_dice}} = 0.5 \cdot \mathcal{L}_{\text{BCEWithLogits}} + 0.5 \cdot \mathcal{L}_{\text{Dice}}. \tag{388}$$

Essa escolha é tecnicamente consistente com a tarefa, pois combina a estabilidade local da BCE em nível de pixel com o alinhamento geométrico da Dice Loss, particularmente relevante em segmentação de lesões pequenas sobre fundo dominante.

5.2 Resultados quantitativos gerais

5.2.1 Tabela consolidada de métricas

A Tabela 28 resume os principais resultados quantitativos da segmentação no conjunto de teste, incluindo Dice global, IoU, *precision*, *recall*, Dice por classe, número de parâmetros, tempo total de treinamento e latência média de inferência por imagem.

Tabela 29 – Resultados consolidados dos modelos de segmentação no conjunto de teste.

Modelo	Dice	IoU	Precision	Recall	Dice benign	Dice malignant	Parâmetros	Inferência (ms)
U-Net++	**0.790**	**0.713**	0.829	0.810	**0.827**	**0.713**	26.1M	2.71
Attention U-Net	0.782	0.700	0.783	**0.841**	0.817	0.709	24.4M	2.17
U-Net	0.774	0.694	**0.836**	0.782	0.816	0.685	24.4M	1.89
DeepLabV3+	0.763	0.684	0.809	0.769	0.790	0.706	**22.4M**	**1.82**

Os resultados evidenciam que as diferenças entre arquiteturas foram mais estreitas do que na classificação, mas ainda assim suficientemente consistentes para sustentar uma hierarquia clara. A U-Net++ apresentou o melhor desempenho absoluto em Dice e IoU, além do melhor Dice por classe tanto em *benign* quanto em *malignant*. A Attention U-Net destacou-se por maior *recall*, a U-Net por maior *precision*, e a DeepLabV3+ por menor custo bruto e melhor latência de inferência.

5.2.2 Comparação entre arquiteturas

A comparação entre arquiteturas revela um cenário de compromissos distintos entre cobertura espacial, precisão de contorno e custo operacional. A U-Net++ foi o modelo mais equilibrado do conjunto, liderando simultaneamente em Dice global, IoU global e Dice por classe. Isso sugere que suas *nested skip connections* contribuíram para uma fusão mais eficiente entre detalhe espacial e abstração semântica, resultando em melhor compromisso entre contorno e cobertura da lesão.

A Attention U-Net apresentou o maior *recall* global $(0{,}841)$, o que indica maior capacidade de recuperar a extensão verdadeira da lesão. Entretanto, esse ganho veio acompanhado de menor *precision*, sugerindo tendência mais forte à sobresegmentação. A U-Net clássica mostrou comportamento oposto: foi o modelo com maior *precision* $(0{,}836)$, mas com *recall* mais baixo, refletindo um perfil mais conservador e propenso à subsegmentação.

A DeepLabV3+ foi o modelo mais leve e mais rápido, mas apresentou o menor Dice global do grupo. Esse resultado sugere que, embora a arquitetura seja eficiente e operacionalmente atraente, sua estratégia de segmentação baseada em contexto global e suavização espacial não foi a mais adequada para capturar, com máxima

fidelidade, as bordas e irregularidades das lesões mamárias neste conjunto de dados.

5.2.3 Melhor modelo em desempenho absoluto

Considerando as métricas globais de qualidade segmentadora, a U-Net++ foi o melhor modelo em desempenho absoluto. Seu Dice de $0{,}7896$ e sua IoU de $0{,}7134$ foram os maiores entre todas as arquiteturas avaliadas, e o modelo também apresentou o melhor desempenho por classe, com Dice de $0{,}827$ para *benign* e $0{,}713$ para *malignant*.

Esse resultado é particularmente relevante porque a U-Net++ não foi simplesmente a melhor em uma métrica isolada, mas a arquitetura mais consistente em diferentes critérios de avaliação. Em outras palavras, ela não apenas sobrepôs melhor as máscaras de referência, como também apresentou o melhor equilíbrio entre cobertura da região tumoral e preservação de contorno. Isso justifica sua escolha como arquitetura segmentadora principal desta pesquisa.

5.3 Curvas de treinamento

5.3.1 Loss de treino e validação

As curvas de *loss* de treino e validação mostraram comportamento globalmente estável para todas as arquiteturas. Em todos os casos, a redução mais intensa ocorreu nas primeiras 10 a 20 épocas, seguida de um regime de platô com refinamentos graduais associados às reduções sucessivas da taxa de aprendizado pelo *scheduler*. Esse padrão é compatível com treinamento bem controlado e com ausência de divergência na otimização.

Entre os modelos, a Attention U-Net manteve a maior *validation loss* ao longo do treinamento, o que é coerente com sua tendência observada de expandir mais a máscara predita e acumular maior quantidade de falsos positivos em alguns casos. Em contrapartida, a U-Net++ apresentou curva mais favorável, convergindo para valores finais mais consistentes com sua liderança em Dice e IoU.

5.3.2 IoU de treino e validação

As curvas de IoU de treino e validação indicaram que o melhor pico de validação foi alcançado pela U-Net++, com *val IoU* $= 0{,}7412$ em sua melhor época. Em seguida vieram U-Net ($0{,}7320$), Attention U-Net ($0{,}7036$) e DeepLabV3+ ($0{,}7026$). Esse resultado confirma que a U-Net++ obteve a melhor relação entre consistência de contorno e sobreposição espacial durante o treinamento.

A proximidade entre U-Net e U-Net++ sugere que a família U-Net, em sentido amplo, continua fortemente adequada ao problema. Já a distância das demais arquiteturas em relação ao melhor pico reforça que tanto o ganho por atenção quanto o ganho por contexto global explícito foram mais limitados neste cenário específico.

5.3.3 Dice Score de treino e validação

Nas curvas de Dice, as melhores épocas ocorreram em momentos distintos para cada arquitetura: época 30 para U-Net++, época 26 para U-Net, época 22 para DeepLabV3+ e época 52 para Attention U-Net. Essa diferença sugere comportamentos de convergência distintos, com algumas arquiteturas saturando cedo e outras exigindo refinamento mais prolongado.

A U-Net++ novamente se destacou por atingir o melhor pico em validação, o que reforça a consistência do resultado final. A Attention U-Net, por outro lado, necessitou de mais épocas para estabilizar sua melhor performance, o que é compatível com uma dinâmica de treinamento mais lenta e maior sensibilidade ao ajuste fino das ativações espaciais.

5.3.4 Estabilidade do treinamento

De forma geral, não houve divergência em nenhuma das arquiteturas. A oscilação final do *val dice* foi baixa em todos os modelos, com desvio nos últimos 10 *epochs* entre aproximadamente $0{,}0009$ e $0{,}0031$. Isso indica que o processo de treinamento foi estável e que a seleção dos melhores *checkpoints* não ocorreu em regiões altamente instáveis da otimização.

O *gap* final entre treino e validação ficou em torno de $0{,}09$ a $0{,}11$, o que sugere presença de *overfitting* moderado, porém controlado. Em segmentação médica, esse nível de diferença é plausível e não invalida os resultados, especialmente porque as métricas finais em teste permaneceram consistentes com o desempenho de validação.

5.4 Comparação quantitativa dos modelos

5.4.1 U-Net

A U-Net apresentou o perfil mais conservador entre os modelos avaliados. Seu principal ponto forte foi a maior *precision* global ($0{,}836$), o que indica menor tendência a expandir excessivamente a máscara além da região tumoral. Essa característica aparece também na razão entre pixels preditos e pixels do *ground truth*, que foi de $0{,}924$, a menor do grupo.

Em contrapartida, esse comportamento conservador veio acompanhado de menor *recall* e Dice inferior ao da U-Net++. Em termos interpretativos, a U-Net tendeu mais à subsegmentação: preferiu errar por omissão parcial de área tumoral do que por expansão excessiva. Ainda assim, seu desempenho permaneceu forte e sua eficiência computacional foi uma das melhores do grupo.

5.4.2 Attention U-Net

A Attention U-Net foi o modelo com maior *recall* global ($0{,}841$) e também o melhor *recall* na classe *malignant* ($0{,}772$). Isso sugere que os mecanismos de atenção ajudaram a arquitetura a recuperar mais pixels relevantes da lesão, sobretudo em casos malignos com contornos difíceis.

Entretanto, essa arquitetura também apresentou a maior tendência à sobresegmentação. Em média, previu $1{,}046\times$ o número de pixels do *ground truth*, o que mostra que o ganho em cobertura espacial veio acompanhado de menor contenção de área. Em termos práticos, trata-se de um modelo mais "expansivo": vê mais lesão, mas nem sempre com a mesma precisão geométrica da U-Net++.

5.4.3 U-Net++

A U-Net++ foi a arquitetura mais equilibrada do experimento. Obteve o melhor Dice global, a melhor IoU global e o melhor Dice por classe, tanto em *benign* quanto em *malignant*. Seu comportamento quantitativo sugere que as *nested skip connections* realmente contribuíram para uma fusão mais eficiente entre detalhe local e semântica profunda.

Além disso, o modelo não foi simplesmente o mais "agressivo" nem o mais "conservador"; foi o que melhor conciliou cobertura e contorno. Esse equilíbrio explica por que superou simultaneamente a U-Net em Dice, a Attention U-Net em precisão global e a DeepLabV3+ em desempenho total. Por isso, foi corretamente identificado como melhor modelo absoluto e também como melhor modelo em equilíbrio entre desempenho e custo.

5.4.4 DeepLabV3+

A DeepLabV3+ apresentou o menor custo bruto do conjunto, o menor número de parâmetros e a melhor latência de inferência. Ainda assim, foi a última colocada em Dice global. Esse resultado sugere que sua estratégia de segmentação, mais orientada a contexto global e suavização, não foi a que melhor se ajustou à morfologia e às bordas das lesões do BUSI.

Em alguns casos, a arquitetura pareceu excessivamente suave, perdendo pequenas estruturas ou falhando em recuperar integralmente a área da lesão. Isso é coerente com a observação de perdas completas em alguns exemplos difíceis. Assim, embora a DeepLabV3+ seja operacionalmente muito atraente, seu teto de qualidade segmentadora foi o mais baixo no contexto deste experimento.

5.5 Análise qualitativa da segmentação

5.5.1 Casos com segmentação adequada

Casos como `benign_33`, `benign_9`, `benign_280`, `benign_62` e `malignant_85` apresentaram Dice muito alto em vários modelos. Esses exemplos mostram que, quando a lesão é relativamente compacta, bem delimitada e visualmente conspícua, todas as arquiteturas tendem a convergir para segmentações bastante próximas da máscara de referência.

Esse comportamento é importante porque mostra que o problema não está na incapacidade global de segmentar ultrassom mamário, mas na sensibilidade a casos estruturalmente mais ambíguos.

5.5.2 Casos com subsegmentação

Exemplos como `benign_236`, `benign_344`, `benign_414` e `benign_422` foram casos claros de subsegmentação. O exemplo `benign_236` foi particularmente crítico, pois todos os modelos falharam quase completamente. Esse padrão reforça a interpretação de que lesões pequenas, pouco contrastadas ou de contorno muito sutil tendem a ser parcialmente omitidas pela maioria das arquiteturas.

A subsegmentação apareceu com maior frequência relativa em U-Net e DeepLabV3+, coerentemente com seus perfis mais conservadores e compactos.

5.5.3 Casos com sobresegmentação

O caso `malignant_191` foi o exemplo mais evidente de sobresegmentação, especialmente em Attention U-Net e U-Net++. Nesse cenário, a máscara predita excedeu significativamente a região verdadeira, expandindo-se para áreas adjacentes ao alvo.

Esse comportamento mostra que, em determinadas configurações de textura e contraste, modelos mais voltados à cobertura espacial podem extrapolar a lesão e comprometer a fidelidade geométrica do contorno. Embora isso preserve sensibilidade, reduz especificidade espacial da segmentação.

5.5.4 Casos difíceis e ambiguidades visuais

Casos como `malignant_192`, `malignant_198` e `malignant_43` apresentaram desempenho ruim em todos os modelos. O padrão visual dominante nesses exemplos foi a combinação de lesão pequena, baixo contraste, sombra acústica forte ou borda pouco definida. Isso indica que parte importante do erro segmentador está associada à própria limitação visual do exame e não apenas à arquitetura empregada.

Esses exemplos mostram que a variabilidade amostral permanece alta mesmo em um protocolo bem estruturado, o que é coerente com os desvios-padrão elevados de Dice observados no conjunto de teste.

5.6 Comparação visual entre ground truth e predição

5.6.1 Imagem original

Na figura de comparação lado a lado, observa-se que lesões compactas e bem delimitadas tendem a ser segmentadas de forma muito semelhante pelos quatro modelos. Nesses casos, a imagem original já oferece forte contraste local e contorno relativamente claro, reduzindo a diferença prática entre arquiteturas.

5.6.2 Máscara de referência

Quando a máscara de referência é regular, isolada e anatomicamente bem definida, todos os modelos acompanham a estrutura com boa fidelidade. Já em casos em que a máscara apresenta forma irregular, alongada ou bordas menos nítidas, as diferenças entre arquiteturas tornam-se mais evidentes, sobretudo entre modelos mais conservadores e mais expansivos.

5.6.3 Máscara predita

Em termos de forma predita, a U-Net++ foi a arquitetura que melhor preservou simultaneamente área e contorno. A Attention U-Net tendeu a expandir a região segmentada, enquanto U-Net e DeepLabV3+ tenderam a produzir máscaras mais compactas. Essa distinção qualitativa é altamente coerente com o padrão quantitativo observado em *precision* e *recall*.

5.6.4 Overlay comparativo

Os *overlays* comparativos mostram tanto alta coincidência em casos simples quanto falha significativa em casos difíceis. Essa variabilidade confirma que a segmentação em ultrassom mamário permanece fortemente dependente da qualidade visual local da lesão. Também explica por que os desvios-padrão de Dice permaneceram relativamente altos, entre aproximadamente $0{,}267$ e $0{,}293$, mesmo nos melhores modelos.

5.7 Análise de hiperparâmetros

5.7.1 Impacto da taxa de aprendizado

Na grade completa, a taxa de aprendizado 10^{-4} superou 10^{-3}, com *mean val Dice* de $0{,}7922$ contra $0{,}7762$. Esse resultado sugere que, na segmentação, um regime de atualização mais conservador foi mais eficaz para estabilizar o ajuste fino dos modelos.

Esse comportamento foi coerente em todo o protocolo final, já que todos os melhores modelos convergiram para $lr = 10^{-4}$. Em tarefas pixel a pixel, nas quais pequenas

instabilidades podem afetar diretamente o contorno segmentado, taxas mais baixas parecem oferecer vantagem clara.

5.7.2 Impacto do tamanho de entrada

O tamanho de entrada 256×256 foi ligeiramente superior ao 224×224, com *mean val Dice* de $0{,}7859$ contra $0{,}7825$. Embora a diferença não tenha sido grande, ela foi consistente o suficiente para justificar a adoção de 256×256 na configuração final.

Além disso, a melhor combinação global da grade foi exatamente 10^{-4} + `bce_dice` + 256×256, com *mean val Dice* de $0{,}7988$. Isso sugere que a resolução um pouco maior ajudou a preservar mais detalhe útil ao contorno da lesão.

5.7.3 Impacto da função de perda

A função de perda `bce_dice` foi superior à perda `dice` na grade principal, com *mean val Dice* de $0{,}7915$ contra $0{,}7769$. Esse resultado é consistente com a literatura e com a intuição metodológica: a BCE fornece estabilidade local de otimização, enquanto a Dice alinha o treinamento com a métrica final de sobreposição.

Na busca com Optuna, `bce_dice` também permaneceu como melhor escolha, embora `focal_dice` tenha aparecido como alternativa competitiva. Ainda assim, não houve evidência de superioridade sistemática de `focal_dice` sobre a melhor configuração final.

5.7.4 Efeito do data augmentation

A pipeline de segmentação utilizou *horizontal flip*, *Affine*, pequenas variações de brilho/contraste e *ElasticTransform*. Contudo, não há nos artefatos uma ablação explícita sem aumento de dados, o que impede afirmar causalmente seu efeito isolado. O máximo que se pode sustentar com rigor é que o melhor *trial* da busca complementar manteve *augmentation* ativa e moderada, e que essa política foi compatível com os melhores resultados do estudo.

Portanto, o aumento de dados deve ser entendido como parte integrada do regime final de treinamento, mas não como fator cujo impacto isolado tenha sido medido diretamente.

5.8 Custo computacional e inferência

5.8.1 Número de parâmetros por modelo

As arquiteturas apresentaram números de parâmetros relativamente próximos, mas ainda assim com diferenças relevantes:

A proximidade dessas escalas ajuda a explicar por que as diferenças de desempenho segmentador foram mais sutis do que na classificação. Ainda assim, o custo

Tabela 30 – Número de parâmetros das arquiteturas de segmentação

Arquitetura	Número de parâmetros
U-Net++	$26{,}1$ milhões
Attention U-Net	$24{,}4$ milhões
U-Net	$24{,}4$ milhões
DeepLabV3+	$22{,}4$ milhões

adicional da U-Net++ não foi excessivo frente ao ganho obtido em Dice e IoU.

5.8.2 Tempo de treinamento

O maior tempo de treinamento foi observado na Attention U-Net, com $225{,}9$ s, seguida pela U-Net++ com $193{,}5$ s. Os modelos mais rápidos foram U-Net ($147{,}2$ s) e DeepLabV3+ ($141{,}2$ s). Isso sugere que os mecanismos adicionais de atenção e os caminhos aninhados impuseram custo extra mensurável ao processo de otimização.

Ainda assim, o aumento de tempo da U-Net++ mostrou-se justificável, dado que foi justamente essa arquitetura que alcançou o melhor desempenho absoluto.

5.8.3 Tempo médio de inferência por imagem

Na etapa de inferência, a DeepLabV3+ apresentou o menor tempo médio por imagem, com $1{,}82$ ms/img. Em seguida, posicionaram-se a U-Net, com $1{,}89$ ms/img, a Attention U-Net, com $2{,}17$ ms/img, e a U-Net++, com $2{,}71$ ms/img. Esse resultado mostra que a U-Net++ incorreu em um custo operacional moderado para alcançar sua superioridade em qualidade de segmentação.

Apesar dessa diferença, a discrepância observada não foi extrema em termos absolutos. Assim, mesmo sendo a arquitetura mais lenta entre as avaliadas, a U-Net++ preserva viabilidade prática em muitos cenários operacionais, especialmente quando o ganho em qualidade segmentadora é considerado mais relevante do que pequenas diferenças no tempo de processamento.

Tabela 31 – Tempo médio de inferência por imagem das arquiteturas de segmentação

Arquitetura	Tempo médio de inferência (ms/img)
DeepLabV3+	$1{,}82$
U-Net	$1{,}89$
Attention U-Net	$2{,}17$
U-Net++	$2{,}71$

5.8.4 Comparação entre desempenho e custo

Sob o critério de *tradeoff_score* utilizado pelo projeto, definido a partir da relação entre Dice e escala logarítmica do número de parâmetros, a U-Net++ foi o melhor modelo em equilíbrio entre desempenho e custo. Esse resultado é importante porque mostra que sua liderança não foi obtida a um custo desproporcional.

Se a prioridade for latência pura, a DeepLabV3+ é a melhor escolha operacional. Contudo, quando se considera simultaneamente sobreposição espacial, qualidade por classe e custo, a U-Net++ permanece superior. Assim, a conclusão final da segmentação é mais simples do que na classificação: o melhor modelo absoluto e o melhor modelo em equilíbrio desempenho/custo coincidiram.

5.9 Síntese dos resultados de segmentação

5.9.1 Melhor modelo global

O melhor modelo global da segmentação foi a U-Net++. A arquitetura liderou em Dice global, IoU global e Dice por classe, mostrando-se a mais equilibrada na recuperação da área tumoral e na preservação do contorno da lesão.

Seu desempenho confirma que a reformulação estrutural das conexões laterais foi vantajosa neste problema, ainda que os ganhos em relação à U-Net clássica não tenham sido muito amplos em magnitude absoluta.

5.9.2 Melhor modelo em equilíbrio desempenho/custo

O melhor modelo em equilíbrio entre desempenho e custo também foi a U-Net++. Embora não tenha sido a mais rápida, sua superioridade em qualidade segmentadora compensou o aumento moderado de latência e parâmetros. Em outras palavras, foi a arquitetura que melhor converteu complexidade adicional em benefício real de segmentação.

Se a prioridade operacional fosse exclusivamente latência, a DeepLabV3+ seria a principal candidata. Contudo, como o objetivo desta pesquisa foi avaliar equilíbrio global entre desempenho e custo, a U-Net++ foi a vencedora também nesse critério.

5.9.3 Principais limitações observadas

As principais limitações da segmentação foram claras. Em primeiro lugar, lesões malignas foram mais difíceis do que benignas, com média de Dice inferior e maior incidência de casos problemáticos. Em segundo, houve falhas totais ou quase totais em lesões pequenas, pouco conspícuas ou marcadas por sombra acústica forte. Em terceiro, cada arquitetura revelou um viés espacial característico: Attention U-Net tendeu à sobresegmentação, enquanto U-Net e DeepLabV3+ tenderam mais à subsegmentação.

Essas limitações mostram que, embora os resultados tenham sido sólidos para o escopo do trabalho, a segmentação de ultrassom mamário permanece um problema de alta dificuldade visual e ainda sujeito a considerável variabilidade amostral.

6 DISCUSSÃO

6.1 Discussão dos resultados de classificação

Os resultados de classificação indicam que a tarefa de discriminar imagens benignas, malignas e normais em ultrassom mamário foi suficientemente sensível às escolhas arquiteturais, mas não de forma linear em relação ao porte do modelo. Em termos absolutos, a ResNet50 apresentou o melhor equilíbrio global entre desempenho discriminativo, sensibilidade clínica e eficiência operacional, superando arquiteturas maiores e mais pesadas em métricas centrais como macro-F_1, macro-AUC e latência de inferência. A ConvNeXt-Large, por sua vez, mostrou forte capacidade de recuperação global, mas sem converter seu custo computacional muito superior em uma vantagem proporcional nas métricas finais. A EfficientNet-B0 destacou-se como alternativa de alta eficiência, enquanto a VGG16 confirmou seu valor como *baseline* histórico, mas revelou limitações claras frente a arquiteturas mais modernas. Esses resultados reforçam a hipótese de que, em bases médicas moderadas como o BUSI, a qualidade do viés indutivo e da estabilidade de treinamento pode ser mais determinante do que o mero aumento bruto de capacidade paramétrica.

6.1.1 Interpretação dos ganhos entre arquiteturas

A principal leitura comparativa entre as arquiteturas é que os ganhos observados decorrem menos de "profundidade por si só" e mais da forma como cada modelo organiza extração hierárquica de características, propagação de gradiente e custo representacional. A ResNet50, ao combinar profundidade efetiva com conexões residuais, mostrou-se particularmente adequada ao problema. Seu desempenho superior sugere que o aprendizado residual permitiu melhor exploração de padrões visuais sutis presentes no ultrassom mamário, sem que a otimização se tornasse instável ou excessivamente dependente de capacidade paramétrica muito alta.

A ConvNeXt-Large atingiu desempenho competitivo, o que confirma que CNNs modernizadas continuam altamente relevantes para classificação médica. No entanto, o fato de ter empatado em *accuracy* com a ResNet50 sem superar de forma consistente

seu macro-F_1, sua macro-AUC ou sua latência mostra que a modernização arquitetural não implica, automaticamente, superioridade prática. O custo de mais de 196 milhões de parâmetros e a latência significativamente superior indicam que parte de sua capacidade ficou subaproveitada no regime de dados disponível.

A EfficientNet-B0 ocupou posição metodologicamente interessante. Embora seu desempenho absoluto tenha ficado abaixo da ResNet50 e da ConvNeXt-Large, ela entregou resultado competitivo com custo computacional substancialmente inferior. Isso é relevante porque mostra que arquiteturas desenhadas com ênfase em eficiência podem se beneficiar fortemente de *transfer learning* em bases médicas moderadas, oferecendo desempenho robusto sem exigir infraestrutura proporcionalmente maior.

A VGG16, por fim, apresentou o pior desempenho entre os quatro modelos. Esse resultado é coerente com a literatura contemporânea: embora a arquitetura continue útil como referência histórica e *baseline*, seu desenho mais antigo, a ausência de mecanismos residuais e seu custo paramétrico elevado limitam sua competitividade em comparação com modelos mais recentes. No presente estudo, a VGG16 confirma mais o valor de servir como ponto de comparação do que como candidata real ao melhor desempenho.

6.1.2 Sensibilidade para lesões malignas

Do ponto de vista clínico, a sensibilidade para a classe maligna é um dos aspectos mais importantes do experimento. Em aplicações de apoio ao diagnóstico, erros na detecção de lesões malignas possuem custo potencialmente mais grave do que erros em outras classes, pois podem contribuir para atraso diagnóstico e subestimação de risco. Nesse sentido, a ResNet50 apresentou o comportamento mais consistente, sendo identificada como melhor modelo em sensibilidade para malignidade na execução principal.

Esse resultado é particularmente importante porque a superioridade da ResNet50 não se restringiu às métricas agregadas. O modelo também foi capaz de preservar desempenho elevado na classe clinicamente mais sensível, o que reforça sua robustez sob uma perspectiva prática. A ConvNeXt-Large e a EfficientNet-B0 também exibiram valores altos de *recall* para malignidade, o que indica que o problema não era intrinsecamente inatingível para arquiteturas concorrentes. Ainda assim, a ResNet50 destacou-se por combinar essa sensibilidade com melhor equilíbrio entre *precision*, F_1 e AUC.

Esse ponto merece ênfase na discussão porque ilustra uma distinção fundamental entre desempenho estatístico e relevância clínica. Um modelo pode apresentar acurácia global alta e, ainda assim, falhar em casos malignos. Ao destacar explicitamente o *malignant recall*, o protocolo adotado evita que a seleção favoreça arquiteturas com bom comportamento médio, mas inadequadas justamente no subconjunto mais im-

portante para apoio diagnóstico.

6.1.3 Robustez dos modelos

A robustez dos modelos pode ser discutida sob três dimensões: consistência entre métricas, estabilidade frente ao custo computacional e comportamento em execuções alternativas. Na execução principal, a ResNet50 apresentou coerência entre *accuracy*, macro-F_1, macro-AUC e sensibilidade para malignidade, o que sugere desempenho robusto e não dependente de uma única métrica favorável. Já a EfficientNet-B0 mostrou robustez operacional, ao sustentar bom desempenho com baixa complexidade. A ConvNeXt-Large, embora forte, pareceu mais sensível ao regime de treinamento e ao custo computacional, enquanto a VGG16 mostrou menor robustez geral.

Quando se observa o panorama entre diferentes execuções consolidadas, percebe-se que a ResNet50 aparece repetidamente como melhor classificador absoluto ou como melhor modelo em sensibilidade para malignidade. Essa recorrência sugere que sua liderança não foi um acidente de uma única rodada experimental, mas um comportamento relativamente estável sob diferentes configurações de treinamento. A ConvNeXt-Large, em contraste, aparece como melhor classificador absoluto em algumas execuções alternativas, o que mostra que seu potencial é real, mas menos consistentemente convertido em superioridade prática.

Em síntese, a robustez classificatória observada favorece arquiteturas que conciliam profundidade suficiente, otimização estável e custo moderado. No cenário deste trabalho, a ResNet50 foi a que melhor reuniu essas propriedades.

6.2 Discussão dos resultados de segmentação

Os resultados de segmentação mostram um cenário distinto do observado na classificação. Enquanto na tarefa classificatória a liderança da ResNet50 foi relativamente clara, na segmentação as diferenças entre arquiteturas foram menores e mais sensíveis a pequenas variações de configuração. Ainda assim, na execução principal, a U-Net apresentou o melhor desempenho absoluto em Dice e IoU, além de também ter sido identificada como melhor modelo em equilíbrio entre desempenho e custo. Isso reforça a força do paradigma *encoder-decoder* clássico em segmentação biomédica.

De modo geral, os resultados sugerem que a tarefa de segmentar lesões mamárias em ultrassom é altamente influenciada pela capacidade do modelo de preservar detalhes de contorno sob ruído, baixo contraste e fronteiras imprecisas. Nesse contexto, arquiteturas mais complexas não produziram ganhos sistemáticos suficientemente grandes para deslocar a U-Net de seu papel de referência mais eficiente.

6.2.1 Impacto da atenção na segmentação

A Attention U-Net foi incorporada ao estudo com a hipótese de que mecanismos de atenção poderiam melhorar a focalização da rede sobre regiões relevantes e reduzir interferência do fundo. No entanto, os resultados da execução principal não indicaram superioridade dessa arquitetura sobre a U-Net clássica. Embora a inclusão de *attention gates* seja conceitualmente atraente, sobretudo em imagens médicas com ruído e estruturas ambíguas, seu ganho empírico neste conjunto de dados foi limitado.

Há duas leituras possíveis para esse resultado. A primeira é que a natureza do BUSI, embora desafiadora, pode não ser suficientemente grande ou diversa para permitir que o custo adicional do mecanismo de atenção se converta em vantagem estável. A segunda é que a U-Net já oferece uma combinação muito eficaz entre contexto e detalhe espacial, de modo que o espaço restante para ganho incremental com atenção se torna relativamente pequeno.

Isso não significa que a atenção seja irrelevante em segmentação médica, mas sim que seu benefício depende fortemente do regime de dados, da complexidade anatômica e da relação entre custo adicional e ganho marginal de qualidade. No presente estudo, a hipótese de ganho sistemático com atenção não se confirmou de forma forte na execução principal.

6.2.2 Ganhos estruturais de arquiteturas mais complexas

A comparação entre U-Net, U-Net++, Attention U-Net e DeepLabV3+ permite uma leitura mais ampla sobre arquiteturas mais complexas. O U-Net++ introduz caminhos aninhados e conexões mais densas para reduzir o hiato semântico entre *encoder* e *decoder*. A DeepLabV3+ incorpora convoluções atrous e agregação explícita de contexto multiescala. A Attention U-Net adiciona seletividade espacial. Em teoria, todas essas modificações deveriam aumentar a capacidade do modelo de lidar com fronteiras ambíguas e estruturas multiescala.

Na prática, porém, os ganhos foram modestos e não universalmente consistentes. A U-Net++ e a DeepLabV3+ mostraram competitividade, e em execuções alternativas chegaram a aparecer como melhores segmentadores absolutos. Isso indica que as ideias estruturais dessas arquiteturas são válidas. No entanto, na execução principal, a U-Net clássica permaneceu superior em Dice e IoU, além de manter excelente eficiência.

Esse resultado é metodologicamente relevante porque sugere que, em datasets médicos moderados, arquiteturas mais complexas nem sempre conseguem transformar sofisticação estrutural em benefício líquido. Em outras palavras, o aumento de complexidade pode ampliar flexibilidade representacional, mas também aumentar sensibilidade a regime de treinamento, custo computacional e variabilidade do conjunto.

6.2.3 Limitações na delimitação das lesões

A delimitação das lesões em ultrassom mamário permanece intrinsicamente difícil, e os resultados segmentadores precisam ser interpretados à luz dessa dificuldade. Mesmo o melhor modelo da execução principal, a U-Net, obteve Dice em torno de $0{,}79$ e IoU em torno de $0{,}71$, o que é bom para o contexto do TCC, mas ainda distante de um cenário de correspondência espacial perfeita. Isso indica que há erro residual relevante na reconstrução do contorno tumoral.

As principais fontes plausíveis dessa limitação incluem ruído *speckle*, contraste reduzido entre lesão e tecido adjacente, presença de margens pouco definidas, heterogeneidade morfológica das massas e variabilidade das próprias anotações. Além disso, a consolidação de múltiplas máscaras por união lógica, embora metodologicamente coerente, pode introduzir regiões-alvo mais heterogêneas em alguns casos. Também é provável que o redimensionamento das imagens para 256×256 tenha imposto alguma perda de detalhe fino em bordas pequenas ou irregulares.

Assim, os resultados segmentadores devem ser lidos menos como tentativa de contorno perfeito e mais como avaliação da capacidade do modelo de recuperar de forma confiável a extensão geral da lesão. Sob esse critério, o desempenho foi consistente, mas ainda sujeito a limitações reais do domínio.

6.3 Comparação entre desempenho e custo computacional

Um dos aspectos mais importantes do estudo foi tratar custo computacional como dimensão central da avaliação, e não como apêndice secundário. Essa escolha permitiu discutir os modelos em termos de utilidade prática e não apenas de desempenho máximo em laboratório. Em tarefas médicas aplicadas, essa distinção é crucial, porque um modelo só é realmente interessante se puder combinar boa qualidade preditiva com custo operacional plausível.

6.3.1 Melhor modelo absoluto versus melhor custo-benefício

Na classificação, o melhor modelo absoluto foi a ResNet50, enquanto o melhor custo-benefício foi a EfficientNet-B0. Essa distinção é importante porque mostra que liderança em macro-F_1 e AUC não coincide necessariamente com liderança em eficiência. A ResNet50 entregou o melhor desempenho global e, ao mesmo tempo, manteve ótima latência, o que a torna extremamente forte em valor prático. A EfficientNet-B0, porém, fez isso com número de parâmetros muito menor, o que a posiciona como opção particularmente atraente em cenários de restrição de memória e armazenamento.

Na segmentação, a coincidência entre melhor desempenho absoluto e melhor trade-off em favor da U-Net torna a interpretação ainda mais clara. Nesse caso, o modelo mais eficaz foi também o mais interessante em equilíbrio entre qualidade e

custo, o que reforça sua adequação como arquitetura de referência para o problema.

Essa diferenciação entre melhor absoluto e melhor compromisso é uma das contribuições metodológicas mais relevantes do trabalho, pois desloca a análise de uma lógica puramente competitiva para uma lógica mais aplicável.

6.3.2 Viabilidade prática em ambientes com recursos limitados

Em ambientes acadêmicos, laboratoriais ou clínicos com recursos restritos, a viabilidade prática dos modelos torna-se um critério decisivo. Sob essa perspectiva, a EfficientNet-B0 e a U-Net assumem papel de destaque. A primeira porque entrega classificação competitiva com número de parâmetros muito reduzido; a segunda porque lidera a segmentação sem exigir custo desproporcional.

A ConvNeXt-Large, embora forte em classificação, aparece como arquitetura menos favorável nesse contexto devido ao seu tamanho e à sua latência substancialmente maiores. Isso não a invalida como modelo experimental, mas reduz sua atratividade para implantação em cenários de infraestrutura limitada. A VGG16, por sua vez, ficou em posição ainda menos favorável, pois combinou desempenho inferior com custo elevado.

Em termos de segmentação, a proximidade de latência entre U-Net e DeepLabV3+ sugere que ambas podem ser consideradas viáveis em ambientes moderadamente restritos, mas a vantagem absoluta da U-Net em Dice e IoU a torna mais convincente como opção prioritária.

6.3.3 Considerações sobre tempo de inferência

O tempo de inferência é particularmente relevante quando se pensa em integração com fluxo clínico ou em apoio interativo à decisão. Na classificação, a ResNet50 foi a mais rápida entre os melhores modelos selecionados, o que fortalece ainda mais sua posição como melhor escolha geral. Na segmentação, a DeepLabV3+ apresentou a menor latência, praticamente empatada com a U-Net, o que mostra que a busca por contexto global não necessariamente impôs penalidade operacional proibitiva.

Esse resultado sugere duas conclusões. Primeiro, a latência, por si só, não deve ser interpretada de maneira isolada, pois pequenas diferenças em milissegundos podem ser pouco relevantes se acompanhadas de mudanças maiores em qualidade segmentadora. Segundo, quando dois modelos apresentam latências muito próximas, a prioridade tende a recair sobre aquele com melhor desempenho clínico-operacional agregado.

No presente estudo, essa lógica favoreceu a ResNet50 na classificação e a U-Net na segmentação.

6.4 Relação com os trabalhos relacionados

6.4.1 Similaridades com a literatura

Os resultados obtidos são amplamente coerentes com a literatura recente em ultrassom mamário e segmentação biomédica. Em classificação, a superioridade de arquiteturas residuais e de CNNs modernas sobre *baselines* clássicos acompanha o padrão já observado em diversos estudos comparativos. Em segmentação, o fato de a U-Net permanecer extremamente competitiva, mesmo diante de variantes mais sofisticadas, também está alinhado ao estado da arte: a U-Net continua sendo a principal referência em segmentação médica justamente por aliar simplicidade estrutural e alta eficácia.

Outra similaridade importante diz respeito à relevância da sensibilidade para classes malignas e ao papel de métricas de sobreposição como Dice e IoU. O protocolo experimental adotado segue a tendência da literatura mais cuidadosa, que reconhece que acurácia global é insuficiente em problemas médicos desbalanceados e que a qualidade de contorno precisa ser avaliada com métricas apropriadas ao problema segmentador.

6.4.2 Diferenças em metodologia e resultados

A principal diferença metodológica do presente trabalho em relação a muitos estudos correlatos é a ênfase simultânea em dois eixos independentes: classificação e segmentação. Em vez de misturar ambas as tarefas em uma única comparação difusa, o estudo as trata como problemas complementares, porém distintos, com métricas, arquiteturas e critérios de seleção próprios. Isso melhora a clareza analítica e evita interpretações metodologicamente frágeis.

Outra diferença importante foi a incorporação explícita do custo computacional como parte do julgamento final dos modelos. Muitos trabalhos relatam apenas métricas finais de desempenho. Aqui, foram integrados número de parâmetros, tempo de treinamento, latência e *trade-off* desempenho/custo. Isso amplia a utilidade da discussão.

Além disso, o trabalho também se diferencia por reconhecer explicitamente limitações do próprio dataset BUSI, incluindo sua escala moderada, a presença de máscaras vazias na classe normal e a ausência de controle por paciente na divisão dos dados. Esse tipo de transparência metodológica nem sempre aparece com clareza em estudos aplicados.

6.4.3 Contribuição do trabalho frente à literatura

A principal contribuição do trabalho não está na proposição de uma arquitetura inédita, mas na realização de uma comparação metodologicamente consistente entre

arquiteturas representativas de classificação e segmentação em ultrassom mamário, sob um protocolo único, reprodutível e orientado tanto a desempenho quanto a custo computacional.

Essa contribuição é relevante porque oferece uma leitura mais equilibrada do problema: mostra quais modelos vencem em desempenho absoluto, quais vencem em compromisso custo-benefício e quais tendências se mantêm ou variam entre execuções. Em vez de apenas maximizar uma métrica final, o estudo oferece uma análise mais próxima do que seria necessário para justificar adoção prática ou extensão científica futura.

6.5 Limitações do estudo

6.5.1 Uso de um único dataset

A primeira limitação importante do estudo é o uso de um único dataset, o BUSI. Embora essa base seja amplamente utilizada e adequada ao recorte do trabalho, sua utilização isolada limita a validade externa dos resultados. Em particular, não é possível afirmar com segurança que as hierarquias entre arquiteturas observadas aqui se manteriam sob outras populações, protocolos de aquisição, equipamentos ou instituições.

Essa limitação é especialmente relevante em imagem médica, onde *domain shift* entre centros pode impactar fortemente a generalização. Assim, os resultados devem ser interpretados como evidência sólida dentro do ambiente BUSI, mas não como prova definitiva de superioridade universal das arquiteturas avaliadas.

6.5.2 Tamanho da base de dados

Embora o BUSI seja útil para pesquisa aplicada, seu tamanho ainda é moderado para padrões de aprendizado profundo. Isso afeta tanto a capacidade de generalização quanto a estabilidade da comparação entre arquiteturas muito grandes. Modelos com alta capacidade representacional, como a ConvNeXt-Large, podem não dispor de dados suficientes para converter integralmente seu potencial em vantagem prática.

Além disso, a quantidade de amostras na classe maligna e a ausência de casos normais na segmentação limitam a diversidade estrutural efetivamente explorada pelo pipeline. Em outras palavras, o estudo opera em um regime experimental realista para TCC, mas ainda aquém de um cenário ideal para conclusões clínicas amplamente generalizáveis.

6.5.3 Limitações de hardware

As limitações de hardware também influenciaram o desenho experimental. Restrições de memória e tempo de execução impuseram escolhas como resoluções espe-

cíficas, tamanhos de lote relativamente controlados e limitação do espaço de busca de hiperparâmetros. Essas decisões foram tecnicamente razoáveis, mas restringem o grau de exploração possível, sobretudo para arquiteturas maiores.

Em cenários com infraestrutura mais robusta, seria plausível testar resoluções mais altas, ajustes mais longos, buscas mais amplas de hiperparâmetros e procedimentos adicionais de validação estatística. Portanto, o desenho adotado deve ser entendido como um equilíbrio entre rigor metodológico e viabilidade computacional.

6.5.4 Restrições metodológicas

A principal restrição metodológica residual é a ausência de particionamento em nível de paciente. O controle de vazamento de dados foi corretamente realizado em nível de imagem, mas não foi possível garantir separação interpaciente. Isso significa que os resultados são metodologicamente sólidos para o escopo do dataset disponível, porém ainda sujeitos a uma limitação importante sob o ponto de vista clínico mais rigoroso.

Outra restrição é a dependência de um protocolo específico de aumento de dados, resolução e normalização. Embora essas escolhas tenham sido consistentes e bem justificadas, resultados diferentes poderiam emergir sob outras combinações de pré-processamento e ajuste fino.

6.6 Implicações práticas

6.6.1 Uso como apoio ao diagnóstico

Os resultados obtidos sugerem que os modelos avaliados têm potencial real como ferramentas de apoio ao diagnóstico, mas não como substitutos da interpretação médica. Na classificação, a ResNet50 mostrou capacidade de distinguir adequadamente entre classes benigna, maligna e normal, com sensibilidade forte para malignidade. Na segmentação, a U-Net demonstrou capacidade consistente de recuperar a extensão geral da lesão.

Esses comportamentos indicam que sistemas desse tipo podem atuar como segunda leitura automatizada, triagem inicial, auxílio à priorização de casos ou apoio visual na delimitação de regiões suspeitas. Em todos esses cenários, seu papel é complementar, ampliando consistência e velocidade, e não removendo a necessidade de julgamento clínico humano.

6.6.2 Potencial de aplicação acadêmica e clínica

Do ponto de vista acadêmico, o pipeline desenvolvido é claramente reaproveitável. Sua modularidade, reprodutibilidade e organização de artefatos o tornam uma base adequada para extensões futuras, como inclusão de novos datasets, validação

cruzada, agrupamento por paciente, explicabilidade e integração multitarefa.

Do ponto de vista clínico, o trabalho ainda está em estágio de prova de conceito robusta, não de implantação. Ainda assim, os resultados indicam que arquiteturas relativamente eficientes já são capazes de produzir desempenho promissor em ultrassom mamário, o que reforça a relevância de aprofundar essa linha em contextos multicêntricos e mais próximos da prática assistencial.

6.6.3 Cuidados éticos e interpretativos

Qualquer discussão sobre uso prático de modelos em saúde deve ser acompanhada de cautela ética e interpretativa. Em primeiro lugar, desempenho elevado em um dataset público não equivale automaticamente a segurança clínica. Em segundo, erros do modelo podem ser assimétricos em gravidade, especialmente quando envolvem lesões malignas. Em terceiro, predições automatizadas podem induzir excesso de confiança se apresentadas sem contexto, sem incerteza e sem supervisão humana.

Por isso, a interpretação dos resultados deste trabalho deve permanecer no escopo apropriado: trata-se de uma investigação experimental rigorosa sobre apoio computacional ao diagnóstico em ultrassom mamário. Seus achados são relevantes e promissores, mas precisam ser integrados a protocolos de validação externa, governança de dados, transparência interpretativa e supervisão médica antes de qualquer extrapolação para uso clínico real.

7 CONCLUSÃO

7.1 Retomada do problema de pesquisa

7.1.1 Síntese do contexto e motivação

Este trabalho partiu do reconhecimento de que o câncer de mama permanece como um problema de saúde pública de elevada relevância, e de que a ultrassonografia mamária, embora amplamente utilizada como método complementar de diagnóstico, impõe desafios interpretativos importantes em razão de ruído *speckle*, baixo contraste, variabilidade de aquisição e dependência do operador. Nesse contexto, a aplicação de arquiteturas de *Deep Learning* foi investigada não como substituição da leitura clínica especializada, mas como estratégia de apoio ao diagnóstico, com foco em duas tarefas complementares: classificação de imagens em *normal*, *benign* e *malignant*, e segmentação binária de lesões mamárias em imagens com máscara anotada. A motivação central foi construir uma avaliação comparativa metodologicamente consistente, capaz de distinguir desempenho absoluto de viabilidade computacional e, ao mesmo tempo, fornecer uma leitura tecnicamente defensável sobre o uso de IA em ultrassonografia mamária.

7.1.2 Resposta ao problema proposto

À luz dos resultados obtidos, a resposta ao problema de pesquisa pode ser formulada em três níveis. Primeiro, há evidência clara de que a escolha arquitetural influencia de forma significativa o desempenho em ambas as tarefas. Segundo, não existe uma arquitetura universalmente superior em todos os critérios: na classificação, o melhor desempenho global e a melhor sensibilidade clínica para malignidade não coincidiram no mesmo modelo; na segmentação, por outro lado, o melhor modelo absoluto e o melhor modelo em equilíbrio desempenho/custo coincidiram. Terceiro, os resultados indicam que arquiteturas modernas e bem ajustadas podem produzir desempenho competitivo e clinicamente promissor em ultrassom mamário, mas que sua interpretação deve permanecer condicionada ao escopo metodológico do estudo, especialmente ao uso de um único dataset e à ausência de particionamento em nível

de paciente.

7.2 Principais achados

7.2.1 Achados na classificação

Na tarefa de classificação, o estudo mostrou que a ConvNeXt-Large foi o melhor modelo global quando considerados conjuntamente *accuracy*, macro-F_1 e macro-AUC, evidenciando forte capacidade de discriminação entre as três classes do problema. Entretanto, a ResNet50 apresentou a maior sensibilidade para a classe *malignant*, tornando-se a opção mais segura quando o foco principal é minimizar falsos negativos em lesões malignas. A EfficientNet-B0, embora inferior em desempenho absoluto, destacou-se como o melhor compromisso entre desempenho e custo computacional, ao passo que a VGG16 cumpriu adequadamente o papel de *baseline* histórico, mas ficou atrás das arquiteturas mais recentes. Esses resultados mostram que, em classificação de ultrassom mamário, o melhor modelo depende do objetivo operacional: desempenho global, sensibilidade clínica ou custo-benefício.

7.2.2 Achados na segmentação

Na segmentação, a U-Net++ foi o melhor modelo do estudo, com liderança em Dice global, IoU global e Dice por classe, tanto para lesões benignas quanto malignas. Esse resultado sugere que a reformulação estrutural das conexões laterais e a redução do hiato semântico entre codificador e decodificador contribuíram de forma efetiva para uma melhor recuperação da área tumoral e do contorno da lesão. A Attention U-Net apresentou o maior *recall*, mostrando maior capacidade de cobertura espacial, porém com tendência mais forte à sobresegmentação. A U-Net clássica apresentou maior *precision*, refletindo um perfil mais conservador e mais propenso à subsegmentação. Já a DeepLabV3+ foi a arquitetura mais rápida e mais leve, mas com o menor Dice global entre os modelos avaliados. Em síntese, os achados mostram que a segmentação de lesões mamárias em ultrassom continua sendo um problema difícil, mas suficientemente sensível às escolhas arquiteturais para justificar comparação detalhada entre modelos.

7.2.3 Achados sobre custo computacional

Um dos achados mais importantes do trabalho foi a confirmação de que custo computacional e desempenho preditivo não devem ser tratados como dimensões independentes. Na classificação, a ConvNeXt-Large foi o melhor modelo absoluto, mas também o mais caro em termos de capacidade e latência, enquanto a EfficientNet-B0 foi muito mais econômica e ainda assim competitiva. A ResNet50 ocupou posição particularmente forte por combinar bom desempenho, alta sensibilidade para malig-

nidade e baixa latência. Na segmentação, a U-Net++ apresentou o melhor equilíbrio entre desempenho e custo, mesmo sem ser a mais rápida, enquanto a DeepLabV3+ se destacou pela menor latência de inferência. Esses resultados reforçam que a escolha arquitetural ideal depende do cenário de aplicação e dos recursos computacionais disponíveis, e não apenas da maior métrica final em teste.

7.3 Contribuições do trabalho

7.3.1 Contribuições técnicas

Do ponto de vista técnico, este trabalho entregou um pipeline completo, modular e reprodutível para classificação e segmentação de lesões mamárias em imagens de ultrassom utilizando o dataset BUSI. O sistema inclui auditoria do dataset, geração de manifestos, split estratificado, pré-processamento, aumento de dados, treinamento com *transfer learning*, busca de hiperparâmetros, checkpointing, avaliação quantitativa e qualitativa e mensuração explícita de custo computacional. Além disso, o projeto incorporou comparação entre arquiteturas representativas de diferentes paradigmas, o que amplia o valor técnico do estudo para além de uma única implementação pontual.

7.3.2 Contribuições metodológicas

Metodologicamente, a principal contribuição do trabalho foi tratar classificação e segmentação como tarefas complementares, porém distintas, evitando comparações conceitualmente inadequadas entre modelos desenhados para problemas diferentes. O estudo também contribuiu ao integrar desempenho clínico e custo computacional em um mesmo quadro analítico, permitindo distinguir o melhor modelo absoluto, o melhor modelo para sensibilidade clínica e o melhor modelo em compromisso desempenho/custo. Outro ponto relevante foi a preocupação explícita com curadoria do dataset, controle de vazamento de dados em nível de imagem, separação entre validação e teste e organização de artefatos reprodutíveis.

7.3.3 Contribuições acadêmicas

No plano acadêmico, o trabalho contribui ao oferecer uma avaliação comparativa robusta de arquiteturas de *Deep Learning* em ultrassonografia mamária, alinhando o rigor esperado em um TCC com práticas metodológicas próximas às de estudos experimentais mais maduros. A monografia organiza o problema, a fundamentação, o pipeline experimental, os resultados, a discussão e as limitações em uma estrutura coerente, capaz de servir tanto como registro acadêmico final quanto como base para continuidade em artigo, projeto de pesquisa ou extensão metodológica futura.

7.4 Limitações finais

7.4.1 Limitações experimentais

Entre as limitações experimentais mais importantes estão o uso de um único dataset, a escala moderada da base, a ausência de ablações completas para todos os componentes do pipeline e as restrições computacionais que limitaram a exploração de espaços mais amplos de hiperparâmetros, resoluções e regimes de treinamento. Também se observou que parte dos resultados, sobretudo na segmentação, permaneceu fortemente dependente da dificuldade visual de casos específicos, como lesões pequenas, pouco conspícuas ou com bordas mal definidas. Isso significa que os achados são tecnicamente sólidos para o escopo adotado, mas ainda condicionados à estrutura e às limitações do ambiente experimental utilizado.

7.4.2 Limitações de generalização

A principal limitação de generalização do estudo decorre da dependência do BUSI como única base experimental e da ausência de particionamento em nível de paciente. Embora o controle de vazamento em nível de imagem tenha sido corretamente implementado, o trabalho não garante isolamento interpaciente, o que reduz a força de generalização clínica dos resultados. Além disso, não é possível afirmar que as hierarquias entre arquiteturas observadas neste estudo se manteriam de forma idêntica em outras populações, protocolos de aquisição, instituições ou equipamentos. Assim, os resultados devem ser interpretados como evidência consistente dentro do domínio BUSI, e não como prova definitiva de superioridade universal das arquiteturas avaliadas.

7.5 Trabalhos futuros

7.5.1 Uso de múltiplos datasets

Uma primeira continuidade natural deste trabalho é ampliar o estudo para múltiplos datasets, de modo a investigar generalização entre bases e *domain shift*. A inclusão de outras coleções públicas de imagem mamária, bem como a avaliação cruzada entre conjuntos de aquisição distintos, permitiria testar se os modelos mantêm desempenho e hierarquia quando expostos a distribuições visuais diferentes. Esse passo é essencial para aproximar o pipeline de um cenário de validade externa mais robusta.

7.5.2 Validação cruzada e análise estatística

Outra evolução importante consiste na adoção de validação cruzada, preferencialmente com agrupamento em nível de paciente quando essa informação estiver disponível, além da incorporação de análise estatística formal para comparação entre ar-

quiteturas. Isso permitiria reduzir a dependência de um único particionamento treino-validação-teste e tornar mais rigorosa a interpretação das diferenças entre modelos, sobretudo quando os ganhos observados são pequenos em magnitude absoluta.

7.5.3 Inclusão de modelos adicionais

Do ponto de vista arquitetural, trabalhos futuros podem incorporar modelos adicionais tanto na classificação quanto na segmentação. No eixo classificatório, seria natural explorar arquiteturas híbridas ou transformers visuais. No eixo segmentador, variantes como modelos 3D, redes multitarefa, arquiteturas com módulos de refinamento de borda ou segmentadores guiados por atenção mais sofisticada poderiam ampliar a análise comparativa e ajudar a entender melhor o custo marginal dos ganhos estruturais.

7.5.4 Explicabilidade e interpretabilidade

A inclusão de mecanismos de explicabilidade e interpretabilidade constitui outro passo fundamental. Na classificação, métodos como Grad-CAM, Score-CAM ou análise de mapas de ativação podem ajudar a verificar se o modelo está de fato baseando sua decisão em regiões clinicamente plausíveis. Na segmentação, a análise de incerteza, de mapas de erro e de comportamento por tipo morfológico de lesão pode tornar a avaliação mais transparente. Em medicina, desempenho sem interpretabilidade tende a ter utilidade limitada; por isso, esse eixo deve ser tratado como prioridade em extensões futuras.

7.5.5 Integração entre classificação e segmentação

Por fim, um desdobramento particularmente promissor é a integração entre classificação e segmentação em um arcabouço multitarefa. Embora este trabalho tenha tratado as duas tarefas de forma separada por rigor metodológico, há forte motivação para investigar se o compartilhamento de representações entre classificação e segmentação pode gerar ganhos adicionais de desempenho, robustez ou interpretabilidade. Uma abordagem multitarefa bem desenhada poderia explorar simultaneamente informação global de classe e informação espacial de contorno, aproximando-se ainda mais das demandas reais do apoio computacional ao diagnóstico mamário.

REFERÊNCIAS

AFRIN, H.; LARSON, N. B.; FATEMI, M.; ALIZAD, A. Deep Learning in Different Ultrasound Methods for Breast Cancer, from Diagnosis to Prognosis: Current Trends, Challenges, and an Analysis. **Cancers**, [S.l.], v.15, n.12, p.3139, 2023.

AGGARWAL, R.; SOUNDERAJAH, V.; MARTIN, G.; TING, D. S. W.; KARTHIKESALINGAM, A.; KING, D.; ASHRAFIAN, H.; DARZI, A. Diagnostic accuracy of deep learning in medical imaging: a systematic review and meta-analysis. **npj Digital Medicine**, [S.l.], v.4, p.65, 2021.

AL-DHABYANI, W.; GOMAA, M.; KHALED, H.; FAHMY, A. Dataset of breast ultrasound images. **Data in Brief**, [S.l.], v.28, p.104863, 2020.

AL-KARAWI, D.; AL-ZAIDI, S.; HELAEL, K. A.; OBEIDAT, N.; MOUHSEN, A. M.; AJAM, T.; ALSHALABI, B. A.; SALMAN, M.; AHMED, M. H. A Review of Artificial Intelligence in Breast Imaging. **Tomography**, [S.l.], v.10, n.5, p.705–726, 2024.

ARUN, S. et al. Systematic scoping review of external validation studies of artificial intelligence tools in medical diagnosis. **npj Precision Oncology**, [S.l.], v.9, 2025. Conferir paginação final na versão publicada.

AUMENTE-MAESTRO, C.; DÍEZ, J.; REMESEIRO, B. A multi-task framework for breast cancer segmentation and classification in ultrasound imaging. **Computer Methods and Programs in Biomedicine**, [S.l.], v.260, p.108540, 2025.

BARRAGÁN-MONTERO, A.; JAVAID, U.; VALDÉS, G.; NGUYEN, D.; DESBORDES, P.; MACQ, B.; WILLEMS, S.; VANDEWINCKELE, L.; HOLMSTRÖM, M.; LÖFMAN, F.; MICHIELS, S.; SOURIS, K.; STERPIN, E.; LEE, J. A. Artificial intelligence and machine learning for medical imaging: A technology review. **Physica Medica**, [S.l.], v.83, p.242–256, 2021.

BOCA BENE, I.; CIUREA, A. I.; CIORTEA, C. A.; DUDEA, S. M. Pros and Cons for Automated Breast Ultrasound (ABUS): A Narrative Review. **Journal of Personalized Medicine**, [S.l.], v.11, n.8, p.703, 2021.

CÈ, M.; CHIRIACÒ, G.; DELLA PEPA, G.; BELFIORE, M. P.; CARUSO, D.; BRUNESE, L.; SPLENDIANI, A.; CELLINA, M. Decoding Radiomics: A Step-by-Step Guide to Machine Learning Workflow in Hand-Crafted and Deep Learning Radiomics Studies. **Diagnostics**, [S.l.], v.14, n.22, p.2473, 2024.

CHAN, H.-P.; SAMALA, R. K.; HADJIISKI, L. M. CAD and AI for breast cancer—recent development and challenges. **The British Journal of Radiology**, [S.l.], v.93, n.1108, p.20190580, 2020.

CHEN, L.; ZHU, Y.; PAPANDREOU, G.; SCHROFF, F.; ADAM, H. Encoder-Decoder with Atrous Separable Convolution for Semantic Image Segmentation. In: EUROPEAN CONFERENCE ON COMPUTER VISION (ECCV), 2018. **Proceedings...** [S.l.: s.n.], 2018. p.801–818.

COBO, M.; MENÉNDEZ FERNÁNDEZ-MIRANDA, P.; BASTARRIKA, G.; TORRES, J. P. de; CAMPOS, G.; ALCAIDE, A. B.; ALEJO, R. Pérez de; CIAFFAGLIONE, G.; FIUZA-LUCES, C.; LLORET IGLESIAS, L. Enhancing Radiomics and Deep Learning Systems through the Standardization of Medical Imaging Workflows. **Scientific Data**, [S.l.], v.10, p.732, 2023.

COLLINS, G. S. et al. TRIPOD+AI statement: updated guidance for reporting clinical prediction models that use regression or machine learning methods. **BMJ**, [S.l.], v.385, p.e078378, 2024.

DAN, Q.; XU, Z.; BURROWS, H.; BISSRAM, J.; STRINGER, J. S. A.; LI, Y. Diagnostic performance of deep learning in ultrasound diagnosis of breast cancer: a systematic review. **npj Precision Oncology**, [S.l.], v.8, p.21, 2024.

ESTEVA, A.; CHOU, K.; YEUNG, S.; NAIK, N.; MADANI, A.; MOTTAGHI, A.; LIU, Y.; TOPOL, E. Deep learning-enabled medical computer vision. **npj Digital Medicine**, [S.l.], v.4, p.5, 2021.

ESTEVA, A.; ROBICQUET, A.; RAMSUNDAR, B.; KULESHOV, V.; DEPRISTO, M.; CHOU, K.; CUI, C.; CORRADO, G.; THRUN, S.; DEAN, J. A guide to deep learning in healthcare. **Nature Medicine**, [S.l.], v.25, n.1, p.24–29, 2019.

GOETZ, L. et al. Generalization—a key challenge for responsible AI in patient-facing clinical applications. **npj Digital Medicine**, [S.l.], v.7, p.178, 2024.

GU, Z. et al. Radiology Workflow Assistance With Artificial Intelligence. **Journal of the American College of Radiology**, [S.l.], 2025. Review article on AI applications across the medical imaging workflow; conferir paginação e lista final de autores na versão publicada.

GUO, R.; LU, G.; QIN, B.; FEI, B. Ultrasound Imaging Technologies for Breast Cancer Detection and Management: A Review. **Ultrasound in Medicine & Biology**, [S.l.], v.44, n.1, p.37–70, 2018.

HE, K.; ZHANG, X.; REN, S.; SUN, J. Deep Residual Learning for Image Recognition. In: IEEE CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION (CVPR), 2016. **Proceedings...** [S.l.: s.n.], 2016. p.770–778.

HUSSEIN, H.; ABBAS, E.; KESHAVARZI, S.; FAZELZAD, R.; BUKHANOV, K.; KULKARNI, S.; FREEDMAN, O. C.; MESUROLLE, B.; ELSER, C.; HODGSON, N.; CRYSTAL, P.; FREITAS, V. Supplemental Breast Cancer Screening in Women with Dense Breasts and Negative Mammography: A Systematic Review and Meta-analysis. **Radiology**, [S.l.], v.306, n.3, p.e221785, 2023.

IACOB, R.; IACOB, E. R.; STOICESCU, E. R.; GHENCIU, D. M.; COCOLEA, D. M.; CONSTANTINESCU, A.; GHENCIU, L. A.; MANOLESCU, D. L. Evaluating the Role of Breast Ultrasound in Early Detection of Breast Cancer in Low- and Middle-Income Countries: A Comprehensive Narrative Review. **Bioengineering**, [S.l.], v.11, n.3, p.262, 2024.

Instituto Nacional de Câncer. **Parâmetros técnicos para detecção precoce do câncer de mama**. Rio de Janeiro: INCA, 2022.

Instituto Nacional de Câncer José Alencar Gomes da Silva. **Diretrizes para a detecção precoce do câncer de mama no Brasil**. Rio de Janeiro: INCA, 2015.

Instituto Nacional de Câncer José Alencar Gomes da Silva. **Detecção precoce do câncer**. Rio de Janeiro: INCA, 2021.

Instituto Nacional de Câncer José Alencar Gomes da Silva. **Estimativa 2023**: incidência de câncer no Brasil. Rio de Janeiro: INCA, 2022.

Instituto Nacional de Câncer José Alencar Gomes da Silva. Estimativa de Incidência de Câncer no Brasil, 2023–2025. **Revista Brasileira de Cancerologia**, [S.l.], 2022. Documento derivado da publicação Estimativa 2023 do INCA.

Instituto Nacional de Câncer José Alencar Gomes da Silva. **Detecção precoce**. Controle do câncer de mama. Accessed: 2026-03-18, `https://www.gov.br/inca/pt-br/assuntos/gestor-e-profissional-de-saude/controle-do-cancer-de-mama/acoes/deteccao-precoce`.

Instituto Nacional de Câncer José Alencar Gomes da Silva. **Parâmetros técnicos para detecção precoce do câncer de mama**. Accessed: 2026-03-

18, https://www.inca.gov.br/sites/ufu.sti.inca.local/files/media/document/parametros-tecnicos-deteccao-precoce-cancer-de-mama.pdf.

Instituto Nacional de Câncer José Alencar Gomes da Silva. Estimativa 2023: incidência de câncer no Brasil. **Revista Brasileira de Cancerologia**, [S.l.], v.69, n.1, p.e–213700, 2023.

International Agency for Research on Cancer. **Atlas of Breast Cancer Early Detection**. Disponível em: <https://publications.iarc.who.int/Databases/Iarc-Cancerbases/Atlas-Of-Breast-Cancer-Early-Detection-2023>. Acesso em: 2025-09-22.

International Agency for Research on Cancer. **Breast cancer cases and deaths are projected to rise globally**. Press Release No. 361. Disponível em: <https://www.iarc.who.int/wp-content/uploads/2025/02/pr361$_E.pdf > .Acessoem : 2025-09-22.$

KOÇAK, B. et al. Bias in artificial intelligence for medical imaging. **Diagnostic and Interventional Radiology**, [S.l.], v.31, 2025. Conferir paginação final na versão publicada.

KOLBINGER, F. R. et al. Reporting guidelines in medical artificial intelligence: a systematic review and comparative analysis. **Communications Medicine**, [S.l.], v.4, p.179, 2024.

LAMBIN, P.; LEIJENAAR, R. T. H.; DEIST, T. M.; PEERLINGS, J.; JONG, E. E. C. de; TIMMEREN, J. van; SANDULEANU, S.; LARUE, R. T. H. M.; EVEN, A. J. G.; JOCHEMS, A.; WIJK, Y. van; WOODRUFF, H.; SOEST, J. van; LUSTBERG, T.; ROELOFS, E.; ELMPT, W. van; DEKKER, A.; MOTTAGHY, F. M.; WILDBERGER, J. E.; WALSH, S. Radiomics: The Bridge between Medical Imaging and Personalized Medicine. **Nature Reviews Clinical Oncology**, [S.l.], v.14, n.12, p.749–762, 2017.

LAWRENCE, R. et al. Artificial intelligence for diagnostics in radiology practice. **Radiology: Artificial Intelligence**, [S.l.], 2025. Review summarizing implementation evidence, perceptions, and evidence gaps in diagnostic imaging AI; conferir dados bibliográficos finais na versão publicada.

LEE, J. G.; JUN, S.; CHO, Y.-W.; LEE, H.; KIM, G. B.; SEO, J. B.; KIM, N. Deep Learning in Medical Imaging: General Overview. **Korean Journal of Radiology**, [S.l.], v.18, n.4, p.570–584, 2017.

LEE, J. G.; JUN, S.; CHO, Y.-W.; LEE, H.; KIM, G. B.; SEO, J. B.; KIM, N. Deep Learning in Medical Imaging: General Overview. **Korean Journal of Radiology**, [S.l.], v.18, n.4, p.570–584, 2017.

LEKADIR, K. et al. FUTURE-AI: international consensus guideline for trustworthy and deployable artificial intelligence in healthcare. **BMJ**, [S.l.], v.388, p.e081554, 2025.

LIU, J.; PIAN, L.; CHEN, J.; ZHAO, J.; LIU, Y.; MENG, F.; ZENG, C. Artificial intelligence in breast ultrasound: a systematic review of research advances. **Frontiers in Oncology**, [S.l.], v.15, p.1619364, 2025.

LIU, J.; PIAN, L.; CHEN, J.; ZHAO, J.; LIU, Y.; MENG, F.; ZENG, C. Artificial intelligence in breast ultrasound: a systematic review of research advances. **Frontiers in Oncology**, [S.l.], v.15, p.1619364, 2025.

LIU, L.; LI, K.; QIN, W.; WEN, T. X.; XIE, H.; CHENG, J.; HUANG, K.; ZHANG, B.; NING, C.; WANG, Y. Automated Breast Tumor Detection and Segmentation with a Novel Computational Framework of Whole Ultrasound Images. **Medical & Biological Engineering & Computing**, [S.l.], v.56, n.7, p.1285–1300, 2018.

LIU, L.; LI, K.; QIN, W.; WEN, T. X.; XIE, H.; CHENG, J.; HUANG, K.; ZHANG, B.; NING, C.; WANG, Y. Automated Breast Tumor Detection and Segmentation with a Novel Computational Framework of Whole Ultrasound Images. **Medical & Biological Engineering & Computing**, [S.l.], v.56, n.7, p.1285–1300, 2018.

LIU, X.; RIVERA, S. C.; MOHER, D.; CALVERT, M. J.; DENNISTON, A. K.; SPIRIT-AI; GROUP, C.-A. W. Reporting guidelines for clinical trial reports for interventions involving artificial intelligence: the CONSORT-AI extension. **BMJ**, [S.l.], v.370, p.m3164, 2020.

LIU, Z.; MAO, H.; WU, C.; FEICHTENHOFER, C.; DARRELL, T.; XIE, S. A ConvNet for the 2020s. In: IEEE/CVF CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION (CVPR), 2022. **Proceedings...** [S.l.: s.n.], 2022. p.11976–11986.

LOBIG, F.; CALEYACHETTY, A.; FORRESTER, L.; MORRIS, E.; NEWSTEAD, G.; HARRIS, J.; BLANKENBURG, M. Performance of Supplemental Imaging Modalities for Breast Cancer in Women With Dense Breasts: Findings From an Umbrella Review and Primary Studies Analysis. **Clinical Breast Cancer**, [S.l.], v.23, n.5, p.478–490, 2023.

MOASSEFI, M. et al. Reproducibility of Deep Learning Algorithms Developed for Medical Imaging Analysis: A Systematic Review. **Journal of Digital Imaging**, [S.l.], 2023. Verificar paginação e lista final de autores conforme versão oficial do periódico.

MOONS, K. G. M. et al. PROBAST+AI: an updated quality, risk of bias, and applicability assessment tool for prediction model studies that use regression or machine learning methods. **BMJ**, [S.l.], v.388, p.e082505, 2025.

National Cancer Institute. **How Is Breast Cancer Diagnosed?** Accessed: 2026-03-18, https://www.cancer.gov/types/breast/diagnosis.

National Cancer Institute. **Screening for Breast Cancer**. Accessed: 2026-03-18, https://www.cancer.gov/types/breast/screening.

OKTAY, O.; SCHLEMPER, J.; LE FOLGOC, L.; LEE, M.; HEINRICH, M.; MISAWA, K.; MORI, K.; MCDONAGH, S.; HAMMERLA, N. Y.; KAINZ, B.; GLOCKER, B.; RUECKERT, D. Attention U-Net: Learning Where to Look for the Pancreas. **arXiv preprint arXiv:1804.03999**, [S.l.], 2018.

PAWŁOWSKA, A.; KARWAT, P.; ZOŁEK, N. Letter to the Editor. Re: "Dataset of breast ultrasound images by W. Al-Dhabyani, M. Gomaa, H. Khaled & A. Fahmy, Data in Brief, 2020, 28, 104863". **Data in Brief**, [S.l.], v.48, p.109247, 2023.

RAHMANI, A. A. et al. Automatic breast mass segmentation in ultrasound images using a deep learning model with resolution enhancement and attention mechanisms. **Biomedical Signal Processing and Control**, [S.l.], 2024. Registro baseado na referência indexada em bases públicas; recomenda-se conferir a lista final de autores no PDF oficial antes da submissão.

RAJKOMAR, A.; DEAN, J.; KOHANE, I. Machine Learning in Medicine. **New England Journal of Medicine**, [S.l.], v.380, n.14, p.1347–1358, 2019.

REN, W.; ZHAO, X.; ZHAO, X.; YAN, H.; HU, S.; QIAO, Y.; XU, Z.; ZHAO, F. The Potential of Adding Mammography to Handheld Ultrasound or Automated Breast Ultrasound to Reduce Unnecessary Biopsies in BI-RADS Ultrasound Category 4a: A Multicenter Hospital-Based Study in China. **Current Oncology**, [S.l.], v.30, n.3, p.3301–3314, 2023.

RENARD, F.; GUEDRIA, S.; DE PALMA, N.; VUILLERME, N. Variability and Reproducibility in Deep Learning for Medical Image Segmentation. **Scientific Reports**, [S.l.], v.10, p.13724, 2020.

RIVERA, S. C.; LIU, X.; CHAN, A.-W.; DENNISTON, A. K.; CALVERT, M. J.; SPIRIT-AI; GROUP, C.-A. W. Guidelines for clinical trial protocols for interventions involving artificial intelligence: the SPIRIT-AI extension. **The Lancet Digital Health**, [S.l.], v.2, n.10, p.e549–e560, 2020.

RONNEBERGER, O.; FISCHER, P.; BROX, T. U-Net: Convolutional Networks for Biomedical Image Segmentation. In: MEDICAL IMAGE COMPUTING AND COMPUTER-ASSISTED INTERVENTION – MICCAI 2015, 2015. **Anais...** Springer, 2015. p.234–241.

SIMKÓ, A. et al. Reproducibility of the Methods in Medical Imaging with Deep Learning. In: MACHINE LEARNING RESEARCH, 2024. **Proceedings...** [S.l.: s.n.], 2024. v.227, p.1–17. MIDL 2024; conferir paginação final conforme versão oficial.

SIMONYAN, K.; ZISSERMAN, A. Very Deep Convolutional Networks for Large-Scale Image Recognition. **International Conference on Learning Representations (ICLR)**, [S.l.], 2015.

SUZUKI, K. Pixel-Based Machine Learning in Medical Imaging. **International Journal of Biomedical Imaging**, [S.l.], v.2012, p.792079, 2012.

TAN, M.; LE, Q. V. EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks. In: INTERNATIONAL CONFERENCE ON MACHINE LEARNING (ICML), 36., 2019. **Proceedings...** PMLR, 2019. v.97, p.6105–6114.

TIMMEREN, J. E. van; CESTER, D.; TANADINI-LANG, S.; ALKADHI, H.; BAESSLER, B. Radiomics in Medical Imaging—"How-to" Guide and Critical Reflection. **Insights into Imaging**, [S.l.], v.11, n.1, p.91, 2020.

TREPANIER, C.; LEI, L.; ELMORE, J. G.; MCDONALD, E. S. Emerging uses of artificial intelligence in breast and axillary ultrasound. **Clinical Imaging**, [S.l.], v.101, p.63–70, 2023.

UEDA, D. et al. Fairness of artificial intelligence in healthcare: review and recommendations. **Current Treatment Options in Oncology**, [S.l.], v.25, p.137–162, 2024.

WENDEROTT, K. et al. Effects of artificial intelligence implementation on efficiency in medical imaging: a systematic literature review and meta-analysis. **npj Digital Medicine**, [S.l.], v.7, p.271, 2024.

World Health Organization. **Guide to Cancer Early Diagnosis**. Geneva: World Health Organization, 2017.

World Health Organization. **Ethics and Governance of Artificial Intelligence for Health**: WHO Guidance. Geneva: World Health Organization, 2021.

World Health Organization. **Breast cancer**. Disponível em: <https://www.who.int/news-room/fact-sheets/detail/breast-cancer>. Acesso em: 2025-09-22.

World Health Organization. **Breast cancer**. Fact sheet. Accessed: 2026-03-18, `https://www.who.int/news-room/fact-sheets/detail/breast-cancer`.

YANG, Y. et al. The limits of fair medical imaging AI in real-world generalization. **Nature Medicine**, [S.l.], v.30, 2024. Conferir paginação final na versão publicada.

YAP, M. H.; GOYAL, M.; OSMAN, F.; AHMAD, E.; MARTI, R.; DENTON, E. R. E.; JUETTE, A.; ZWIGGELAAR, R. End-to-End Breast Ultrasound Lesions Recognition with a Deep Learning Approach. In: MEDICAL IMAGING 2018: BIOMEDICAL APPLICATIONS IN MOLECULAR, STRUCTURAL, AND FUNCTIONAL IMAGING, 2018. **Anais...** SPIE, 2018. v.10578, p.1057819.

YU, K.-H.; BEAM, A. L.; KOHANE, I. S. Artificial intelligence in healthcare. **Nature Biomedical Engineering**, [S.l.], v.2, n.10, p.719–731, 2018.

YU, X.; ZHOU, Q.; WANG, S.; ZHANG, Y. A systematic survey of deep learning in breast cancer. **International Journal of Intelligent Systems**, [S.l.], v.37, n.1, p.152–216, 2022. Entrada usada como correspondência plausível para a chave ambígua “Zhou2021”.

ZHANG, Y.; XIAN, M.; CHENG, H. D.; SHAREEF, B.; DING, J.; XU, F.; HUANG, K.; ZHANG, B.; NING, C.; WANG, Y. BUSIS: A Benchmark for Breast Ultrasound Image Segmentation. **Healthcare**, [S.l.], v.10, n.4, p.729, 2022.

ZHOU, L.; FAN, M.; HANSEN, C.; JOHNSON, C. R.; WEISKOPF, D. A Review of Three-Dimensional Medical Image Visualization. **Health Data Science**, [S.l.], v.2022, p.9840519, 2022.

ZHOU, Z.; SIDDIQUEE, M. M. R.; TAJBAKHSH, N.; LIANG, J. UNet++: A Nested U-Net Architecture for Medical Image Segmentation. **Deep Learning in Medical Image Analysis and Multimodal Learning for Clinical Decision Support**, [S.l.], p.3–11, 2018.